

当代科学前沿论丛

NEW FRONTIERS OF SCIENCES

Logistic 回归模型 ——方法与应用

王济川 郭志刚 WANG JICHUAN GUO ZHIGANG

LOGISTIC REGRESSION MODELS: METHODS AND APPLICATION



高等教育出版社
HIGHER EDUCATION PRESS

LOGISTIC REGRESSION MODELS: METHODS AND APPLICATION

Quantitative analytical techniques are widely employed in the social sciences. Logistic regression is the most popular method for regression analysis of dichotomous dependent variables (e.g., $y=1$ or 0) in the social science disciplines, such as sociology, psychology, population studies, political science, and economics, as well as in public health studies. This book provides an introduction to logistic regression analyses and how it can be applied. The ordered logistic regression and multinomial model are also addressed for dealing with ordinal and nominal dependent variables with more than two categories. Both SAS and SPSS are used to demonstrate a variety of sample applications, and the results of the computer output are interpreted in detail. The intended audience is graduate students, teachers, and researchers in the social sciences.

当代科学前沿论丛

Logistic 回归模型 ——方法与应用

王济川 郭志刚

高等教育出版社

内容简介

在社会科学诸如社会学、心理学、人口学、政治学、经济学以及公共卫生学当中,大量的观测因变量是二分类测量(即 $y=1$ 或 $y=0$)。本书专题介绍了在分析二分类因变量时最常使用的统计分析模型之一——logistic 回归模型。本书深入浅出,理论联系实际,通过例题分析,并结合计算机统计软件的应用,详细介绍、阐述了该模型及其应用。同时,还介绍了如何将 logistic 回归模型扩展到序次 logistic 回归模型和多项 logit 模型,以分析序次变量和多分类名义变量为因变量的数据。本书提供用 SAS 和 SPSS 进行具体例题分析的计算机程序及相关数据,并对这两种软件的模型估计结果进行详尽的解释和对比分析。本书的读者对象为社会科学各专业的教师及研究生,以及社会科学专业研究人员。

图书在版编目(CIP)数据

Logistic 回归模型——方法与应用/王济川,郭志刚.

北京:高等教育出版社,2001.9

ISBN 7-04-009910-1

I. L… II. ①王…②郭… III. 回归分析—统计模型 IV. 0212.1

中国版本图书馆 CIP 数据核定(2001)第 023720 号

Logistic 回归模型——方法与应用

王济川 郭志刚

出版发行 高等教育出版社

社 址 北京市东城区沙滩后街 55 号

邮政编码 100009

电 话 010-64054588

传 真 010-64014048

网 址 <http://www.hep.edu.cn>

<http://www.hep.com.cn>

经 销 新华书店北京发行所

印 刷 国防工业出版社印刷厂

开 本 787×960 1/16

版 次 2001 年 9 月第 1 版

印 张 18.25

印 次 2001 年 9 月第 1 次印刷

字 数 260 000

定 价 38.20 元

本书如有缺页、倒页、脱页等质量问题,请到所购图书销售部门联系调换。

版权所有 侵权必究

《当代科学前沿论丛》专家委员会

(按姓氏笔画为序)

(国内部分)

王 夔	冯 端	师昌绪	曲钦岳	朱清时
孙 枢	李三立	李大潜	李国杰	杨芙清
吴建屏	邹承鲁	张尧庭	陈 竺	陈佳洱
陈希孺	陈宜瑜	周秀骥	姜伯驹	袁亚湘
钱 易	徐光宪	徐端夫	徐冠华	翟中和
戴立信	戴汝为			

(海外部分)

王中林	文小刚	邓兴旺	田 刚	丛京生
刘 钧	汤 超	许 田	危 岩	严晓海
李 凯	李 明	邱子强	余振苏	范剑青
周午纵	郑元芳	宫 鹏	俞陆平	袁钧瑛
徐希平	程正迪	鄂维南		



王济川

1947 年出生。1982 年四川大学经济系毕业。1986 年于美国康乃尔大学获社会学硕士学位，1990 年获该校博士学位。1989 年 9 月—1991 年 8 月于美国密执安大学人口研究中心作博士后研究。现任美国俄亥俄州怀特州立大学医学院社区卫生系教授。

王济川博士的主要研究领域为社会学定量分析方法、人口分析方法、毒品滥用及疾病预防项目的评估。



郭志刚

1954 年出生。1982 年于中国人民大学工业经济系获经济学学士，1985 年于加拿大西安大略大学获社会学硕士，1990 年于中国人民大学人口研究所获法学博士。1992 年 10 月至 1994 年 1 月于美国布朗大学人口研究中心作博士后研究。1985 年至 1999 年在中国人民大学人口研究所工作。现任北京大学社会学系教授。

郭志刚博士的主要研究领域为人口统计技术、社会学定量分析方法，以及人口、婚姻、家庭、老年等社会问题的分析。曾编著《社会科学研究量化方法》、《社会统计分析方法——SPSS 软件应用》，并撰写、编著、翻译多部人口学研究著作，发表了大量学术论文。

出版者的话

人类创造了科学技术，科学技术推动了人类的文明进程。两者的互动影响，今天已达到了前所未有的程度：人类的经济发展和社会进步的需要，为科学技术迅猛的创新，提供了强大的动力；科学技术的发展，在急剧地改变着人类的思维方式、学习方式、工作方式、生活方式、娱乐方式。科学技术已成为强大的社会生产力和巨大的社会资本。现在，每个国家，每个地区，甚至每个单位，都把科学技术创新、科学技术转化为生产力作为头等大事，抢占科学技术制高点，以此来提高自己的综合实力。

新中国成立 50 多年特别是改革开放 20 多年来，随着经济的蓬勃发展，科学技术得到了长足的进步，两弹一星、载人飞船、生物工程、信息技术等正在大步追赶国际先进水平。科学技术转化成的强大生产力，对国民经济发展和社会进步、对增强综合国力产生了重大的影响。

改革开放以来，在中国共产党的“科教兴国”方针的鼓舞下，举国上下，尊重科技，学习科技，普及科技，创新科技，应用科技，发展科技，已蔚然成风。科技结硕果、神州尽彩虹的绚丽画面，正在展示于世人面前。自 16 世纪中叶中国科学技术失去世界领先地位后所形成的中西科学技术的差距，现在正在缩小。重振中华科学技术雄风的序幕已经拉开。

为了能使我国的科学技术水平在不久的将来赶上并达到世界先进水平，我们不仅要自己进行科学技术创新，也要学习世界上一切国家的先进科学技术；不仅要靠国内的科技工作者发展我国的科学技术，还要借助海外学者特别是华人学者的力量。在这种思想的指导下，我们萌生了组织海外学者编写科技前沿丛书的想法。这一想法在海内外学者中引起了强烈的反响：在他们中，有的出谋献策，有的出资开会，有的撰稿，有的审稿，有的愿把稿酬作为基金，……海内外学者的诚言乐行，极大地感染着我们，鼓舞着我们；这一想法得到了教育部陈至立部长和分管我社的周远清副部长的肯定和支持，这增加了我们开展此项工作的决心和信心。根据各方面意见，经过反复研究，最后将丛书定名为《当代科学前沿论丛》。《论丛》是我们献给祖国母亲的 21 世纪的圣礼，企盼我国能在 21 世纪夺回三四百年前失去的科学技术领先的地位。《论丛》如能在推动我国科学技术进步和“科教兴国”中有所作用，将是我们的最大欣慰。为了



出版者的话

做好本《论丛》的出版工作，我们邀请了国内一些著名科学家和在海外工作的部分优秀学者组成《论丛》的专家委员会，帮助筹划、组织和评议《论丛》的出版。随着学科的发展，专家委员会的成员可能会有所变化。我们向一切关心和支持《论丛》出版工作的人士，表示衷心的感谢。由于缺乏经验，《论丛》出版后，编辑出版方面的不足，在所难免，诚望各方指正。

高等教育出版社

2000年6月

前 言

在过去的 20 年中, 由于计算机技术和相应统计软件的迅猛发展, 量化分析已经成为社会科学各个学科领域中广为应用的技术方法. 在社会科学诸如社会学、心理学、人口学、政治学、经济学以及公共卫生学当中, logistic 回归模型是对二分类因变量(dichotomous dependent variable)(即 $y=1$ 或 $y=0$)进行回归分析时最为普遍应用的多元量化分析方法. 根据 Hosmer 及其同事的统计(1991), 在 1985—1989 年间, 国际知名刊物《美国公共卫生杂志》上发表的文章中约有 20% (579 篇文章中的 113 篇)应用了 logistic 回归模型. 虽然 logistic 回归已经达到了如此流行的程度, 但不少使用这一模型的人对于该模型的性质和原理的理解仍不很充分, 在实际应用中常有困惑和这样那样的问题, 对于模型结果的阐释还存在许多不一致. 并且, 在很多应用该方法的研究中连模型拟合优度的评价也被忽略了. 比如, 在上述所统计的 113 篇文章中, 只有 5% (6 篇文章)涉及到模型拟合优度的评价^①.

在现有的统计教科书中, 一般都有 logistic 回归模型的内容. 然而, 在这些教科书中, logistic 回归往往不是作为中心内容, 缺乏关于这种方法的详尽讨论. 有关专著在国外很少, 国内尚无. 国外的一些专著中对于 logistic 回归模型的实际应用, 特别是结合统计软件运行模型并对模型结果进行解释方面较为欠缺. 本书的主要目的是提供对于 logistic 回归模型的深入专题介绍, 专注于这一方法本身的讨论, 以及模型结果的详细阐释. 作者尽量以深入浅出的手法, 旁证博引, 理论联系实际, 大量运用例题并结合计算机统计软件的使用, 介绍和讨论该模型的原理及运用. 本书的服务对象是社会科学各专业及公共卫生学专业的教师及研究生, 以及社会科学专业研究人员. 读者在学习本书内容之前应对多元回归和统计推断的基础知识有所了解.

本书将采用国际上广泛使用的统计软件 SAS (Statistics Analysis System) 和 SPSS (Statistics Package for Social Sciences) 来分析书中的例题. 本书将提供用这两种软件进行具体例题分析的计算机程序, 并对于这两种软件的模型估计结果进行详细的解释和对比分析. 本书中例题的主要数据是由作者模拟制作

^① Hosmer, Taber, and Lemeshow, 1991.

的, 其原始数据可从下列网址下载:

<http://www.hep.com.cn>; <http://www.wright.edu/~jwang>;

<http://www.disa.pku.edu.cn/课程>.

本书共由 8 章组成.

在第 1 章中, 我们将首先讨论分析二分类因变量时所产生的问题, 并讨论经典的线性概率模型(linear probability model, 简标为 LPM)及其局限性. 然后介绍 logistic 回归模型.

在第 2 章中, 我们将介绍 logistic 回归模型估计所用的最大似然估计法(maximum likelihood estimation, 简标为 MLE)、模型估计的假设条件, 以及最大似然估计的性质. 此外, 还将介绍对分组数据进行 logit 分析的加权最小二乘法(weighted least squares, 简标为 WLS).

第 3 章介绍 logistic 回归模型的评价, 讨论各种拟合优度(goodness of fit), 预测准确性(predictive accuracy)和模型卡方统计(model chi-square statistic).

第 4 章关注于 logistic 模型回归系数意义的阐释. 除了讨论发生比率(odds ratio)、预测概率(predicted probability)和互动影响(interactions)外, 这一章还要讨论使用各种不同编码时分类自变量回归系数的意义和解释.

第 5 章讨论 logistic 回归系数的统计推断(statistical inference).


第 6 章的内容涉及模型的选择, 讨论建立模型过程中的策略.

第 7 章关于模型的诊断, 讨论多元共线性(multicollinearity)、有问题的数据架构(problematic data configuration)、极端值(outliers)、特异影响案例(influential observations)和过离散分布(overdispersion)等问题, 以及这些问题的补救对策.


在最后一章中, 我们将介绍与 logistic 回归类似的另外一种分析二分类因变量的备选模型——probit 模型. 然后, 将 logistic 回归模型扩展到序次 logistic 回归模型(ordered logistic regression model)和多项式 logit 模型(multinomial logit model), 这些模型分别用以解决序次变量和多分类名义变量为因变量的问题.

责任编辑	林云裳
封面设计	刘晓翔
责任绘图	朱 静
版式设计	周顺银
责任校对	陈 荣
责任印制	杨 明

ISBN 7-04-009910-1



9 787040 099102 >



目 录

1. 二分类因变量与 logistic 回归模型	(1)
1.1 引言	(2)
1.2 线性概率模型(Linear Probability Model, LPM)	(3)
1.3 Logistic 回归模型	(6)
2. Logistic 回归模型估计	(13)
2.1 最大似然估计(Maximum Likelihood Estimation, MLE)	(14)
2.2 Logistic 回归模型估计的假设条件	(17)
2.3 最大似然估计的性质	(17)
2.4 模型估计的样本规模	(18)
2.5 拟合 logistic 回归的示范模型	(19)
2.6 用分组数据作 logistic 回归分析	(33)
3. Logistic 回归模型评价	(57)
3.1 拟合优度(Goodness of fit)	(58)
3.1.1 皮尔逊 χ^2 (Pearson χ^2)	(58)
3.1.2 偏差(Deviance)	(62)
3.1.3 Hosmer-Lemeshow 拟合优度指标	(65)
3.1.4 信息测量指标(Information Measures)	(67)
3.2 Logistic 回归模型的预测准确性	(72)
3.2.1 类 R^2 指标(Analogous R^2)	(72)
3.2.2 预测概率与观测值之间的关联	(75)
3.2.3 分类表(Classification Table)	(80)
3.3 模型 χ^2 统计(Model Chi-Square Statistic)	(88)
4. Logistic 回归系数解释	(91)
4.1 发生比和发生比率(Odds and Odds Ratio)	(92)
4.2 按发生比率来解释 logistic 回归系数	(95)
4.2.1 连续自变量的发生比率	(96)
4.2.2 二分类自变量的发生比率	(98)
4.2.3 分类自变量的发生比率	(100)
4.3 用概率来解释自变量的作用	(111)



4.4	预测概率	(112)
4.5	标准化系数	(115)
4.6	偏相关(Partial Correlation)	(120)
5.	Logistic 回归系数的统计推断	(123)
5.1	Logistic 回归系数的显著性检验	(124)
5.1.1	Wald 检验	(125)
5.1.2	似然比检验	(126)
5.1.3	检验系数子集	(132)
5.2	Logistic 回归参数的置信区间	(136)
5.2.1	Logistic 回归系数的置信区间	(137)
5.2.2	发生比率的置信区间	(138)
5.2.3	事件概率的置信区间	(141)
6.	建立模型	(145)
6.1	选择变量	(146)
6.1.1	筛选自变量	(146)
6.1.2	模型的比较	(152)
6.1.3	逐步模型选择法	(153)
6.1.4	排除有意义的变量和包括没有意义的变量	(171)
6.2	非线性与非加性(Nonlinearity and Nonadditivity)	(172)
6.2.1	非线性	(172)
6.2.2	非加性	(177)
7.	Logistic 回归诊断	(183)
7.1	过离散(Overdispersion)	(184)
7.2	空单元(Zero Cell Count)	(187)
7.3	完全分离(Complete Separation)	(188)
7.4	多元共线性(Multicollinearity)	(190)
7.5	特异值和特殊影响案例(Outliers and Influential Observations)	(195)
7.5.1	残差影响的测量	(195)
7.5.2	检查特异值和特殊影响案例	(202)
8.	Logistic 回归的替代模型及扩展	(219)
8.1	Probit 模型	(220)
8.1.1	Probit 模型的对数似然函数	(220)
8.1.2	拟合 probit 示范模型	(221)
8.1.3	Probit 模型的解释	(225)
8.1.4	用分组数据建立 probit 模型	(227)



8.1.5 Logistic 回归模型与 probit 模型的比较	(235)
8.2 Logistic 回归扩展于多分类反应变量	(237)
8.2.1 累积 logistic 回归模型(Cumulative Logistic Regression Model)	(237)
8.2.2 多项 logit 模型(Multinomial Logit Model)	(249)
参考文献	(263)
关键词索引	(267)

TABLE OF CONTENTS

1. Dichotomous dependent variable and logistic regression model	(1)
1.1 Introduction	(2)
1.2 Linear probability model (LPM)	(3)
1.3 Logistic regression model	(6)
2. Estimation of logistic regression model	(13)
2.1 Maximum likelihood estimation (MLE)	(14)
2.2 Assumptions of logistic regression model estimation	(17)
2.3 Properties of MLE	(17)
2.4 Sample size for model estimation	(18)
2.5 Examples of logistic regression models	(19)
2.6 Logistic analysis with grouped data	(33)
3. Evaluation of logistic regression model	(57)
3.1 Goodness of fit	(58)
3.1.1 Pearson χ^2	(58)
3.1.2 Deviance	(62)
3.1.3 Hosmer-Lemeshow goodness of fit statistic	(65)
3.1.4 Information measures	(67)
3.2 Predictive accuracy of logistic regression model	(72)
3.2.1 Measures of analogous R^2	(72)
3.2.2 Association between predicted probability and observed response	(75)
3.2.3 Classification table	(80)
3.3 Model Chi-square statistic	(88)
4. Interpretation of logistic regression coefficients	(91)
4.1 Odds and odds ratio	(92)



Table of Contents

4.2	Interpretating logistic regression coefficients in odds ratio	(95)
4.2.1	Odds ratio for continuous variable	(96)
4.2.2	Odds ratio for indicator variable	(98)
4.2.3	Odds ratio for categorical variable	(100)
4.3	Interpretating effect on probability	(111)
4.4	Predicted probabilities	(112)
4.5	Standardized coefficients	(115)
4.6	Partial correlation	(120)
5.	Statistical inference for logistic regression coefficients	(123)
5.1	Significance test of logistic regression coefficients	(124)
5.1.1	Wald test	(125)
5.1.2	Likelihood ratio test	(126)
5.1.3	Testing a subset of coefficients	(132)
5.2	Confidence intervals for logistic regression parameter estimate	(136)
5.2.1	Confidence intervals for logistic regression coefficient	(137)
5.2.2	Confidence intervals for odds ratio	(138)
5.2.3	Confidence intervals for predicted probabilities	(141)
6.	Model building	(145)
6.1	Variable selection	(146)
6.1.1	Screening candidates of independent variables	(146)
6.1.2	Model comparison	(152)
6.1.3	Stepwise computer model selection	(153)
6.1.4	Excluding relevant variables and including irrelevant variables	(171)
6.2	Nonlinearity and nonadditivity	(172)
6.2.1	Nonlinearity	(172)
6.2.2	Nonadditivity	(177)
7.	Logistic regression model diagnostics	(183)
7.1	Overdispersion	(184)
7.2	Zero cell count	(187)
7.3	Complete separation	(188)

7.4	Multicollinearity	(190)
7.5	Outliers and influential observations	(195)
7.5.1	Residuals and measures of influence	(195)
7.5.2	Detecting Outliers and influential observations	(202)
8.	Alternative model and extension of logistic regression	(219)
8.1	Probit model	(220)
8.1.1	The log likelihood function of probit model	(220)
8.1.2	Examples of probit model	(221)
8.1.3	Interpretation of probit model	(225)
8.1.4	Probit model with grouped data	(227)
8.1.5	Comparison between the logistic regression and probit models	(235)
8.2	Extension of logistic regression to polytomous response variables	(237)
8.2.1	Cumulative logistic regression model	(237)
8.2.2	Multinomial logit model	(249)
	Reference	(263)
	Subject index	(267)

二分类因变量与 logistic 回归模型



- 1.1 引言 (2)
- 1.2 线性概率模型 (Linear Probability Model, LPM) (3)
- 1.3 Logistic 回归模型 (6)

1.1 引言

线性回归模型 (linear regression model) 在定量分析的实际研究中也许是最流行的统计分析方法了。然而在许多情况下, 线性回归会受到限制。比如, 当因变量是一个分类变量 (categorical variable) 而不是一个连续变量 (continuous variable) 时, 线性回归就不适用。实际上, 许多社会科学的观察都只是分类的而不是连续的。比如, 政治学中经常研究的是否选举某候选人。又如, 经济学研究中所涉及的是否销售或购买某种商品、是否签订一个合同, 等等。这种选择量度通常分为两类, 即“是”与“否”。在社会学和人口研究中, 人们的社会行为与生命事件的发生如犯罪、逃学、迁移、结婚、离婚、生育、患病等等都可以按照二分类变量来测量。在研究中, 态度与偏好等心理现象经常也是按几个类型进行测量的, 如“强烈反对”、“反对”、“中立”、“支持”和“强烈支持”。此外, 虽然一些测量在理论上可以是连续变量, 比如某件事物对于人们生活的重要程度, 但是在实际调查中却常常按序次分类(如, “不重要”、“重要”、“非常重要”)进行测量。还有的时候, 人们甚至更愿意将连续量度转换为类型划分。一种常见的情况就是当分析学生升学考试成绩的影响因素时, 考试分数可以被划分成两类: 录取线以上和录取线以下。只要选定一个分界点, 连续变量便可以转换为二分类变量。

在分析分类变量时, 通常采用的一种统计方法是对数线性模型(log-linear model)^①。在本书中, 我们将提供对数线性模型的一种特殊形式——logistic 回归模型。当对数线性模型中的一个二分类变量被当作因变量并定义为一系列自变量的函数时, 对数线性模型就变成了 logistic 回归模型。为了便利广大读者, 我们将不从一般对数线性模型的原理出发, 而是按类比于线性回归模型的方式来描述 logistic 回归模型。

^① Feinberg, 1985; Agresti, 1990

1.2 线性概率模型(Linear Probability Model, LPM)

我们知道,线性回归模型没有对所使用的自变量值的量度加以限制,只是要求每个自变量不能是其它自变量的完全线性组合(exact linear combination),并且自变量不能与误差项相关.自变量可以是连续的,也可以只取正数和0值(如百分比),也可以都是整数(如一个家庭的子女数),或者也可以是二分类型的(如男性取1值,女性取0值).然而,因变量却必须是连续的.由于对回归方程中的自变量、回归系数及残差的取值并无任何限制,因此作为一套自变量 x 的函数的因变量 y 就必须能够在负无穷至正无穷之间自由取值.然而,在实际数据中, y 可能只在有限区间取值.比如,如果 y 是个人收入,观测值只是存在于一个相对很小的值域中(从最低收入至最高收入之间).如果我们假设收入是调查对象的年龄、受教育年限、性别等变量的函数,那么关于因变量为连续测量的假设也许是个不坏的近似,因为所有的自变量也同样是有一定限制的.换句话说,没有哪个自变量能真的取任何值.比如,年龄就被限制在寿命的区间内;受教育年限可以在0至像20这样的最大值中间;性别只能被测量为两个值(如0为女性、1为男性).正因为如此,即使因变量 y (收入)并不能自由取任何值,关于因变量为连续测量的假设也可以接受.但是,如果因变量 y 只取分类值,尤其是只取二类值(即0或1),有关连续测量假设的违反就极为严重,值得给予特别的注意.

让我们用一个例子来看看,要是在线性回归模型中的因变量只取0和1两个值会怎样.假设用一个常规最小二乘法(ordinary least squares,缩写为OLS)线性回归模型来解释是否购买某项家庭耐用消费品,如VCD的消费情况.所构想的回归方程为:

$$y_i = \alpha + \beta x_i + e_i, \quad 1.2.1$$

其中 x_i 是第 i 个家庭的年收入, y_i 是一个二分类变量,于是有:



当第 i 个家庭在一段时间(如某年)内购买 VCD 机时, $y_i = 1$, 否则, $y_i = 0$.

假设随机自变量 x_i 独立于残差项 e_i . 残差项 e_i 是一个平均值为 0 且独立于 e_j 的随机变量($i \neq j$)(即在残差项之间不存在相关).

因为 y_i 只能取值为 0 或 1, 在给定 x_i 的条件下, y_i 的期望值为

$$E(y_i | x_i) = E(\alpha + \beta x_i + e_i) = \alpha + \beta x_i. \quad 1.2.2$$

由于 y_i 的取值不是 0 就是 1, y_i 的期望值实际上就是 $E(y_i | x_i) = P(y_i = 1 | x_i)$, 它可以解释为对于第 i 个家庭购买 VCD 机的条件概率测量. 所以, 公式 1.2.2 的左侧可以作为事件发生的概率来解释. 正因为如此, 因变量为二分类型的线性回归模型也被称为线性概率模型(linear probability model, 缩写为 LPM), x_i 每增加一个单位总是导致事件发生的概率相应增加一个固定的量(Kmenta, 1986; Long, 1997). 回归系数 β 代表相应于 x_i 一个单位变化时的概率增量. 与此对应, 事件不发生的概率应该为

$$P(y_i = 0 | x_i) = 1 - (\alpha + \beta x_i) = 1 - \alpha - \beta x_i.$$

从公式 1.2.1, 我们可以得出线性概率模型的残差项为

$$e_i = y_i - \alpha - \beta x_i,$$

因为 y_i 只能取值为 0 或 1, 那么

当 $y_i = 0$ 时, 有 $e_i = 0 - \alpha - \beta x_i = -\alpha - \beta x_i$,

当 $y_i = 1$ 时, 有 $e_i = 1 - \alpha - \beta x_i$.

令 $f(e_i)$ 为残差项的密度函数, 我们定义

当 $y_i = 0$ 时, 有 $f(e_i) = f_i$,

当 $y_i = 1$ 时, 有 $f(e_i) = 1 - f_i$.

残差的期望值等于

$$E(e_i) = f_i \times (-\alpha - \beta x_i) + (1 - f_i) \times (1 - \alpha - \beta x_i). \quad 1.2.3$$

因为残差的期望值假设为 0, 根据公式 1.2.3, 我们有

$$f_i = 1 - \alpha - \beta x_i,$$

按照定义, e_i 的方差等于

$$\text{Var}(e_i) = f_i \times (-\alpha - \beta x_i)^2 + (1 - f_i) \times (1 - \alpha - \beta x_i)^2 \quad 1.2.4$$

$$\begin{aligned}
 &= (1 - \alpha - \beta x_i)(\alpha + \beta x_i)^2 + (\alpha + \beta x_i)(1 - \alpha - \beta x_i)^2 \\
 &= (\alpha + \beta x_i)(1 - \alpha - \beta x_i) \\
 &= P(y_i = 1 | x_i) \times P(y_i = 0 | x_i).
 \end{aligned}$$

从公式 1.2.4 中可以看出, 残差的方差依赖于条件概率测量值, 因而也就依赖于因变量的值而变动. 于是不同的观测值便有不同的方差. 在统计中, 这称为方差的非齐性(heteroscedasticity).

由于公式 1.2.1 中因变量的特殊性质, 线性概率模型(LPM)的估计和预测存在许多问题:

第一, 由于在线性概率模型中残差的非齐性, 参数估计的估计方差将是有偏的. 因此, 任何假设检验, 比如 t 检验和 F 检验, 都是无效的, 即使样本很大也是如此.

第二, 由线性概率模型估计的事件概率值($\hat{y}_i = \hat{\alpha} + \hat{\beta}x_i$)在遇到很大或很小的 x_i 值时可能超出 $[0, 1]$ 区间.

最后, 线性概率模型最严重的问题是它的函数形式. 因为线性概率模型是线性的, 即无论 x_i 取什么值, 其回归系数 α 和 β 都应是常数. 然而, 公式 1.2.1 中的截距 α 和斜率 β 对于所有 x_i 值并不是常数, 而是有如下变化:

在 $x_i \leq -\alpha/\beta$ 时, 截距 = 0 且 斜率 = 0,

在 $-\alpha/\beta \leq x_i \leq (1-\alpha)/\beta$ 时, 截距 = α 且 斜率 = β ,

在 $x_i \geq (1-\alpha)/\beta$ 时, 截距 = 1 且 斜率 = 0.

图 1.1 显示了这种变量与自变量之间的关系. 很明显, 以二分类变量作为因变量的模型在自变量与事件发生概率之间存在非线性关系. 而线性概率模型(LPM)不能拟合这种非线性关系(见尾注 1).




图 1.1 线性概率模型的图示

1.3 Logistic 回归模型

由于常规最小二乘法模型的不适宜性, 建议对于二分类因变量的分析使用非线性函数. 事件发生的条件概率 $P(y_i = 1 | x_i)$ 与 x_i 之间的非线性关系通常是单调函数, 即随着 x_i 的增加 $P(y_i = 1 | x_i)$ 也单调增加, 或者是随着 x_i 的减少 $P(y_i = 1 | x_i)$ 也单调减少. 一个自然的选择便是值域在 $(0, 1)$ 之间有着 S 形状的曲线, 这样在 x_i 趋近于负无穷时有 $E(y_i)$ 趋近于 0, 在 x_i 趋近于正无穷时有 $E(y_i)$ 趋近于 1. 这种曲线类似于一个随机变量的累积分布曲线. 在二分类因变量分析中曾使用多种分布函数 (Cox, 1970). 然而, 最常用的函数是流行的 logistic 分布. 另一种可供替换的分布函数是标准正态分布, 与之相应的是 probit 模型 (将在第 7 章介绍). 这里我们先简要地描述一下把 logistic 函数用于二分类因变量分析的理论依据.

假设有一个理论上存在的连续反应变量 y_i^* 代表事件发生的可能性, 其值域为负无穷至正无穷. 当该变量的值跨越一个临界点 c (比如 $c = 0$), 便导致事件发生. 于是有:

$$\begin{aligned} \text{当 } y_i^* > 0 \text{ 时,} & \quad y_i = 1, \\ \text{在其他情况下,} & \quad y_i = 0. \end{aligned}$$

这里, y_i 是实际观察到的反应变量. $y_i = 1$ 表示事件发生, $y_i = 0$ 表示事件未发生. 如果假设在反应变量 y_i^* 和自变量 x_i 之间存在一种线性关系, 即

$$y_i^* = \alpha + \beta x_i + \epsilon_i, \quad 1.3.1$$

由公式 1.3.1, 我们得到

$$\begin{aligned} P(y_i = 1 | x_i) &= P[(\alpha + \beta x_i + \epsilon_i) > 0] \quad 1.3.2 \\ &= P[\epsilon_i > (-\alpha - \beta x_i)]. \end{aligned}$$

通常, 假设公式 1.3.1 中误差项 ϵ_i 有 logistic 分布或标准正态分布. 为了取得一个累积分布函数 (cumulative distribution function, 缩写为 CDF), 一个变量的概率需要小于一个特定值.

所以,我们必须改变公式 1.3.2 中不等号的方向. 由于 logistic 分布和正态分布都是对称的, 因此公式 1.3.2 可以改写为:

$$P(y_i = 1 | x_i) = P[\epsilon_i \leq (\alpha + \beta x_i)] \quad 1.3.3$$

$$= F(\alpha + \beta x_i),$$

其中 F 为 ϵ_i 的累积分布函数. 分布函数的形式依赖于公式 1.3.1 中 ϵ_i 的假设分布. 如果假设 ϵ_i 为 logistic 分布, 就得到 logistic 回归模型; 如果假设 ϵ_i 为标准正态分布, 就得到 probit 模型 (Long, 1997). 因为 y_i^* 不能直接观察, 其量度既不能由 logistic 回归模型来决定, 也不能由 probit 模型来决定. 在 probit 模型中, 误差项 ϵ_i 的方差为 1. 而在 logistic 回归模型中, 误差项 ϵ_i 的方差为 $\pi^2/3 \approx 3.29$. 在本书中, 我们将主要介绍 logistic 回归模型, 然后在第 7 章对 probit 模型作一简要介绍. 标准 logistic 分布的平均值等于 0, 方差等于 $\pi^2/3 \approx 3.29$. 之所以选择这样一个方差是因为它可以使累积分布函数取得一个较简单的公式:

$$P(y_i = 1 | x_i) = P[\epsilon_i \leq (\alpha + \beta x_i)] \quad 1.3.4$$

$$= \frac{1}{1 + e^{-\epsilon_i}}.$$

这一函数称为 Logistic 函数, 它具有 S 型的分布, 图 1.2 中给出它的图形.

如果我们将 ϵ_i 在负无穷至正无穷区间变化时的函数值标画出来, 就得到了图 1.2 中的图形. 注意在这一图形的左侧, 当 ϵ_i 趋近于负无穷时, logistic 函数有




图 1.2 logistic 函数的曲线图



$$\begin{aligned}
 P(y_i = 1 | x_i) &= 1 / (1 + e^{-(-\infty)}) \\
 &= 1 / (1 + e^{\infty}) \\
 &= 0.
 \end{aligned}$$

与此相对, 当 ϵ_i 趋近于正无穷时, logistic 函数有

$$\begin{aligned}
 P(y_i = 1 | x_i) &= 1 / (1 + e^{-(-\infty)}) \\
 &= 1 / (1 + e^{-\infty}) \\
 &= 1.
 \end{aligned}$$

正如图形所示, 无论 ϵ_i 取任何值, logistic 函数 $P(y_i = 1 | x_i) = 1 / (1 + e^{-\epsilon_i})$ 的取值范围均在 0 至 1 之间. logistic 函数的这一性质保证了由 logistic 模型估计的概率决不会大于 1 或小于 0. logistic 函数的另一个性质也是很有用的, 即这个函数的形状对于研究概率也很合适. 如图 1.2 所示, 如果我们从 $\epsilon_i = -\infty$ 开始向右移动, 当 ϵ_i 增加时, 这一函数的值先是很缓慢地增加, 然后转向迅速增加, 之后增加的速度又开始逐渐减缓, 最后当 ϵ_i 趋近于 $+\infty$ 时, 函数值趋近于 1. logistic 函数的 S 型曲线表明, ϵ_i 的作用对于某个案例发生某一事件的可能性是变化的, 在 ϵ_i 值很小时其作用也很小, 然而在中间阶段对应的可能性增加很快, 但是在 ϵ_i 值增加到一定程度以后, 可能性就保持在几乎不变的水平了. 这说明, ϵ_i 在 $P(y_i = 1 | x_i)$ 接近于 0 或 1 时的作用要小于当 $P(y_i = 1 | x_i)$ 处于中间阶段时的作用. 这种非线性函数的形式有助于解决线性概率模型所不能解决的问题. 比如, 就前面例题中提到的家庭购买 VCD 的概率问题而言, 并不是家庭收入每增加一定量, 购买 VCD 的概率就固定增加一定值. 实际情况是, 家庭收入在某一段水平内变化时对购买概率的变化影响较大, 而较低或较高收入对购买概率的变化影响都不大. 因为前者多买不起, 后者则差不多都有了.

现在让我们从 logistic 函数转向 logistic 回归模型, 它才是我们真正的兴趣所在. 为了根据 logistic 函数取得 logistic 回归模型, 我们将公式 1.3.4 重写为:

$$P(y_i = 1 | x_i) = \frac{1}{1 + e^{-(\alpha + \beta x_i)}} \quad 1.3.5$$

其实, 这就是当 ϵ_i 取值为 $(\alpha + \beta x_i)$ 时的累积分布函数. 在

这里, ϵ_i 被定义为一系列影响事件发生概率的因素的线性函数, 即

$$\epsilon_i = \alpha + \beta x_i, \quad 1.3.6$$

其中 x_i 为自变量, α 和 β 分别为回归截距和回归系数. 为了简单, 这里以一元回归为例. 然而, 同样的原则也适用于多元回归.

将事件发生的条件概率标注为 $P(y_i = 1 | x_i) = p_i$, 我们就能得到下列 logistic 回归模型

$$\begin{aligned} p_i &= \frac{1}{1 + e^{-(\alpha + \beta x_i)}} \\ &= \frac{e^{\alpha + \beta x_i}}{1 + e^{\alpha + \beta x_i}}, \end{aligned} \quad 1.3.7$$

其中, p_i 为第 i 个案例发生事件的概率, 它是一个由解释变量 x_i 构成的非线性函数 (non-linear function). 然而这个非线性函数可以被转变为线性函数 (linear function).

首先, 定义不发生事件的条件概率为

$$\begin{aligned} 1 - p_i &= 1 - \left(\frac{e^{\alpha + \beta x_i}}{1 + e^{\alpha + \beta x_i}} \right) \\ &= \frac{1}{1 + e^{\alpha + \beta x_i}}, \end{aligned} \quad 1.3.8$$

那么, 事件发生概率与事件不发生概率之比为

$$\frac{p_i}{1 - p_i} = e^{(\alpha + \beta x_i)}. \quad 1.3.9$$

这个比被称之为事件的发生比 (the odds of experiencing an event), 简标为 odds. 我们将在第 4 章讨论 odds 及其有关概念. odds 一定为正值, 因为 $0 < p_i < 1$, 并且没有上界. 将 odds 取自然对数就能够得到一个线性函数:

$$\ln \left(\frac{p_i}{1 - p_i} \right) = \alpha + \beta x_i. \quad 1.3.10$$

公式 1.3.10 将 logistic 函数做了自然对数转换, 这称作 logit 形式 (logit form), 也称作 y 的 logit, 即 $\text{logit}(y)$.

这一转换的重要性在于, $\text{logit}(y)$ 有许多可利用的线性回归



模型的性质, $\text{logit}(y)$ 对于其参数而言是线性的, 并且依赖于 x 的取值, 它的值域为负无穷至正无穷. 从公式 1.3.10 我们可以看出, 当 odds 从 1 减少到 0 时, $\text{logit}(y)$ 取负值且绝对值越来越大; 当 odds 从 1 增加到正无穷时, 它取正值且值越来越大. 于是, 我们就不为概率估计值会超过概率值域的问题所困了. logit 模型的系数 α 和 β 可以按照一般回归系数那样来解释. 一个变量的作用如果是增加对数发生比($\log \text{odds}$)的话, 也就增加事件发生的概率, 反之亦然.

就概念而言, 公式 1.3.7 表达的是“logistic 回归”, 因为它是 logistic 分布函数, 而公式 1.3.10 则表达的是“logit 模型”, 因为它采用的是 logit 形式. 在有关文献中, 有时对 logistic 回归和 logit 模型是根据所用自变量是否为连续变量来划分. 有些研究人员将以分类自变量(categorical independent variables)构成的模型称为 logit 模型, 而将既有分类自变量又有连续自变量(continuous independent variables)的模型称为 logistic 回归模型. 有时为了方便, 不管自变量是什么类型, 人们将 logistic 回归模型统叫作 logit 模型. 更通常的是, 人们将“logistic 回归”、“logistic 模型”、“logistic 回归模型”及“logit 模型”的称谓相互通用, 来指同一个模型(Feinberg, 1985; DeMaris, 1992; Liao, 1994). 本书中, 我们统一称 logistic 回归模型.

尽管线性回归分析的原则也应用于 logistic 回归模型, 但我们应当记住, logistic 回归与线性回归是完全不同的. 首先, 线性回归的结果变量(outcome variable)(或称因变量(dependent variable)或反应变量(response variable))与其自变量之间的关系是线性的, 而 logistic 回归中结果变量与自变量之间的关系是非线性的, 尽管非线性关系可以被转换为线性关系. 其次, 我们在线性回归中通常假设, 对应自变量 x_i 的某个值, 结果变量 y_i 的观测值有正态分布. 但是在 logistic 回归中, 结果变量的观测值 y_i 却为二项分布. 最后, 在 logistic 回归模型中(即公式 1.3.10), 不存在线性回归模型中有的残差项.

在有 k 个自变量时, 公式 1.3.7 便扩展为:

$$p_i = \frac{e^{\alpha + \sum_{k=1}^k \beta_k x_k}}{1 + e^{\alpha + \sum_{k=1}^k \beta_k x_k}}. \quad 1.3.11$$

那么, 相应的 logistic 回归模型将有下列形式:

$$\ln\left(\frac{p_i}{1-p_i}\right) = \alpha + \sum_{k=1}^k \beta_k x_{ki}. \quad 1.3.12$$

其中, $p_i = P(y_i = 1 | x_{1i}, x_{2i}, \dots, x_{ki})$ 为在给定系列自变量 $x_{1i}, x_{2i}, \dots, x_{ki}$ 的值时的事件发生概率.

一旦我们拥有各个案例的观测自变量 x_1 至 x_k 值构成的样本, 并同时拥有其事件发生与否的观测值, 我们就能够使用这些信息来分析和描述在特定条件下事件的发生比及发生的概率.

尾注 1

Goldberger (1964) 建议一种两步骤程序来解决这一问题. 在第一步中先采用最小二乘法 (Least Squares) 将 y_i 对 x_i 进行回归分析, 估计出系数 α 和 β . 这一步产生出公式 $y_i = \alpha + \beta x_i + \epsilon_i$ 中参数的一致性估计 (consistent estimate). 在第二步中, 再对残差的方差 $\text{Var}(\epsilon_i)$ 进行估计. 然后, 采用 ϵ_i 的标准误的倒数作为权数来进行加权最小二乘法 (weighted least squares, 缩写为 WLS) 的回归. 其权数 w_i 的计算公式为:

$$\begin{aligned} w_i &= 1/\text{SE}(\epsilon_i) = 1/[\text{Var}(\epsilon_i)]^{1/2} \\ &= 1/[(\hat{\alpha} + \hat{\beta}x_i)(1 - (\hat{\alpha} + \hat{\beta}x_i))]^{1/2}, \end{aligned}$$

然后, 将公式 1.2.1 的两侧分别乘以权数 w_i , 得到

$$w_i y_i = \alpha^* w_i + \beta^* w_i x_i + w_i \epsilon_i,$$

可以证明 (Goldberger, 1964), $w_i \epsilon_i$ 有相同的方差, 因此再用常规最小二乘法将 $w_i y_i$ 对 $w_i x_i$ 回归便能够得到无偏的参数估计和有效的统计检验. 然而, 所得到的事件发生概率的估计值 $(\hat{\alpha}^* w_i + \hat{\beta}^* w_i x_i)$ 仍然可能超出 0 至 1 的范围.

Logistic 回归模型 估计

2

第 二 章

- 2.1 最大似然估计(Maximum Likelihood Estimation, MLE) (14)
- 2.2 Logistic 回归模型估计的假设条件 (17)
- 2.3 最大似然估计的性质 (17)
- 2.4 模型估计的样本规模 (18)
- 2.5 拟合 logistic 回归的示范模型 (19)
- 2.6 用分组数据作 logistic 回归分析 (33)

在第 1 章对 logistic 回归模型做了介绍以后,现在我们来介绍该模型的估计.通常用以估计 logistic 回归模型的数据有两种形式,或是单个案例数据,或是以分组形式构成的数据.单个案例数据,也称微观数据,一般从抽样调查中取得,每个案例的变量值反映一个观察对象的各方面的情况,如 x 为自变量, y 为取值 0 或 1 的反映变量.分组数据,也称宏观数据,来自于汇总水平.我们先介绍用微观数据进行模型估计,然后介绍一个转形的 OLS 模型对分组数据做 logistic 回归分析,并用分组数据来运行微观水平的 logistic 回归模型.

2.1 最大似然估计 (Maximum Likelihood Estimation, MLE)

在线性回归中估计未知总体参数时主要采用最小二乘法.这一方法的原理是根据线性回归模型选择参数估计值,使因变量的观测值与模型估计值之间的离差平方值为最小.而最大似然估计法则是统计分析中另一常用模型参数估计方法.在线性回归分析中,最大似然估计法可以得到与最小二乘法相同的结果.与最小二乘法相比,最大似然估计法既可以用于线性模型,也可以用于更为复杂的非线性估计.由于 logistic 回归是非线性模型,因此最大似然估计法是最常用的模型估计方法.

在应用最大似然估计法之前,我们先要建立一个函数,称为似然函数(likelihood function).这一函数将观测数据的概率表述为未知模型参数的函数.模型参数的最大似然估计是选择能够使这一函数值达到最大的参数估计值.换句话说,这套参数估计能够通过模型以最大概率再现样本观测数据.下面,我们介绍如何通过最大似然估计法来估计 logistic 回归模型的参数.

假设有由 N 个案例构成的总体, $Y_1, \dots, Y_N$. 从中随机抽取 n 个案例作为样本,观测值标注为 $y_1, \dots, y_n$. 设 $p_i = P(y_i = 1 | x_i)$ 为给定 x_i 的条件下得到结果 $y_i = 1$ 的条件概率;而在同样条件下得到结果 $y_i = 0$ 的条件概率为 $P(y_i = 0 | x_i) = 1 - p_i$.

于是, 得到一个观测值的概率为:

$$P(y_i) = p_i^{y_i} (1 - p_i)^{1 - y_i}, \quad 2.1.1$$

其中, $y_i = 1$ 或 $y_i = 0$. 式中 y_i 或 $(1 - y_i)$ 只是表示对于一个特定观测, 哪一项概率是有关的. 当 $y_i = 1$ 时, $P(y_i) = p_i = P(y_i = 1 | x)$, 否则 $P(y_i) = (1 - p_i) = P(y_i = 0 | x_i)$. 因为各项观测相互独立, 所以它们的联合分布可以表示为各边际分布的乘积:

$$L(\theta) = \prod_{i=1}^n p_i^{y_i} (1 - p_i)^{(1 - y_i)}. \quad 2.1.2$$

式 2.1.2 也称为 n 个观测的似然函数. 在第 1 章中讲过, $p_i = e^{\alpha + \beta x_i} / (1 + e^{\alpha + \beta x_i})$. 我们的目的是求出能够使这一似然函数的值最大的参数估计. 这就是说, 最大似然估计就是求解出具有最大可能取得所给定的样本观测数据的参数估计. 于是, 最大似然估计的关键是估计出参数 α 和 β 的值, 并通过它们使式 2.1.2 取得最大值. 然而, 使似然函数 $L(\theta)$ 最大化的实际过程是非常困难的. 一般是通过使似然函数的自然对数变换式 (即 $\ln[L(\theta)]$) 最大的方法, 而不是直接对似然函数本身求最大. 因为 $\ln[L(\theta)]$ 是 $L(\theta)$ 的单调函数, 使 $\ln[L(\theta)]$ 取得最大值的 θ 值同样使 $L(\theta)$ 取得最大值. 通过分析 $\ln[L(\theta)]$, 式 2.1.2 中相乘各项转变为对数项的相加, 于是使得数学运算变得较为容易. 以式 1.3.10 作为示范, 其 logistic 回归模型的对数似然值为:

$$\begin{aligned} \ln[L(\theta)] &= \ln \left[\prod_{i=1}^n p_i^{y_i} (1 - p_i)^{(1 - y_i)} \right] \\ &= \sum_{i=1}^n [y_i \ln(p_i) + (1 - y_i) \ln(1 - p_i)] \\ &= \sum_{i=1}^n \left[y_i \ln \left(\frac{p_i}{1 - p_i} \right) + \ln(1 - p_i) \right] \quad 2.1.3 \\ &= \sum_{i=1}^n \left[y_i (\alpha + \beta x_i) + \ln \left(1 - \frac{e^{\alpha + \beta x_i}}{1 + e^{\alpha + \beta x_i}} \right) \right] \\ &= \sum_{i=1}^n [y_i (\alpha + \beta x_i) - \ln(1 + e^{\alpha + \beta x_i})]. \end{aligned}$$

式 2.1.3 称为对数似然函数 (log likelihood function). 为了估计能使 $\ln[L(\theta)]$ 最大的总体参数 α 和 β 值, 先分别对 α 和 β 求偏导数, 然后令它等于 0:



$$\frac{\partial \ln[L(\theta)]}{\partial \alpha} = \sum_{i=1}^n \left[y_i - \frac{e^{\alpha + \beta x_i}}{1 + e^{\alpha + \beta x_i}} \right], \quad 2.1.4$$

$$\frac{\partial \ln[L(\theta)]}{\partial \beta} = \sum_{i=1}^n \left[y_i - \frac{e^{\alpha + \beta x_i}}{1 + e^{\alpha + \beta x_i}} \right] x_i. \quad 2.1.5$$

式 2.1.4 和式 2.1.5 称为似然方程(likelihood equations). 如果模型中有 k 个自变量, 那么就有 $k+1$ 个联立方程来估计 α 和 $\beta_1, \beta_2, \dots, \beta_k$ 的值. 在线性回归中, 似然方程是通过把偏差平方和分别对 α 和 β 求偏导数所得到的, 它对于未知参数都是线性的, 因此很容易求解. 但是对于 logistic 回归, 如式 2.1.4 和式 2.1.5 是 α 和 β 的非线性函数, 所以求解十分困难. 实际上, 不求助于现代计算机技术, 几乎是无法求解的. 最大似然估计法是通过迭代计算完成的. 其迭代程序已经置于 logistic 回归软件之中. 所以, 我们用不着关心具体的迭代方法, 因为计算机可以为我们处理好各种计算细节. 对 logistic 回归模型中最大似然估计方法感兴趣的读者, 可参阅 McCullagh and Nelder (1983) 与 Eliason (1993).

由式 2.1.4 和式 2.1.5 提供的 α 和 β 值估计称为最大似然估计(maximum likelihood estimates). 按照一般统计标注法, 我们用加 “ $\hat{\cdot}$ ” 符号的方法表示参数估计. 于是, 我们所感兴趣的是 $\hat{\alpha}$ 和 $\hat{\beta}$. 它们是 α 和 β 的模型估计值; 而 $\hat{p}_i$ 是条件概率 p_i 的最大似然估计. 这个值是在给定 x_i 的条件下 $y_i = 1$ 的条件概率的估计, 它代表了 logistic 回归模型的拟合值或预测值. 当令偏导函数等于 0 时, 由式 2.1.4 可以得到如下的结果:

$$\sum_{i=1}^n y_i = \sum_{i=1}^n \hat{p}_i. \quad 2.1.6$$

这意味着观测值 y_i 之和等于预测概率之和. 这一性质在评价模型拟合情况时非常有用, 我们将在第 3 章看到式 2.1.6 的应用.

最大似然估计的渐近方差(asymptotic variance)和协方差(covariance)可以由信息矩阵的逆矩阵(inverse of the information matrix)估计出来. 信息矩阵实际上是 $\ln[L(\theta)]$ 二阶导数的负值的期望, 可以用下列形式表达:

$$I(\theta) = E \left[- \frac{\partial^2 \ln(L)}{\partial \theta^2} \right]. \quad 2.1.7$$

信息矩阵的逆为：

$$[\mathbf{I}(\theta)]^{-1}. \quad 2.1.8$$

$\hat{\alpha}$ 和 $\hat{\beta}$ 渐近方差的估计就是信息矩阵的逆的对角线上元素值，而对角线以外各元素值为各项参数之间的协方差估计。

2.2 Logistic 回归模型估计的假设条件

Logistic 回归模型估计的一些假设条件与 OLS 回归中的十分类似。首先，数据必须来自于随机样本。第二，因变量 y_i 被假设为 K 个自变量 x_{ki} ($k=1, 2, \dots, K$) 的函数。第三，正如 OLS 回归，logistic 回归也对多元共线性(multicollinearity)敏感。自变量之间存在的多元共线性会导致标准误的膨胀。

Logistic 回归模型还有一些与 OLS 回归不同的假设。第一，logistic 回归的因变量 y_i 是二分变量，这个变量只能取值 0 或 1。研究的兴趣在于事件发生的条件概率，即 $P(y_i=1|x_{ki})$ 。第二，正如公式 1.3.11 中所定义的，logistic 回归中因变量和各自变量之间的关系是非线性的。第三，在 OLS 回归中要假设相同分布性(homoscedasticity)或称方差不变，类似的假设在 logistic 回归中却不需要。最后，logistic 回归也没有关于自变量分布的假设条件。各自变量可以是连续变量，也可以是离散变量，还可以是虚拟变量(dummy variable)。并且，也不需要假设它们之间存在多元正态分布(multinormality)。但是，自变量之间如果存在多元正态分布关系将能够增加模型的功效(power)，求解也能够提高稳定性(Tabachnick & Fidell, 1996)。

2.3 最大似然估计的性质

本书不准备推导 logistic 回归的最大似然估计的统计性质，而仅仅对于这些统计性质加以概括。只要上述假设条件得到满足，

最大似然估计与 OLS 估计的统计性质几乎完全相同。这就是说，logistic 回归的最大似然估计具有一致性(consistency)、渐近有效性(asymptotically efficiency)和渐近正态性(asymptotically normal)。一致性指当样本规模增大时，模型参数估计逐渐向真值收敛。这意味着在样本规模很大时，估计将近似于无偏。所谓渐近有效性指当样本规模增大时，参数估计的标准误(standard error)相应缩小。这就是说，在样本规模很大时，估计的标准误至少不比用其他方法估计的标准误大。最后，渐近正态性指随着样本规模增大，最大似然参数估计值的分布趋近于正态分布。这意味着，我们可以利用这一性质进行假设的显著性检验和计算参数的置信区间。与 OLS 回归估计的不同之处是，最大似然估计的上述性质具有渐近性，也就是说，在样本较大时这些性质才能保持。

2.4 模型估计的样本规模

最大似然估计具有的一致性、有效性和正态性都是一些很好的统计性质，然而保持这些性质的条件为样本规模要很大。但是，这并不等于说最大似然估计在小样本时统计性质就一定不好。简单而言，我们通常并不知道在小样本时的统计性质究竟如何。更实际的问题是，样本在多大时就可以应用最大似然估计，或多大样本可以保证统计检验得到显著的结果。这个问题现无明确的答案^①。许多研究者在没有其他方法可供选择的条件下，便无论对大样本还是对小样本都用最大似然估计方法。然而，当样本很小时，对于概率估计值和置信区间的解释就必须十分谨慎。

^① 有人认为，样本太大对于建立统计模型并不可取。因为样本太大时，几乎任何多元相关都会呈统计显著，甚至在因变量上微不足道的变化也会令统计检验显著。所以，无论是从统计分析的角度还是从实际资料收集的角度，最好是在能取得无偏、一致、有效统计的可能性的前提下尽量使样本规模最小(Tabachnick & Fidell, 1996, p. 133)。

根据一些资深研究人员的看法,最大似然估计的大样本性质一般维持得较好,即使在中等规模样本(比如 $n=100$)的条件下也能够接受(Aldrich and Nelson, 1984). Long (1997) 提到,在样本规模小于 100 时使用最大似然估计风险较大,但样本量大于 500 时就显得比较充分了. 样本规模的确定依赖于模型和数据的特点. 首先,如果在模型中有很多参数要估计时,就需要较多的观测案例. 在关于结构方程模型(structural equation modeling)的文献中,一般经验认为,平均而言,每一参数至少需要 5 个观测案例,还有人认为每一参数至少需要 10 个案例. 这种经验规则并不是说,如果只有几个参数就用不着样本规模要大于 100 了. 其次,要是数据条件不太好,比如自变量之间有高度共线性或因变量的变化太小(如有太多的案例的反应值都相同)等问题存在,就需要较大的样本. 最后,模型的反应变量中有更多分类(分类数大于 2, logistic 回归的一种特殊应用可以处理此类情况,我们将在第 8 章介绍)时,也需要更多的观测案例.

2.5 拟合 logistic 回归的示范模型

为了示范如何估计 logistic 回归模型,我们采用一套模拟数据来分析高中毕业生继续进入大学学习的可能性的影响因素. 这套数据仅仅是为了示范应用 logistic 回归模型分析而模拟的,所以其数据和所有分析结果并没有什么实际意义(案例原始数据可从下列网址下载: <http://www.hep.com.cn>; <http://www.wright.edu/~jwang>; <http://www.disa.pku.edu.cn/课程>).

模型中的反应变量是高中毕业生是否进入大学. 如果一个高中毕业生升入了大学,反应变量的编码为 $y=1$; 如果没有升入大学,其编码 $y=0$. 模型中有三个自变量. logistic 回归的示范模型如下:

$$\ln(p/(1-p)) = \alpha + \beta_1 \text{ GENDER} + \beta_2 \text{ KEYSCH} + \beta_3 \text{ MEANGR}.$$

2.5.1

其中,变量 p 为高中毕业后进入大学的概率;变量



GENDER表示性别(1 为男性, 0 为女性); 变量 KEYSCH 表示高中类型(1 为重点中学, 0 为其他中学); 变量 MEANGR 代表高中平均成绩, 由其高中各门考试成绩的平均值确定(由原始数据变量计算而来). GENDER 和 KEYSCH 都是虚拟变量, 而 MEANGR 是连续变量, 它被实际测量为各学生的高中平均分数与所有学生总平均分数之间的离差(deviation). 这样, 当变量 MEANGR 取零值时, 它便代表了学生的总平均分数. 这三个变量是 logistic 回归模型的自变量, 用以预测学生在高中毕业后进入大学的概率. 表 2.5.1 中提供了这套摹拟的高校入学情况数据的描述性统计指标.

表 2.5.1 摹拟的高校入学数据的描述性统计

变量	高中平均成绩			进入高校	
	案例数	均值	标准差	%	标准差
性别					
男性	550	85.045	3.932	0.471	0.549
女性	450	81.996	4.135	0.169	0.375
高中类型					
重点中学	132	83.829	4.249	0.477	0.501
非重点中学	868	83.650	4.309	0.313	0.464
合计	1000	83.673	4.299	0.335	0.472

在这套数据中, 有 1000 名高中毕业生, 其中 55% 为男生, 45% 为女生. 在这些学生中从一般中学毕业的占 86.8%, 从重点高中毕业的占 13.2%. 高中平均成绩的总平均值为 83.7 分. 高中平均成绩和大学升学比例两项都与性别显著相关: 在高中时男生成绩显著高于女生成绩, 且高中毕业后男生的大学升学比例也显著高于女生. 重点中学毕业生升入高校的比例为 48%, 显著高于非重点中学的升学比例 31%. 然而, 在重点中学和非重点中学的毕业生的高中平均成绩上并没有显著差别. 我们这样模拟数据, 是考虑到不同类型学校的评分标准有所不同, 同样的成绩在不同的学校可能反应不同的水平. 这也是为什么我们要在模型中控制变量 KEYSCH 的原因.

本书将示范用 logistic 回归来分析应用于这套摹拟的高校升学数据，并对其估计过程和结果加以讨论。我们采用两种国际通用统计软件包 SAS^①和 SPSS^②来进行这一分析。我们先介绍如何应用 SAS 来运行 logistic 回归分析。在 SAS 系统中有几种不同程序可以用来完成 logistic 回归分析，比如 PROC LOGISTIC 程序、PROC CATMOD 程序和 PROC GENMOD 程序。其中，PROC LOGISTIC 程序是专门为运行 logistic 回归分析所设计的。而 PROC CATMOD 程序是设计用于拟合分类反应变量模型的一般程序，当模型中使用分类变量时，这一程序将非常方便。PROC GENMOD 是一般线性模型分析的程序，而 logistic 回归模型只是这类模型的一种特例。本书的主要讨论将集中在应用 SAS PROC LOGISTIC 程序和 SPSS LOGISTIC REGRESSION 程序。但在第 8 章中，当我们讨论 logistic 回归的扩展模型时，我们会介绍 SAS 的 PROC CATMOD 及 SPSS 的相关程序。下面是应用 SAS 的 PROC LOGISTIC 程序的一个简单例子：

*** SAS PROGRAM EXAMPLE 1: LOGISTIC REGRESSION MODEL;**

OPTIONS NOCENTER PS = 500 LS = 150;

LIBNAME LIB ' D: \ LOGIT';

DATA LIB.COLLEGE;

INFILE ' D: \ LOGIT \ COLLEGE.DAT';

INPUT GENDER 1 KEYSCH 3 GRADE 5 - 8 COLLEGE 10;

MEANGR = GRADE - 83.7;

-
- ① SAS 本来是英文 Statistical Analysis System (统计分析系统)的缩写。然而，它已经发展成为全套信息传送系统，不仅提供统计分析应用，而且包括了工商数据管理、分析、决策和许多其他方面的应用。今天的 SAS 已经成为一个商标，不再代表任何具体应用的缩写。
- ② SPSS 本来是英文 Statistics Package for the Social Sciences 的缩写，意思是社会科学统计软件包。与 SAS 一样，SPSS 也是世界著名的综合灵活的统计与数据管理系统。SPSS 5.0 视窗版 (SPSS for Windows) 或更新版本是最能适应视窗 95 的各种功效和支持功能的一流个人电脑统计软件。


```
PROC LOGISTIC DESCENDING;  
MODEL COLLEGE = GENDER KEYSCH MEANGR;  
RUN;
```

一般的 SAS 程序包括三个部分：第一部分（即上述程序的第 1 行和第 2 行）为程序的注释和一般设置。这里的第 1 行是注释，在 SAS 程序中只要以星号开始的行便是注释行，将不作为程序来运行。如果注释为多行，可以用“/*”和“*/”将所有注释行包括于其中，也可以使 SAS 识别为注释。第 2 行是关于程序输出或报告页的设置，其中 PS 和 LS 分别定义输出纸的规格和输出行的规格。比如命令 PS 设置每页输出的行数，其范围是 20 行至 500 行。它的默认值为 21 行。命令 LS 设置输出时每行中的列数，其范围可定在 64 列至 256 列之间。它的默认值为 80 列。在本例中，我们设置输出为每页 500 行、每行列数的最大值为 150。

第二部分为数据设置（本程序中第 3-7 行）。第 3 行定义 SAS 数据的存取位置（LIBRARY），我们定义 D 盘上子目录 D:\LOGIT 为数据存取位置，并给予一个名称为 LIB。然后，下一行中的 DATA 命令指示数据存入指定位置上的数据文件名 COLLEGE，于是 SAS 数据文件将按指定文件名加自动形成的扩展名 SD2（注意，在 SAS6.08 版及以前扩展名为 SSD）存放于指定位置 LIB，即子目录 D:\LOGIT。注意，如果文件位置名 LIB 没有在 SAS 数据文件名之前指定的话，SAS 只形成临时数据文件。换句话说，要是命令写成 DATA COLLEGE，那么 SAS 只形成名为 COLLEGE 的临时数据文件，程序一运行完毕，这数据文件就不复存在了。

下面的几行命令还是数据设置部分。命令 INFILE 指定一个外部数据文件（ASCII 格式文件）的文件名并指定其所在位置。然后，INPUT 命令指定这一输入文件中各变量的位置，并给定相应的变量名。SAS 软件以变量来代表所收集资料中的每一观测案例中的各项信息（在研究中我们称观测案例为分析单位，analytic unit，本例中即为每个高中毕业生）。每次我们要将 ASCII 数据读入 SAS 软件时，都需要为每个变量

指定变量名。只有这样才能在进行统计或计算时区别不同变量。在为变量取名时有一些规则。第一，变量名必须以一个字母开始。第二，它不能超过 8 个字符的长度。第三，变量名的字符中不包括空格及其他特殊字符，如逗号、分号等等。取变量名最好能有助于记忆变量的内容。比如，本例中的变量名 GENDER、KEYSCH、GRADE 和 COLLEGE 实际都是变量意义的英文或缩写，它们的位置分别在数据文件的第 1、3、5-8、和 10 列中。如果数据中各变量信息都有空白间隔，在 INPUT 命令中可不需指定各变量的位置。即可以“自由格式”(free format)读取数据。

程序 MEANGR = GRADE - 83.7 是数据转换命令，它产生一个新变量 MEANGR，其值为各学生的高中平均分数(GRADE)与所有学生总平均分数(83.7)之间的离差。

程序的最后一部分(本程序中第 8-10 行)为模型运行程序。其中，PROC 是英文 PROCEDURE 的缩写，代表运行程序，其作用是指定要求运行的统计分析工作，并为这一分析制定所需设置。PROC LOGISTIC 命令表示要求对数据进行 logistic 回归分析。MODEL 命令行是设置分析模型，模型的反应变量在等号左侧，自变量在等号右侧。最后一行的命令 RUN 在 SAS 6.07 或更新版本中十分重要，如果程序中没有 RUN 命令，模型结果将不能打印到输出中。特别需要注意的是，类似于句号是一般语言结束的标志一样，分号“;”是 SAS 程序结束的标志。也许，SAS 程序中最容易发生的错误就是遗漏表示结束的分号。它将导致计算机读入和执行其他命令，造成混乱。

在 logistic 回归中，二分类反应变量 y 的编码无硬性规定。但是，我们通常习惯于在虚拟变量中将“事件发生”编码为 1 (即 $y=1$)，而将“事件未发生”编码为 0 (即 $y=0$)。有时，研究者会发现 SAS 的 PROC LOGISTIC 程序得到的所有系数估计表示的方向都与其他软件程序计算的相反，这是因为在默认状态下，与很多统计软件不同，SAS 的 PROC LOGISTIC 程序是为反应变量中较小编码值的类别求解。这就是说，如果反应变量将事件未发生类编码为 0，事件发生类编码为 1，SAS 的 PROC

LOGISTIC 程序所建立的模型将求解事件不发生(即 $y = 0$)的概率。模型的系数估计不是关于自变量对事件对数发生比的影响,而是对非事件的对数发生比的影响。这常常会造成误解。所以,在使用 SAS 的 PROC LOGISTIC 程序运行 logistic 回归时,十分重要的是要确保 PROC LOGISTIC 程序是按自己所要求的方式为反应变量求解的。

如果我们将反应变量的事件未发生类编码为 0,事件发生类编码为 1,可以有几种不同的方法来保证 SAS 程序是在求解事件发生(即 $y = 1$)的概率。最简单易行的方法是在编制 PROC LOGISTIC 程序时加上备选命令 DESCENDING(如上述示范程序中所示)。加上这个备选命令后,SAS 的 PROC LOGISTIC 程序将按与默认方式相反的顺序选择反应变量中较大编码值类别作为模型求解的基础。SAS 6.07 及其更新版本中提供了备选命令 DESCENDING。

要是在进行数据分析之前我们就已经拥有存放在子目录 D:\LOGIT 中的 SAS 系统文件 COLLEGE.SD2 的话,所要用的 SAS 程序如下所示:

```
* SAS PROGRAM EXAMPLE 2: LOGISTIC REGRESSION MODEL;
OPTIONS NOCENTER PS = 500 LS = 150;

LIBNAME LIB ' D: \ LOGIT';
DATA DATA1;
SET LIB.COLLEGE;
PROC LOGISTIC DESCENDING;
MODEL COLLEGE = GENDER KEYSCH MEANGR;
RUN;
```

在示范程序 2(即 SAS program example 2)中,我们直接从子目录 D:\LOGIT 中提取已有 SAS 系统数据文件 COLLEGE.SD2 的内容,将其调入 SAS 临时数据文件 DATA1。示范程序 2 的分析结果将与前一个示范程序完全相同。

表 2.5.2 是上述 LOGISTIC REGRESSION 程序的默认输出。输出的第一部分描述了工作数据情况、模型的反应变量、样

本规模和关联函数^①的情况。标题为“Response Profile”的部分提供了反应变量中各类别的排序、变量值及其频数的信息。由于程序中调用了备选命令 DESCENDING，所以事件发生的类别($y=1$)被排序为第 1 位，事件未发生($y=0$)排在第 2 位。因为 SAS 的 PROC LOGISTIC 程序将反应变量值排序值较小者作为模型求解对象，所以我们的程序建立的模型是关于事件发生($y=1$)概率的。在“Response Profile”栏目中提供了反应变量的排序信息，使我们能够确保所建立模型提供我们所要分析的参数的参数估计。

表 2.5.2 SAS 的 LOGISTIC REGRESSION 程序的输出

The LOGISTIC Procedure			
Data Set: WORK.DAT1			
Response Variable: COLLEGE			
Response Levels: 2			
Number of Observations: 1000			
Link Function: Logit			
Response Profile			
Ordered			
Value	COLLEGE	Count	
1	1	335	
2	0	665	
Model Fitting Information and Testing Global Null Hypothesis BETA = 0			
Intercept			
Intercept and			
Criterion	Only	Covariates	Chi-Square for Covariates

① 在 logistic 回归模型中，logistic 函数是关于因变量函数(即 $\ln[p/(1-p)]$)与事件概率(即 p)之间的关系。表示这种关系的函数称为关联函数(link function)。不同的关联函数定义不同的模型。



续表

AIC	1277.326	847.965	.
SC	1282.234	867.596	.
-2 LOG L	1275.326	839.965	435.361 with 3 DF (p = 0.0001)
Score	.	.	344.873 with 3 DF (p = 0.0001)

Analysis of Maximum Likelihood Estimates							
Variable	DF	Parameter Estimate	Standard Error	Wald Chi-Square	Pr > Chi-Square	Standardized Estimate	Odds Ratio
INTERCEPT	1	-1.7575	0.1587	122.7106	0.0001	.	.
GENDER	1	0.8661	0.1821	22.6201	0.0001	0.237677	2.378
KEYSCH	1	0.9130	0.2411	14.3335	0.0002	0.170465	2.492
MEANGR	1	0.4245	0.0305	193.8485	0.0001	1.006257	1.529

Association of Predicted Probabilities and Observed Responses			
Concordant	= 86.8%	Somers'D	= 0.737
Discordant	= 13.0%	Gamma	= 0.739
Tied	= 0.2%	Tau-a	= 0.329
(222775 pairs)		c	= 0.869

在默认条件下,输出中“Model Fitting Information and Testing Global Null Hypothesis: BETA = 0”栏目提供四项指标: AIC、SC、-2 Log L、和 Score。前两项是关于模型拟合程度的指标,后两项是零假设检验情况的指标(零假设即所有回归系数均为 0 的假设)。输出在“Analysis of Maximum Likelihood Estimates.”栏目下提供各参数的估计值及其标准误、标准化参数估计值、显著性检验情况以及相应的发生比率(odds ratio)。在“Association of Predicted Probabilities and Observed Responses”栏目中列出了若干关于 logistic 回归模型的评价指标。表 2.5.2 中的模型拟合及评价各项指标的意义将在第 3、4、5 章中分别加以说明。

在 SPSS 中, logistic 回归分析可以用 LOGISTIC REGRESSION 命令或 LOGIT LOGLINEAR ANALYSIS 命令来完成。这两个命令的前者运行的分析过程与 SAS 的 PROC

LOGISTIC 程序过程十分类似；而后者所提供的结果可以像对数线性模型 (Loglinear Model) 那样来解释。在本书中，我们采用 SPSS 的 LOGISTIC REGRESSION 程序来做与 SAS 的 PROC LOGISTIC 程序同样的工作。

微机版的 SPSS 5.0 及后来的新版本均为视窗版。也就是说，绝大部分操作工作可以通过鼠标器点击完成。在视窗版 SPSS 环境下统计分析的基本步骤为：第一，选择数据文件。既可以调用已有的 SPSS 系统文件，也可以输入其他类型的数据文件，如数据库、数据表或 ASCII 格式的文件。第二，从菜单上选择要用的统计程序，然后在对话框中选择要分析的变量或其他统计设置 (SPSS, Inc., 1997a)。

下面是在 SPSS 窗口中将一个 ASCII 数据调入 SPSS 工作数据窗口的步骤：

- 1) 启动 SPSS，于是自动出现一个空的 SPSS 数据编辑窗口。
- 2) 点击主菜单中的 File 命令。
- 3) 点击 File 菜单中的 Read ASCII Data (新版改为 Read Text Data)。
- 4) 点击对话框中的 BROWSE 以选择数据文件 D:\LOGIT\COLLEGE.DAT。
- 5) 定义数据格式：比如自由格式选择 Freefield；或定义每个变量在数据中的具体位置，如第 5 列到第 8 列为变量 GRADE。
- 6) 定义变量：比如四个数值变量（即 GENDER、KEYSCH、GRADE、COLLEGE）。
- 7) 点击 OK 钮或按 ENTER 键，便执行所选择或设置的命令，于是取得的数据便显示在 SPSS 数据窗口中。
- 8) 点击主菜单中的 Transform，再继续点击子菜单中的 Compute，以建立新变量 MEANGR。
- 9) 新变量产生之后，点击主菜单中的 File，然后再选择 Save，便可以将数据窗口中的数据存成 SPSS 系统文件 D:\LOGIT\COLLEGE.SAV。亦可选择 Save As 将数据窗口中的数据另存为别的文件名。SPSS for Windows 的数据文件的扩展名为 SAV (SPSS for Windows 之前的数据文件的扩展名为 SYS)。

在数据读入 SPSS 工作窗口中去后，便可以运行 logistic 回归

分析了, 这时的操作步骤为:

1) 选择 logistic 回归程序:

- 点击主菜单中的 Statistics (新版本改为 Analyze)
- 然后点击 Statistic 菜单中的 Regression
- 再点击 Logistic... (新版本改为 Binary Logistic), 屏幕上便出现 Logistic 回归对话框

2) 设定模型:

- 选择 COLLEGE 作为二分类因变量(Dependent Variable)
- 选择 GENDER、KEYSCH、MEANGR 作为协变量(Covariates)

3) 点击 OK 钮或按 ENTER 键, 运行所选命令

在视窗版 SPSS 中, 上述操作虽然十分简单, 但在本书中我们更愿意采用运行 SPSS 程序命令形式来完成模型估计. 首先, 这样做有利于比较 SPSS 和 SAS 的程序命令. 其次, 这些程序命令可以专门存为一个命令文件, 以后再运行该程序或修改原程序较为方便.

视窗版的 SPSS 能够让我们将在对话框所做的选择和设置方便地通过点击“PASTE”钮而粘到命令编辑窗口(Syntax Window). 在这个窗口中, 前面所做的模型设置都完全以命令程序的格式出现. 并可以将它存为一个 SPSS 程序文件, 以供将来需要时使用. SPSS 的程序文件的扩展名为 SPS.

转入命令窗口(Syntax Window)后, 我们就可以看到对例题数据运行 logistic 回归分析的命令已经存在于这个窗口中了, 它处于前面所选择的数据处理程序之后. 通过在主菜单上点击 FILE, 再点击 Save As, 再指定文件位置和文件名, 比如 D:\LOGIT\LOGIT.SPS, 便可以将这些程序命令存成专门的命令文件. 将这个程序文件存盘以后, 以后就可以随时调用这个文件, 并且可以在命令窗口修改和运行文中的命令.

此外, 所有 SPSS 实际完成的操作所对应的命令还自动存入特定子目录下的名为 SPSS.JNL 的临时文件(如果视窗系统是安装于计算机的 C 盘上, 那么这一文件的默认位置是 C:\WINDOWS\TEMP 子目录). 注意, 每次我们退出 SPSS

系统时，新运行的程序命令便会自动替代这一文件的原有内容或附接在原有内容之后，成为供查询的工作档案。

下列的 SPSS 程序命令中既包括在 Read ASCII Data 窗口选择的对应命令，也包括在 Logistic Regression 对话框选择的对应命令。这些程序命令在我们实际运行之后还会自动存入 C:\WINDOWS\TEMP\SPSS.JNL 文件。

```
* SPSS PROGRAM EXAMPLE 1: LOGISTIC REGRESSION MODEL.
SET UNDEFINED = WARN.
DATA LIST FILE = ' D: \ LOGIT \ COLLEGE.DAT'
/GENDER 1 KEYSCH 3 GRADE 5 - 8 COLLEGE 10.
COMPUTE MEANGR = GRADE - 83.7.
EXECUTE.
SAVE OUTFILE = ' D: \ LOGIT \ COLLEGE.SAV'
/COMPRESSED.

LOGISTIC REGRESSION VAR = COLLEGE
/METHOD = ENTER GENDER KEYSCH MEANGR
/CRITERIA PIN (.05) POUT (.10) ITERATE(20) CUT (.5).
```

在这个程序中，第 2-3 行是将 ASCII 格式文件 COLLEGE.DAT 中的数据读入 SPSS 系统的命令。注意，在 SPSS 程序命令中，是以英文句号（而不是像 SAS 那样以分号）来结束每一命令的。如果一行命令之后接斜线符号“/”所引的子命令时，便不需要句号，但这一命令的全部终了之处仍须用句号表示结束。以上 SPSS 程序中的第 2 行和第 3 行实际上是执行同一命令，而第 1 行的 SET 命令行是要求 SPSS 在读入数字型变量时遇到任何非数字或非空格的情况都显示警告信息。

关于变量的定义是在 DATA 命令中的斜线符号“/”之后。按照默认方式（即没有特别设置的条件下所执行的设置），数据输入时按固定格式（FIXED）处理。所有变量都以默认方式定义为数字型变量，并设置这四个变量分别在文件的第 1、3、5-8、10 列中。当选用“自由格式”读取数据时，在 DATA 命令行中，需使用 FREE LIST 子命令。



当原始数据输入 SPSS 后, SPSS 系统又按照命令将其存成名为 COLLEGE.SAV 的系统文件, 并存于子目录 D:\LOGIT\ 中。

在 LOGISTIC REGRESSION 程序命令中, 子命令 VAR 是变量 VARIABLES 的缩写, 它设置了因变量为 COLLEGE. 还可以以另一种方式定义变量, 即在因变量名之后加命令 WITH, 再加入所有自变量名。下列命令将与前面的变量定义完全等价:

```
LOGISTIC REGRESSION VAR = COLLEGE WITH GENDER KEYSCH MEANGR
/METHOD = ENTER GENDER KEYSCH MEANGR
/CRITERIA PIN(.05) POUT(.10) ITERATE(20) CUT(.5).
```

子命令 METHOD 用来设置自变量如何进入模型。在上述示范程序中的设置方法即为默认方式 ENTER, 这种方式是将所选自变量一次全部纳入模型。子命令 CRITERIA 控制运行回归分析时的统计标准。前两个标准为自动筛选显著自变量的默认方式。标准 PIN 设置自变量自动进入模型时的 F 值对应的概率值为 0.05。标准 POUT 设置自变量自动被排除出模型时的 F 值对应的概率值为 0.10。因为我们设置的自变量纳入方式为强制纳入, 不是逐步纳入或排除方法, 因此实际上这两个标准在此不起作用。

子命令 ITERATE 设置在最大似然估计时最多迭代 20 次。子命令 CUT 设置了计算案例分类表时的概率界限值为 0.5。这一子命令只存在于 SPSS 7.5 或更高版本中, 它在检查 logistic 回归模型的预测准确性时是十分有用的 (我们将在第 3 章讨论这个问题)。以上 SPSS 程序中 CRITERIA 子命令中的统计指标皆为默认值。如果我们认同这些默认值, 我们在编程时则不需要这一子命令。

要是我们在子目录 D:\LOGIT 处已有 SPSS 系统数据文件 COLLEGE.SAV 的话, 我们便可以通过下列步骤来直接提取使用这一文件的数据:

- 1) 启动 SPSS
- 2) 选择数据文件



- 点击主菜单中的 File
- 点击 File 菜单中的 Open
- 点击 Open 子菜单中的 DATA
- 在 Open Data File 窗口中选择文件位置及文件名 D:\ LOGIT \ COLLEGE.SAV
- 点击该窗口的 OK 钮或按 ENTER 键
- 3) 选择 logistic 回归程序
 - 点击主菜单中的 Statistics (或 Analyze)
 - 然后点击 Statistic 菜单中的 Regression
 - 再点击 Logistic... (或 Binary Logistic), 屏幕上便出现 Logistic Regression 对话框
- 4) 设定模型
 - 选择 COLLEGE 作为二分类因变量(Dependent Variable)
 - 选择 GENDER、KEYSCH、MEANGR 作为协变量 (Covariates)
- 5) 点击 OK 钮或按 ENTER 键, 运行所选命令

相应的 SPSS 命令为:

*** SPSS PROGRAM EXAMPLE 2: LOGISTIC REGRESSION MODEL.**

GET

FILE = ' D: \ LOGIT \ COLLEGE.SAV' .

EXECUTE.

LOGISTIC REGRESSION VAR = COLLEGE

/METHOD= ENTER GENDER KEYSCH MEANGR

/CRITERIA PIN (.05) POUT(.10) ITERATE(20) CUT(.5).

这一程序从子目录 D: \ LOGIT 读入 SPSS 系统文件 COLLEGE.SAV 的数据, 其中包括变量 GENDER、KEYSCH、MEANGR、COLLEGE; 然后运行与前面同样的 logistic 回归模型.

运行的输出结果在表 2.5.3 中, 它们与 SAS 的 PROC LOGISTIC 程序得到的结果相同.



表 2.5.3 SPSS 的 LOGISTIC REGRESSION 程序的输出结果

Total number of cases:	1000 (Unweighted)
Number of selected cases:	1000
Number of unselected cases:	0
Number of selected cases:	1000
Number rejected because of missing data:	0
Number of cases included in the analysis:	1000
Dependent Variable Encoding:	
Original Value	Internal Value
.00	0
1.00	1
Dependent Variable: COLLEGE	
Beginning Block Number 0. Initial Log Likelihood Function	
-2 Log Likelihood 1275.3263	
* Constant is included in the model.	
Beginning Block Number 1. Method: Enter	
Variable (s) Entered on Step Number	
1. .	GENDER
	KEYSCH
	MEANGR
Estimation terminated at iteration number 5 because: parameter estimates changed by less than .001	
-2 Log Likelihood	839.965
Goodness of Fit	1417.363
Cox & Snell - R ²	.353

续表

Nagelkerke - R ²		.490					
		Chi-Square	d.f.	Significance			
Model		435.361	3	.0000			
Block		435.361	3	.0000			
Step		435.361	3	.0000			
Classification Table for COLLEGE							
The Cut Value is .50							
		Predicted		Percent Correct			
		.00	1.00				
		0	1				
Observed							
.00	0	589	76	88.57%			
1.00	1	117	218	65.07%			
		Overall		80.70%			
----- Variables in the Equation -----							
Variable	B	S.E.	Wald	d.f.	Sig	R	Exp (B)
GENDER	.8661	.1821	22.6201	1	.0000	.1272	2.3776
KEYSCH	.9130	.2411	14.3335	1	.0002	.0983	2.4917
MEANGR	.4245	.0305	193.8484	1	.0000	.3879	1.5289
Constant	-1.7575	.1587	122.7106	1	.0000		

注：SPSS 输出中的分块(Block)和逐步(Step)回归的卡方统计将在第 6 章中讨论。

2.6 用分组数据作 logistic 回归分析

建立统计模型通常所涉及的是个案数据。然而，看看如何从分组数据来进行 logistic 回归分析也是十分有益的。在本节中，我们讨论以分组数据(grouped data)或交互表(contingency table)来进行 logistic 回归分析。

为了示范目的, 我们从现有的大学升学数据中将所有案例按性别、学校类型、学习成绩进行分组汇总. 学习成绩分为三个档次, 即 GRADE 值小于 80 的为一档次, GRADE 值在 80 至 85 以下的为一档次, GRADE 值大于等于 85 的为一档次. 于是, 汇总成交互组以后形成了汇总水平的 12 个观测案例 (参见表 2.6.1).

表 2.6.1 大学升学的分组数据

GENDER	KEYSCH	GRADE2	n_j	f_j
0	0	1	123	0.0244
0	0	2	181	0.1160
0	0	3	102	0.4216
0	1	1	12	0.0833
0	1	2	20	0.1500
0	1	3	12	0.4167
1	0	1	36	0.0278
1	0	2	197	0.1980
1	0	3	229	0.7205
1	1	1	12	0.0833
1	1	2	35	0.5143
1	1	3	41	0.8537

注: GENDER: 1 - 男生; 0 - 女生

KEYSCH: 1 - 重点高中; 0 - 非重点高中

GRADE2: 1 - ($\text{Grade} < 80$); 2 - ($80 \leq \text{Grade} < 85$); 3 - ($\text{Grade} \geq 85$)

n_j : 第 j 组中的观测频数

f_j : 第 j 组中的大学升学比例

在这套新数据中, 分组 (即 12 个分组观测) 替代单个案例成了分析单位. 每个自变量即 GENDER、KEYSCH、GRADE2 的值对于每个组中的个案是相同的. 升入大学的概率 p_j (即总体中各分组的升学比例) 也假设为对同一分组中的所有人是相同的. 用样本的升学比例或升学相对频数 f_j 来估计 p_j . 并且, 我们还假设:

$$f_j = p_j + \varepsilon_j, \quad 2.6.1$$

其中 ε_j 为残差. f_j 的数学期望为 $E(f_j) = p_j$. 这就是说, 当样

本规模很大时, ϵ_j 会很小, 且 f_j 将十分近似于 p_j . 如果一个组有很大的观测频数, 就有可能计算其结果的相对频数, 并以它作为本组事件发生的概率估计. 随着每个组的样本规模增大, 其观测的相对频数将变为概率真值的很好估计. 为了使组内频数增大, 通常将连续变量分成少数档次. 比如在我们的例子中, 就以这种方法建立了一个分类变量 GRADE2. 当连续变量 GRADE < 80 时, 令 GRADE2 = 1; 当 $80 \leq \text{GRADE} < 85$ 时, 令 GRADE2 = 2; 当 $\text{GRADE} \geq 85$ 时, 令 GRADE2 = 3. 我们可以使用分组数据来计算观测对数发生比(observed log odds), 它是对真实对数发生比的估计. 计算公式如下

$$\ln\left(\frac{f_j}{1-f_j}\right) = \ln\left(\frac{p_j + \epsilon_j}{1-p_j - \epsilon_j}\right). \quad 2.6.2$$

假设对数发生比是性别、高中类型、学生高中分数的函数, 就可以建立下列 logistic 回归模型来分析这一分组数据:

$$\ln\left(\frac{f_j}{1-f_j}\right) = \alpha + \beta_1 \text{GENDER}_j + \beta_2 \text{KEYSCH}_j + \beta_3 \text{GRADE2}_j + \epsilon_j. \quad 2.6.3$$

由于对数发生比可以从分组数据计算, 所以这一 logistic 回归模型可以通过应用 OLS 方法来计算. 这种方法是由 Berkson (1953) 所创造, 并由 Theil (1970) 所发展. 它先将个人数据按自变量进行分组, 然后估计每组的事件概率 f_j , 再将每组的事件概率估计转换成对数发生比, 并将之作为线性回归模型的因变量. 而这个线性回归的自变量全都是分类变量.

请记住公式 2.6.3 所设定的模型具有异方差性(heteroskedastic), 因为每组的残差项依赖于本组的事件发生概率, 还依赖于本组的观测频数. 在这种情况下, 通常采用一般最小二乘法(GLS)来进行数据分析. 这里我们介绍一种变形的 OLS 模型, 它与 GLS 模型相同. 为了运行这种转换的 OLS (transformed OLS) 模型, 模型中所有的原始变量包括常数项都需要加权进行转换. 其权数就是残差项的标准误的倒数. 首先, 我们来看看这一权数是如何从观测信息中计算出来的. 从公式 2.6.2 可以推导出:



$$\begin{aligned}
 \ln\left(\frac{f_j}{1-f_j}\right) &= \ln\left(\frac{p_j + \epsilon_j}{1-p_j - \epsilon_j}\right) \\
 &= \ln\left[\frac{p_j}{1-p_j} \frac{1 + \epsilon_j/p_j}{1 - \epsilon_j/(1-p_j)}\right] \\
 &= \ln\left(\frac{p_j}{1-p_j}\right) + \ln(1 + \epsilon_j/p_j) - \ln\left(1 - \frac{\epsilon_j}{1-p_j}\right).
 \end{aligned} \quad 2.6.4$$

利用泰勒扩展公式:

$$\ln(1+a) = a - a^2/2 + a^3/3 - \dots,$$

有

$$\ln\left(1 + \frac{\epsilon_j}{p_j}\right) = \frac{\epsilon_j}{p_j} - \frac{(\epsilon_j/p_j)^2}{2} + \dots \quad 2.6.5$$

和

$$\ln\left(1 - \frac{\epsilon_j}{1-p_j}\right) = -\frac{\epsilon_j}{1-p_j} - \frac{[-\epsilon_j/(1-p_j)]^2}{2} + \dots \quad 2.6.6$$

当 n_j 很大时, $\epsilon_j = f_j - p_j$ 很小, 所以公式 2.6.5 和公式 2.6.6 中高于一次项的那些项的值很小, 可以省略. 于是有:

$$\begin{aligned}
 \ln\left(\frac{f_j}{1-f_j}\right) &\approx \ln\left(\frac{p_j}{1-p_j}\right) + \frac{\epsilon_j}{p_j} + \frac{\epsilon_j}{1-p_j} \\
 &= a + \beta x_j + \frac{\epsilon_j}{p_j(1-p_j)}.
 \end{aligned} \quad 2.6.7$$

其中, $\epsilon_j/p_j(1-p_j)$ 是模型中的残差项, 其平均值等于 0, 即:

$$E\left(\frac{\epsilon_j}{p_j(1-p_j)}\right) = 0. \quad 2.6.8$$

其方差^①为:

$$\begin{aligned}
 \text{Var}\left(\frac{\epsilon_j}{p_j(1-p_j)}\right) &= \frac{\text{Var}(f_j)}{[p_j(1-p_j)]^2} \\
 &= \frac{1}{[p_j(1-p_j)]^2} \frac{p_j(1-p_j)}{n_j} \\
 &= \frac{1}{n_j p_j(1-p_j)}.
 \end{aligned} \quad 2.6.9$$

① 假设所有观测相互独立及观测频数 f_j 围绕概率 p_j 呈二项分布的条件下, f_j 的期望值为: $E(f_j) = p_j$, 且 f_j 的方差为 $\text{Var}(f_j) = n_j p_j(1-p_j)/n_j^2 = p_j(1-p_j)/n_j$.

$\text{Var}\{\epsilon_j/[p_j(1-p_j)]\}$ 的一致性估计为:

$$S_j^2 = \widehat{\text{Var}}\left(\frac{\epsilon_j}{p_j(1-p_j)}\right) = \frac{1}{n_j f_j(1-f_j)}. \quad 2.6.10$$

由于残差的标准误依赖于 f_j , 而 f_j 又在各组之间变化, 所以关于残差项有相同方差的假设条件不能保持. 这种情况称为异方差性问题. 如果不修正异方差性问题, 参数估计的方差将是有偏的, 那么关于参数估计的显著性假设检验将是无效的. 为了修正异方差性, 就需要在运行 OLS 估计之前转换数据. 数据转换后的 OLS 模型为:

$$\begin{aligned} \left(\frac{1}{S_j}\right) \ln\left(\frac{f_j}{1-f_j}\right) &= \left(\frac{1}{S_j}\right) \alpha^* + \beta_1^* \text{GENDER}_j \left(\frac{1}{S_j}\right) + \beta_2^* \text{KEYSCH}_j \left(\frac{1}{S_j}\right) \\ &+ \beta_3^* \text{GRADE2}_j \left(\frac{1}{S_j}\right) + u_j. \end{aligned} \quad 2.6.11$$

其中 u_j 是转换后的残差项, 它将具有同方差性(homoscedastic). 估计 $\hat{\alpha}^*$ 和 $\hat{\beta}^*$ 即最小二乘估计, 没有受到残差异方差性问题的影响. 这种模型也称为最小 χ^2 估计(minimum chi-square estimation)(Berkson 1953)^①.

需要指出的是, 在 $n_j = 0$ 、 $f_j = 0$ 或 $f_j = 1$ 时, 如何定义权数. 如果分组频数 $n_j = 0$, 就不存在问题, 因为这些组实际上并不会包括在数据中. 对于 $f_j = 0$ 的组而言, 可以用一个很小的正小数, 如 0.0001 赋值于 f_j . 而对于 $f_j = 1$ 的组, 可以用一个十分接近于 1 的正小数, 如 0.9999 赋值于 f_j .

为了更容易地示范转换的 OLS 模型, 我们在表 2.6.2 中列出所有观测指标和转换以后的指标. 第 2-8 列为 12 个组(即分组数据分析的分析单位)的观测指标, 其中第 7 列(即 $\ln\text{odds1}$)是观测对数发生比. 第 8 列中的值是 12 个组的权数. 将第 2、3、4、6 列数据分别乘以第 8 列便得到第 10、11、12、13 列中的转

① 之所以称为最小 χ^2 估计是因为 Berkson (1944) 的最初推导是根据使 χ^2 最小的原则, 它与常规交互表中独立性的 χ^2 检验十分类似. Theil (1970) 将这种估计方法引入社会科学, 但却是按加权最小二乘法的方式推导的. 所以, 这种估计也可以称之为 Berkson-Theil weighted least squares (WLS) 估计.

表 2.6.2 分组的大学升学数据

	OBS	GENDER	KEYSCH	G80	n_j	EVENT	f_j	lnodds1	w_j	GENDERW	KEYSCHW	G80W	lnodds2
1	0	0	0	0	123	3	0.0244	-3.6885	0.5844	0.0000	0.0000	0.0000	-2.1556
2	0	0	0	1	181	21	0.1160	-2.0309	0.2321	0.0000	0.0000	0.2321	-0.4714
3	0	0	0	1	102	43	0.4216	-0.3162	0.2005	0.0000	0.0000	0.2005	-0.0634
4	0	0	1	0	12	1	0.0833	-2.3983	1.0447	0.0000	1.0447	0.0000	2.5054
5	0	0	1	1	20	3	0.1500	-1.7346	0.6262	0.0000	0.6262	0.6262	-1.0863
6	0	0	1	1	12	5	0.4167	-0.3363	0.5855	0.0000	0.5855	0.5855	-0.1969
7	1	0	0	0	36	1	0.0278	-3.5545	1.0138	1.0138	0.0000	0.0000	3.6036
8	1	0	0	1	197	39	0.1980	-1.3988	0.1788	0.1788	0.0000	0.1788	-0.2501
9	1	0	0	1	229	165	0.7205	0.9469	0.1473	0.1473	0.0000	0.1473	0.1394
10	1	1	1	0	12	1	0.0833	-2.3983	1.0447	1.0447	1.0447	0.0000	-2.5054
11	1	1	1	1	35	18	0.5143	0.0572	0.3382	0.3382	0.3382	0.3382	0.0194
12	1	1	1	1	41	35	0.8537	1.7639	0.4419	0.4419	0.4419	0.4419	0.7795

换数据，然后，用公式 2.6.11 对这些转换数据进行转换的 OLS 估计。

用 SAS 软件来运行 OLS 和转换的 OLS 模型的程序命令如下：

```
* SAS PROGRAM WITH GROUPED DATA: OLS AND TRANSFORMED OLS MODELS;
OPTIONS NOCENTER PS = 500 LS = 150;
DATA DATA;
INPUT GENDER KEYSCH GRADE2 N F;
LNODDS1 = LOG(F/(1 - F));
W = (1/(N * F * (1 - F))) ** 0.5;
LNODDS2 = LNODDS1 * W;
GENDERW = GENDER * W;
KEYSCHW = KEYSCH * W;
G80 = 0;
IF GRADE2 > 1 THEN G80 = 1;
G80W = G80 * W;
CARDS;
0 0 1      123      0.0244
0 0 2      181      0.1160
0 0 3      102      0.4216
0 1 1       12      0.0833
0 1 2       20      0.1500
0 1 3       12      0.4167
1 0 1       36      0.0278
1 0 2      197      0.1980
1 0 3      229      0.7205
1 1 1       12      0.0833
1 1 2       35      0.5143
1 1 3       41      0.8537
;

* OLS MODEL;
PROC REG;
MODEL LNODDS1 = GENDER KEYSCH G80;
RUN;
```



```
* TRANSFORMED OLS MODEL;
PROC REG;
MODEL LNODDS2 = W GENDERW KEYSCHW G80W/NOINT;
RUN;
```

由于样本数据规模很小，所以不再读入外部数据文件，而是直接在 SAS 程序中输入数据。对于这种数据输入方式来说，在 SAS 程序中不再使用 INFILE 命令。在定义了变量并完成变量的加工以后，用 CARDS 或 DATALINES (新版 SAS) 命令引导数据行的输入。注意，在数据中变量 N 不是样本规模，而是代表各分组中的案例数，它是二项分布试验的次数 (如对 GENDER = 0, KEYSCH = 0, GRADE2 = 1 的一组，N 的值为 123)。

对于 OLS 方法和转换的 OLS 方法都是用 PROC REGRESSION 程序来运行同一分组数据。分析结果列在表 2.6.3 中。从理论上讲，当样本规模增大时，OLS 系数应该非常接近于参数真值。然而，系数估计的标准误则向上偏差。从结果中可以看到，OLS 的系数估计除性别外其他都十分接近于转换 OLS 的结果。并且，OLS 估计的标准误大于转换 OLS 的标准误。不幸的是，在转换的 OLS 估计中 GENDER 的系数统计性不显著，尽管其方向符号与期望的相同。这种结果在很大程度上是由于在汇总水平上的观测数量太少所致。

需要注意，在运行转换的 OLS 模型时，我们需要取消 (suppress) 截距的影响。因为在转换 OLS 模型中的常数为 $1/S_j$ (即新变量 W) 而不是 1，我们就需要设置 $1/S_j$ 作为新的常数，并要求程序取消默认的截距。结果是， $1/S_j$ 的系数成为模型的截距。在 SAS 的 PROC REG 程序中，备选命令 NOINT 表示取消默认的截距。

运行 OLS 模型和转换 OLS 模型的相应 SPSS 程序如下：

```
* SPSS PROGRAM WITH GROUPED DATA: OLS AND TRANSFORMED OLS MODELS.
DATA LIST FREE /GENDER KEYSCH GRADE2 N F.
BEGIN DATA
```

```

0 0 1      123      0.0244
0 0 2      181      0.1160
0 0 3      102      0.4216
0 1 1       12      0.0833
0 1 2       20      0.1500
0 1 3       12      0.4167
1 0 1       36      0.0278
1 0 2      197      0.1980
1 0 3      229      0.7205
1 1 1       12      0.0833
1 1 2       35      0.5143
1 1 3       41      0.8537

END DATA.

COMPUTE LNODDS1 = LN (F/(1 - F)).
COMPUTE W = (1/(N * F * (1 - F))) * 0.5 .
COMPUTE LNODDS2 = LNODDS1 * W.
COMPUTE GENDERW = GENDER * W.
COMPUTE KEYSCHW = KEYSCH * W.
COMPUTE G80 = 0.
IF (GRADE2 > 1) G80 = 1.
COMPUTE G80W = G80 * W.
REGRESSION
/DEPENDENT LNODDS1
/METHOD = ENTER GENDER KEYSCH G80
REGRESSION
/ORIGIN
/DEPENDENT LNODDS2
/METHOD = ENTER W GENDERW KEYSCHW G80W.

```

在这个 SPSS 程序中，也是直接输入分析数据，因此用不着使用 FILE 子命令。所有数据在命令 BEGIN 和命令 END DATA 之间加以输入。在数据的结尾不用加入句号。

同样，对于转换的 OLS 模型，需要取消截距。在 SPSS 中，ORIGIN 和 NOORIGIN 两个子命令分别控制要不要模型中的截距。默认方式为 NOORIGIN，所以模型中包括截距。如果加入子命令 ORIGIN，便表示要求回归线通过原点，即截距被取消。



以上所讨论的 SAS 和 SPSS 的程序输出了同样的结果 (参见表 2.6.3).

表 2.6.3 关于 OLS 模型和转换的 OLS 模型的输出

SAS 输出:

(OLS 模型)

Dependent Variable: LNODDS1

Analysis of Variance

Source	DF	Sum of Squares	Mean Square	F Value	Prob>F
Model	3	23.42979	7.80993	7.218	0.0115
Error	8	8.65645	1.08206		
C Total	11	32.08623			

Root MSE	1.04022	R-square	0.7302
Dep Mean	-1.25737	Adj R-sq	0.6290
C.V.	-82.72979		

Parameter Estimates

Variable	DF	Parameter Estimate	Standard Error	T for H0: Parameter = 0	Prob > T
INTERCEP	1	-3.919640	0.67145850	-5.838	0.0004
GENDER	1	0.986866	0.60057074	1.643	0.1390
KEYSCH	1	0.832584	0.60057074	1.386	0.2031
G80	1	2.628818	0.63700147	4.127	0.0033

(转换的 OLS 模型)

NOTE: No intercept in model. R-square is redefined.

Dependent Variable: LNODDS2

Analysis of Variance

Source	DF	Sum of Squares	Mean Square	F Value	Prob>F
Model	4	30.74086	7.68521	38.900	0.0001
Error	8	1.58050	0.19756		
U Total	12	32.32136			

Root MSE	0.44448	R-square	0.9511
Dep Mean	-0.99165	Adj R-sq	0.9267

续表

C. V. -44.82229

Parameter Estimates

Variable	DF	Parameter	Standard	T for H0:	
		Estimate	Error	Parameter = 0	Prob > T
W	1	-3.907484	0.48321345	-8.086	0.0001
GENDERW	1	0.504038	0.43215907	1.166	0.2771
KEYSCHW	1	1.220263	0.46156092	2.644	0.0295
G80W	1	2.189316	0.49533006	4.420	0.0022

SPSS 输出:

(OLS 模型)

ANOVA

Model	Sum of Squares	d.f.	Mean Square	F	Sig.
Regression	23.430	3	7.810	7.218	.012
Residual	8.656	8	1.082		
Total	32.086	11			

a Predictors: (Constant), G80, KEYSCH, GENDER

b Dependent Variable: LNODDS1

Coefficients

Model	Unstandardized Coefficients		Standardized Coefficients	t	Sig.
	B	Std. Error	Beta		
(Constant)	-3.920	.671	-5.838	.000	
GENDER	.987	.601	.302	1.643	.139
KEYSCH	.833	.601	.255	1.386	.203
G80	2.629	.637	.758	4.127	.003

a Dependent Variable: LNODDS1

(转换的 OLS 模型)

ANOVA

Model	Sum of Squares	d.f.	Mean Square	F	Sig.
Regression	30.749	4	7.687	39.119	.000
Residual	1.572	8	.197		
Total	32.321	12			



续表

- a Predictors: (Constant), G80, KEYSCH, GENDER
 b This total sum of squares is not corrected for constant because the constant is zero for regression through origin
 c Dependent Variable: LNODDS2
 d Linear Regression through the Origin

Model	Coefficients				
	Unstandardized		Standardized	t	Sig.
	Coefficients		Coefficients		
	B	Std. Error	Beta		
(Constant)	-3.907	.483	-1.497	8.086	.000
GENDER	.504	.432	.140	1.166	.277
KEYSCH	1.220	.462	.386	2.644	.030
G80	2.189	.495	.421	4.420	.002

a Dependent Variable: LNODDS2

b Linear Regression through the Origin

必须指出, 转换的 OLS 模型有一些潜在的问题. 首先, 汇总的分析单位的数量(即分组数)如果不够大将不能保证在零假设实际为假时有拒绝零假设的足够的统计功效. 在本例题中, 我们可以看到变量 GENDER 的系数在转换的 OLS 模型中变得不显著了. 其次, 各组内案例的观测频数如果不够大则会导致一个有偏的本组事件发生概率真值的估计 f_j . 而 f_j 是计算权数 S_j 的基础, 所以它是转换的 OLS 估计程序的关键. 如果各组中的个案观测数量过少, 将会导致参数估计的无效性(inefficiency). 最后, 第 j 组的事件发生概率 p_j 是被假设为对本组所有案例是同样的, 这就是说假设 $p_{ij} = p_j$, 但是实际上经常并不是这样. 同组不同案例之间概率 p_{ij} 的差别将会导致转换的 OLS 模型的权数出现误差. 同组不同概率的问题不仅将造成估计的无效性, 还会导致估计发生偏差(Hanushek & Jackson, 1977).

上述这些问题如果从准确估计自变量影响的角度来说可能不是小问题. 不过, 我们可以利用分组汇总数据通过 SAS 及 SPSS 程序来运行微观水平的 logistic 回归模型. 在下列的 SAS 程序中,

我们来示范如何应用分组数据来进行个案水平上的 logistic 回归分析.

```
* SAS PROGRAM: LOGISTIC REGRESSION MODEL USING GROUPED DATA;
OPTIONS NOCENTER PS = 500 LS = 150;
DATA DATA1;
INPUT GENDER KEYSCH GRADE2 N EVENT;
G80 = 0;
IF GRADE2 > 1 THEN G80 = 1;
CARDS;
0 0 1 123 3
0 0 2 181 21
0 0 3 102 43
0 1 1 12 1
0 1 2 20 3
0 1 3 12 5
1 0 1 36 1
1 0 2 197 39
1 0 3 229 165
1 1 1 12 1
1 1 2 35 18
1 1 3 41 35
;
PROC LOGISTIC DESCENDING;
MODEL EVENT / N = GENDER KEYSCH G80;
RUN;
```

在以上的 SAS 程序中, 代表各分组相对频数的变量不再需要了, 而一新变量 EVENT 代表相应子分组中事件发生的数量. 在上面的程序中输入了 12 条观测(数据行), 并且进行了内部的加权. 作为结果, 这一分析还是基于 1000 个案例(335 个发生了事件, 665 个未发生事件)(参见表 2.6.4 的上部).

我们还可以在运行 SAS 和 SPSS 的 logistic 回归之前进行数据加权而得到同样的结果. 在加权时, 我们先要根据分组数据计算一个交互表(contingency table). 换句话说, 我们需要一个按



自变量分类的二分类反应变量 y_j 的频数表. 比如, 在 (GENDER = 0、KEYSCH = 0、GRADE2 = 1) 的分组中有 3 个 $y_j = 1$ 的案例和 120 个 $y_j = 0$ 的案例. 我们还要计算出一个变量 WEIGHT, 它实际上就是这一组的案例数据中那些 $y_j = 1$ 或 $y_j = 0$ 的频数. 然后用变量 WEIGHT 为相应的案例加权. 这样一来就使得分析重新回到微观水平上. 在以下的 SAS 和 SPSS 程序中, 分组数据是由先前的分组数据中产生出来的一个数据交互表.

*** SAS PROGRAM: LOGISTIC REGRESSION MODEL USING WEIGHTED DATA;**

OPTIONS NOCENTER PS = 500 LS = 150;

DATA DATA1;

INPUT GENDER KEYSCH GRADE2 WEIGHT Y;

G80 = 0;

IF GRADE2 > 1 THEN G80 = 1;

CARDS;

0	0	1	3	1
0	0	1	120	0
0	0	2	21	1
0	0	2	160	0
0	0	3	43	1
0	0	3	59	0
0	1	1	1	1
0	1	1	11	0
0	1	2	3	1
0	1	2	17	0
0	1	3	5	1
0	1	3	7	0
1	0	1	1	1
1	0	1	35	0
1	0	2	39	1
1	0	2	158	0
1	0	3	165	1
1	0	3	64	0
1	1	1	1	1
1	1	1	11	0
1	1	2	18	1

```

1  1  2      17      0
1  1  3      35      1
1  1  3       6      0

```

```
;
```

```
PROC LOGISTIC DESCENDING;
```

```
FREQ WEIGHT;
```

```
MODEL Y = GENDER KEYSCH G80;
```

```
RUN;
```

```
* SPSS PROGRAM: LOGISTIC REGRESSION MODEL USING WEIGHTED DATA.
```

```
DATA LIST FREE /GENDER KEYSCH GRADE2 WEIGHT Y.
```

```
BEGIN DATA
```

```

0  0  1       3       1
0  0  1     120       0
0  0  2      21       1
0  0  2    160       0
0  0  3      43       1
0  0  3      59       0
0  1  1       1       1
0  1  1     11       0
0  1  2       3       1
0  1  2     17       0
0  1  3       5       1
0  1  3       7       0
1  0  1       1       1
1  0  1     35       0
1  0  2     39       1
1  0  2    158       0
1  0  3    165       1
1  0  3     64       0
1  1  1       1       1
1  1  1     11       0
1  1  2     18       1
1  1  2     17       0
1  1  3     35       1
1  1  3       6       0

```



```

END DATA.
WEIGHT BY WEIGHT.
COMPUTE G80 = 0.
IF (GRADE2 > 1) G80 = 1.
LOGISTIC REGRESSION VAR = Y
/METHOD = ENTER GENDER KEYSCH G80
/CRITERIA PIN (.05) POUT (.10) ITERATE (20) CUT (.5) .

```

注意 SAS 程序和 SPSS 程序之间在加权上的差别。在 SAS 中，加权是在执行 PROC LOGISTIC REGRESSION 程序时以命令 FREQ 完成的；而在 SPSS 中，加权是在数据被读入系统之后通过命令 WEIGHT 所完成的。SAS 模型和 SPSS 模型的结果都列在表 2.6.4 中。我们看到，所有的回归系数现在都取得了统计性显著的结果。

表 2.6.4 应用分组数据的 logistic 回归输出

SAS 输出 (应用分组数据):

The LOGISTIC Procedure

Data Set: WORK.DAT1

Response Variable (Events): EVENT

Response Variable (Trials): N

Number of Observations: 12

Link Function: Logit

Response Profile

Ordered Value	Binary Outcome	Count
1	EVENT	335
2	NO EVENT	665

Model Fitting Information and Testing Global Null Hypothesis BETA = 0

Criterion	Intercept and		Chi-Square for Covariates
	Intercept Only	Covariates	
AIC	1277.326	1084.911	.
SC	1282.234	1104.542	.

续表

- 2 LOG L	1275.326	1076.911	198.415 with 3 DF (p=0.0001)				
Score	.	.	160.647 with 3 DF (p=0.0001)				
Analysis of Maximum Likelihood Estimates							
Variable	DF	Parameter Estimate	Standard Error	Wald Chi-Square	Pr > Chi-Square	Standardized Estimate	Odds Ratio
INTERCPT	1	-4.0075	0.4322	85.9877	0.0001	.	.
GENDER	1	1.2080	0.1585	58.0653	0.0001	0.331507	3.347
KEYSCH	1	0.7035	0.2116	11.0583	0.0009	0.131361	2.021
G80	1	2.7329	0.4277	40.8264	0.0001	0.582888	15.377
Association of Predicted Probabilities and Observed Responses							
Concordant = 60.4%		Somers' D = 0.483					
Discordant = 12.1%		Gamma = 0.666					
Tied = 27.4%		Tau-a = 0.215					
(222775 pairs)		c = 0.741					

SAS 输出 (LOGISTIC 回归应用于加权数据)

The LOGISTIC Procedure

Datz Set: WORK.DATA1

Response Variable: Y

Response Levels: 2

Number of Observations: 24

Frequency Variable: WEIGHT

Link Function: Logit

Response Profile

Ordered Value	Y	Count
1	1	335
2	0	665

Model Fitting Information and Testing Global Null Hypothesis $BETA = 0$

Criterion	Intercept Only	Intercept and Covariates	Chi-Square for Covariates
-----------	-------------------	--------------------------------	---------------------------



续表

AIC	1277.326	1084.911	.
SC	1282.234	1104.542	.
- 2 LOG L	1275.326	1076.911	198.415 with 3 DF (p=0.0001)
Score	.	.	160.647 with 3 DF (p=0.0001)

Analysis of Maximum Likelihood Estimates						
Variable	DF	Parameter Estimate	Standard Error	Wald Chi-Square	Pr > Chi-Square	Standardized Odds Ratio
INTERCPT	1	-4.0075	0.4322	85.9877	0.0001	.
GENDER	1	1.2080	0.1585	58.0653	0.0001	0.331507
KEYSCH	1	0.7035	0.2116	11.0583	0.0009	0.131361
G80	1	2.7329	0.4277	40.8264	0.0001	0.582888

Association of Predicted Probabilities and Observed Responses		
Concordant	= 60.4 %	Somers' D = 0.483
Discordant	= 12.1 %	Gamma = 0.666
Tied	= 27.4 %	Tau-a = 0.215
(222775 pairs)		c = 0.741

SPSS 输出 (LOGISTIC 回归应用于加权数据)

Total number of cases: 24 (Unweighted)
 Number of selected cases: 24
 Number of unselected cases: 0

Number of selected cases: 24
 Number rejected because of missing data: 0
 Number of cases included in the analysis: 24

Dependent Variable Encoding:

Original Value	Internal Value
.00	0
1.00	1

Dependent Variable: Y

续表

Beginning Block Number 0. Initial Log Likelihood Function

- 2 Log Likelihood 1275.3263

* Constant is included in the model.

Beginning Block Number 1. Method: Enter

Variable (s) Entered on Step Number

1. GENDER
KEYSCH
G80

Estimation terminated at iteration number 5 because
Log Likelihood decreased by less than .01 percent.

- 2 Log Likelihood	1076 .911
Goodness of Fit	1038 .009
Cox & Snell - R ²	.180
Nagelkerke - R ²	.250

	Chi-Square	d.f.	Significance
Model	198.415	3	.0000
Block	198.415	3	.0000
Step	198.415	3	.0000

Classification Table for Y

The Cut Value is .50

		Predicted		Percent Correct
		.00 0	1.00 1	
Observed	.00 0	642	23	96.54%
	1.00 1	282	53	15.82%
Overall				69.50%

续表

Variables in the Equation							
Variable	B	S.E.	Wald	d.f.	Sig.	R	Exp (B)
GENDER	1.2080	.1585	58.0654	1	.0000	.2097	3.3469
KEYSCH	.7035	.2116	11.0583	1	.0009	.0843	2.0209
G80	2.7328	.4277	40.8257	1	.0000	.1745	15.3756
Constant	-4.0074	.4322	85.9883	1	.0000		

最后，我们来介绍另一种能够从分组数据产生微观数据的方法。从分组数据中产生的微观数据可以被存成为一个新的文件，以便用于其他微观统计分析。下面的 SAS 程序便能够完成这一工作。

*** SAS PROGRAM: GENERATING MICRO DATA FROM MACRO DATA;**

OPTIONS NOCENTER PS = 500 LS = 150;

LIBNAME LIB ' D: \ LOGIT';

DATA DATA1;

INPUT GENDER KEYSCH GRADE2 WEIGHT EVENT;

DO I = 1 TO EVENT;

Y = 1;

OUTPUT;

END;

DO I = 1 TO WEIGHT - EVENT;

Y = 0;

OUTPUT;

END;

CARDS;

0	0	1	123	3
0	0	2	181	21
0	0	3	102	43
0	1	1	12	1
0	1	2	20	3
0	1	3	12	5

```

1    0    1        36        1
1    0    2       197       39
1    0    3       229      165
1    1    1        12        1
1    1    2        35       18
1    1    3        41       35
;

DATA LIB.NEWDATA;
    SET DATA1;
    G80 = 0;
    IF GRADE2 > 1 THEN G80 = 1;

PROC LOGISTIC DESCENDING;
MODEL Y = GENDER KEYSCH G80;
RUN;

```

在上面的程序中，使用 SAS 的 DO 命令通过循环处理产生了一个二分类变量 y。通过循环处理，从分组数据中再产生出微观数据，先将其存为 SAS 的临时系统数据文件，文件名为 DATA1。然后，再通过第二步 DATA 程序提取临时统计数据文件 DATA1，并完成一些数据处理后将其在子目录 D:\LOGIT 中存为永久性的 SAS 数据文件 NEWDATA.SD2。在这个新文件中所有的变量，也包括新的虚拟变量 G80，都是在个体水平上的测量。除了分类变量 G80 及 GRADE2 以外，这一套新的 SAS 数据与我们的原始数据文件 COLLEGE.SD2 的内容完全相同。注意，这种循环方法只能在个体水平上产生分类变量，因为分组数据所提供的信息只局限于分类变量。使用这套微观数据文件 NEWDATA 的 logistic 回归结果与表 2.6.4 中所列的结果相同。SPSS 也可做同样的工作，其程序如下：

```

* SPSS PROGRAM: GENERATING MICRO DATA FROM MACRO DATA.
DATA LIST FREE /GENDER KEYSCH GRADE2 WEIGHT Y.
BEGIN DATA
0    0    1        3        1

```



0	0	1	120	0
0	0	2	21	1
0	0	2	160	0
0	0	3	43	1
0	0	3	59	0
0	1	1	1	1
0	1	1	11	0
0	1	2	3	1
0	1	2	17	0
0	1	3	5	1
0	1	3	7	0
1	0	1	1	1
1	0	1	35	0
1	0	2	39	1
1	0	2	158	0
1	0	3	165	1
1	0	3	64	0
1	1	1	1	1
1	1	1	11	0
1	1	2	18	1
1	1	2	17	0
1	1	3	35	1
1	1	3	6	0

END DATA.

SORT CASES BY WEIGHT.

LOOP #W = 1 TO WEIGHT.

XSAVE OUTFILE = ' NEWDATA'

/KEEP GENDER KEYSCH GRADE2 WEIGHT Y.

END LOOP.

EXE.

GET FILE ' NEWDATA' .

COMPUTE G80 = 0.

IF (GRADE2 > 1) G80 = 1.

LOGISTIC REGRESSION VAR = Y

/METHOD = ENTER GENDER KEYSCH G80

/CRITERIA PIN(.05) POUT(.10) ITERATE(20) CUT(.5).

由上面的 SPSS 程序所产生的数据文件 NEWDATA 是一个微观水平的 SPSS 系统文件，其中包括 1000 个案例。应用这套产生数据进行分析的结果与表 2.6.4 中的结果相同。一旦这一程序运行完毕，所产生的微观数据便显示在 SPSS 的数据窗口。然后，我们可以将其在子目录 D:\LOGIT 中存为 SPSS 的永久性数据文件。

注意，在以上 SAS 和 SPSS 程序中，所输入的分组数据的格式不同。在 SAS 程序中，每一行数据即每一分组的全部数据；在 SPSS 程序中，每一行数据则是一个分组数据中 $y=1$ 或 $y=0$ 的数据。

Logistic 回归模型 评价



• 3.1	拟合优度 (Goodness of fit)	(58)
3.1.1	皮尔逊 χ^2 (Pearson χ^2)	(58)
3.1.2	偏差 (Deviance)	(62)
3.1.3	Hosmer-Lemeshow 拟合优度指标	(65)
3.1.4	信息测量指标 (Information Measures)	(67)
• 3.2	Logistic 回归模型的预测准确性	(72)
3.2.1	类 R^2 指标 (Analogous R^2)	(72)
3.2.2	预测概率与观测值之间的关联	(75)
3.2.3	分类表 (Classification Table)	(80)
• 3.3	模型 χ^2 统计 (Model Chi-Square Statistic)	(88)

在模型估计以后, 需要考虑模型的适当性(adequacy). 这一章讨论与此有关的一些问题, 如模型的拟合优度(goodness of fit), 预测准确性(predictive accuracy)和模型的 χ^2 (model chi-square statistic) 检验.

3.1 拟合优度(Goodness of fit)

模型估计完成以后, 我们需要评价模型如何有效地描述反应变量及模型匹配观测数据的程度. 如果模型的预测值能够与对应的观测值有较高的一致性, 就认为这一模型拟合数据. 否则, 将不能接受这一模型, 而需要对模型重新设置. 从这一点上说, 模型的适当性指的是拟合优度. 不过, 在评价模型时, 我们实际所需要测量的是模型预测值与实际观测值之间的差别. 换句话说, 我们实际上检验的是模型预测的“劣度”, 而不是“优度”, 即拟合不佳检验(lack of fit test). 不过, 在统计分析中, 人们还是习惯地称其为拟合优度检验. 有许多方法可以对 logistic 回归模型的拟合优度进行评价. 我们将从一些拟合优度的概要指标入手, 因为它们提供的是 logistic 回归模型的整体检验指标.

3.1.1 皮尔逊 χ^2 (Pearson χ^2)

在开始讨论具体拟合优度统计指标之前, 我们先来介绍一下协变类型(covariate pattern)的概念. 这一概念又称为子总体(subpopulations). 协变类型描述的是模型中协变量(covariate)不同值的特定组合. 对于一个含有分类自变量的模型来说, 数据所含的协变类型的数目由每个分类自变量的情况所决定. 如果模型只包括两个分类变量(比如性别和重点大学), 那么 logistic 回归模型为:

$$\ln [p/(1-p)] = \alpha + \beta_1 \text{GENDER} + \beta_2 \text{KEYSCH}. \quad 3.1.1$$

由于性别(GENDER)和重点大学(KEYSCH)都是二分类变量, 因此模型中只有 4 种(即 2×2)可能的协变类型组合. 换句话说, 协变类型或子总体为 4 个, 也就是说两个分类变量之间只有 4 种特定值的组合, 每个案例都可以被归入这 4 个协变类型之

一中(参见表 3.1.1). 以 n 来表示样本规模, j 表示协变类型的数目, n_j 表示在第 j 个协变类型中的案例数. 显然, j 小于样本规模 n , 且 $\sum n_j = n$.

表 3.1.1 按协变类型划分的观测值和预测值

协变量	n_j	观测结果		预测结果	
		是	否	是	否
重点大学					
男性	88	54	34	51.91	36.09
女性	44	9	35	11.09	32.91
非重点大学					
男性	462	205	257	207.09	254.91
女性	406	67	339	64.91	341.09

在固定样本规模 n 情况下, 协变类型越多, 每个类型(即每个子总体)中的案例数 n_j 就越少. 在每个协变类型中, 预测的事件发生频数表示为 $n_j \times \hat{p}_j$, 其中 $\hat{p}_j$ 是第 j 种协变类型中事件发生的模型预测概率. 与此类似, 我们也可以计算每种协变类型中事件未发生的频数. 皮尔逊 χ^2 (Pearson chi-square)可以用来通过比较模型预测的和观测的事件发生和不发生的频数检验模型成立的假设.

表 3.1.1 显示了按协变类型划分的事件发生和不发生的观测结果和预测结果. 对事件发生(即“是”)的预测值为这一模式中所有案例的预测概率 $\hat{p}_j$ 之和(参见式 2.2.6); 对事件不发生(即“否”)的预测值为这些案例的事件不发生的概率 $1 - \hat{p}_j$ 的和. 将观测频数和预测频数代入标准 χ^2 统计量计算公式, 有:

$$\chi^2 = \sum_{j=1}^J \frac{O_j - E_j}{E_j} = 0.85, \quad 3.1.2$$

其中, $j=1, 2, \dots, J$, 且 J 是协变类型的种类数目, O_j 和 E_j 分别为第 j 类协变类型中的观测频数和预测频数. χ^2 统计量可以方便地得到. 即式 3.1.1 所示的 logistic 回归模型有 3 个系数(即截距和对应变量 GENDER 和 KEYSCH 的 2 个回归系数); χ^2 的自由度(d.f.)是协变类型数目与参数数目之差(本例中即 $4 - 3 = 1$). χ^2 统计量要是很小就意味着预测值与观测值之间没有显著差别, 表示这一模型很好地拟合了数据. 与此相反, 如果

χ^2 统计量很大, 统计检验就显著, 于是提供了拟合不佳的证据. 当拟合不好时, 可以用残差和其他诊断测量来描述每个案例对模型拟合的影响, 以便寻找模型不合理的原因. 我们将在第 7 章专门讨论这方面的问题.

SAS 的 PROC LOGISTIC 程序中如果设置了 AGGREGATE 和 SCALE 两个备选方式 (在 SAS 的 6.10 版中开始提供), 便可以输出皮尔逊 χ^2 值. 备选方式 AGGREGATE 用来设置协变类型, 在此基础上才能够计算皮尔逊 χ^2 和偏差 (deviance) 统计量. 由于偏差和皮尔逊 χ^2 统计量只有在选择备选方式 SCALE 时才计算, 所以 AGGREGATE 方式必须与 SCALE 方式同时设置. 下面是用 SAS 软件分析示范模型的命令:

```
PROC LOGISTIC DESCENDING;
MODEL COLLEGE = GENDER KEYSCH /SCALE = NONE AGGREGATE;
RUN;
```

其中, AGGREGATE 以默认设置形式运行, 它相当于设置了 AGGREGATE = (KEYSCH GENDER), 即列出所有自变量. SCALE 命令可以用来进行过离散情况的修正, 这个问题将在第 7 章讨论. 设置备选方式 SCALE = none 表示对过离散情况不做调整.

SCALE 和 AGRREGATE 备选命令产生两个拟合优度统计指标, 皮尔逊 χ^2 和 deviance (偏差). 在输出结果中 (见表 3.1.2), 统计指标 Pearson 便是 χ^2 . 在表 3.1.2 下方的注释 “number of unique profiles: 4” 表示拟合优度统计是按照 4 类协变类型计算的. χ^2 值等于 0.8495, d.f. = 1. 这与根据式 3.1.2 计算的这一统计量相等. χ^2 检验不显著说明这一模型充分拟合了数据. 另一项拟合优度指标 deviance 得到与皮尔逊 χ^2 很近似的值. 我们将在下一节中讨论 deviance 统计量.

表 3.1.2 SAS 的 LOGISTIC 命令输出的 χ^2 和偏差统计量

Criterion	DF	Value	Value/DF	Pr >
				Chi-Square
Deviance	1	0.874 7	0.874 7	0.349 6
Pearson	1	0.849 5	0.849 5	0.356 7
Number of unique profiles: 4				

SPSS 软件的 LOGISTIC REGRESSION 程序以默认设置提供一个“goodness of fit”统计指标,它在输出中位于“-2 Log Likelihood”指标之后(参见输出表 3.1.3)。在 SPSS 手册中(SPSS Inc., 1997b),“goodness of fit”指标被称为 Z^2 统计量,定义为:

$$Z^2 = \sum_{i=1}^N \frac{\text{residual}_i^2}{\hat{p}_i(1-\hat{p}_i)} \quad 3.1.3$$

其中残差(residual)是指皮尔逊残差(Pearson residual),它是观测值 y_i 与预测值 $\hat{p}_i$ 之差。实际上,这一统计量是在案例基础上形成的 χ^2 值(参见尾注 1)。SPSS 的 LOGISTIC 程序所提供的 Z^2 统计量对于拟合优度的评价其实没有什么功效。在实际应用中,研究人员经常发现 Z^2 统计量表明自己的模型不能拟合数据,其实并不如此。

在表 3.1.3 中,SPSS 对我们的示范模型所输出“goodness of fit”统计量为 $Z^2 = 1002.606$ 。它比从表 3.1.2 中计算所得到的值大得多,因为它们是两个不同的统计量。注意, Z^2 的自由度为样本规模与系数个数之间的差(对于本例有 $n - k - 1 = 1000 - 2 - 1 = 997$, k 为包括在模型中的自变量数。)(SPSS Inc., 1990: B46 页)。这一统计值经统计检验显著,便给出了一个使人误解的模型拟合的结论。作者注意到,在 SPSS for Windows 10.0 版本中,这一错误的统计量已不再打印输出。尽管如此,我们认为仍有必要在这里指出这个问题。因为,SPSS 用户过去在这个问题上可能被误导,而且,不少 SPSS 用户仍然在使用旧版的 SPSS,因此澄清这个问题对更好地理解 and 运用 logistic 回归模型是有帮助的。

表 3.1.3 SPSS 的 LOGISTIC 程序所输出的 Z^2 统计量

-2 Log Likelihood	1 161.172
Goodness of Fit	1 002.606
Cox & Snell - R ²	.108
Nagelkerke - R ²	.150

3.1.2 偏差 (Deviance)

观测值与预测值的比较还可以根据对数似然函数 (log likelihood function) 表示. 所谓“似然” (likelihood) 即在一定参数估计条件下得到该观测结果的概率. 以 $\hat{L}_s$ 作为设定模型所估计的最大似然值, 它概括了样本数据由这一模型所拟合的程度. 但是, 由于这一统计量不能独立于样本规模, 因此不能仅根据它的值来估计模型的拟合优度. 对于同一套数据我们还必须有一个基准模型作为比较所设模型拟合优度的标准. 一种基准模型是饱和模型 (full or saturated model), 它可以“完美地预测”观测值. 饱和模型的最大似然值被标注为 $\hat{L}_f$. 饱和模型并不能提供比实际观测更多的概要统计, 然而, 通过比较 $\hat{L}_s$ 与 $\hat{L}_f$, 便可以估价所设模型代表数据的充分程度.

在似然函数的基础上, 比较 $\hat{L}_s$ 与 $\hat{L}_f$ 实际上就是比较预测值和观测值. 通常采用 -2 乘以设定模型和饱和模型之间最大似然值之比的对数:

$$D = -2 \ln \left(\frac{\hat{L}_s}{\hat{L}_f} \right) = -2 (\ln \hat{L}_s - \ln \hat{L}_f). \quad 3.1.4$$

在公式 3.1.4 的括号中的数量就是似然比 (likelihood ratio, 记为 L.R.). -2 乘以似然比 L.R. 的自然对数形成一个统计量, 当样本规模足够大时, 它服从 χ^2 分布, 其自由度等于所设模型中协变类型个数减去系数个数所得之差. D 统计量被称为偏差 (deviance), 通过似然函数测量所设模型与饱和模型之间的差异程度 (Hosmer & Lemeshow, 1989; Collett, 1991; Agresti, 1996). 当 $\hat{L}_s$ 值相对于 $\hat{L}_f$ 值较小时, 就会有较大的 D 值, 表示所设模型拟合很差. 与此相反, 当 $\hat{L}_s$ 值近似于 $\hat{L}_f$ 值时, D 值就会很小, 表示所设模型拟合很好. 这一特点正像 χ^2 值. 由于饱和模型的似然函数代表了完美拟合, 而 D 统计量, 即设定模型与饱和模型的似然函数之差, 就可以视为类似于线性回归中的残差平方和或误差平方和 (residual sum of squares; 或 error sum of squares, 缩写为 ESS). 这一重要概念在后面章节中将要用来测量类确定系数 (analogous R^2).

D 统计量和皮尔逊 χ^2 统计量有着同样的渐近 χ^2 分布. 然而, 这两个统计量的值一般有所不同. 模型的最大似然估计使所设

立的模型取得最大的似然函数, 作为拟合优度指标的偏差通过这些估计便取得其最小值. 就这点而言, 当用最大似然值来拟合 logistic 回归模型时, 偏差比皮尔逊 χ^2 更适用于测量拟合优度. 在输出表 3.1.2 中, D 和 χ^2 的值非常接近, 并通常导致同样的结论.

有时, D 值与 χ^2 值差别很大. 这种情况可被视为这两个统计量对于 χ^2 分布的近似程度不够充分的表现. 这可能是由于样本规模太小 (Agresti, 1990; Clogg & Eliason, 1988). 关于 D 统计量和 χ^2 统计量近似于 χ^2 分布在样本方面的要求包括 (Stokes, Davis, & Koch, 1995, p.169):

- 每一协变类型中至少有 10 例观测 (即 $n_j \geq 10$);
- 80% 的协变类型要有 5 个以上预测事件数 (predicted number of events);
- 在余下的协变类型中, 预测事件数应大于 2.

从这些要求来看, 我们可以清楚地理解, 当在建立模型中涉及连续型自变量时, D 和皮尔逊 χ^2 不适合用来检验模型拟合优度, 因为这时有些协变量 (即连续型自变量) 有过多的不同值, 导致大量的协变类型存在. 在样本规模固定为 n 时, 大量的协变类型意味着每种协变类型中只能有少数案例.

SPSS 的 LOGISTIC 回归程序不输出 D 统计量, 而只输出 “-2 log likelihood”. 它可以被看成是在案例基础上 (即协变类型的数量等于样本规模 n 时, 换句话说, 每种协变类型只有一个案例时) 的 D 统计量. 然而, 在这种情况下, D 统计量不能告诉我们观测值与其相应预测概率之间的吻合程度. 因此, 这个 D 统计量不能作为一个模型拟合优度的概要性量度 (Collett, 1991).

虽然 SAS 软件的 PROC LOGISTIC 程序提供了 D 统计量, 但我们经常看到在模型包括连续变量时, D 与皮尔逊 χ^2 之间有很大的差异. 如果我们将连续变量 MEANGR 纳入模型, 那么相应的 SAS 和 SPSS 的程序如下:

SAS 程序

.....

```
PROC LOGISTIC DESCENDING;
```

```
MODEL COLLEGE = GENDER KEYSCH MEANGR
```

```
/SCALE = NONE AGGREGATE;
```

```
RUN;
```

SPSS 程序

```
.....
```

```
LOGISTIC REGRESSION VAR = COLLEGE
```

```
/METHOD = ENTER GENDER KEYSCH MEANGR.
```

以上 SAS 和 SPSS 的 logistic 回归程序的部分结果列在输出表 3.1.4 中。请注意，SAS 与 SPSS 的输出中有不同的 D 值。这是因为 SAS 的 PROC LOGISTIC 程序是在协变类型的基础上计算 D 和皮尔逊 χ^2 统计量，而 SPSS 的 LOGISTIC REGRESSION 程序是在案例的基础上进行计算。在连续自变量 MEANGR 纳入模型以后，SAS 输出表明，协变类型的数量增加到 412 种， D 和皮尔逊 χ^2 的自由度增加到 408（即 412 减去模型中系数（包括截距）的数目）。这两个统计量现在变得差别很大，两者导致不同结论（即 D 统计量表明有很好的拟合，而皮尔逊 χ^2 统计量却表明拟合不好，见表 3.1.4 的上半部）。

表 3.1.4 当模型中加入连续自变量后的偏差和皮尔逊拟合优度

SAS 输出:				
Criterion	DF	Value	Pr> Value/DF	Chi-Square
Deviance	408	378.0	0.9266	0.8537
Pearson	408	632.6	1.5506	0.0001
Number of unique profiles: 412				
SPSS 输出:				
-2 Log Likelihood	839.965			
Goodness of Fit	1 417.363			

在 SPSS 输出中（表 3.1.4 的下半部），拟合优度 “Goodness of Fit” 即 Z^2 统计量，而 “-2 Log Likelihood” 可以理解为是在案例基础上的 “偏差”，它与 SAS 在协变类型基础上计算的 D 统计量不同，两者都显示拟合不好，显然，这是一种误导。

表 3.1.4 的意义在于说明，模型中如有连续变量作为预测变量时，应该采用一种特殊的拟合优度指标。这将是第 3.1.3 节讨



论的题目。

简而言之，SAS 的 PROC LOGISTIC 程序所提供的偏差指标和皮尔逊 χ^2 统计量是拟合优度估价的重要指标。然而，当模型中有连续自变量时或协变类型的数目太多时，它们又不能适当地用于同一目的。但是，不管协变类型的数量如何，偏差指标在比较嵌套模型(nested models)(即一个模型在原有模型变量的基础上再加入或减少某些变量)时仍是重要的指标。两个有嵌套关系的模型之间的差别可以用来判断特定变量的重要性，但皮尔逊 χ^2 却不能服务于这一目的。这个问题将在第 5 章中讨论。

3.1.3 Hosmer-Lemeshow 拟合优度指标

当自变量数量增加时，尤其是连续自变量纳入模型之后，协变类型的数量便会很大，于是许多协变类型只有很少的观测案例。结果，指标 D 和皮尔逊 χ^2 不再适用于估价拟合优度。Hosmer 和 Lemeshow (1989)研制了一种对 logistic 回归模型拟合优度的检验方法。这种检验根据预测概率值将数据分成大致相同规模的 10 个组，而不管模型中有多少协变类型。将观测数据按其预测概率做升序排列。第一组包括估计概率最小的那些观测案例，而最后一组包括估计概率最大的那些观测案例。在实际应用中，因为很多观测案例有同样的预测概率，而具有相同预测概率的所有观测案例都要放在同一组中，所以通常组的规模不可能完全相同。

Hosmer-Lemeshow 指标(记为 HL)是一种类似于皮尔逊 χ^2 统计量的指标。它可以从观测频数和预测频数构成的 $2 \times G$ 交互表中求得。其统计公式如下：

$$HL = \sum_{g=1}^G \frac{(y_g - n_g \hat{p}_g)^2}{n_g \hat{p}_g (1 - \hat{p}_g)}, \quad 3.1.5$$

其中 G 代表分组数，且 $G \leq 10$ ； n_g 为第 g 组中的案例数； y_g 为第 g 组事件的观测数量； $\hat{p}_g$ 为第 g 组的预测事件概率； $n_g \hat{p}_g$ 为事件的预测数，实际上它等于第 g 组的预测概率之和(参见公式 2.1.6)。

通过皮尔逊 χ^2 来概括这些分组中事件结果的观测数和预测数，然而将其与自由度为 $G-2$ 的 χ^2 分布进行比较。 χ^2 检验不显著表示模型拟合数据。相反， χ^2 值统计显著表示拟合不好。



SAS 的 PROC LOGISTIC 程序在其输出的最下方提供 HL 指标。在应用包括连续自变量的 logistic 回归模型时, HL 是广为接受的拟合优度指标。

SAS 6.10 和 SPSS for Windows 7.0 及以后版本的 logistic 回归模型程序提供了 HL 指标。在 SAS 的 PROC LOGISTIC 程序中, 备选(option)命令 LACKFIT 调用 Hosmer-Lemeshow 拟合优度检验, 而 SPSS 中则需要调用备选命令 “Goodfit”。SAS 的程序命令如下:

```
.....
PROC LOGISTIC DESCENDING;
MODEL COLLEGE = GENDER KEYSCH MEANGR
  /LACKFIT SCALE = NONE AGGREGATE;
RUN;
```

相应的 SPSS 的 LOGISTIC REGRESSION 的命令是 GOODFIT, 其格式如下所示:

```
.....
LOGISTIC REGRESSION VAR = COLLEGE
  /METHOD = ENTER GENDER KEYSCH MEANGR
  /PRINT = GOODFIT.
```

表 3.1.5 显示, 示范模型的观测案例被分为十组, 每组大约 100 案例。HL 指标值为 7.21, 其自由度等于 8。将这一指标与 χ^2 分布相比较, 得到的概率值为 $p=0.5142$, 说明统计不显著。因此, 我们不能拒绝关于模型拟合数据很好的假设。换句话说, 模型很好地拟合了数据。SAS 和 SPSS 所计算的 HL 指标有微小差别, 但是两者都表示这个模型很好地拟合了数据。

表 3.1.5 Hosmer-Lemeshow 拟合优度指标

SAS 输出					
Hosmer and Lemeshow Goodness-of-Fit Test					
		COLLEGE = 1		COLLEGE = 0	
Group	Total	Observed	Expected	Observed	Expected
1	100	1	1.05	99	98.95
2	100	3	3.58	97	96.42
3	102	8	7.34	94	94.66

续表

4	101	16	12.31	85	88.69
5	100	22	20.45	78	79.55
6	100	27	30.63	73	69.37
7	101	40	43.43	61	57.57
8	102	52	57.38	50	44.62
9	100	82	74.02	18	25.98
10	94	84	84.82	10	9.18

Goodness-of-fit Statistic = 7.21 with 8 DF (p = 0.5142)

SPSS 输出

Hosmer and Lemeshow Goodness-of-Fit Test

Group	COLLEGE = .00		COLLEGE = 1.00		Total
	Observed	Expected	Observed	Expected	
1	99.000	98.948	1.000	1.052	100.000
2	97.000	96.424	3.000	3.576	100.000
3	94.000	94.660	8.000	7.340	102.000
4	85.000	88.687	16.000	12.313	101.000
5	78.000	79.555	22.000	20.445	100.000
6	73.000	69.368	27.000	30.632	100.000
7	61.000	57.568	40.000	43.432	101.000
8	49.000	43.557	50.000	55.443	99.000
9	19.000	26.535	81.000	73.465	100.000
10	10.000	9.698	87.000	87.302	97.000
Chi-Square d.f. Significance					
Goodness-of-fit test	6.8034	8	.5580		

HL 指标也存在一些缺点。首先,它是一种保守的检验,它在揭示拟合不好的具体类型方面(比如,解释变量中的非线性问题)的功效很低。其次,这一指标高度依赖于观测数据是如何分组的。第三,如果根据预测概率只能将观察案例分成很少几个分组(比如 5 个或更少的分组)来计算这一指标,这一指标的计算值会总是显示模型很好拟合数据 (SAS Institute Inc., 1995)。尽管如此,HL 指标仍然是估价 logistic 回归模型的拟合优度方面最为广泛应用的指标。

3.1.4 信息测量指标 (Information Measures)

另一种估价 logistic 回归模型的拟合优度的指标是信息测量类的指标。这些指标也可以用来比较不同模型的优劣。其中一种著名的信息测量指标是 Akaike 信息标准 (Akaike's information criterion, 记为 AIC)。(Akaike, 1973)它的定义为:



$$AIC = \left(-\frac{2LL_s}{n} + \frac{2(K+S)}{n} \right), \quad 3.1.6$$

其中 K 为模型中自变量的数目； S 为反应变量类别总数减 1 (对于 logistic 回归有 $S = 2 - 1 = 1$)； n 是观测数量； LL_s 是所设模型的估计最大似然值的自然对数，其值较大表示拟合较好。 $-2LL_s$ 的值域为 0 至 $+\infty$ ，其值越小说明拟合越好。

当模型中的参数数量越大时，似然值也就越大， $-2LL_s$ 值就变得很小。因此，将 $2(K+S)$ 加到 AIC 公式的分子中抵销参数数量产生的影响。此外，由于我们知道观测数也会影响似然值，所以公式 3.1.6 中通过除以 n 来取得每一观测对于调整的 $-2LL_s$ 的贡献。在其他条件不变的情况下，较小的 AIC 值表示拟合模型较好。AIC 指标还常常应用于比较不同样本的模型，或应用于比较非嵌套关系的模型，而这些模型的比较不能采用似然比(L.R.)检验。

请读者注意，SAS 的 PROC LOGISTIC 程序所提供的 AIC 指标不同于公式 3.1.6 的定义。在 SAS 的 PROC LOGISTIC 程序中，AIC 指标所用的定义如下：

$$AIC = -2LL_s + 2(K+S), \quad 3.1.7$$

其中，调整的 $-2LL_s$ 没有被观测数所除。换句话说，它不能视为每一观测对调整的 $-2LL_s$ 所做的贡献。因此，这种定义只能用于比较对同一数据的不同模型(SAS Institute Inc., 1990)。

在 SAS 的 PROC LOGISTIC 程序中，还提供另一种信息指标 SC。它与 AIC 一起在 SAS 打印输出中的“The Testing Global Null Hypothesis: BETA=0”栏内提供。SC 指标是对 AIC 指标的一种修正，代表 Schwartz 标准(Schwartz criterion)的意思(SAS Institute Inc., 1990)。这一指标根据自变量数目和观测数量对 $-2LL_s$ 值进行另外一种调整。SC 指标的定义为：

$$SC = -2LL_s + (K+S) \times \ln(n), \quad 3.1.8$$

其中 $\ln(n)$ 是观测数量的自然对数。尽管通过在公式 3.1.8 中加入 $\ln(n)$ 项，在某种程度上对观测数量变化的影响进行了调整，SC 仍然不是每个观测对调整的 $-2LL_s$ 所做贡献的测量。所以，这一指标也只能用于比较对同一数据所设的不同模型(SAS Institute Inc., 1990)。

在其他条件相同时，一个模型的 AIC 或 SC 值越小说明模型

拟合越好。在应用这些指标比较模型时，包括非嵌套关系的模型，我们可以将不同模型按其 AIC 或 SC 指标值排序，选择 AIC 或 SC 指标值最小者。

还有一种使用得越来越多的信息指标，就是贝叶斯信息标准 (Bayesian information criterion, 记为 BIC) (Raftery, 1996)。BIC 有两种不同的类型。在假设所设模型是与饱和模型相比较时，第一种 BIC 指标定义为：

$$\text{BIC} = -2LL_s - \text{d.f.}_s \times \ln(n), \quad 3.1.9$$

其中， $-2LL_s$ 是 -2 乘以所设模型的对数似然值； d.f._s 为模型的自由度，它等于样本规模与模型估计系数数目之差 (即 $\text{d.f.}_s = n - K - 1$)； $\ln(n)$ 为样本规模总数的自然对数。

应该记住，在以案例为基础的情况下，饱和模型的估计系数数目等于样本观测数。正因为如此，饱和模型的自由度等于 0。此外，饱和模型的 $-2LL_f$ 也等于 0。因而，饱和模型的 BIC_f 等于 0。所以， $\text{BIC}_s > 0$ 表示所设模型比饱和模型差，而 $\text{BIC}_s < 0$ 说明饱和模型包括了太多的自变量，而所设模型更好。

另一种 BIC 指标用来对所设模型与零假设模型 (null model, 即只包含常数项的模型) 进行比较。其统计公式为：

$$\text{BIC}' = -G_s + \text{d.f.}'_s \times \ln(n), \quad 3.1.10$$

其中 $\text{d.f.}'_s$ 为自变量数目 (即 K)，而 G_s 为 -2 乘以所设模型与零假设模型之间的最大似然比之差的绝对值，即：

$$\begin{aligned} G_s &= -2LL_0 - (-2LL_s) \\ &= 2LL_s - 2LL_0. \end{aligned} \quad 3.1.11$$

对于零假设模型而言， G_0 和 $\text{d.f.}'_0$ 的值都是 0，所以 BIC'_0 的值也是 0。因此， $\text{BIC}'_s > 0$ 表示所设模型比零假设模型要差，而 $\text{BIC}'_s < 0$ 表示所设模型比零假设模型要好。

与 AIC 和 SC 一样，在其他条件相同时，具有最小 BIC 或 BIC' 值的模型最好。好多少取决于不同模型之间 BIC 或 BIC' 值差异幅度。Raftery (1996) 在 Jeffreys (1961) 研究的基础上，提出了根据 BIC 或 BIC' 值差别来判断一个模型比另一个模型优越程度的一些标准 (见表 3.1.6)。因为 BIC 或 BIC' 具有绝对值更大的负值的模型更好，如果 $(\text{BIC}_1 - \text{BIC}_2) > 0$ ，便说明第 2 个模型更好。

表 3.1.6 根据 BIC 或 BIC' 指标差异绝对值确定模型优越程度

差异绝对值	优越程度
0-2	弱
2-6	肯定
6-10	强
>10	非常强

最后,要想知道 BIC 指标与其他拟合指标之间的联系,可以参看 Raftery (1996,P19)提出的计算线性回归模型的 BIC' 值的公式:

$$BIC' = n \times \ln(1 - R^2) + d.f. \times \ln(n), \quad 3.1.12$$

其中 R^2 为所设定的 OLS 模型的决定系数。这对于计算线性回归模型的 BIC' 指标是一个非常方便的计算公式。

SAS 的 PROC LOGISTIC 程序只提供指标 AIC 和 SC (见表 3.1.7)。SPSS 的 LOGISTIC REGRESSION 程序对这四种信息测量指标都不提供,但是这四种指标可以根据模型的 $-2LL$ 指标计算出来。现在,我们比较两个示范模型的这四种信息测量指标。

$$\text{模型 1: } \ln[p/(1-p)] = \alpha + \beta_1 \text{ GENDER} + \beta_2 \text{ KEYSCH},$$

$$\text{模型 2: } \ln[p/(1-p)] = \alpha + \beta_1 \text{ GENDER} + \beta_2 \text{ KEYSCH} + \beta_3 \text{ MEANGR}.$$

模型的 $-2LL$ 值以及 SAS 提供的这两个模型的 AIC 和 SC 指标值列在输出表 3.1.7 中。根据公式 3.1.8 至公式 3.1.10,计算出两个模型的 AIC、SC、BIC 和 BIC' 四个指标,并列在表 3.1.8 中。模型 2 的所有四个信息测量指标值都分别小于模型 1 的相应值,并且两个模型在 BIC 和 BIC' 指标上的绝对差距都大大超过 10,说明模型 2 比模型 1 要好得多。换句话说,模型 2 更有可能产生已经观测到的数据。

比较模型 1 和模型 2,我们发现 BIC_1 与 BIC_2 之间的差别等于 BIC'_1 和 BIC'_2 之间的差别(见表 3.1.8)。实际上,可以从理论上证明(Raftery, 1996; Long, 1997):

$$BIC_1 - BIC_2 = BIC'_1 - BIC'_2.$$

这说明, 选择使用哪一种 BIC 指标只不过是方便和偏好问题. 重要的是, 我们还可以用这一等式验算 BIC 和 BIC' 的计算是否正确.

表 3.1.7 SAS 的 PROC LOGISTIC 程序估计的信息指标的部分输出结果

模型 1:

Model Fitting Information and Testing Global Null Hypothesis BETA=0			
	Intercept		
	Intercept	and	
Criterion	Only	Covariates	Chi-Square for Covariates
AIC	1277.326	1167.172	.
SC	1282.234	1181.895	.
-2 LOG L*	1275.326	1161.172	114.154 with 2 DF ($p=0.0001$)
Score	.	.	109.227 with 2 DF ($p=0.0001$)

模型 2:

Model Fitting Information and Testing Global Null Hypothesis BETA=0			
	Intercept		
	Intercept	and	
Criterion	Only	Covariates	Chi-Square for Covariates
AIC	1277.326	847.965	.
SC	1282.234	867.596	.
-2 LOG L*	1275.326	839.965	435.361 with 3 DF ($p=0.0001$)
Score	.	.	344.873 with 3 DF ($p=0.0001$)

* 在“Intercept and Covariates”一栏的 -2LOG L 就是模型的 -2LL, 而在“Chi-Square for Covariates”一栏的 -2 LOG L 就是模型的 G_2 .

表 3.1.8 两个示范模型的 AIC、SC、BIC 和 BIC' 指标

Measure	Model1	Model2
$-2LL_s$	1161.17	839.97
G_s	114.15	435.36
d.f.	997	996
d.f. [*]	2	3
$K + S$	3	4
AIC [*]	1.1672	0.8479
SC	1 181.90	867.60
BIC	-5725.86	-6040.64
BIC'	-100.33	-414.64
N	1000	1000

* 这里报告的 AIC 指标是用 SAS 所提供的 AIC 值除以观测数量所得列。

3.2 Logistic 回归模型的预测准确性

对 logistic 回归模型的另一种评价是模型的预测准确性。通常有三种不同的方法服务于这一目的。

3.2.1 类 R^2 指标 (Analogous R^2)

除了拟合优度之外,应用回归分析的研究人员往往对确定系数(coefficient of determination),即 R^2 的值感兴趣。线性回归中的 R^2 有一种十分诱人的解释特性,即它描述因变量的变动中由模型的自变量所“解释”的百分比。但是,在 logistic 回归分析中却没有相应的统计指标。不过,在模型似然值对数的基础上,可以为 logistic 回归模型计算某种类似 R^2 的指标,如似然比指数(likelihood ratio index,记为 LRI)(Greene, 1990; Hosmer and Lemeshow, 1989)。

在线性回归中,拟合模型的残差平方和(residual sum of squares)与这一模型的似然值对数成比例(Hosmer and Lemeshow, 1989)。按照这一观点,可以将 $-2LL_0$ (其中 LL_0 为零模型的最大似然值对数)类比于线性回归中的总平方和(total sum of squares,记为 TSS)。另一方面, $-2LL_s$ 又类似于误差平方和(ESS)(在第 3.1.2 节中,我们提到偏差 $D = -2(LL_s - LL_f)$ 可以被看作类似线性回归中的误差平方和(ESS)。因为饱和模型的

$-2LL_f=0$, 所以 $-2LL_s$ 即可被视为 ESS)。于是, logistic 回归也可以有一个类似于 R^2 的指标, 表示为:

$$LRI = \left(\frac{-2LL_0 - (-2LL_s)}{-2LL_0} \right). \quad 3.2.1$$

与 R^2 类似, LRI 的值域为 0 至 1. 当自变量与因变量完全不相关时(即所有的回归系数为 0 时), LRI 等于 0. 当模型的拟合程度提高时, LRI 值增加. 拟合得越好, LRI 值越接近 1. 只有当模型“完全”拟合数据时, LRI 值达到 1. 在实际应用中, LRI 值可能非常接近 1, 但不会等于 1.

Cox 和 Snell (1989)、Maddala (1983) 以及 Magee (1990) 都曾建议过一般线性模型的确定系数的一般形式为:

$$R^2 = 1 - \left(\frac{\hat{L}_0}{\hat{L}_s} \right)^{2/n}, \quad 3.2.2$$

其中 $\hat{L}_s$ 与 $\hat{L}_0$ 表示所设模型与零假设模型各自的似然值, n 为样本规模. 这种一般定义应用于线性回归便能得到经典的 R^2 指标. 然而对于 logistic 回归, 这样定义的 R^2 的最大值却小于 1 (Nagelkerke, 1991). 这一最大值可以通过下列公式计算:

$$R_{\max}^2 = 1 - (\hat{L}_0)^{2/n}. \quad 3.2.3$$

Nagelkerke (1991) 提出一种 logistic 回归的调整类确定系数:

$$R_{\text{adj}}^2 = \frac{R^2}{R_{\max}^2}. \quad 3.2.4$$

这种调整类确定系数 (R_{adj}^2) 可以得到最大值为 1.

在 SAS 的 PROC LOGISTIC 程序中如要打印模型的类 R^2 指标, 必须调用备选命令 RSQ. 而在 SPSS 的 LOGISTIC 程序中, 这一指标的输出是默认的, 不需要调用备选命令. 下面列出 SAS 的有关命令:

```
PROC LOGISTIC DESCENDING;
MODEL COLLEGE = GENDER KEYSCH MEANGR /RSQ;
RUN;
```

一般化的确定系数 (generalized coefficient of determination) 和调整的确定系数在上述 SAS 命令的打印输出中分别被称为

“RSquare”和“Max-rescaled RSquare”，列在 SAS 输出的“Model Fitting Information and Testing Global Null Hypothesis BETA=0”栏的底部(参见输出表 3.2.1 的上半部)。在 SPSS 输出中，相应的指标被分别称为“Cox & Snell - R^2 ”和“Nagelkerke - R^2 ”(见表 3.2.1 的下部)。

表 3.2.1 Logistic 回归的确定系数输出值

SAS 输出:

Model Fitting Information and Testing Global Null Hypothesis BETA=0

Criterion	Intercept		
	Only	and Covariates	Chi-Square for Covariates
AIC	1277.326	847.965	.
SC	1282.234	867.596	.
-2 LOG L	1275.326	839.965	435.361 with 3 DF ($p=0.0001$)
Score	.	.	344.873 with 3 DF ($p=0.0001$)
RSquare = 0.3530		Max-rescaled RSquare = 0.4898	

SPSS 输出:

-2 Log Likelihood	839.965
Goodness of Fit	1417.363
Cox & Snell - R^2	.353
Nagelkerke - R^2	.490

根据 Nagelkerke (1991)的归纳，类确定系数有许多重要性质：

- 1) 与经典 R^2 的定义相一致；
- 2) 对于模型参数的最大似然估计可以保证类 R^2 取得最大值；
- 3) 类 R^2 有渐近独立于样本规模的性质；
- 4) 它可以被理解为变异中被解释的比例，反之，用 $1 - \text{类 } R^2$ 表示未得到解释的变异。

但是有人认为，不应该将类 R^2 解释为模型所解释的变动比例，因为似然对数根本不是一个可解释的量(DeMaris, 1992)。相反，他们认为类 R^2 倒是估价预测准确性的粗略近似。在自变量与因变量完全无关时，类 R^2 值趋近于 0；当拟合模型能够完美预测时，类 R^2 趋近于 1。

5) 类 R^2 是无量纲的量。这就是说, 它并不依赖模型中所使用的测量单位。

3.2.2 预测概率与观测值之间的关联

对 logistic 回归模型预测准确性的第二种测量方法建立在观测的反应变量和模型预测的条件事件概率之间的关联基础上。有若干种这样的概要指标来评价这种关联, 这类指标称为序次相关指标(rank correlation index)。指标值越高(这种测量的正负号通常被忽略), 表示预测概率与观测反应变量之间的关联越紧密。在本节中, 我们将介绍一些 SAS 的 PROC LOGISTIC 程序能够默认输出的序次相关指标, 有 Gamma、Somers'D、Tau-a 和 c。

在讨论这些指标前, 先对有反应变量不同值的观测数据对(pair of observations)的概念作一介绍。由于 logistic 回归模型的反应变量只能取两种可能值(0 或 1), 因此观测数据对的总数等于取 0 值的频数乘以取 1 值的频数之积。在一个观测数据对中, 如果观测的反应值为 1 的预测事件概率大于观测反应值为 0 的预测事件概率, 就定义该观测数据对为和谐的(concordant)。如果观测的反应值为 1 的预测事件概率小于观测反应值为 0 的预测事件概率, 就定义该观测数据对为不和谐的(discordant)。如果一个观测数据对既不是和谐的也不是不和谐的, 就称为结(tie)。

我们用一个简单例子来示范和谐的以及不和谐的观测数据对是如何定义的。假设一个样本有五例观测, 其中第一例、第三例和第五例的反应值为 0 (即事件未发生), 而另外两例所观测的反应值为 1 (事件发生)(见表 3.2.2)。

表 3.2.2 案例的观测反应值与相应的预测事件发生概率

	观测案例				
	1	2	3	4	5
应用值	0	1	0	1	0
预测事件概率	0.40	0.60	0.55	0.50	0.30

本例中观测数据对总数共有 $3 \times 2 = 6$ 个, 其中包括: (1,2)、(2,3)、(3,4)、(4,5)、(2,5)和(1,4)。对数据对(1,2)来说, 第二案例的观测反应值为 1, 且预测事件概率为 0.60, 大于观测反应

值为 0 的第一案例的预测概率 0.40. 因此, 该数据对(1,2)是和谐数据对. 同理, 数据对(2,3)、(4,5)、(2,5)和(1,4)也为和谐数据对. 与此相反, 数据对(3,4)则是不和谐数据对, 因为观测反应值为 1 的第四案例的预测概率小于观测反应值为 0 的第三案例的预测概率. 在本例中, 没有“结”存在.

SAS 的 PROC LOGISTIC 程序能够提供观测数据对总数, 以及和谐对、不和谐对和结的数量. 在大学入学示范模型的模拟数据中, 反应变量(college)反应值中, 有 665 个 0 和 335 个 1 (见输出表 3.2.3 中上部的反应变量数据), 所以本例共有 $665 \times 335 = 222\,775$ 个观测数据对. 其中有 86.8% 为和谐的, 有 13.0% 为不和谐的, 有 0.2% 为结(参见输出表 3.2.3 的下部).

表 3.2.3 SAS 的 PROC LOGISTIC 程序提供的序次相关指标

Response Profile		
Ordered		
Value	COLLEGE	Count
1	1	335
2	0	665
Association of Predicted Probabilities and Observed Responses		
Concordant = 86.8%		Somers' D = 0.737
Discordant = 13.0%		Gamma = 0.739
Tied = 0.2%		Tau-a = 0.329
(222775 pairs)		c = 0.869

表 3.2.3 提供了四个序次相关指标, 它们都是根据和谐对、不和谐对、结等数据计算出来的. 相对来说, 如果一个模型在这些指标上取得较高数值, 就意味着有较强的预测能力. 反之, 序次相关指标值较低说明模型的预测能力较差.

序次相关指标 Gamma、Somers'D、Tau-a、和 c 的计算公式如下 (SAS Institute Inc., 1995, p.23):

$$\begin{aligned}
 \text{Gamma} &= (nc - nd) / (nc + nd), \\
 \text{Somers'D} &= (nc - nd) / t, \\
 \text{Tau-a} &= (nc - nd) / 0.5n(n-1), \\
 c &= (nc + 0.5(t - nc - nd)) / t.
 \end{aligned}
 \tag{3.2.5}$$

其中 n 为样本观测案例总数; t 为拥有不同反应值的观测数据对的总数; nc 是和谐对的数量; nd 为不和谐对的数量.

注意, Somers' D 与 c 这两个指标可以互相换算:

$$\text{Somers' D} = 2(c - 0.5) \text{ 或 } c = \text{Somers' D} / 2 + 0.5.$$

Gamma 可以视为和谐对的概率减去不和谐对的概率之差. Gamma 的缺点是倾向于高估预测概率与反应变量状况之间的联系强度, 因为它的分母没有包括结的数量. Somers' D 是对 Gamma 的一种扩展. 与 Gamma 的不同之处在于, Somers' D 的分母包括结的数量. 因此, 它的值总是小于 Gamma.

应当记住, 在公式 3.2.5 中所描述的 Somers' D 实际上是 Somers' D(r|c), 它定义反应变量相关于(depends upon)预测概率. 然而, SAS 的 PROC LOGISTIC 程序所提供的 Somers' D 并不是 Somers' D(r|c), 而是 Somers' D(c|r), 它定义预测概率相关于反应变量. 注意, 表 3.2.3 的 c 指标不是与 D(r|c)相联系的, 而是与 D(c|r)相联系的, 即 $c = D(c|r) / 2 + 0.5 = 0.737 / 2 + 0.5 = 0.869$.

要取得 Somers' D(r|c), 只要在 SAS 的 PROC LOGISTIC 程序中通过 OUT 命令形成一个预测概率的变量就可以完成. 在示范例题中, 反应变量是 COLLEGE, 预测事件概率以变量名 PHAT 存于一个 SAS 临时数据文件 PRED 之中. 下面所列出的是 SAS 的 PROC LOGISITC 和 PROC FREQUENCY 程序命令, 通过这两个程序可以得到 Somers' D(r|c).

```
.....
PROC LOGISTIC DESCENDING;
MODEL COLLEGE = GENDER KEYSCH MEANGR;
OUTPUT OUT = PRED P = PHAT;
RUN;

DATA NEW;
  SET PRED;
PROC FREQ;
TABLES COLLEGE * PHAT / MEASURE;
RUN;
```

SAS 的 PROC FREQ 程序如果加上备选命令 MEASURE,

其输出就能够同时提供指标 Somers' $D(r|c)$ 和 Somers' $D(c|r)$ (参见表 3.2.4 中输出的上部)。注意, 这里输出的 Somers' $D(c|r)$ 的值正是 SAS 的 PROC LOGISTIC 所报告的 Somers' D (见表 3.2.3), 并且 $D(r|c)$ 与 $D(c|r)$ 是不同的。

SPSS 的 LOGISTIC REGRESSION 程序不提供这些 SAS 的 LOGISTIC 程序所提供的关联指标。但是, 我们可以通过将预测概率存成新变量, 然后再通过运行 CROSSTABS 程序将这一预测变量与观测的反应变量作交互表分析, 得到其中的一些指标, 如 Somers' D 和 Gamma 指标。 c 可以根据 Somers' D 指标值来计算。下面列出的 SPSS 命令先运行 logistic 回归, 然后预测概率并将其存为临时变量, 最后运行 CROSSTABS 程序。

```
LOGISTIC REGRESSION VAR = COLLEGE
  /METHOD = ENTER GENDER KEYSCH MEANGE
  /SAVE PRED.
```

```
CROSSTABS
  /TABLES = COLLEGE BY PRE __ 1
  /FORMAT = AVALUE TABLES
  /STATISTIC = GAMMA D
  /CELLS = COUNT.
```

其中, 子命令“SAVE PRED”将预测概率存为一新变量(其默认变量名为 **pre_1**)。子命令“STATISTIC = GAMMA D”执行输出指标 GAMMA 和 D。注意, 在表 3.2.4 下部标注为“Predicted Value Dependent”的一行中报告的 Somers' D 实际上是 $D(c|r)$, 然而在标注为“College Dependent”的一行中报告的 Somers' D 是 $D(r|c)$ 。

简而言之, 序次相关指标是根据观测数据对和谐、不和谐或是结的情况计算的。所有序次相关指标都不是从指标绝对值角度来使用, 而是用以比较给定反应变量的不同模型。指标 c 和 Somers' D 在应用于比较 logistic 模型时通常较好。

表3.2.4 序次相关指标

SAS 输出：			
Statistic	Value	<u>ASE</u>	
Gamma	0.739	0.023	
Kendall' s Tau - b	0.493	0.017	
Stuart' s Tau - c	0.657	0.025	
Somers' D C R	0.737	0.024	
Somers' D R C	0.330	0.013	
Pearson Correlation	0.631	0.022	
Spearman Correlation	0.603	0.020	
Lambda Asymmetric C R	0.006	0.002	
Lambda Asymmetric R C	0.624	0.030	
Lambda Symmetric	0.162	0.010	
Uncertainty Coefficient C R	0.070	0.002	
Uncertainty Coefficient R C	0.638	0.019	
Uncertainty Coefficient Symmetric	0.127	0.004	
Sample Size = 1000			
SPSS 输出：			
	Directional Measures		
	Asymp.		Approx.
	Value	Std. Error ^a	Approx. I ^b Sig.
Ordinal by Ordinal Somers'd Symmetric	.456	.015	25.772 .000
Predicted Value Dependent	.737	.024	25.772 .000
COLLEGE Dependent	.330	.013	25.772 .000
a:	Not assuming the null hypothesis.		
b:	Using the asymptotic standard error assuming the null hypothesis.		

续表

	Symmetric Measures			Approx. Sig.
	Value	Asymp. Std. Error ^a	Approx. T ^b	
Ordinal by Ordinal Gamma	.739	.023	25.772	.000
N of Valid Cases	1000			
a:	Not assuming the null hypothesis.			
b:	Using the asymptotic standard error assuming the null hypothesis.			

3.2.3 分类表(Classification Table)

分类表是将观测案例分为事件发生或不发生的频数表,也可以用来检验 logistic 回归模型的预测准确性。通过比较预测的事件概率和设定的概率界限(cutpoint),便可将案例分成预测事件发生或不发生。如果一个案例的预测事件概率大于概率界限,就将其界定为预测事件发生,否则就作为预测事件不发生。当然,一个观测被界定为预测事件发生分类依赖于概率界限的确定。概率界限值越大,案例被界定为预测事件发生类的可能性越小。通常,我们采用 0.5 作为概率界限,这就是说,如果一个观测的预测事件概率值等于或大于 0.50,就会被分入预测事件发生的类别,否则就被分入预测事件不发生的类别。一旦所有观测分为预测发生或不发生两类,我们便可以建立一个 2×2 的交互表来比较预测情况和实际观测情况,这就是分类表。

下面所列出的 SAS 命令,先运行 logistic 回归模型,然后建立一套输出数据(存在一命名为 PRED 的临时数据文件中),其中包含输入数据中每一观测的预测事件概率(新变量 PHAT),第三步便是产生一个新变量“PREDICT”,当预测概率大于或等于概率界限值时,这个变量值为 1,否则这个变量值为 0,最后,这个程序将建立反应变量的预测值和观测值的分类表。

```
.....
PROC LOGISTIC DESCENDING;
MODEL COLLEGE = GENDER KEYSCH MEANGR;
OUTPUT OUT = PRED P = PHAT;

RUN;
```

```

DATA NEW;
SET PRED;
IF PHAT <= 0.5 THEN PREDICT = 1;
ELSE PREDICT = 0;
PROC FREQ;
TABLES COLLEGE * PREDICT /NOROW NOCOL NOPERCENT;
RUN;

```

表 3.2.5 是由 SAS 的 PROC FREQ 程序打印的分类表。从这一表中, 可以看到 1000 个案例中有 $589 + 218 = 807$ 个被 logistic 回归模型所正确分类, 因此, 总正确率 (percentage of correct, 即被正确分类的案例数和案例总数之比) 为 $807/1000 = 80.7\%$ 。在 335 个事件实际发生的观测中有 218 个被正确地预测为事件发生, 因此, 敏感度 (sensitivity, 即正确预测事件发生的案例数与观测事件发生的总数之比) 为 $218/335 = 65.1\%$ 。在 665 个事件未发生的观测中有 589 例被正确预测为事件未发生, 因此, 其指定度 (specificity, 即正确分类的事件未发生数与观测事件未发生的总数之比) 为 $589/665 = 88.6\%$ 。在 294 个分类为发生的案例中, 有 76 个分类不正确, 因此错误肯定率 (false positive rate, 即错分类为发生事件的实际未发生事件数与观测事件发生数之比) 为 $76/294 = 25.9\%$ 。在 706 个分类为事件未发生的案例中, 有 117 个为错分类, 所以错误否定率 (false negative rate, 即错分类为未发生而实际为发生事件的案例数与观测未发生事件的总数之比) 为 $117/706 = 16.6\%$ 。综上所述, 在分类表中我们可以计算出正确率、敏感度、指定度、错误肯定率、错误否定率等五个指标来估计 logistic 回归模型的预测准确性。

表 3.2.5 有偏 (Biased) 分类表 (SAS 输出)

COLLEGE	PREDICT		
Frequency	0	1	Total
0	589	76	665
1	117	218	335
Total	706	294	1000

SPSS 的 LOGISTIC REGRESSION 程序也自动输出分类表,

其格式与表 3.2.5 中的 SAS 输出完全相同。实际上, 这种分类表是有偏的, 原因是同一套数据被用来拟合模型并产生预测的分类表。这里, 我们介绍两种方法来建立无偏的分类表。

第一种方法: 将样本数据随机地平分为两半, 一半作为预测样本 (prediction sample), 另一半作为确认样本 (validation sample)。这种方法称为交叉确认 (cross-validation), 是鉴别分析中常用的一种方法。在这里我们所要做的是, 先根据预测样本来估计 logistic 回归模型; 然后再将所预测的模型应用于确认样本, 计算其所有案例的事件概率; 最后, 根据由确认样本所估计的事件概率来建立分类表。整个工作都可以应用 SAS 或 SPSS 来完成。

第二种方法: 在原始数据中省略一个案例, 然后运行 logistic 回归模型, 计算这一省略案例的预测概率, 并根据观测值和预测值进行分类。重复上述过程 n 次 (n 为样本规模), 即一次省略一个案例, 直至每个案例都得到分类。这一方法通常称为刀切法 (jackknife method)。它能够避免分类表的偏差, 但是这种方法非常费时, 尤其是原始数据包含大量观测案例时。

下面我们先应用第一种方法来示范我们的模型。相应的 SAS 程序命令如下:

```
* SAS PROGRAM: GENERATE UNBIASED CLASSIFICATION TABLES;
* PROGRAM 1;
OPTIONS NOCENTER PS = 500 LS = 150;
LIBNAME LIB ' D: \ LOGIT';
DATA DATA1;
    SET LIB.COLLEGE;
    RANDOM = RANUNI (6);

* PROGRAM 2;
DATA SPLIT;
    SET DATA1;
    COLLEGE1 = .; COLLEGE2 = .;
    IF RANDOM < 0.5 AND COLLEGE = 1 THEN COLLEGE1 = 1;
    IF RANDOM < 0.5 AND COLLEGE = 0 THEN COLLEGE1 = 0;
    IF RANDOM >= 0.5 AND COLLEGE = 1 THEN COLLEGE2 = 1;
```



```
IF RANDOM >= 0.5 AND COLLEGE = 0 THEN COLLEGE2 = 0;
```

```
* PROGRAM 3;  
PROC LOGISTIC DESCENDING;  
MODEL COLLEGE1 = GENDER KEYSCH MEANGR;  
OUTPUT OUT = PRED P = PHAT;  
RUN;
```

```
* PROGRAM 4;  
PROC PRINT;  
VAR COLLEGE1 COLLEGE2 PHAT;  
RUN;
```

```
* PROGRAM 5;  
DATA NEW;  
SET PRED;  
IF PHAT >= 0.5 THEN PREDICT = 1;  
ELSE PREDICT = 0;
```

```
* PROGRAM 6;  
PROC FREQ;  
TABLES COLLEGE2 * PREDICT / NOROW NOCOL NOPERCENT;  
RUN;
```

SAS 程序 1 将根据一致分布函数(uniform distribution function)产生一个随机变量 RANDOM, 这一变量是用来建立预测样本和确认样本的. SAS 程序 2 将原始数据分成规模大致相等的两部分, 一部分将作为预测样本, 另一部分将作为确认样本. 也就是说, 当变量 RANDOM 的值大于 0.5 时, 如原始反应变量 COLLEGE 等于 1, 就令预测样本的反应变量 COLLEGE1 为 1, 否则变量 COLLEGE1 = 0. 而确认样本的反应变量定义为 COLLEGE2. 当变量 RANDOM 的值大于或等于 0.5 时, 如原始反应变量 COLLEGE 等于 1, 令其新反应变量 COLLEGE2 等于 1, 否则令 COLLEGE2 等于 0. 这样, 在预测样本中变量 COLLEGE2 的值为缺失, 而在确认样本中变量 COLLEGE1 的值为缺失.

SAS 程序 3 基于预测样本运行 logistic 模型, 并预测事件概率 PHAT, 将其值存入 SAS 临时数据文件 PRED. SAS 程序 4 分别列出预测样本和确认样本中的原始反应变量 COLLEGE 及新反应变量 COLLEGE1 和 COLLEGE2. 正如表 3.2.6 所示, 每一个观测案例都有原始反应变量 COLLEGE 等于 1 或 0, 而其新反应变量 COLLEGE1 和 COLLEGE2 却分别有许多案例为缺失值, 这正好识别了案例属于预测样本还是确认样本. 根据预测样本, SAS 的 PROC LOGISTIC 程序估计了所有案例的事件概率, 也包括属于确认样本的那些案例. 这就使我们得以根据确认样本来建立一个分类表. SAS 程序 5 用来计算预测事件, 即预测事件概率如果大于等于概率界限 0.5 就令表示预测事件发生与否的变量(定变量名为 PREDICT)等于 1. 否则, 令其等于 0. 然后, SAS 程序 6 用预测事件发生与否的变量 PREDICT 和新反应变量 COLLEGE2 来建立确认样本的分类表. 由表 3.2.7 可知, 确认样本包括 495 个案例, 而预测样本规模即为 $1000 - 495 = 505$. 由这一分类表所计算出的正确率为 $(296 + 97) / 495 = 79.4\%$, 它比表 3.2.5 的分类表所计算的相应指标要略低一些. 读者可以自行计算表 3.2.7 所示的敏感度、指定度、错误肯定率和错误否定率等指标, 并将它们与表 3.2.5 所表示的相应指标进行比较.

表 3.2.6 SAS 的 PROC LOGISTIC 程序所输出的反应变量
与预测事件概率(部分案例)

OBS	COLLEGE	COLLEGE1	COLLEGE2	PHAT
1	0	0	.	0.06126
2	1	.	1	0.92288
3	1	1	.	0.80161
4	1	.	1	0.50980
5	0	.	0	0.04739
6	0	.	0	0.01136
7	0	0	.	0.20225
8	0	0	.	0.01334
9	0	0	.	0.00822
10	0	0	.	0.02528
11	0	.	0	0.01742
12	0	0	.	0.11674
13	0	0	.	0.00822
14	0	0	.	0.02156

续表

ORS	COLLEGE	COLLEGE1	COLLEGE2	PHAT
15	1	.	1	0.53688
16	0	.	0	0.00202
17	0	.	0	0.01334
18	0	0	.	0.01838
19	0	.	0	0.07132
20	0	0	.	0.00225
...				

表 3.2.7 SAS 的 LOGISTIC 程序输出的由确认样本所估计的无偏分类表

COLLEGE2	PREDICT		
Frequency	0	1	Total
0	296	36	332
1	66	97	163
Total	362	133	495
Frequency Missing = 505			

采用第二种方法(“刀切法”)的 SAS 程序命令如下:

```
* SAS PROGRAM: JACKKNIFE METHODS;
.....
PROC LOGISTIC DESCENDING;
MODEL COLLEGE = GENDER KEYSCH MEANGR
    /CTABLE PPROB (0.05 TO 1.0 BY 0.05);
RUN;
```

上述程序中的备选命令 CTABLE 可以建立一个默认分类表,其中 PPROB (0.05 TO 1.0 BY 0.05)设置了一个区间和增加间隔来形成分类表的事件概率界限。

表 3.2.8 列出从最小预测概率 0.05 至最大预测概率 1.00 之间按间隔 0.05 增加形成的所有概率界限的分类表。比如,在预测概率为 0.5 一行中,标志分别为正确(Correct)和不正确(Incorrect)的列给出了正确和不正确分类的频数。比如,在这一行中模型正确分类了 216 个事件发生和 589 个事件未发生案例,

同时将 76 个事件未发生的观测错误地预测为发生, 并有 119 个事件发生的观测被错误地预测为未发生. 而百分比 (Percentages) 栏目下的各列提供了对应每一概率界限上的五种预测准确性的指标. 比如, 在概率界限为 0.50 时, 分类总正确率为 80.5%.

与表 3.2.5 中所提供的有偏分类表相比, 第一种无偏分类表方法所得到正确率小于有偏正确率约 $80.7\% - 79.4\% = 1.3\%$, 而根据“刀切法”估计的第二种无偏正确率只比其小 $80.7\% - 80.5\% = 0.2\%$.

表 3.2.8 SAS 的 PROC LOGISTIC 程序以刀切法所得到的分类表

Prob Level	Classification Table								
	Correct		Incorrect		Percentages				
	Non - Event	Non - Event	Non - Event	Non - Event	Sensi - Correct	Speci - tivity	False ficty	False POS	False NEG
0.050	331	192	473	4	52.3	98.8	28.9	58.8	2.0
0.100	320	303	362	15	62.3	95.5	45.6	53.1	4.7
0.150	307	375	290	28	68.2	91.6	56.4	48.6	6.9
0.200	296	408	257	39	70.4	88.4	61.4	46.5	8.7
0.250	285	453	212	50	73.8	85.1	68.1	42.7	9.9
0.300	271	482	183	64	75.3	80.9	72.5	40.3	11.7
0.350	260	516	149	75	77.6	77.6	77.6	36.4	12.7
0.400	250	549	116	85	79.9	74.6	82.6	31.7	13.4
0.450	239	570	95	96	80.9	71.3	85.7	28.4	14.4
0.500	216	589	76	119	80.5	64.5	88.6	26.0	16.8
0.550	201	614	51	134	81.5	60.0	92.3	20.2	17.9
0.600	183	630	35	152	81.3	54.6	94.7	16.1	19.4
0.650	165	637	28	170	80.2	49.3	95.8	14.5	21.1
0.700	145	646	19	190	79.1	43.3	97.1	11.6	22.7
0.750	126	649	16	209	77.5	37.6	97.6	11.3	24.4
0.800	96	653	12	239	74.9	28.7	98.2	11.1	26.8
0.850	72	657	8	263	72.9	21.5	98.8	10.0	28.6
0.900	43	661	4	292	70.4	12.8	99.4	8.5	30.6
0.950	14	665	0	321	67.9	4.2	100.0	0.0	32.6
1.000	0	665	0	335	66.5	0.0	100.0	.	33.5

SPSS 的 LOGISTIC REGRESSION 程序有备选命令 SELECT. 选用这个命令便可以对用来建立模型的案例进行选择, 自动建立预测样本和确认样本, 并且按概率界限为 0.5 估计出事件概率, 计算出无偏分类表. 以下 SPSS 程序用来完成这项工作. 首先, 程序随机地抽选 50% 的案例作为预测样本, 并基于这些样本运行 logistic 模型, 预测事件概率. 然后, 对所选案例和未选案例分别计算分类表 (程序将未选案例作为确认样本). 表 3.2.9 所示是根据确认样本得到的无偏估计分类表. 所用的 SPSS 命令如下:

* SPSS PROGRAM: GENERATE UNBIASED CLASSIFICATION TABLE.

.....

COMPUTE RANDOM = UNIFORM(1).

LOGISTIC REGRESSION COLLEGE

/SELECT RANDOM LT 0.5

/METHOD = ENTER KEYSCH GENDER MEANGR.

表 3.2.9 用 SPSS 的 LOGISTIC REGRESSION 程序的
Selection 备选命令所得到分类表

		Predicted		Percent Correct
		.00	1.00	
Observed	0	265	40	305
	1	57	118	175
		322	158	480

从表 3.2.9 看到, 分类总正确率约为 $(265 + 118)/480 = 79.8\%$, 十分接近于 SAS 得到的无偏估计.

与 SAS 比较, 使用 SPSS 的 LOGISTIC REGRESSION 程序来产生无偏分类表较为容易, 但 SPSS 的 LOGISTIC REGRESSION 程序不能提供刀切法来产生分类表.

3.3 模型 χ^2 统计(Model Chi-Square Statistic)

为了对 logistic 回归模型进行有意义的解释, 要求模型中所包含的自变量必须对因变量有显著的解释能力, 也就是说所设模型必须要比零假设模型(即只包含常数项的模型)要好. 在多元线性回归及 ANOVA 模型中, 常用自由度分别为 K 和 $n - K - 1$ 的 F 检验(其中 K 是自变量的个数, n 为样本规模)来检验“除常数项外的所有系数都等于 0”的无关假设. 而在 logistic 回归中服务于同一目的的检验却是似然比检验(likelihood ratio test), 它可以用来检验 logistic 回归模型是否统计性显著. 似然比统计量近似地服从于 χ^2 分布(Hanushek & Jackson, 1977; Aldrich & Nelson, 1984; Greene, 1990).

所谓模型 χ^2 (model chi-square) 定义为零假设模型与所设模型之间在 $-2LL$ 上的差距, 也就是公式 3.1.11 中所描述的 G 指标. 模型 χ^2 的自由度为零假设模型自由度与所设模型自由度之间的差, 即 K (回归系数个数).

在第 3.2.1 节我们曾经提到, $-2LL_0$ 与 $-2LL$ 分别类似于线性回归中总平方和(TSS)与误差平方和(ESS). 所以, $-2LL_0$ 与 $-2LL$ 之间的差也对应着线性模型中的回归平方和(RSS), 它在 SPSS 的 LOGISTIC REGRESSION 程序的输出报告中被称为“Model Chi-square”; 而在 SAS 的 PROC LOGISTIC 的输出报告中被称为“-2 Log L”, 列标题为“Chi-Square for Covariates”栏下. 实际上, 模型 χ^2 与多元线性回归中的 F 检验十分类似. 模型 χ^2 作为一种 χ^2 统计量来检验可以提供关于零假设(即“除常数项外的所有系数都等于 0”的假设, 通常以公式表示为 $H_0: B_1 = B_2 = \dots = B_k = 0$)的检验. 如果模型 χ^2 的统计性显著, 我们便拒绝零假设, 认为自变量所提供的信息有助于我们更好地预测事件是否发生.

对应示范模型公式 3.1.1, 我们有 $-2LL_0 = 1275.326$ 和 $-2LL = 1161.172$. 因此, 模型 χ^2 统计为 $\chi^2 = 1275.326 - 1161.172 = 114.154$, 其自由度为 d.f. = $3 - 1 = 2$ (参见表 3.3.1 的结果).

表3.3.1 模型 χ^2 统计

SAS 输出:

Model Fitting Information and Testing Global Null Hypothesis: BFA = 0

Criterion	Intercept and		Chi-Square for Covariates
	Intercept Only	Covariates	
AIC	1277.326	1167.172	.
SC	1282.234	1181.895	.
- 2 LOG L	1275.326	1161.172	114.154 with 2 DF (p = 0.0001)
Score	.	.	109.227 with 2 DF (p = 0.0001)
RSquare = 0.1079 Max-rescaled RSquare = 0.1497			

SPSS 输出:

- 2 Log Likelihood	1161.172		
Goodness of Fit	1002.606		
	Chi-Square	d.f.	Significance
Model Chi-Square	114.154	2	.0000
Improvement	114.154	2	.0000

必须强调, 模型 χ^2 值不是关于模型对数据拟合优度的检验, 而只是关于自变量是否与所研究事件的对数发生比(log odds)线性相关的检验。按照理想情况, 最好是模型 χ^2 统计性显著而拟合优度统计性不显著。但是, 我们有时发现, 模型 χ^2 和拟合指标都是显著的, 尤其是在大样本的情况下, 这种矛盾现象可能出现。这种现象一方面说明模型并不能很好拟合数据, 另一方面又说明自变量对因变量能够进行很好的解释。有些学者在这种情况下喜欢首先关注模型 χ^2 , 其次才关注拟合优度。因此, 他们经常在其文献中只报告模型 χ^2 , 而不报告拟合优度。而我们认为, 两者都应该报告。并且, 如果模型 χ^2 统计性不显著或拟合优度(尤其是 HL 指标)统计性显著, 那么这个模型应该重新设定。

**尾注:**

1. 假设我们有一个多维二分类变量数据样本, 其协变类型共有 J 种, 其中第 j 种协变类型中包含的事件数为 y_j ; ($j = 1, 2, \dots, J$). 假设在第 j 种协变类型中的 n_j 个观测案例有共同的事件发生概率 p_j (其估计值 $\hat{p}_j = y_j/n_j$). 将第 j 种协变类型中的预测事件发生数定义为 $n_j\hat{p}_j$. 下列统计量

$$\sum_{j=1}^J \frac{(y_j - n_j\hat{p}_j)^2}{n_j\hat{p}_j(1 - \hat{p}_j)} \quad \text{附 3.1}$$

服从自由度为 $J - K - 1$ 的 χ^2 分布 (Collett, 1991, p. 67). 一旦每种协变类型中的观测数减少到 1, 即 $n_j = 1$, 那么有 $J = n$, 于是这个统计量将变成

$$\sum_{j=1}^J \frac{(y_j - \hat{p}_j)^2}{\hat{p}_j(1 - \hat{p}_j)}, \quad \text{附 3.2}$$

此统计量即为 SPSS 的 LOGISTIC 程序所提供的 Z^2 统计量 (SPSS Inc., 1997b).

Logistic 回归系数 解释

4

第 四 章

- 4.1 发生比和发生比率(Odds and Odds Ratio) (92)
- 4.2 按发生比率来解释 logistic 回归系数 (95)
 - 4.2.1 连续自变量的发生比率 (96)
 - 4.2.2 二分类自变量的发生比率 (98)
 - 4.2.3 分类自变量的发生比率 (100)
- 4.3 用概率来解释自变量的作用 (111)
- 4.4 预测概率 (112)
- 4.5 标准化系数 (115)
- 4.6 偏相关(Partial Correlation) (120)



当 logistic 回归模型能够较好地拟合数据时, 我们便可以对模型的系数进行解释了. 类似于线性回归系数, logistic 回归系数也可以被解释为对应自变量一个单位的变化所导致的因变量上的变化. logistic 回归模型的系数如果是正值且统计显著, 意味着在控制其他自变量的条件下, 对数发生比随对应自变量值增加而增加. 相反, 一个显著的负系数代表对数发生比随对应自变量的增加而减少. 如果系数的统计性不显著, 说明对应自变量的作用在统计上与 0 无差异. 在本章中, 我们将讨论如何对 logistic 回归系数进行解释, 并在下一章讨论其统计推断.

由于 logistic 回归的因变量不是常规的连续变量, 而是 logit (即对数发生比 $\ln[p/(1-p)]$), 那么对应每个自变量的估计系数便是该自变量对 logit 的作用. 尽管这种解释直截了当, 但是其实十分含糊, 因为 logit 或对数发生比没有较直观的含义. 通常, 较方便的是将 logit 进行转换后再进行解释, 而不是直接解释系数本身. 如果我们将回归模型等式两侧取自然指数, 于是左边便成为发生比 ($p/(1-p)$). 这样, x_k 对 logit 或对数发生比的作用现在便转换为 e^{β_k} , 即对发生比的作用. 由于发生比是日常生活中的常用概念, 比如关于高校录取或投票选举结果等成功与失败的比率, 因此这种解释便变得容易理解. 因为在解释 logistic 回归系数时所需要理解的基本概念是发生比(odds)和发生比率(odds ratio), 我们将在开始讨论 logistic 回归系数的解释工作之前, 简要地介绍一下发生比和发生比率.

4.1 发生比和发生比率(Odds and Odds Ratio)

发生比是事件的发生频数与不发生频数之间的比, 即:

$$\text{odds} = (\text{事件发生频数}) / (\text{事件不发生频数}), \quad 4.1.1$$

如对于第 k 种事件, 式 4.1.1 还可以表示为

$$\text{odds}_k = [p_k / (1 - p_k)]. \quad 4.1.2$$

这是通过用第 k 组观测频数 n_k 分别去除式 4.1.1 的分子和分母而得到的. 其分子除以 n_k 便得到 $p_k = (\text{第 } k \text{ 组中事件发生频数}) / n_k$, 它便是作为研究对象的事件发生的概率估计; 其分

母除以 n_k 便得到 $(1 - p_k) = (\text{第 } k \text{ 组中事件不发生频数}) / n_k$, 即事件不发生的概率估计. 所以, 发生比又可以理解为同一组中事件发生概率与事件不发生概率之间的比.

由于发生比被表示为一个比值, 因此其值域的上限无边界, 即可以在所有非负值域取值. 当比值大于 1 时, 事件更为可能发生. 比如, 一个事件发生的概率为 0.6, 那么事件不发生的概率即 0.4, 于是发生比便等于 $0.6/0.4 = 1.5$. 这意味着, 事件发生的可能性是不发生的可能性的 1.5 倍, 或者说我们期望看到对应每一次事件不发生有 1.5 次事件发生. 如果发生比 $\text{odds} = 0.25$, 说明事件不发生可能性是发生可能性的 4 倍, 或者说可以期望对应每 4 次事件不发生有 1 次事件发生.

比较两组发生比的适当方法不是通过减法 (即像计算百分点差异那样), 而是通过除法得到发生比率 (odds ratio). 它是 logistic 回归模型的基本概念. 请注意, 在比较发生比率之间谁高谁低时可能产生误导. 比如, 乍一看到两个发生比率 2.0 和 0.5 时好像表明了两种不同的作用幅度, 其实它们可以反映同一作用的幅度, 只是更换了比较的方向而已. 当比较中变化了参照组, 发生比率便可由 2.0 变为 0.5, 后者不过是前者的倒数而已^①.

让我们用表 4.1.1 中的数据来说明发生比和发生比率的概念. 假设研究事件 (event) 为 “高中毕业后考入大学” (简标为 “是”), 否事件 (nonevent) 便是 “未能考入大学” (简标为 “否”). 共有 1000 名高中毕业生, 其中 550 名男生、450 名女生. 因此, 考入大学的发生比为 “是” 的频数除以 “否” 的频数. 假如分别有 259 名男生和 76 名女生考入了大学 (同时有 291 名男生和 374 名女生落榜), 男生和女生的 (是/否) 发生比分别为:

① 与线性回归相似的是, 在参照组变化的情况下 logistic 回归系数估计具有对称性的特点. 比如, 当性别变量中编码 1 为男、0 为女时, 女性被作为参照组. 如果性别的系数估计为 0.69, 便意味着男性比女性有更大可能经历事件发生. 而当我们把男性作为参照组时 (编码 1 为女、0 为男), 性别的系数估计将成为 -0.69. 回归系数 0.69 和 -0.69 关于 0 值对称. 然而, 就发生比率而言, 这种对称特点便不复存在. 当系数值为 0.69 和 -0.69 时, 相应的发生比率值分别为 $\exp(0.69) \approx 2.0$ 和 $\exp(-0.69) \approx 0.5$. 它们不是关于 1 值对称. 这就是为什么有的人更愿意使用 logistic 回归系数.

$$\text{odds}_m = 259/291 = 0.8900,$$

$$\text{odds}_f = 76/374 = 0.2032.$$

而男生与女生的发生比率(OR)为: $\text{OR} = \text{odds}_m / \text{odds}_f = 0.8900/0.2032 = 4.38$, 它是与性别相连的两个发生比之间差别的测量. 这一发生比率表示, 男生考入大学的发生比约为女生考入大学发生比的 4.38 倍〔注意, 这里的数据是作者根据模型(式 2.5.1)虚拟的, 没有任何实际含意〕. 发生比率可以描述为:

$$\begin{aligned} \text{OR} &= \frac{p_1/(1-p_1)}{p_2/(1-p_2)} = \frac{n_{11}/n_{12}}{n_{21}/n_{22}} \\ &= \frac{n_{11}/n_{22}}{n_{12}/n_{21}} = \frac{259 \times 374}{291 \times 76} \\ &= 4.38. \end{aligned} \quad 4.1.3$$

因此, 发生比率实际等于表 4.1.1 中关于对角线对称的交叉单元频数的积之间的比. 所以, 发生比率又称为交叉积比率(cross-product ratio).

表 4.1.1 分性别的大学入学情况

性别	大学入学	
	是	否
男	$n_{11} = 259$	$n_{12} = 291$
女	$n_{21} = 76$	$n_{22} = 374$

还有另外一种测量指标, 称为相对风险(relative risk), 也经常被用来进行两个组概率之间的比较(Hosmer & Lemeshow, 1989). 它是第 1 组与第 2 组概率之间的比, 即 (p_1/p_2) . 它的值为非负真数. 假如第 1 组和第 2 组的事件发生概率分别为 0.05 和 0.01, 那么相对风险为 $0.05/0.01 = 5$; 而概率分别为 0.4 和 0.2 时, 相对风险为 $0.4/0.2 = 2.0$. 当 $p_1 = p_2$ 时, 相对风险为 1, 表示两组在事件发生方面没有差别.

在 logistic 回归中应用发生比率来理解自变量对事件概率的作用是最好的方法, 因为发生比率在测量关联时具有一些很好的性质(Feinberg, 1985; Morgan & Teachman, 1988):

1) 它可以给予清楚的解释. 大于 1 的发生比率表明事件发生的可能性会提高, 或者说自变量对事件概率有正的作用; 小于 1 的发

生比率表示事件发生的可能性会降低,或者说自变量对事件概率有负的作用.在加法模型中 0 作为正作用和负作用之间的界限,与此类似,1 是乘法模型的划分界限.对于发生比率而言,1 是揭示关联的界限值.发生比率值为 1 表示变量对事件概率无作用.

2) 比较组的顺序发生变化时,发生比率可以互相转换.如第 1 组和第 2 组的事件发生比分别为 0.25 和 0.20,那么第 1 组和第 2 组之间的发生比率可以互相转换:

$$\begin{aligned}\text{odds}_1/\text{odds}_2 &= 1/(\text{odds}_2/\text{odds}_1) \\ &= 1/(0.20/0.25) \\ &= 1.25.\end{aligned}$$

3) 对变量的频数扩大若干倍,发生比率不变.比如,对表 4.1.1 中“是”一列频数扩大任意常数 c 倍将导致男生和女生升学的频率发生变化,但其发生比率 $\text{odds}_m/\text{odds}_f$ 则不变.

4) 发生比率还可以用于多分类变量(polytomous variables)或用于多元模型.比如,要是表 4.1.1 数据中还有地区分类(如城乡划分),我们还可以按城乡来估计不同性别的升学发生比之间的联系.于是,发生比率能够按地区-性别组进行计算,并加以比较.

4.2 按发生比率来解释 logistic 回归系数

对 logistic 回归系数进行解释时,很难具体把握以对数单位测量的作用幅度,所以通常将以 logit 单位推导的作用转换为对应的发生比率.

在升学例子的模型中(见式 2.5.1),截距 α 可以作为基准发生比的对数.这里,基准的意思是指当 logistic 回归模型中没有任何自变量时所产生的发生比.或者说,除常量外,所有自变量都取 0 值时所产生的发生比.因为变量“平均成绩”(即模型中的自变量 MEANGR)是按与其样本平均值的离差测量的,所以模型是以高中成绩的样本平均分数(而不是 0 分)来作为参照组的特征之一.于是模型的参照组将是那些在普通中学(KEYSCH=0)取得高中总平均成绩(即 GRADE=83.7 或 MEANGR=0)的女生(GENDER=0).



因为理解发生比比理解对数发生比更容易, logistic 回归模型可以按事件发生比的形式改写为:

$$\begin{aligned}\text{odds} &= \frac{p}{1-p} = \exp(\alpha + \beta_1 \text{GENDER} + \beta_2 \text{KEYSCH} + \beta_3 \text{MEANGR}) \\ &= e^\alpha \times e^{\beta_1 \text{GENDER}} \times e^{\beta_2 \text{KEYSCH}} \times e^{\beta_3 \text{MEANGR}}.\end{aligned}$$

这样, 各项作用之间不再是加法关系, 而是乘法关系.

当 β_k 为正值时, e^{β_k} 将大于 1, 这就是说, x_k 每增加一个单位值时发生比会相应增加. 当 β_k 为负值时, e^{β_k} 将小于 1, 说明 x_k 每增加一个单位值时发生比会相应减少. 当 β_k 为 0 时, e^{β_k} 将等于 1, 那么 x_k 不论怎样变化发生比都不会变化. 发生比的变化由 e^{β_k} 所代表, 实际上它就是一个发生比率. 在下面, 我们将讨论如何以发生比率来对各种自变量(如连续变量、二分变量、分类变量)的 logistic 回归系数进行解释.

4.2.1 连续自变量的发生比率

β_k 的自然指数 e^{β_k} 提供了在 x_k 增加一个单位时发生比所变化的倍数. 这就是说, 在 $(x_k + 1)$ 时的发生比将等于在 x_k 时的发生比乘以 e^{β_k} , 即 $e^{\beta_k x_k} \cdot e^{\beta_k}$.

对于示范模型(式 2.5.1)而言, 自变量 MEANGR 的 logistic 回归系数为 $\hat{\beta}_3 = 0.4245$ (参见表 2.5.2), 因此 MEANGR 增加一个单位将会使发生比变化 $e^{0.4245} = 1.529$ 倍. 实际上, 发生比的变化倍数就是一个发生比率, 即它是 MEANGR + 1 时的发生比与原 MEANGR 时的发生比之比. 我们可以从下列推导中看到这一关系.

$$e^{\hat{\beta}_3} = \frac{e^\alpha e^{\beta_1 \text{GENDER}} e^{\beta_2 \text{KEYSCH}} e^{\beta_3 (\text{MEANGR} + 1)}}{e^\alpha e^{\beta_1 \text{GENDER}} e^{\beta_2 \text{KEYSCH}} e^{\beta_3 \text{MEANGR}}}, \quad 4.2.1$$

且 $e^{\hat{\beta}_3} = 1.529$.

这实际上就是对自变量 MEANGR 所估计的发生比率(参见表 2.5.2)^①.

给定的 $e^{\hat{\beta}_3}$ 为估计的发生比变化倍数, 自变量 x_k 每增加一个

^① 注意表 2.5.2 中截距(intercept)没有发生比率的输出, 这是因为截距的指数幂不是发生比率, 而只是参照组的发生比.

单位时所估计的发生比的百分点变化^①为 $(e^{\hat{\beta}_k} - 1) \times 100\%$. 因而, 自变量 MEANGR 每变化一个单位, 发生比率的变化率为:

$$(e^{0.4245} - 1) \times 100\% = 52.89\%.$$

由于 $\hat{\beta}_3$ 为自变量 MEANGR 的偏系数 (partial coefficient) 估计 (即在控制或调整模型中其他自变量的条件下 MEANGR 的作用), $e^{\hat{\beta}_3}$ 为调整发生比率 (adjusted odds ratio, 简称为 AOR) 的估计.

在社会科学研究中, 人们对一些连续变量中一个单位值的变化通常不感兴趣. 比如, 年龄增加 1 岁或收入增加 1 元的作用十分微小, 并不重要. 而一个离散的变化, 如年龄增加 5 岁或收入增加 100 元的变化也许更有意义. 为了估计连续变量的调整发生比率, 通常先要设定两个要比较的变量值. 比方用 a 和 b 标志这两个代表连续自变量 x_k 水平的值, 那么这个变量从 a 变到 b 时, 其 logit 的变化为:

$$\Delta(\text{odds})_{(x_k: b \text{ vs } x_k: a)} = (b - a)\hat{\beta}_k. \quad 4.2.2$$

其调整发生比率为:

$$\text{AOR} = e^{(\Delta \ln(\text{odds}))_{(x_k: b \text{ vs } x_k: a)}} = e^{(b - a)\hat{\beta}_k}. \quad 4.2.3$$

其中, $\hat{\beta}_k$ 代表在控制其他变量条件下 x_k 变化一个单位时导致 logit (或称对数发生比) 的变化估计.

在我们的例子中, 变量 MEANGR 是按总平均值的离差测量的. 让我们来看一看当该变量值比总平均值高 5 分时调整发生比率是多少. 应用式 4.2.2, 我们有

$$\text{AOR} = \exp[(5 - 0) \times 0.4245] = 8.352.$$

这意味着, 当一个学生的高中平均成绩高于总平均值 5 分时 ($83.7 + 5.0 = 88.7$), 进入大学的发生比约为平均水平的 8 倍. 与此相反, 当 MEANGR 比总平均分低 5 分时 ($83.7 - 5 = 78.7$), 相应的调整发生比率估计为:

$$\text{AOR} = \exp[(-5 - 0) \times 0.4245] = 0.120.$$

这表明, 一个学生的高中平均成绩比总平均成绩低 5 分时, 其升学的发生比将只有平均水平的 0.12 倍, 或只有平均水平的 12%.

① $100\% \times [e^{\hat{\beta}(r+1)} - e^{\hat{\beta}r}] / e^{\hat{\beta}r} = (e^{\hat{\beta}} - 1) \times 100\%.$

在 SAS 的 PROC LOGISTIC 程序中写入 UNITS 命令将得到特定单位变化的发生比率输出. 为了取得 MEANGR 在正负 5 分变化时的发生比率, 我们设定命令如下:

```
PROC LOGISTIC DESCENDING;
MODEL COLLEGE = GENDER KEYSCH MEANGR;
UNITS MEANGR = 5 - 5;
RUN;
```

在 SAS 输出中, 连续变量 MEANGR 在 ± 5 分变化时的发生比率被称为“Conditional Odds Ratio”, 它们的值与我们的手工计算相同(见表 4.2.1).

表 4.2.1 变量 MEANGR 在 ± 5 分变化时的发生比率

Conditional Odds Ratios		
Variable	Unit	Odds Ratio
MEANGR	5.000 0	8.354
MEANGR	-5.000 0	0.120

应该指出, 对于不同高中成绩水平的学生而言, 连续自变量 MEANGR 一定量的变化对发生比的作用也许不是一个常数. 比如, 高中平均成绩从 65 分到 70 分、从 80 分到 85 分, 及从 90 分到 95 分都是提高了 5 分, 然而它们对升学发生比的作用也许会有所不同. 当用连续自变量建立 logit 线性模型时, 这种非线性关系在建模时应加以考虑. 如果认为在自变量与 logit 之间存在着非线性关系, 那么应该考虑建立非线性模型. 我们将在第 6 章中对此加以比较详细的讨论.

4.2.2 二分类自变量的发生比率

正如在线性回归中一样, 像性别这样的二分类变量可以用 1 或 0 的编码值来表示男性或女性. 当变量只取值 1 或 0 时, 通常

称为标志变量(indicator variable)或虚拟变量(dummy variable). 在我们的例子中, 变量 GENDER 和 KEYSCH 都是二分类变量, 并已经按 1 或 0 编码. 当我们以普通中学为参照来看重点中学的发生比率时, 普通中学学生的编码 KEYSCH=0, 重点中学学生的编码 KEYSCH=1. 当 KEYSCH=1 时, logit 为:

$$\ln(p_i/(1-p_i))_{KEYSCH=1} = \alpha + \beta_1 \text{GENDER} + \beta_2 \times 1 + \beta_3 \text{MEANGR}, \quad 4.2.4$$

当 KEYSCH=0 时, logit 为:

$$\ln(p_i/(1-p_i))_{KEYSCH=0} = \alpha + \beta_1 \text{GENDER} + \beta_2 \times 0 + \beta_3 \text{MEANGR}. \quad 4.2.5$$

从 KEYSCH=1 的 logit 式中减去 KEYSCH=0 的 logit 式后, 我们发现两个 logit 式的差别正好为变量 KEYSCH 的系数 β_2 , 这可以从下面推导中获得:

$$\begin{aligned} \ln(\text{odds})_{(KEYSCH=1 \text{ vs } KEYSCH=0)} &= \ln(p/(1-p))_{KEYSCH=1} - \ln(p/(1-p))_{KEYSCH=0} \\ &= (1-0)\beta_2 \\ &= \beta_2, \end{aligned} \quad 4.2.6$$

其中 $\ln(\text{odds})$ 为控制其他自变量条件下, 重点中学与普通中学之间对数发生比的差. 其实, 它就是发生比率的对数. 那么 e^{β_2} 即为控制 GENDER 和 MEANGR 条件下 KEYSCH=1 对比 KEYSCH=0 的发生比率, 其估计值为:

$$\text{AOR} = \exp(\ln(\text{odds})_{KEYSCH=1 \text{ vs } KEYSCH=0}) = e^{\beta_2}. \quad 4.2.7$$

我们又一次看到调整发生比率就是变量 KEYSCH 的 logistic 回归系数的指数幂.

在这一例题中, 重点中学对比普通中学的调整发生比率为 $e^{\beta_2} = 2.492$ (见表 2.5.2). 这表示重点中学学生在毕业后考入大学的发生比约为普通中学学生的 2.5 倍. 此外, 对 GENDER 的调整发生比率为 $e^{\beta_1} = 2.378$, 这表示在控制了变量 KEYSCH 和 MEANGR 的条件下, 男生的发生比约为女生的 2.4 倍.

有必要指出, 将发生比率看作事件发生可能性或概率的倍数是不正确的. 比如, 我们不能说男生考入大学的可能性是女生的 2.4 倍, 因为这意味着男生考入大学的概率是女生的 2.4 倍. 为什么呢? 比方 p_m 为男生考入大学的概率, p_f 为女生考入大学

的概率, 那么男生对女生的考入大学的发生比率为:

$$\frac{p_m/(1-p_m)}{p_f/(1-p_f)} = \left(\frac{p_m}{p_f} \right) \left(\frac{1-p_f}{1-p_m} \right). \quad 4.2.8$$

上述错误解释只能应用于式 4.2.8 中右侧的第一项 (p_m/p_f), 它被称为考入大学的相对风险 (Hosmer and Lemeshow, 1989). 然而, 这并不等于发生比率, 除非 p_m 和 p_f 值都非常小, 在这种情况下式 4.2.8 右侧第二项 $(1-p_f)/(1-p_m)$ 接近于 1.

4.2.3 分类自变量的发生比率

当分类自变量多于两个类别时, 我们就需要建立一组虚拟变量来代表类型的归属性质. 如果一个分类变量包括 m 个类别, 那么可以产生 m 个相应的虚拟变量. 但是, 建模需要的虚拟变量的数目应等于分类总数减 1. 这就是说, 如果变量包括 m 个类别, 那只需要建立 $m-1$ 个虚拟变量即可. 我们不能同时在模型中包括 m 个虚拟变量, 因为其中的每一个虚拟变量都是其余虚拟变量的线性组合, 这会违反回归的基本假设条件.

从建模中省略的那个类别 (omitted category) 称作参照类 (reference category). 比如, 学校的类型是个名义变量, 如果我们定义它有三个类别: 重点中学, 城市普通中学, 农村普通中学. 我们将在模型中设置两个虚拟变量 SCH1 (表示重点中学) 和 SCH2 (表示城市普通中学). 模型中没有包括表示农村普通中学的虚拟变量, 所以农村普通中学这个类别就作为参照类了. 分类变量的哪一类别应为参照类是随意的, 通常取决于研究人员的偏好, 或解释上的方便. 在省略农村普通中学虚拟变量的情况下, 当一个学生属重点中学时, 虚拟变量 SCH1 = 1, 否则, SCH1 = 0; 当属城市普通中学时, 虚拟变量 SCH2 = 1, 否则, SCH2 = 0. 这时, 我们的模型如下:

$$\ln\left(\frac{p}{1-p}\right) = \alpha + \beta_1 \text{GENDER} + \beta_2 \text{SCH1} + \beta_3 \text{SCH2} + \beta_4 \text{MEANGR}. \quad 4.2.9$$

如同在线性回归中一样, 系数 β_2 代表重点中学与农村普通中学 (参照类) 在因变量上的差别. 所以,

$$\beta_2 = \ln(\text{odds})_{\text{sch1 vs sch3}},$$

并且 e^{β_2} 为重点中学对农村普通中学的发生比率, 在同样的基础上, e^{β_3} 为城市普通中学对农村普通中学的发生比率.

有时, 我们还将连续变量值分段改为分类变量来使用. 比如, 对于学习成绩(GRADE), 可以不用其实际值, 而将其分成三个档次: 低、中、高. 因此, 建模需要产生两个虚拟变量, 如 $85 \leq \text{GRADE} < 90$ 时令 $\text{GRADE2} = 1$, 否则令 $\text{GRADE2} = 0$; 当 $\text{GRADE} \geq 90$ 时令 $\text{GRADE3} = 1$, 否则令 $\text{GRADE3} = 0$; 而代表第一档次($\text{GRADE} < 85$)的虚拟变量 GRADE1 从建模中省略, 因而, 第一档次就作为参照类. 这一模型将如下所示:

$$\ln \left(\frac{p}{1-p} \right) = \alpha + \beta_1 \text{GENDER} + \beta_2 \text{KESCH} + \beta_3 \text{GRADE2} + \beta_4 \text{GRADE3}, \quad 4.2.10$$

β_3 即高中平均成绩在 85 至 90 分的学生与低于 85 分的学生之间在因变量(即对数发生比)值上的差别, 所以

$$\beta_3 = \ln(\text{odds})_{\text{GRADE2 vs GRADE1}},$$

并且, GRADE2 对 GRADE1 的发生比率为 e^{β_3} . 同样, GRADE3 对 GRADE1 的发生比率为 e^{β_4} .

让我们运行模型 4.2.10 作为示范. 下面列出 SAS 和 SPSS 的程序, 相应的输出见表 4.2.2.

```
* SAS PROGRAM: LOGISTIC REGRESSION WITH CATEGORICAL VARIABLE;
OPTIONS NOCENTER PS = 500 LS = 150;
LIBNAME LIB 'D:\ LOGIT';
DATA DATA1;
SET LIB.COLLEGE;
GRADE1 = 0; GRADE2 = 0; GRADE3 = 0;
IF GRADE < 85 THEN GRADE1 = 1;
IF 85 < = GRADE < 90 THEN GRADE2 = 1;
IF GRADE > = 90 THEN GRADE3 = 1;
PROC LOGISTIC DESCENDING;
MODEL COLLEGE = GENDER KEYSCH GRADE2 GRADE3;
RUN;
```

```

* SPSS PROGRAM: LOGISTIC REGRESSION WITH CATEGORICAL VARIABLE.
GET FILE = 'D:\LOGIT\COLLEGE.SAV'.
COMPUTE GRADE2 = 0.
COMPUTE GRADE3 = 0.
IF (GRADE >= 85 AND GRADE < 90)   GRADE2 = 1.
IF (GRADE >= 90)   GRADE3 = 1.
LOGISTIC REGRESSION VAR = COLLEGE
  /METHOD = ENTER GENDER KEYSCH GRADE2 GRADE3.

```

表 4.2.2 对分类自变量的 logistic 回归

SAS 输出

Analysis of Maximum Likelihood Estimates							
Variable	DF	Parameter Estimate	Standard Error	Wald Chi-Square	Pr > Chi-Square	Standardized Estimate	Odds Ratio
INTERCPT	1	-2.5732	0.1709	226.7748	0.0001		
GENDER	1	1.1156	0.1742	41.0011	0.0001	0.306155	3.052
KEYSCH	1	0.8519	0.2292	13.8159	0.0002	0.159065	2.344
GRADE2	1	2.0911	0.1705	150.4666	0.0001	0.534877	8.094
GRADE3	1	3.8223	0.4230	81.6679	0.0001	0.541484	45.708

SPSS 输出

Variable	B	S.E.	Wald	d.f.	Sig.	R	Exp (B)
GENDER	1.1156	.1742	41.0006	1	.0000	.1749	3.0515
KEYSCH	.8519	.2292	13.8158	1	.0002	.0963	2.3441
GRADE2	2.0911	.1705	150.4660	1	.0000	.3412	8.0938
GRADE3	3.8222	.4230	81.6680	1	.0000	.2499	45.7060
Constant	-2.5731	.1709	226.7741	1	.0000		

从表 4.2.2 所列 SAS 和 SPSS 的 logistic 回归的输出中, 我们看到 $e^{\beta_2} = 8.09$ 和 $e^{\beta_3} = 45.71$. 这说明, 在其他条件相同时, GRADE2 和 GRADE3 升学的发生比分别约为参照类 GRADE1 发生比的 8.09 倍和 45.71 倍.

在应用 SPSS 做 logistic 回归分析时, 我们用不着专门从分类变量建立虚拟变量的数据处理步骤(新版 SAS 也增加了此功能,

见尾注)。SPSS 的 logistic 回归程序中有一个十分方便的功能能够自动将分类变量转换为一套设计变量 (design variables)、如虚拟编码变量 (dummy coding variables)、效应编码变量 (effect coding variables)、及其他一些设计变量 (下面我们会具体介绍虚拟编码和效应编码)。它们都是作为一组变量, 同时纳入或排除出模型。程序既对这个分类变量作为整体进行显著性检验, 也对每一类别单独进行显著性检验。不同的设计变量类型可以通过选择程序中不同对比 (contrast) 类型来获得。其中, 最常用的对比类型有离差 (deviation)、简单 (simple) 和标记 (indicator) 三种。

程序默认的对比类型为使用效应编码的离差对比 (deviation contrast)。在这种对比中, 分类变量的每一类型是与整体 logit 进行比较 (即, 与 logistic 回归的总 logit 平均值比较, 而不是与被省略的参照类进行比较)。按照默认状态, 分类自变量的最后一类将作为参照类, 程序不输出其参数估计。要选择其他类型作为参照类, 可以在程序命令中 DEVIATION 关键词后的括号内设定此类型的编码值。

简单对比 (simple contrast) 使用虚拟编码产生设计变量。分类自变量中的每一类型是与参照类比较。简单对比也可以灵活地选择参照类。标记对比 (indicator contrast) 标志分类属性是否出现, 实际上这种对比产生的结果与简单对比相同。

让我们对变量 MEANGR 重新编码为三档的分类自变量 CGRADE; CGRADE = 1 代表平均高中成绩在 85 分以下; CGRADE = 2 为 85 至 90 分之间; CGRADE = 3 代表 90 分及以上。注意, 这个新变量仍是数字型变量, 取值为 1、2、3, 分别代表不同类型。如果在 SPSS 的 logistic 回归程序中以变量 CGRADE 作为分类自变量, 必须在模型设置窗口应用子命令 “CONTRAST (CGRADE) = OPTION” 将其设为分类变量, 否则 SPSS 的 logistic 回归程序会将其作为连续变量对待。

在下面的 SPSS 程序中的第一个 logistic 回归程序中, 因为默认状态为选择最后一类为参照类, 所以省略了子命令 “CONTRAST = DEVIATION” 之后的对参照类 CGRADE = 3 的设置。参照类无系数估计, 而 CGRADE (1) 和 CGRADE (2) 的系数估计显示在表 4.2.3 的上部, 分别代表 CGRADE = 1 类和



CGRADE = 2 类的升学发生比与总平均升学发生比的差别。CGRADE (1) 的系数为负值且统计性显著, 表明第一档成绩 (GRADE < 85) 的学生比平均水平有较低的升学发生比。然而, CGRADE (2) 的系数统计性不显著, 表明这一档 ($85 \leq \text{GRADE} < 90$) 成绩的学生与总的升学发生比没有显著差别。

总的来说, 对分类变量 CGRADE, Wald 统计量是显著的, 这表明至少有一类在升学方面与其他类存在差别。我们将在下一章对 Wald 统计量进行讨论。

尽管参照类无系数估计, 该系数的估计值很容易计算, 因为所有设计变量系数估计值的和等于零, 因而, 参照类的系数估计值就是其他类别系数估计值之和的相反数。在本例中, CGRADE = 3 类的系数值为 $-(-1.9711 + 0.12) = 1.8511$ 。然而, 有时有必要运行两次以不同类别作为参照类的模型估计, 因为这不仅可以取得所有三种类别的系数估计, 而且还可以取得省略类型的标准误和显著性检验结果。

在第二个 logistic 回归程序中, 我们设置 “DEVIATION (1)” 来省略分类变量 CGRADE 的第 1 类 (即 GRADE < 85)。因此, 这一类作为参照类而无系数输出。于是, 在表 4.2.3 中部表示的 CGRADE (1) 和 CGRADE (2) 的系数便分别是 CGRADE = 2 类和 CGRADE = 3 类的系数。CGRADE (2) 的系数为正值且统计性显著, 表明第三档成绩 (GRADE ≥ 90) 的学生比平均水平有更高的升学发生比。

*** SPSS PROGRAM: LOGISTIC REGRESSION WITH CATEGORICAL VARIABLES.**

GET FILE = 'D: \ LOGIT \ COLLEGE.SAV'.

IF (GRADE < 85) CGRADE = 1.

IF (GRADE $\geq$ 85 AND GRADE < 90) CGRADE = 2.

IF (GRADE $\geq$ 90) CGRADE = 3.

*** (DEVIATION CONTRAST OMITTING THE LAST CATEGORY).**

LOGISTIC REGRESSION VAR = COLLEGE

/METHOD = ENTER GENDER KEYSCH CGRADE

/CONTRAST (CGRADE) = DEVIATION.

* (DEVIATION CONTRAST OMITTING THE FIRST CATEGORY).

LOGISTIC REGRESSION VAR = COLLEGE

/METHOD = ENTER GENDER KEYSCH CGRADE

/CONTRAST (CGRADE) = DEVIATION (1).

在回归分析中对分类变量还经常采用标记对比(indicator contrast),我们在下列 SPSS 程序中对此进行示范. 在 SPSS 的 LOGISTIC 回归程序中子命令“CONTRAST (CGRADE) = INDICATOR (1)”将分类变量 CGRADE 的第一类(即 GRADE < 85)作为参照类,并输出表 4.2.3 中下部的统计结果,它与表 4.2.2 中应用虚拟变量的回归结果一样.

* (INDICATOR CONTRAST).

LOGISTIC REGRESSION VAR = COLLEGE

/METHOD = ENTER GENDER KEYSCH CGRADE

/CONTRAST (CGRADE) = INDICATOR (1).

表 4.2.3 对分类变量进行 logistic 回归的输出

SPSS 输出

1. CONTRAST (CGRADE) = DEVIATION ; 最后一类为参照类

-----Variables in the Equation-----							
Variable	B	S.E.	Wald	d.f.	Sig.	R	Exp (B)
GENDER	1.1156	.1742	41.0006	1	.0000	.1749	3.0515
KEYSCH	.8519	.2292	13.8158	1	.0002	.0963	2.3441
CGRADE			194.4753	2	.0000	.3865	
CGRADE (1)	-1.9711	.1626	146.9836	1	.0000	.3372	.1393
CGRADE (2)	.1200	.1617	.5508	1	.4580	.0000	1.1275
Constant	-.6020	.1895	10.0897	1	.0015		

2. CONTRAST (CGRADE) = DEVIATION (1); 第一类为参照类

Variable	B	S.E.	Wald	d.f.	Sig.	R	Exp (B)
GENDER	1.1156	.1742	41.0006	1	.0000	.1749	3.0515
KEYSCH	.8519	.2292	13.8158	1	.0002	.0963	2.3441

续表

CGRADE			194.4753	2	.0000	.3865	
CGRADE (1)	.1200	.1617	.5508	1	.4580	.0000	1.1275
CGRADE (2)	1.8511	.2758	45.0407	1	.0000	.1837	6.3670
Constant	-.6020	.1895	10.0897	1	.0015		

3. CONTRAST (CGRADE) = INDICATOR (1); 第一类为参照类

Variables in the Equation							
Variable	B	S.E.	Wald	d.f.	Sig.	R	Exp (B)
GENDER	1.1156	.1742	41.0006	1	.0000	.1749	3.0515
KEYSCH	.8519	.2292	13.8158	1	.0002	.0963	2.3441
CGRADE			194.4753	2	.0000	.3865	
CGRADE (1)	2.0911	.1705	150.4660	1	.0000	.3412	8.0938
CGRADE (2)	3.8222	.4230	81.6680	1	.0000	.2499	45.7060
Constant	-2.5731	.1709	226.7741	1	.0000		

从以上示范中, 我们看到选择不同对比方式对分类自变量作为整体的显著性检验没有影响(不论选用哪一种对比方式, Wald 统计量值不变), 但是对于个别类型的系数及其统计检验结果却有所影响。尽管不同对比方式导致不同的 logistic 回归系数, 但并不表明其结果是互相矛盾的。应用 deviation 对比(参见表 4.2.3 的第一和第二部分)得到某一特定类别与所有类别的平均水平的比较情况; 而应用 simple 及 indicator 对比(参见表 4.2.3 的第三部分)则得到某一特定类别与参照类(即省略的类别)的比较。我们可以通过选择不同对比方式来进行所想要的比较。

在 SPSS 的 LOGISTIC 回归程序中可以调用不同的编码方式, 其中最常用的是虚拟编码和效应编码。当选用 indicator 对比方式时, 计算机程序将自动建立 $(m - 1)$ 个设计变量按虚拟编码标志类别属性。其中, 编码 1 表示案例属于变量所标志的类别, 编码 0 则表示案例不属于变量所标志的类别。我们看到, 通过数

据处理建立 $(m - 1)$ 个虚拟变量与直接应用分类变量 (即 CGRADE) 并且调用 indicator 子命令可以得到相同的回归系数和统计检验结果 (参见表 4.2.2 和表 4.2.3)。

若选用 deviation 对比, 计算机程序将使用效应编码产生设计变量。在效应编码规则中, 与虚拟编码相同的是, 1 代表案例属于变量所标志的类别。然而, 对于案例不属于变量标志类别时, 却是分别用 0 或 -1 来代表, 其中 0 代表包括在模型中的其他类别, 而 -1 代表参照类。

在我们的例子中, DEVIATION (1) 将变量 CGRADE 的第一类作为“参照类”, 即将其从模型中省略。其结果在表 4.2.4 的上部。在“Parameter Coding (1)”栏目之下, 可以看到编码值 -1 被赋予参照类, 即分类变量 CGRADE 的第一类 ($\text{GRADE} < 85$); 编码值 1 被赋予第二类 (即 $85 \leq \text{GRADE} < 90$); 编码值 0 被赋予第三类 ($\text{GRADE} \geq 90$)。这些编码产生的变量 CGRADE (1) 的系数估计在表 4.2.3 的第二部分, 它代表第二类的平均 logit 水平与总平均 logit 水平的对比。在“Parameter Coding (2)”栏目下的编码产生变量 CGRADE (2) 的系数估计, 代表第三类的平均 logit 水平与总平均 logit 水平的对比。

对应于 indicator 对比的编码很简单。即, 1 代表此类出现, 0 代表此类不出现。这些编码产生的结果见表 4.2.4 的下半部分。

表 4.2.4 SPSS 的 logistic 回归程序中离差对比和标记对比的编码形式

CONTRAST (CGRADE) = DEVIATION (1) 的编码形式				
	Value	Freq	Parameter Coding	
			(1)	(2)
CGRADE				
	1.00	616	-1.000	-1.000
	2.00	313	1.000	.000
	3.00	71	.000	1.000

续表

	Value	Freq	Parameter Coding	
			(1)	(2)
CGRADE				
	1.00	616	.000	.000
	2.00	313	1.000	.000
	3.00	71	.000	1.000

用 SAS 和 SPSS 运行模型 4.2.10 时, 虚拟编码是很容易建立的. 现在我们来示范如何在数据处理中建立效应编码:

$$\ln \left(\frac{p}{1-p} \right) = \alpha + \beta_1 \text{GENDER} + \beta_2 \text{KEYSCH} + \beta_3 \text{GD2} + \beta_4 \text{GD3}, \quad 4.2.11$$

其中, 变量 GD2 和 GD3 代表 CGRADE 中的第 2 类和第 3 类. 然而, 它们是按效应编码, 因此有三种赋值: -1, 0, 1. 若 CGRADE = 1, 令 GD2 = -1; 若 CGRADE = 2, 令 GD2 = 1; 若 CGRADE = 3, 令 GD2 = 0. 以同样方式, 若 CGRADE = 1, 令 GD3 = -1; 若 CGRADE = 2, 令 GD3 = 0; 若 CGRADE = 3, 令 GD3 = 1. 表 4.2.5 所提供的一些数据案例表明在变量 CGRADE 各类上效应编码与虚拟编码的不同.

表 4.2.5 采用虚拟编码和效应编码的若干案例变量

OBS	GRADE	CGRADE	Dummy-coding		Effect-coding	
			GRADE2	GRADE3	GD2	GD3
1	82.20	1	0	0	-1	-1
2	91.80	3	0	1	0	1
3	89.80	2	1	0	1	0
4	87.30	2	1	0	1	0
5	81.70	1	0	0	-1	-1
...						

续表

996	92.90	3	0	1	0	1
997	88.70	2	1	0	1	0
998	85.10	2	1	0	1	0
999	88.80	2	1	0	1	0
1000	85.40	2	1	0	1	0

对于变量 GRADE2 和 GRADE3 采取的是虚拟编码, 而对变量 GD2 和 GD3 采取的是效应编码. 虚拟编码十分简单, 而效应编码与虚拟编码很类似, 只不过对参照类所赋的值是 -1. 相应的 SAS 和 SPSS 程序如下.

```
* SAS PROGRAM: Effect - coding;
OPTIONS NOCENTER PS = 500 LS = 150;
LIBNAME LIB 'D: \ LOGIT';
DATA DATA1;
SET LIB.COLLEGE;

GD2 = 0; GD3 = 0;
IF 85 <= GRADE < 90 THEN GD2 = 1;
IF GRADE >= 90 THEN GD3 = 1;
IF GRADE < 85 THEN GD2 = - 1;
IF GRADE < 85 THEN GD3 = - 1;

PROC LOGISTIC DESCENDING;
MODEL COLLEGE = GENDER KEYSCH GD2 GD3;
RUN;
```

```
* SPSS PROGRAM: Effect - coding;
GET FILE = 'D: \ LOGIT \ COLLEGE.SAV'.
COMPUTE GD2 = 0.
COMPUTE GD3 = 0.
IF (GRADE >= 85 AND GRADE < 90) GD2 = 1.
IF (GRADE >= 90) GD3 = 1.
IF (GRADE < 85) GD2 = - 1.
```

```

IF (GRADE<85) GD3 = -1.
LOGISTIC REGRESSION VAR = COLLEGE
/METHOD = ENTER GENDER KEYSCH GD2 GD3.

```

表 4.2.6 提供了变量以效应编码的模型的输出。我们可以看到，GD2 和 GD3 的系数与表 4.2.3 中第 2 部分相应类别的系数完全相同。

表 4.2.6 效应编码变量的 logistic 回归的输出

SAS 输出

Analysis of Maximum Likelihood Estimates							
		Parameter	Standard	Wald	Pr >	Standardized	Odds
Variable	DF	Estimate	Error	Chi-Square	Chi-Square	Estimate	Ratio
INTERCPT	1	-0.6020	0.1895	10.0895	0.0015	.	.
GENDER	1	1.1156	0.1742	41.0011	0.0001	0.306155	3.052
KEYSCH	1	0.8519	0.2292	13.8159	0.0002	0.159065	2.344
GD2	1	0.1200	0.1617	0.5508	0.4580	0.060555	1.127
GD3	1	1.8511	0.2758	45.0408	0.0001	0.637656	6.367

SPSS+ 输出

Variable	B	S.E.	Wald	d.f.	Sig.	R	Exp (B)
GENDER	1.1156	.1742	41.0006	1	.0000	.1749	3.0515
KEYSCH	.8519	.2292	13.8158	1	.0002	.0963	2.3441
GD2	.1200	.1617	.5508	1	.4580	.0000	1.1275
GD3	1.8511	.2758	45.0407	1	.0000	.1837	6.3670
Constant	.6020	.1895	10.0897	1	.0015		

4.3 用概率来解释自变量的作用

在 logistic 回归模型中因变量是对数发生比, 即 $\ln(\text{odds})$ 或 logit. 这两种概念都比较难以把握. 比如, 虚拟编码的自变量“性别”(GENDER, 1 表示男, 0 表示女)的系数为 1.12. 这表明男生对于对数发生比有正的作用. 然而, 1.12 单位的对数发生比差别并没有明确说明男生比女生在升学机会上的差别到底有多大. 尽管用发生比率(odds ratio)来解释较为容易理解, 但很多人更愿意用概率来描述这一问题. 这样, 我们除了需要检查自变量对于对数发生比的偏作用(partial effect)以外, 还要检查其对事件发生概率的偏作用. 对事件发生概率的偏作用可以通过对 logistic 函数(式 1.3.11)求该自变量的偏导数来检查. 其求导公式如下:

$$\begin{aligned}\frac{\partial P(y=1|x)}{\partial x_k} &= \frac{\partial [e^{\alpha + \sum \beta_k x_k} / (1 + e^{\alpha + \sum \beta_k x_k})]}{\partial x_k} \\ &= \frac{\beta_k e^{\alpha + \sum \beta_k x_k}}{(1 + e^{\alpha + \sum \beta_k x_k})^2} \\ &= \beta_k \frac{e^{\alpha + \sum \beta_k x_k}}{1 + e^{\alpha + \sum \beta_k x_k}} \frac{1}{1 + e^{\alpha + \sum \beta_k x_k}} \\ &= \beta_k p(1-p).\end{aligned}\quad 4.3.1$$

于是, 变量 x_k 对事件发生概率的偏作用就等于自变量回归系数 β_k 与 $p(1-p)$ 的乘积(p 为事件发生概率). 偏作用的符号由 β_k 决定, 因为 $p(1-p)$ 永远为正值. 作用的幅度依赖于 β_k 的幅度和对应于 x_k 特定值的概率, 因而它与模型中所有其他自变量有关. 这样, 不同于对发生比的作用的解释, 对事件发生概率的偏作用是随 p 值的变化而变化的.

在图 4.1 中我们用一个简单模型(式 1.3.7)来显示当 x 变化一个单位时 $P(y=1|x)$ 的变化率. 如图所示, 画一条直线与 x 在特定值时的曲线相切, 描述了在切点上的斜率. 对于 logistic 回归系数 β 而言, 这条直线的斜率等于 $\beta p(1-p)$. 比如, 这一直线在 $p=0.9$ 或 $p=0.1$ 点与曲线相切的话, 其斜率为 $\beta(0.9)(0.1)=0.09\beta$. 而在概率接近于 0 或 1 时相切, 直线的斜率接

近于 0. 在 $p = 0.5$ 时相切, 直线的斜率最陡, 达到 $\beta(0.5)$ ($0.5) = 0.25\beta$, 此时的 x 值为 $-\alpha/\beta$. 我们可以通过式 1.3.10 验证: 将 $p = 0.5$ 代入, 可解得 $x = -\alpha/\beta$. 这一 x 值有时被称为中位有效水平 (median effective level), 它代表了两种结果都有 50% 机会时的 x 水平 (Agresti, 1996).




图 4.1 当 x 变化一个单位时 $P(y=1|x)$ 的变化率

通常研究对概率的偏作用时所采用的方法是, 在自变量的平均值 $\bar{x}$ 处计算 $\hat{p}$, 然后再用公式 4.3.1 计算出偏作用.

这种方法的局限性是: 第一, 这种测量不适用标记变量和名义变量; 其次, 通常实际所需要的是对自变量的离散性变化 (而不是一个无限小的变化) 所导致的概率变化进行研究. 在预测概率中通常需要测量离散性变化, 这一问题将在下一节讨论.

4.4 预测概率

正如线性回归模型能够预测一样, 根据 logistic 回归模型, 我们也能够获得事件发生的预测概率. 如果我们已知所有参数估计 $\hat{\alpha}$ 和 $\hat{\beta}_k$, 并且已确定某一案例的 x_1 到 x_k 的所有值, 便可将这些值代入 logistic 回归公式, 并计算出预测概率. 这一预测概率即该案例在定义条件下经历某事件的预测概率.

将系数估计和自变量值代入 logistic 函数 (式 1.3.11), 便取

得下列公式来计算预测概率：

$$\begin{aligned}\hat{p} &= \frac{e^{\hat{\alpha} + \sum \hat{\beta}_k x_k}}{1 + e^{\hat{\alpha} + \sum \hat{\beta}_k x_k}} \\ &= \frac{\text{odds}}{1 + \text{odds}},\end{aligned}\quad 4.4.1$$

其中, $\hat{\alpha}$ 是截距参数估计, $\hat{\beta}_k$ 为第 k 个自变量 x_k 的斜率系数估计. 这样, 我们可以由式 1.3.12 来计算估计的 logit (即 $\ln(\text{odds})$), 再将其转换成估计的 odds, 然后用式 4.4.1 来计算预测概率^①.

作为示范, 我们通过模型 2.5.1 (系数在表 2.5.2 中提供) 来预测具有平均成绩的普通高中男生的升学概率 (即 $\text{GENDER} = 1$, $\text{KEYSCH} = 0$, $\text{MEANGR} = 0$). 这组学生的 logit 估计为:

$$-1.76 \times 1 + 0.87 \times 1 + 0.91 \times 0 + 0.42 \times 0 = -0.89,$$

随后, 推算出发生比为 $e^{-0.89} = 0.41$, 并得到概率估计为 $0.41/(1+0.41) = 0.29$.

在得到给定自变量值的预测概率后, 我们就可以计算在某一自变量值发生离散变化时预测概率的变化了. 其方法为, 在该自变量初始值 and 变化值条件下计算预测概率的差. 这种方法称为概率离散变化法 (discrete change in probability) (Long, 1997), 既可以应用于连续变量, 也可以用于离散变量 (Greene, 1990; Roncek, 1991, 1993; Long, 1997).

我们用 Δ 表示 x_k 的离散变化, 那么 x_k 变化 Δ 个单位导致预测概率的变化为:

$$P[y=1|x, (x_k + \Delta)] - P(y=1|x, x_k). \quad 4.4.2$$

这可以解释为随变量 x_k 从值 x_k 变化到值 $(x_k + \Delta)$ 时, 事件发生的预测概率的变化. 随 x_k 变化产生的概率变化量值赖于 x_k 的变化量、 x_k 的初始值、以及决定这一概率的所有其他变量值.

我们在实际研究中计算预测概率变化的时候, 需要选择适当的自变量值. 例如, 我们需要了解在来自重点中学和普通中学的具有平均成绩水平的男生之间的升学方面的预测概率的差别. 这等于是计算在 $\text{GENDER} = 1$ 和 $\text{MEANGR} = 0$ 的条件下当变量

^① 式 4.4.1 还可以看作: $\frac{\text{odds}}{1 + \text{odds}} = \frac{\hat{p}/(1 - \hat{p})}{1 + \hat{p}/(1 - \hat{p})} = \hat{p}$.

KEYSCH 的值从 0 变为 1 时预测概率的变化。

从上面的计算中我们已经知道, 当 $GENDER = 1$ 、 $KEYSCH = 0$ 、 $MEANGR = 0$ 时, 预测概率为 0.29。要了解预测概率的变化, 就要在模型中设定 $GENDER = 1$ 、 $KEYSCH = 1$ 、 $MEANGR = 0$ 。那么, 估计的 logit 为: $-1.76 + 0.87 \times 1 + 0.91 \times 1 + 0.42 \times 0 = 0.02$ 。

于是, 推算出 odds 为 $e^{0.02} = 1.02$, 并进一步推算出概率为 $1.02 / (1 + 1.02) = 0.51$ 。那么, 来自重点中学和普通中学的具有平均成绩水平的男生之间的升学方面的预测概率的差别为: $0.51 - 0.29 = 0.22$ 。

同样, 离散变化法也可以用于一个连续自变量值变化时的概率变化。

最后, 在解释发生比率和预测概率时有两点必须注意:

1) 式 4.4.2 所表达的预测概率变化是离散变化, 它不等于式 4.3.1 所表达的概率上的偏变化, 除非 Δ 的值为无限小。

2) 发生比乘以一个常量因子产生的变化不等于相应概率乘以同一常量因子产生的变化。这可以从表 4.4.1 中看到。当发生比乘以一个常量因子 2 时, 发生比变化的倍数是个常量 2, 而相应的概率变化却不是一个常量。表 4.4.1 中, 在“Original”栏下, 是原有的发生比和相应概率; 在“Changed”栏下, 是乘以一个常量因子 2 以后的发生比和相应概率; “Factor Change”栏的值是“Changed”栏的值与“Original”栏的值的商。我们可以看见, 当发生比非常小时, 概率变化的倍数约等于发生比变化的倍数。当发生比很大时, 概率变化的倍数约等于 1, 而发生比的变化倍数仍然是 2。

表 4.4.1 发生比乘以一个常量因子产生的变化与相应概率乘以同一常量因子

Original		Changed		Factor Change	
Odds	Prob.	Odds	Prob.	Odds	Prob.
1/1000	0.001	2/1000	0.002	2.000	1.998
1/100	0.010	2/100	0.020	2.000	1.980
1/10	0.091	2/10	0.167	2.000	1.833
1/2	0.333	2/2	0.500	2.000	1.500
1/1	0.500	2/1	0.667	2.000	1.333

续表

Original		Changed		Factor Change	
Odds	Prob.	Odds	Prob.	Odds	Prob.
2/1	0.667	4/1	0.800	2.000	1.200
10/1	0.909	20/1	0.952	2.000	1.048
100/1	0.990	200/1	0.995	2.000	1.005
1000/1	0.999	2000/1	0.999	2.000	1.000

注：此表引自 Long (1997, p.82) 的表 3.10.

4.5 标准化系数

通常在线性回归模型中的自变量是以不同尺度测量的。比如，收入的单位是元，年龄的单位是岁，长度单位可用厘米、分米、或米，如此等等。有时一个变量是按 Likert 标度 (Likert scale) 测量的，比如 5 档尺度 (5-point scale) (0 - 强烈反对; 1 - 反对; 2 - 中立; 3 - 支持; 4 - 坚决支持)。于是，某个自变量中的一个单位的变化并不等价于另一个自变量上一个单位的变化。如果我们要比较因变量与不同自变量之间关系的强度，通常采用标准化回归系数。出于同样的原因，在 logistic 回归分析中也可以考虑使用标准化系数 (standardized coefficients)。

什么是标准化系数？标准化系数表示自变量一个标准差的变化所导致的因变量上以其标准差为单位测量的变化。在线性回归中，标准化回归系数 β^* 可以由未标准化的回归系数 β 和 y 及 x_k 的标准差 (即 s_y 和 s_{x_k}) 来计算：

$$\beta^* = \beta (s_x / s_y). \quad 4.5.1$$

另外一种取得标准化系数的方法是，在回归前先将因变量和自变量转换为标准化变量，即将每个原始变量值分别减去其平均值，然后再除以其标准差，得到 $y^* = (y - \bar{y}) / s_y$ 和 $x^* = (x - \bar{x}) / s_x$ ，然后再对标准化变量进行回归，也能得到同样的标准化回归系数。

在应用标准化因变量和多个标准化自变量的模型中，所有自变量与因变量的关系都是以同样的单位 (标准差) 测量的。所以，虽然其原始变量是以不同尺度测量的，但通过标准化后自变量对

因变量的作用便具可比性。

应该注意的是,对分类变量如性别、民族等,变量的标准化没有意义,因而标准化系数也就无意义了。通常,标准化系数是用来比较不同尺度的连续自变量的作用幅度的。尤其是 Likert 标度是带随意性的,比如,5 档尺度可以是:0, 1, 2, 3 和 4;也可以是:1, 2, 3, 4 和 5。因而,将 Likert 标度测量标准化,使之具有可比性,是很有意义的。

在 logistic 回归中,标准化系数的计算较为复杂。因为 logistic 回归中的因变量不是观测二类变量 y ,而是 logit 或称对数发生比,对于它不能直接计算其平均值和标准差。然而,我们可以通过估计的 logit 和类 R^2 来间接计算其标准差。在回归分析中通常用 RSS 表示回归平方和,用 TSS 表示总平方和,而模型确定系数 $R^2 = \text{RSS}/\text{TSS}$ 。将其分子分母同时除以各自的自由度 k 和 $(n-1)$ (其中 k 是自变量个数, n 为样本规模),有:

$$\begin{aligned} R^2 &= [\text{RSS}/k] / [\text{TSS}/(n-1)] \\ &= s_y^2 / s_y^2. \end{aligned} \quad 4.5.2$$

将式 4.5.2 变形以求解 s_y^2 , 有

$$s_y^2 = s_y^2 / R^2. \quad 4.5.3$$

对 logistic 回归来说,式 4.5.3 便为 $s_{\text{logit}(y)}^2 = s_{\text{logit}}^2 / R^2$ 。我们可以根据估计的 logit 的方差和模型的类 R^2 计算 logit 的方差。这样,logistic 回归的标准化系数可以估计为:

$$\hat{\beta}^* = \frac{\hat{\beta}s_x}{\sqrt{s_{\text{logit}}^2 / R^2}} = \frac{\hat{\beta}s_x R}{s_{\text{logit}}}, \quad 4.5.4$$

其中, β^* 为 logistic 回归的标准化系数, β 为未标准化系数, s_x 为自变量 x 的标准差, s_{logit} 为估计的 logit 的标准差, R 为模型确定系数 R^2 的平方根(Menard, 1995)。

我们来计算模型 2.4.1 中自变量 MEANGR 的标准化回归系数,其计算步骤为:

1. 用 SAS 或 SPSS 对模型 2.5.1 进行 logistic 回归
2. 估计 $\hat{\beta}_3$ 、 R 和预测概率 $\hat{p}$
3. 计算估计的 logit: $\ln[\hat{p}/(1-\hat{p})]$
4. 计算 s_{logit} (即估计的 logit 的标准差) 和 s_{MEANGR} (即

MEANGR 的标准差)

5. 根据 s_{logit} 、 $\hat{\beta}_3$ 、 s_{MEANGR} 和 R 计算 $\hat{\beta}_3^*$

相应的 SAS 和 SPSS 程序命令如下:

```
* SAS PROGRAM: STANDARDIZED LOGISTIC REGRESSION COEFFICIENT;
OPTIONS NOCENTER PS = 500 LS = 150;
LIBNAME LIB 'D: \ LOGIT';
```

```
DATA DATA1;
  SET LIB.COLLEGE;
PROC LOGISTIC DESCENDING;
MODEL COLLEGE = GENDER KEYSCH MEANGR/RSQ;
OUTPUT OUT = PRED P = PHAT;
RUN;
```

```
DATA DATA2;
  SET PRED;
  LOGIT = LOG (PHAT/(1 - PHAT)) ;
PROC MEANS;
  VAR MEANGR LOGIT;
RUN;
```

```
* SPSS PROGRAM: STANDARDIZED LOGISTIC REGRESSION COEFFICIENT.
GET FILE = 'D: \ LOGIT \ COLLEGE.SAV'.
LOGISTIC REGRESSION VAR = COLLEGE
  /METHOD = ENTER GENDER KEYSCH MEANGR
  /SAVE PRED.
COMPUTE LOGIT = LN (PRE __ 1/(1 - PRE __ 1)) .
EXECUTE.
DESCRIPTIVES
  VARIABLES = LOGIT MEANGR
  /STATISTICS = MEAN STDDEV MIN MAX.
```

* 注: SPSS 程序中命令 $\text{LN}(\text{PRE_1}/(1 - \text{PRE_1}))$ 和 SAS 程序中命令 $\text{LOG}(\text{PHAT}/(1 - \text{PHAT}))$ 都是取自然对数.

SAS 程序输出中的变量 PHAT 即预测概率 $\hat{p}$, 可以根据其计算估计的 logit. 用 PROC MEANS 命令可以输出描述性统计, 从中能够得到新变量 LOGIT 和自变量 MEANGR 的标准差.

与此对应, 在 SPSS 程序中命令 SAVE PRED 是为了将预测概率 PRE _ 1 (默认变量名) 储存为新变量, 而命令 DESCRIPTIVES 可以提供变量 LOGIT 和 MEANGR 的描述性统计指标.

在计算标准化系数时需要的信息有:

$$\hat{\beta}_3 = 0.4245; \quad s_{\text{MEANGR}} = 4.2990; \quad R = 0.5941; \\ s_{\text{logit}} = 2.0514.$$

于是 logistic 回归的标准化系数 $\hat{\beta}_3^*$ 便可以按下列公式计算:

$$\begin{aligned} \hat{\beta}_3^* &= \frac{\hat{\beta}_3 s_{\text{MEANGR}} R}{s_{\text{logit}}} \\ &= \frac{0.4245 \times 4.2991 \times 0.5941}{2.0514} \\ &= 0.5285. \end{aligned}$$

按上述方法计算的 logistic 回归标准化系数称为完全标准化系数. DeMaris (1995) 建议了另一种计算 logistic 回归标准化系数的方法. 在本书第 1 章提到, $y^* = \alpha + \beta x + \varepsilon$, 其中 y^* 为非观测的因变量, ε 被假设为服从 logistic 分布. 如同标准正态分布, 这种分布的平均值为 0; 但其方差为 $\pi^2/3$, 其中 π 值约为 3.1416. 那么, y^* 的方差估计为:

$$\begin{aligned} \text{Var}(y^*) &= \text{Var}(\hat{\alpha} + \Sigma \hat{\beta} x) + \text{Var}(\varepsilon) \\ &= \text{Var}(\hat{\alpha} + \Sigma \hat{\beta} x) + 3.290. \end{aligned}$$

其中, 我们假设误差项与自变量无关, 因此上式中没有协方差项. 误差项的方差 $\text{Var}(\varepsilon)$, 即 $\pi^2/3$, 且 $\text{Var}(\hat{\alpha} + \Sigma \hat{\beta} x)$ 的估计方差可以由 SAS 程序取得. 方法为, 在 PROC LOGISTIC 程序的 OUTPUT 命令之后加入备选项 XBETA, 便能在运行中将一个线性预测变量 (linear predictor variable, 如 Z) 加入输出数据, 然后再用 PROC MEANS 命令取得它的估计方差 $\text{var}(Z) = \text{Var}(\hat{\alpha} + \Sigma \hat{\beta} x)$. 于是, 我们便可以根据上述公式计算 $\text{Var}(y^*)$ 了

$$\text{Var}(y^*) = \text{Var}(\hat{\alpha} + \Sigma \hat{\beta} x) + 3.290.$$

然后, 再根据因子 (S_{y^*}/S_{y^*}) 来调整未标准化的 logistic 回归

系数 β_k , 取得标准化系数 β_k^* .

对模型 2.4.1 用 SAS 得到线性预测变量并计算其方差的程序命令如下:

```
* SAS FILE: GENERATE THE LINEAR PREDICTOR VARIABLE;
```

```
OPTIONS NOCENTER PS = 500 LS = 150;
```

```
LIBNAME LIB 'D: \ LOGIT';
```

```
DATA DATA1;
```

```
SET LIB.COLLEGE;
```

```
PROC LOGISTIC DESCENDING;
```

```
MODEL COLLEGE = GENDER KEYSCH MEANGR/RSQ;
```

```
OUTPUT OUT = PRED XBETA = Z;
```

```
RUN;
```

```
DATA DATA2;
```

```
SET PRED;
```

```
PROC MEANS;
```

```
VAR MEANGR Z;
```

```
RUN;
```

由这个程序可以取得线性预测变量的方差为 $\text{Var}(Z) = 4.2082$, 因此有:

$$\text{Var}(y^*) = 4.2082 + 3.290 = 7.4982,$$

和

$$\hat{\beta}_3^* = \hat{\beta}_3(s_{\text{MEANGR}}/s_y) = 0.4245(4.2991/2.7383) = 0.6665.$$

注意, DeMaris 公式中 $\text{Var}(\hat{\alpha} + \Sigma \hat{\beta}_x)$ 部分与 Menard 公式中的 $\text{Var}(\text{logit})$ 相同. 这就是说, 由以上 SAS 程序估计的 $\text{Var}(Z)$ 与前面用 SAS 和 SPSS 分别估计的 $\text{Var}(\text{logit})$ 相同. 然而, DeMaris 标准化系数与 Menard 标准化系数有一定差别. 将他们的公式变形, 就可以看到差别所在:

$$\text{Menard 公式: } \hat{\beta}_3^* = \frac{\hat{\beta}_3 S_{\text{MEANGR}}}{\sqrt{\text{Var}(\text{logit})/R^2}},$$

$$\text{DeMaris 公式: } \hat{\beta}_3^* = \frac{\hat{\beta}_3 S_{\text{MEANGR}}}{\sqrt{\text{Var}(\text{logit}) + 3.290}}.$$

完全标准化系数的缺点是 logit 的方差会因模型预测变化而变化, 即随 logit 的方差估计值变化而变化. 这意味着, 即使一个变量在不同模型中的非标准化的作用保持不变时, 其不同模型中的标准化的作用却可能发生变化. 这并不是标准化估计的理想性质.

用 SAS 的 PROC LOGISTIC 程序计算的标准化系数没有上述问题, 因为计算时所用的公式为(SAS Institute Inc., 1995):

$$\beta^* = \frac{\beta S_x}{\pi/\sqrt{3}} = \frac{\beta S_x}{1.8138}, \quad 4.5.5$$

其中的分母 $\pi/\sqrt{3}$ 为标准 logistic 分布的标准差. 很明显, SAS 提供的标准化系数是偏标准化 (partially standardized) 的, 而不是完全标准化的. 偏标准化系数的计算不受 logit 的方差估计值的影响, 而是在用同一个常数 $\pi/\sqrt{3}$ 作为式 4.5.5 的分母.

对 logistic 回归标准化系数的解释与线性回归时相同. 也就是说, 它是 x_k 变化一个标准差导致 logit (y) 上 β^* 个标准差的变化.

因为示范模型中只有一个连续变量 (即 MEANGR), 只计算一个标准化系数, 所以这一模型中没有其他标准化系数可供比较. 如果在模型中有多个连续自变量, 我们就可以根据标准化的 logistic 回归系数来比较有着不同量度的自变量对事件发生比及概率作用的强度了.

4.6 偏相关 (Partial Correlation)

在上一节中, 我们讨论了自变量对发生比和事件概率的偏作用. 有时, 我们还想了解某一个变量对 logistic 回归的贡献. 在多元回归中, 每一个自变量的贡献都依赖于其他自变量, 尤其是当自变量之间高度相关时.

SPSS 的 LOGISTIC 回归程序能提供一个统计指标 R (注意, 它不是确定系数 R^2 的平方根!), 用来检查因变量与每一个自变量之间的偏相关 (SPSS Inc., 1997b; Atkinson, 1980). R 表示在

控制其他变量的情况下, 该自变量对因变量的作用. 这个 R 的值域为 -1 至 $+1$, 其为正值时表示当自变量值增加时事件发生的可能性也增加, 其为负值时则相反. 当其绝对值很小时表示对应自变量对模型的偏贡献 (partial contribution) 很小, 而其绝对值很大时则表示该自变量对模型的偏贡献很大. R 指标的计算公式为:

$$R = \sqrt{\frac{(\text{Wald}\chi^2 - 2\text{d.f.})}{-2LL_0}}, \quad 4.6.1$$

其中, d.f. 为变量的自由度. 分母为 -2 倍的截距模型 (即只有截距的模型, 或称零模型, 即 null model) 的对数似然值. R 的符号与相应系数相同. 式 4.6.1 中的值 2d.f. 用来对估计系数的数目进行调整. 如果 Wald 统计量小于 2, SPSS 输出中的 R 将被设定为 0.

让我们用式 4.6.1 计算几个 R 值来检查表 4.2.3 第 3 部分中的结果. 当 -2 倍的截距模型的对数似然值 $-2LL_0 = 1275.33$ 时, 变量 GENDER 的偏相关 R 为:

$$\begin{aligned} R_{\text{GENDER}} &= \sqrt{\frac{(\text{Wald}\chi^2 - 2 \times 1)}{-2LL_0}} \\ &= \sqrt{\frac{(41.00 - 2)}{1275.33}} \\ &= 0.1749. \end{aligned}$$

式 4.6.1 不仅可以对分类变量的每一个类型 (除了参照类) 计算偏相关, 还可以计算分类变量作为整体的偏相关. 下面, 我们对示范模型的分类变量 CGRADE 作为整体来计算偏相关:

$$\begin{aligned} R_{\text{CGRADE}} &= \sqrt{\frac{(\text{Wald}\chi^2 - 2 \times 2)}{-2LL_0}} \\ &= \sqrt{\frac{(194.48 - 4)}{1275.33}} \\ &= 0.3865. \end{aligned}$$

这里的计算结果与表 4.2.3 中第三部分的 SPSS 输出结果相同. 我们还可以根据 SAS 的 PROC LOGISTIC 程序的输出结果用式 4.6.1 来计算变量的偏相关.

尾注：

在新版的 SAS 6.12 的 PROC LOGISTIC 程序中，分类自变量可由 CLASS 指令定义后纳入模型。如果该分类变量有 m 个类别，SAS 程序将使用效应编码(effect coding)自动产生 $m - 1$ 个设计变量(design variables)，它们作为一组变量，同时被纳入模型，程序对每一类别单独进行显著性检验，也提供对这一分类变量整体显著性的检验。SAS 程序的指令如下：

```
PROC LOGISTIC DESCENDING;  
CLASS OGRADE;  
MODEL COLLEGE = GENDER KEYSCH OGRADE;  
RUN;
```

Logistic 回归系数的统计推断



Copyright © 2005, China Communications Press, Inc. All rights reserved. No part of this publication may be reproduced, stored in a retrieval system, or transmitted, in any form or by any means, electronic, mechanical, photocopying, recording, or otherwise, without the prior written permission of China Communications Press, Inc.

如果模型满足假设条件,我们可以由样本模型的结果对总体参数进行统计推断.统计推断有两个含义,即假设检验和参数估计.假设检验涉及的一系列工作最后导致接受或拒绝关于总体参数所作假设陈述的结论;参数估计便是估计出总体参数的值(包括点估计和置信区间估计).本章将讨论如何进行 logistic 回归的假设检验和计算回归系数、发生比率、概率的置信区间(confidence intervals,简称为 C.I.).

5.1 Logistic 回归系数的显著性检验

本节讨论在 logistic 回归模型中自变量 x_k 对 logit 作用的显著性检验.这涉及到一个自变量是否与反应变量显著相关的统计假设,以及如何建立和检验这一假设并做出结论.

logistic 回归系数的最大似然估计是总体参数的渐近无偏和有效(asymptotically unbiased and efficient)的点估计.对系数的估计标准误提供了在换用不同样本时估计系数的可能变化范围.在第 2 章的 2.3 节已经讨论过,logistic 回归系数的 MLE 估计近似服从正态分布,所以我们可以直接对回归系数进行显著性统计检验.

假设零假设 H_0 为: $\beta_k = 0$ (表示自变量 x_k 对事件发生可能性无影响作用).如果零假设被拒绝,说明事件发生可能性依赖于 x_k 的变化.要检验这一假设,我们需要先选择显著性水平,即通常所说的 α 水平.显著性水平就是在零假设为真时错误地拒绝它的概率,也称为第一类错误(type I error)或弃真错误.选择的 α 水平由研究者自行决定,选择的依据为我们愿在多大程度上接收可能犯拒绝一个真的零假设的错误.愿意冒的风险越大,则可选的 α 值越大.常用的 α 水平为 0.05,也称为在 0.05 水平统计性显著(另一常用的 α 水平为 0.01).在 $\alpha = 0.05$ 水平上,100 次拒绝零假设中零假设为真的情况不超过 5 次.

由于 α 是犯第一类错误的概率,为什么不能选择一个更小的 α 值呢?这是因为,当 α 减小时,我们接受一个实际为假的

零假设的错误概率便同时增大. 未拒绝一个实际为假的假设称为第二类错误(type II error)^①或取伪错误. 上述这两类错误的概率是此长彼消、相辅相成的.

5.1.1 Wald 检验

选择 α 水平以后, 我们就可以计算检验统计量了. 所谓检验统计量就是根据样本数据所统计出的决定是否拒绝零假设的判断值. 对于规模很大的样本, 检验其总体系数是否为 0 可以采用 Z 统计量:

$$Z = \hat{\beta}_k / SE_{\hat{\beta}_k}. \quad 5.1.1$$

其中, $SE_{\hat{\beta}_k}$ 为 $\hat{\beta}_k$ 的标准误. 当零假设为真时(即 $H_0: \beta_k = 0$), Z 为标准正态分布. 可以按常规根据 Z 计算值查标准正态分布表中单侧或双侧检验的 p 值(当样本规模较小时, 式 5.1.1 所示 Z 检验值便成为 t 检验值).

常用统计软件中, 对 logistic 回归系数进行显著性检验时, 通常使用 Wald 检验, 其公式为:

$$W = (\hat{\beta}_k / SE_{\hat{\beta}_k})^2. \quad 5.1.2$$

它实际上就是式 5.1.1 中 Z 统计量的平方. 在零假设条件下, 每一个回归系数都等于 0, 那么这个单变量 Wald 统计量为自由度等于 1 的渐近 χ^2 分布. 于是, 这个统计量的值可以表示相应的模型自变量是否显著. 在自由度等于 1 条件下, $\alpha = 0.05$ 的 χ^2 临界值为 3.841; $\alpha = 0.01$ 的 χ^2 临界值为 6.635; $\alpha = 0.001$ 的 χ^2 临界值为 10.828^②. 因此, 决策的规则为: 如果 Wald 在 $\alpha = 0.05$ 水平的 χ^2 值大于 3.841, 便拒绝零假设 $H_0: \beta_k = 0$.

Wald 统计量的一般形式为:

$$Q\beta = r, \quad 5.1.3$$

其中, β 为待检验的模型参数向量, Q 为常数矩阵(通常, 各元素值

① 第一类错误是当拒绝零假设而其实际为真的错误; 这类错误概率通常用 α 表示. 第二类错误是当未拒绝一个零假设而其实际为假的错误, 第二类错误的概率通常用 β 表示. 对第二类错误的表达中, 通俗的说法是接受假设, 而未拒绝假设则是在方法论上更确切的表述方法.

② 用 SAS 或 SPSS 程序可以计算任意显著水平和自由度的 χ^2 值, 具体操作见尾注.

为 0 或 1), r 表示常数矩阵(其元素为 0). 例如, 当检验 $H_0: \beta_1 = \beta_2 = 0$ 时, 实际上等价于检验下列假设:

$$H_0: \begin{pmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} \begin{bmatrix} \alpha \\ \beta_1 \\ \beta_2 \end{bmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}.$$

上述假设可以通过 Wald 统计量来检验:

$$W = [Q\hat{\beta} - r]' [Q \text{Var}(\hat{\beta}) Q']^{-1} [Q\hat{\beta} - r], \quad 5.1.4$$

其中 W 为 χ^2 分布, 其自由度为约束的数目(即 Q 中的行数). Wald 统计量由两部分组成: 一是 $[Q\hat{\beta} - r]$, 测量的是估计值和假设值之间的差别; 二是 $[Q \text{Var}(\hat{\beta}) Q']^{-1}$, 表示估计值的变化范围.

SAS 的 PROC LOGISTIC 程序对每一个自变量系数提供 $\text{Wald}\chi^2$ 值, 而不是提供 t 统计量或 Z 统计量的值. SPSS 的 LOGISTIC REGRESSION 程序同时提供检验单个系数和检验有 m 类的分类变量整体的 Wald 统计值.

对例题模型 2.5.1 来说, 所有自变量(GENDER, KEYSCH, MEANGR)都有 $\text{Wald}\chi^2$ 值大于 3.841, 所以它们都在 $\alpha = 0.05$ 水平上统计性显著(见表 2.5.2 中的 SAS 输出和表 2.4.3 中的 SPSS 输出). 对带有分类变量 CGRADE (其中分 $m = 3$ 类, 见第 4 章 4.2.3 小节), SPSS 对于分类变量提供了整体的显著性检验, 同时对代表各类的每一个设计变量(模型中有 $m - 1$ 个设计变量)也提供了单独的检验. 新版 SAS 也提供同样的检验(见第 4 章尾注).

根据正态分布理论, Wald 统计量很容易计算. 但是它有一个不太好的性质, 即当回归系数的绝对值很大时, 这一系数的估计标准误就会膨胀, 于是会导致 Wald 统计值变得很小, 以致第二类错误的概率增加. 也就是说, 在实际上会导致应该拒绝零假设时却未能拒绝. 所以在研究中, 如果发现回归系数的绝对值很大, 就不要再使用 Wald 统计值来检验零假设, 而应该使用似然比(L.R.)检验法来代替.

5.1.2 似然比检验

统计学已经证明, 在大样本时, 如果两个模型之间有嵌套

(nested)关系,那么两个模型之间的对数似然值乘以 -2 的结果(简称为 $-2LL$)之差近似服从 χ^2 分布.这一检验统计量称为似然比(likelihood ratio,简称为L.R.)(Hanushek & Jackson, 1977; Aldrich & Nelson, 1984; Greene, 1990; Long, 1997).

用一个例子加以说明.一个模型 M_1 中有自变量 x_k ,另一个模型 M_2 包含 M_1 中所有其他自变量但没有自变量 x_k ,我们就说 M_2 嵌套于 M_1 .也就是说, M_1 中包含着 M_2 .如果要进行L.R.检验的话,两个模型的 $-2LL$ 之间的差为:

$$\begin{aligned} \text{L.R.} &= (-2LL_{m2}) - (-2LL_{m1}) \\ &= -2\ln\left(\frac{LL_{m2}}{LL_{m1}}\right), \end{aligned} \quad 5.1.5$$

其中 LL_{m1} 为我们所设定原模型(包括所有自变量)的最大似然函数的对数; LL_{m2} 为省略模型(省略了自变量 x_k)的最大似然函数的对数.两者之间的差乘以 -2 近似服从于 χ^2 分布,其自由度等于省略自变量的数目(此处为d.f. = 1).

现在,我们用L.R.统计量来检验模型2.5.1中变量MEANGR的显著性(等价于零假设 $H_0: \beta_3 = 0$ 的检验).所要做的是先建立省略模型,即省略式2.5.1中的变量MEANGR,得到模型如式3.1.1.于是,我们要比较的两个模型为:

$$M_1: \ln[p/(1-p)] = \alpha + \beta_1 \text{GENDER} + \beta_2 \text{KEYSCH} + \beta_3 \text{MEANGR},$$

$$M_2: \ln[p/(1-p)] = \alpha + \beta_1 \text{GENDER} + \beta_2 \text{KEYSCH}.$$

显然, M_2 是由在 M_1 中令 $\beta_3 = 0$ 得到的.当一个模型能够从另一个模型中通过令若干自变量的系数为0得到,便称这个模型嵌套于另一模型.原模型(较大者)有时也称为“完全(full)”模型,通过省略得到的模型也称为简化(reduced)模型.注意,这时的“完全”模型不是真正意义上的完全模型,而只是相对于简化模型而言.

此处 M_2 嵌套于 M_1 .检验假设 $H_0: \beta_3 = 0$ 表示检验在建立简化模型 M_2 时令 $\beta_3 = 0$ 是否合乎实际.

令 LL_{m2} 和 LL_{m1} 分别为简化模型和“完全”模型的最大似然函数值的对数,似然比统计量即为二者的差:

$$(-2LL_{m2}) - (-2LL_{m1}) = 1161.17 - 839.97 = 321.20.$$

(参见表 5.1.1) 在 $d.f. = 3 - 2 = 1$ 时(即省略的变量数或两个模型自由度之差), 这一 χ^2 值非常显著, 表示变量 MEANGR (即高中平均分数)对高中毕业后考入大学的可能性有很强的作用。

表 5.1.1 单个自变量系数的似然比检验

Variable	Model 1	Model 2
INTERCEPT	-1.76 *	-1.66 *
GENDER	0.87 *	1.45 *
KEYSCH	0.91 *	0.57 *
MEANGR	0.42 *	
-2LL	839.97	1161.17
MODEL CHI-SQUARE	435.36	114.15
D.F.	3	2

注: * 标志在 $\alpha = 0.05$ 水平统计性显著。

现在讨论 L.R. 检验如何操作。在上述检验中考虑的是, 在模型中新加入变量 MEANGR 是否在原有变量 GENDER 和 KEYSCH 的基础上对解释升学可能性有显著的贡献, 即最大似然值 $\hat{L}_1$ (即式 2.5.1 的最大似然函数值)是否显著大于 $\hat{L}_2$ 的最大似然值(即式 3.1.1 的最大似然函数值)。如果 $\hat{L}_1$ 确实显著大于 $\hat{L}_2$, 则说明似然比 $\hat{L}_2/\hat{L}_1$ 是个非常小的分数, 那么似然比的自然对数 $\ln(\hat{L}_2/\hat{L}_1)$ 将为负值; 并且 $-2\ln(\hat{L}_2/\hat{L}_1)$ 将为很大的正值。这样, 作用显著的变量 MEANGR 的似然比 L.R. 会取很大的正值。这与用 χ^2 检验的形式相同。

相反, 要是新加变量(如 MEANGR)对解释升学可能性没有新贡献, 即 $\hat{L}_1$ 与 $\hat{L}_2$ 基本相等, 这意味着似然比 $(\hat{L}_1/\hat{L}_2)$ 近似于 1。所以, L.R. 统计量等于 -2 乘以一个十分接近于 1 的数的自然对数, 因此 L.R. 近似于零。也就是说, 要是 MEANGR 的作用不显著, 似然比将近似于 0。这也同一般 χ^2 检验形式相同。

简而言之, 不论具体比较的是哪两个模型, 似然比值应在 0 和 $+\infty$ 之间。当新加变量的作用不显著时, 似然比值应很小, 但大于

零；而当新加变量的作用很显著时，似然比应为一较大的正数。

除模型似然函数可以用来进行两个嵌套模型的似然比检验之外，还有两种统计量，即模型 χ^2 (model chi-square) 和偏差统计量(deviance statistic)也可以用于似然比检验。

我们在 3.4 节所讨论的比较设定模型和截距模型(null model)的 χ^2 检验实际上是似然比检验。因此，含与不含 x_k 的两个模型的 χ^2 统计也可以提供与式 5.1.5 同样的结果。

$$\begin{aligned} & \chi^2 (\text{含 } x_k \text{ 的模型}) - \chi^2 (\text{不含 } x_k \text{ 的模型}) \\ &= (2L\hat{L}_{m1} - 2L\hat{L}_{m0}) - (2L\hat{L}_{m2} - 2L\hat{L}_{m0}) \\ &= -2(L\hat{L}_{m2} - L\hat{L}_{m1}) \\ &= -2\ln(\hat{L}_{m2}/\hat{L}_{m1}). \end{aligned} \quad 5.1.6$$

式中 $L\hat{L}_{m1}$ 、 $L\hat{L}_{m2}$ 和 $L\hat{L}_{m0}$ 分别为模型 1、模型 2 和截距模型的对数最大似然值。由于两个模型的 χ^2 中都有截距模型最大似然值的共同项，所以式 5.1.6 与式 5.1.5 相同。

将表 5.1.1 的模型 χ^2 值代入式 5.1.6 中，有：

$$\begin{aligned} & \chi^2 (\text{含 MEANGR 的模型}) - \chi^2 (\text{不含 MEANGR 的模型}) \\ &= 435.36 - 114.15 \\ &= 321.21. \end{aligned}$$

这一结果与我们由式 5.1.5 所计算的结果相同。

偏差统计量也可以用于同一目的。在第 3 章 3.1.2 节中已经说明偏差统计量也是一个似然比统计量，它用于比较设定模型与完全模型或称饱和模型(见式 3.1.4)。于是，两个嵌套模型之间的偏差统计量之差为：

$$\begin{aligned} & D(\text{不含 } x_k \text{ 的模型}) - D(\text{含 } x_k \text{ 的模型}) \\ &= (2L\hat{L}_f - 2L\hat{L}_{m2}) - (2L\hat{L}_f - 2L\hat{L}_{m1}) \\ &= -2(L\hat{L}_{m2} - L\hat{L}_{m1}) \\ &= -2\ln(\hat{L}_{m2}/\hat{L}_{m1}). \end{aligned} \quad 5.1.7$$

其中 $L\hat{L}_f$ 为完全模型的对数似然值。注意，这里的完全模型是第三章中讨论到的真正意义上的完全模型。由于式 5.1.7 的两个 D 统计量都包含完全模型最大似然值的共同项，可以从式中去，式 5.1.7 其实与式 5.1.5 表示的 L.R. 统计量完全相同。

还有很重要的一点应该记住，由 SAS 的 PROC LOGISTIC 程序提供的偏差统计量是根据数据中协变类型或子总体的数目计

算的, 而不是根据观测案例计算的. 然而 SPSS 的 LOGISTIC REGRESSION 程序却不提供真正的偏差统计量(参见第 3.1.2 节). 注意, 当我们用 SAS 的 PROC LOGISTIC 程序所提供的偏差统计量来进行 L.R. 检验时, 需要特别注意两个相比的模型中须有同样数量的协变类型. 但是当模型包含不同协变量(即自变量)时会产生不同数量的协变类型, 因而会导致不同的偏差统计值和不同的自由度. 这个问题可以通过 SAS 程序的适当备选命令加以解决. 在下列的 SAS 程序中, 前两个会产生适当的偏差统计量来比较式 2.5.1 模型和式 3.1.1 模型; 然而后一个程序产生的偏差统计量却不能用比较. 以上所述 SAS 程序输出的偏差统计量、自由度和协变类型数在表 5.1.2 中报告.

```
* SAS PROGRAM 1;
PROC LOGISTIC DESCENDING;
MODEL COLLEGE = GENDER KEYSCH MEANGR/AGGREGATE SCALE = NONE;
RUN;

* SAS PROGRAM 2;
PROC LOGISTIC DESCENDING;
MODEL COLLEGE = GENDER KEYSCH
/AGGREGATE = (GENDER KEYSCH MEANGR) SCALE = NONE;
RUN;

* SAS PROGRAM 3;
PROC LOGISTIC DESCENDING;
MODEL COLLEGE = GENDER KEYSCH/AGGREGATE SCALE = NONE;
RUN;
```

表 5.1.2 偏差统计量和协变类型数

(程序 1 输出)				
Deviance and Pearson Goodness-of-Fit Statistics				
Criterion	DF	Value	Value/DF	Pr > Chi-Square
Deviance	408	378.0	0.9266	0.8537

续表

Pearson	408	632.6	1.550 6	0.000 1
---------	-----	-------	---------	---------

Number of unique profiles: 412

(程序 2 输出)

Deviance and Pearson Goodness-of-Fit Statistics

Criterion	DF	Value	Value/DF	Chi-Square	Pr >
Deviance	409	699.2	1.709 6	0.0001	
Pearson	409	590.5	1.443 7	0.0001	

Number of unique profiles: 412

(程序 3 输出)

Deviance and Pearson Goodness-of-Fit Statistics

Criterion	DF	Value	Value/DF	Chi-Square	Pr >
Deviance	1	0.8747	0.8747	0.3496	
Pearson	1	0.8495	0.8495	0.3567	

Number of unique profiles: 4

在第 2 个 SAS 程序中, 我们用命令 “AGGREGATE = (GENDER KEYSCH MEANGR)” 来设置协变类型数等于第 1 个 SAS 程序产生的统计, 即 412. 偏差统计量的自由度等于由模型估计的协变类型数与系数数目(含截距)之差. 这样一来, 由第 1 个和第 2 个程序产生的偏差统计量的自由度分别为 $d.f. = 412 - 4 = 408$ 和 $d.f. = 412 - 3 = 409$.

由第 3 个程序产生的协变类型数为 4, 因此 $d.f. = 4 - 3 = 1$. 这一 SAS 程序得到的偏差统计量不能用于比较式 2.5.1 和式 3.1.1 两个模型的 L.R. 检验. 因此, 我们只能用第 1 个和第 2 个程序取得的偏差统计量来进行 L.R. 检验. 应用式 5.1.7, 有:

$$\begin{aligned} D(\text{不含 } x_k \text{ 的模型}) - D(\text{含 } x_k \text{ 的模型}) \\ = 699.2 - 378.0 \end{aligned}$$

$$= 321.2.$$

这一结果与应用 $-2LL$ 或模型 χ^2 值计算的结果相同.

注意, L.R. 检验必须是根据同一数据的不同模型之间的比较. 由于最大似然估计将排除那些有缺失值的案例, 因此在选用不同变量时, 可能会因某变量有缺失值而使样本规模有所变化. 比如, 要是 x_k 有 10 个案例缺失值, 那么当 x_k 被排除出模型时, 可用的样本规模会增加 10 个. 为了在模型比较时有同样的样本规模, 我们应排除所有自变量为缺失值的案例. 或者, 在数据分析之前将缺失值补充上.

就此, 我们讨论了两种对单个回归系数的统计检验: Wald 检验和 L.R. 检验. 尽管有时(当系数值很大时)我们需要依靠 L.R. 检验, 但主要是用 Wald 统计量进行单个系数的检验. L.R. 检验则主要是在进行一组系数的整体检验时使用, 我们将在下一节讨论这一内容.

5.1.3 检验系数子集

L.R. 检验不仅可以用于检验一个系数, 还可以像多元线性回归中 F 检验那样, 用于检验一组系数(Hanushek & Jackson, 1977; Aldrich & Nelson, 1984; Greene, 1990; Long, 1997).

有时研究兴趣在于同时检验几个参数, 即检验在模型中包含其他变量的条件下一组自变量(J 个)作为子集是否与因变量显著相关. 这一检验的零假设为 $H_0: \beta_1 = \beta_2 = \cdots = \beta_J = 0$. 我们可以通过比较包括所有 K 个自变量的模型与只包括 $(K - J)$ 个自变量的模型来进行这种检验. L.R. 检验便可以服务于这一目的. 检验 J 个自变量整体上是否显著的 L.R. 检验的步骤与第 5.1.2 小节中讨论的检验单个自变量相同. 先要令原始模型中的 $\beta_1 = \beta_2 = \cdots = \beta_J = 0$ 后建立起简化模型. 因为简化模型是原模型的一个特殊情况, 这两个模型之间有嵌套关系, 所以可以用 L.R. 检验 J 个系数构成的子集的显著性. 如果 L.R. 检验结果统计性显著, 就表示 J 个系数中至少有一个统计显著. 现在, 我们来示范如何对模型中一个分类变量进行整体检验. 如果我们有原模型和简化模型如下:

$$M_1: \ln[p/(1-p)] = \alpha + \beta_1 \text{GENDER} + \beta_2 \text{KEYSCH} +$$

$$\beta_3 \text{GRADE2} + \beta_4 \text{GRADE3},$$

$$M_2: \ln[p/(1-p)] = \alpha + \beta_1 \text{GENDER} + \beta_2 \text{KEYSCH}.$$

其中变量 GRADE2 和 GRADE3 是分类变量 CGRADE 的两个标志变量(参见第 4.2.3). 在模型 M_2 中 β_3 和 β_4 被设定为等于 0, 因此零假设为 $H_0: \beta_3 = \beta_4 = 0$.

两个模型 M_2 和 M_1 之间的对数似然值乘以 -2 的积之差近似 χ^2 分布, 可以用于检验零假设, 其自由度为要检验的参数数目(此处 d.f. = 2). 正如在第 5.1 节提到的, 我们既可以用 $-2LL$, 也可以用模型 χ^2 , 还可以用偏差统计量, 来计算 L.R. 统计量. 由 SAS 的 PROC LOGISTIC 程序对所分析的两个模型取得的这些统计量列在表 5.1.3 中. 整体检验标记变量 GRADE2 和 GRADE3 的 L.R. 统计值为:

应用 $-2LL$ 统计值:

$$\text{L.R.} = (-2LL_2) - (-2LL_1) = 1\,161.172 - 910.764 = 250.41$$

$$\text{d.f.} = 4 - 2 = 2$$

或应用模型卡方值:

$$\text{L.R.} = \chi_1^2 - \chi_2^2 = 364.563 - 114.154 = 250.41$$

$$\text{d.f.} = 4 - 2 = 2$$

或应用偏差统计值:

$$\text{L.R.} = D_2 - D_1 = 255.2 - 4.770\,0 = 250.43$$

$$\text{d.f.} = 8 - 6 = 2$$

根据这三种统计值计算的 L.R. 检验值相同, 且都非常显著, 表示分类变量 CGRADE (即高中平均成绩)作为整体对结果变量有十分显著的影响作用.

表 5.1.3 对系数子集进行似然比检验所用的偏差、 $-2LL$ 、模型 χ^2 统计值

SAS 输出				
(模型 1)				
Deviance and Pearson Goodness-of-Fit Statistics				
Criterion	DF	Value	Value/DF	Pr > Chi-Square

续表

Deviance	6	4.7700	0.7950	0.5736
Pearson	6	4.4518	0.7420	0.6158

Number of unique profiles: 11

Model Fitting Information

Criterion	Intercept Only	Intercept and Covariates	Chi-Square for Covariates
AIC	1277.326	920.764	.
SC	1282.234	945.302	.
- 2 LOG L	1275.326	910.764	364.563 with 4 DF (p=0.000 1)
Score	.	.	338.917 with 4 DF (p=0.000 1)

(模型 2)

Deviance and Pearson Goodness-of-Fit Statistics

Criterion	DF	Value	Value/DF	Pr > Chi-Square
Deviance	8	255.2	31.897 3	0.0001
Pearson	8	255.8	31.972 4	0.0001

Number of unique profiles: 11

Model Fitting Information and Testing Global Null Hypothesis BETA=0

Criterion	Intercept Only	Intercept and Covariates	Chi-Square for Covariates
AIC	1 277.326	1 167.172	.
SC	1 282.234	1 181.895	.
- 2 LOG L	1 275.326	1 161.172	114.154 with 2 DF (p=0.000 1)
Score	.	.	109.227 with 2 DF (p=0.000 1)

注: 模型 2 中的协变类型数被设定等于模型 1 中的相应数值(即 11)。

此外, 在 6.10 版及以后 SAS 的 PROC LOGISTIC 程序中, 我们还可以根据 Wald 统计量检验一组自变量的联合作用。在 SAS 的 PROC LOGISTIC 程序中设定一个“TEST”命令, 就可以用 Wald 统计量联合检验零假设 $H_0: \beta_1 = \beta_2 = \cdots = \beta_j = 0$ 。比如, 我们想检验相对于 GRADE1 而言的 GRADE2 和 GRADE3

的整体作用, 实际上就是要检验零假设 $H_0: \beta_3 = \beta_4 = 0$.

我们还可能想确定 GRADE2 和 GRADE3、或 GRADE2 和 GRADE1、或 GRADE3 和 GRADE1 的作用是否相同, 那么检验的零假设分别为: $H_0: \beta_3 = \beta_4$; $H_0: \beta_3 = 0$; $H_0: \beta_4 = 0$. (注意, 在该模型中, GRADE1 为分类自变量的参照类, 系数 β_3 和 β_4 分别代表与 GRADE1 和 GRADE2 类相对应的因变量均值与参照类相对应的因变量均值的差.)

在 TEST 命令后加入变量名便构成相应作用的假设检验设置. 由于所有检验在一个 SAS 输出中显示, 因此最好在 TEST 命令之前对它们加上最多 8 个字符的标签, 并以一个冒号附于各个标签之后. 下列 SAS 程序命令便可以进行这些检验:

```
* SAS PROGRAM: LINEAR HYPOTHESIS TESTS;
PROC LOGISTIC DESCENDING;
MODEL COLLEGE = GENDER KEYSCH GRADE2 GRADE3;
TEST1: TEST GRADE2 = GRADE3 = 0;
TEST2: TEST GRADE2 = GRADE3;
TEST3: TEST GRADE2 = 0;
TEST4: TEST GRADE3 = 0;
RUN;
```

在上述 SAS 程序中, 用 TEST 命令设置四个线性假设检验: TEST 1 检验假设 $H_0: \beta_3 = \beta_4 = 0$; TEST 2 检验 $H_0: \beta_3 = \beta_4$; TEST 3 检验 $H_0: \beta_3 = 0$; TEST 4 检验 $H_0: \beta_4 = 0$. 所有检验的结果都在 $\alpha = 0.0001$ 水平统计性显著(参见表 5.1.4).

表 5.1.4 线性假设检验的结果

Linear Hypotheses Testing			
Label	Wald Chi-Square	DF	Pr > Chi-Square
TEST1	194.4760	2	0.0001
TEST2	16.8365	1	0.0001
TEST3	150.4666	1	0.0001
TEST4	81.6679	1	0.0001

在 SPSS 中,不是用 GRADE2 和 GRADE3 这样的标记变量,而是直接用分类变量 CGRADE,用编码值 1、2、3 表示各类(分别代表 $\text{GRADE} < 85$, $85 \leq \text{GRADE} < 90$, $\text{GRADE} \geq 90$),并在运行 SPSS 的 LOGISTIC REGRESSION 程序时纳入模型作为一个整体(参见第 4 章第 4.2.3 小节).相应的 SPSS 程序及模型结果列在表 4.2.3 中. SPSS 可以提供综合的 Wald 统计值来检验变量 CGRADE 的整体检验.注意,上述 SAS 程序输出的综合 Wald 统计量($W = 194.48$)与 SPSS 输出的结果相同.因为 TEST3 和 TEST4 的 Wald 统计量检验的是 GRADE2 和 GRADE3 的作用是否与参照类 GRADE1 的作用有所不同,所以它们与表 4.2.3 下部的 Wald 统计值相同. Test 2 表示 GRADE2 和 GRADE3 的作用各不相同.

从上面的示范可以看到,检验系数子集的综合检验既可以用 L.R. 检验,也可以用 Wald 检验.对于大样本,两者检验的结果很接近,所以如果实际研究的样本很大,用哪一种检验方法无关紧要.然而,对于小样本,两种统计检验可能取得不同的结果.统计学已经证明,在这种情况下 L.R. 统计量比 Wald 统计量效果好(Hauck & Donner, 1977).因此,当对此有疑问时,最好采用 L.R. 统计量的检验.当然,采用 Wald 统计量检验线性假设相对比较方便,因为只需要拟合一个模型便可以取得必要的信息来完成检验工作.比较对我们的示范模型采用 L.R. 统计量和 Wald 统计量检验假设 $H_0: \beta_3 = \beta_4 = 0$ 的结果,两者的结论完全一样.但是, L.R. 统计值 ($L.R. = 250.41$) 比 Wald 统计值 ($W = 194.48$) 大.

5.2 Logistic 回归参数的置信区间

一个显著的 logistic 回归系数估计 $\hat{\beta}_k$ 告诉我们,相应的自变量 x_k 对事件发生比有显著作用. $\hat{\beta}_k$ 的值是未知总体参数 β_k 的点估计.然而, $\hat{\beta}_k$ 并没有说明它离真实参数值 β_k 有多远.换句话说,它没有提供任何关于估计精度的测量,或者说没有提供关于估计值与参数真值之间误差幅度的信息.因为,我们不能期望样

本的参数估计 $\hat{\beta}_k$ 等于未知总体参数的真值 β_k , 所以我们应该谨慎地对其留出一定的允差范围, 即只将总体参数看作处于样本估计一定范围之内, 而不是正好等于样本估计。尽管我们实际上知道总体参数并不正好等于 $\hat{\beta}_k$, 但我们几乎可以确信总体参数 β_k 处于 $\hat{\beta}_k$ 两侧一定区间之内。这一区间称为置信区间 (Confidence Interval, 简称为 C.I.)。本节的首要目的是示范 logistic 回归系数及由此推导的发生比率、预测概率的置信区间估计。

5.2.1 Logistic 回归系数的置信区间

在控制一定概率的条件下确定参数真值处于一定范围置信区间完全是可能的。这一概率称为置信度或置信概率 (confidence degree/probability), 通常用 $(1-\alpha)$ 表示。在估计工作中, α 表示一种决策错误的概率, 于是 $1-\alpha$ 或 $100\% \times (1-\alpha)$ 是对正确估计的置信程度的测量。

对于所选的 α , 参数 β_k 的 $100\% \times (1-\alpha)$ 的置信区间为:

$$\hat{\beta}_k \pm Z_{\alpha/2} \times SE_{\hat{\beta}_k} \quad 5.2.1$$

其中 $\pm Z_{\alpha/2}$ 为与正态曲线下中心部分 $100\% \times (1-\alpha)$ 概率相连的临界 Z 值 (critical value); $SE_{\hat{\beta}_k}$ 为系数估计 $\hat{\beta}_k$ 的标准误; $(\hat{\beta}_k - Z_{\alpha/2} \times SE_{\hat{\beta}_k})$ 和 $(\hat{\beta}_k + Z_{\alpha/2} \times SE_{\hat{\beta}_k})$ 两值便分别是置信区间 C.I. 的下限和上限。

当样本较大时, $\alpha=0.05$ 水平的系数 β_k 的 95% 置信区间为:

$$\hat{\beta}_k \pm 1.96 \times SE_{\hat{\beta}_k} \quad 5.2.2$$

其中, ± 1.96 为正态曲线中心部分 95% 相联系的临界 Z 值^①。于是可以说, 我们有 95% 的置信度相信总体参数值处于 $(\hat{\beta}_k - 1.96 \times SE_{\hat{\beta}_k})$ 至 $(\hat{\beta}_k + 1.96 \times SE_{\hat{\beta}_k})$ 的区间之内。所说的“95% 的置信度”指, 如果我们在同一总体中随机抽取 100 次相同规模的大样本, 按照上述同样的程序建立置信区间, 将期望 100 次中有 95 次使置信区间将总体参数值包括在内, 总体参数值可能会有 5 次处于置信区间之外。

① 在置信度为 0.95 时, $\alpha=1-0.95=0.05$, $\alpha/2=0.025$, 我们需在标准正态分布表中查询与 0.475 区域对应的 Z 值, 其结果为 $Z_{\alpha/2}=1.96$

有时, 95% (或 0.95) 的置信度也不能令人满意, 但这属于个人不愿意未知总体参数值落入局外的程度有多高的问题. 根据实际情况, 可以将置信度设置为十分严格的水平 (即采取更高的概率), 也可以将置信度设置在不太严格的水平. 比如, 当我们认为应该采取 99% 的置信度时, 只要在式 5.2.1 中改用更大的 Z 值即可. 当 $(1-\alpha)=0.99$ 时, 有 $(1-\alpha)/2=0.4950$, 查阅标准正态分布表, 可以得到相应的 Z 值应该定为 2.57 或 2.58. 于是, 使用 2.57 和 2.58 的平均数来计算置信区间, 有:

$$\hat{\beta}_k \pm 2.575 \times SE_{\hat{\beta}_k}. \quad 5.2.3$$

注意, 在置信度较高时, 置信区间 C.I. 将比置信度为 0.95 时变得更宽 (意味着估计精度较差). 由此可以得到一个准则: 在一定样本规模条件下, 置信度与估计精度此长彼消. 如果研究者采用较高置信度, 他能够得以对估计有较大把握, 但估计会损失精度水平. 要同时取得较高置信度和较高精度, 唯一的办法是扩大样本规模.

我们以模型 2.5.1 来示范 logistic 回归系数置信区间的计算.

对表示性别的变量 GENDER 所估计的 logistic 回归系数为 $\hat{\beta}_1=0.866$, 标准误 $SE_{\hat{\beta}_1}=0.182$ (见表 2.5.2), β_1 的 95% 的置信区间 C.I. 为:

$$(0.866 \pm 1.96 \times 0.182) \longrightarrow (0.509, 1.223).$$

5.2.2 发生比率的置信区间

上一小节我们讨论了如何建立 logistic 回归系数的置信区间. 但是多数研究人员对取得 logistic 回归变量系数的置信区间并不太感兴趣, 而是更愿意取得与回归系数及其他系数 (如交互作用) 有关的发生比率的置信区间. 发生比率的置信区间可以通过对相应 logistic 回归系数置信区间的上下限求指数幂的方法取得. 比如对式 2.5.1 中的自变量 GENDER, 调整发生比率为 e^{β_1} , 这一发生比率的相应 95% 置信区间可根据回归系数 β_1 置信区间限值 (0.509, 1.223) 取指数幂得到. 于是, GENDER 对应的调整发生比率的 95% 置信区间为:

$$(e^{0.509}, e^{1.223}) \longrightarrow (1.664, 3.397).$$

这表明在其他条件不变时, 男生考入大学的发生比 (注意, 不

是概率)比女生至少高 1.66 倍,至多高 3.4 倍。

β_k 和 e^{β_k} 的置信区间基于参数的渐近正态性,有时也称为正态置信区间。在 SAS 的 PROC LOGISTIC 程序中,备选命令 WALDRL 可以计算所有自变量的发生比率的正态置信区间(在 6.10 版以前的 SAS 版本中,这一命令与备选命令 RISKLIMITS 或 RL 为同一命令)。置信度 $(1-\alpha)$ 的设定要使用备选命令 ALPHA=option。按照默认状态,只要在 SAS 的 PROC LOGISTIC 程序中设定备选命令 WALDRL (或 RISKLIMITS,或 RL),每一个系数估计的发生比率的 95% 置信区间 C.I. 便能够自动计算并报告。

以此相应,在 SPSS 的 LOGISTIC REGRESSION 程序中子命令 PRINT=CI(95)将输出每一个系数估计的发生比率的 95% 正态置信区间。如果需要的是所有系数发生比率的 99% 置信区间,就需要在 SPSS 程序中设定 PRINT=CI(99)。

有关 SAS 和 SPSS 程序命令如下,其输出结果在表 5.2.1 中提供。

*** SAS PROGRAM: ESTIMATING 95% C.I. FOR ODDS RATIO;**

PROC LOGISTIC DESCENDING;

MODEL COLLEGE = GENDER KEYSCH MEANGR/WALDRL ALPHA = 0.05;

RUN;

*** SPSS PROGRAM: ESTIMATING 95 % C. I. FOR ODDS RATIO.**

LOGISTIC REGRESSION VAR = COLLEGE

/METHOD = ENTER GENDER KEYSCH MEANGR

/PRINT = CI (95).

表 5.2.1 发生比率的 95% 置信区间

SAS 输出:

Conditional Odds Ratios and 95% Confidence Intervals

Variable	Unit	Odds Ratio	Wald Confidence Limits	
			Lower	Upper
GENDER	1.000 0	2.378	1.664	3.397
KEYSCH	1.000 0	2.492	1.553	3.997
MEANGR	1.000 0	1.529	1.440	1.623

续表

SPSS 输出:			
Variable	Exp (B)	95%CI for Exp (B)	
		Lower	Upper
GENDER	2.3776	1.6639	3.3975
KEYSCH	2.4917	1.5532	3.9973
MEANGR	1.5289	1.4402	1.6230

如第 4 章第 4.2.1 小节所述, 连续变量的离散变化(非一个单位)的发生比率经常是研究兴趣所在. 再以式 2.5.1 的模型为例, 在平均高中成绩这一变量上提高 5 分的发生比率为:

$$e^{(5 \times 0.4245)} = 8.35$$

该发生比率的 95% 置信区间为^①

$$(e^{(5 \times 0.4245 - 1.96 \times 5 \times 0.0305)}, e^{(5 \times 0.4245 + 1.96 \times 5 \times 0.0305)}) \\ = (6.19, 11.26)$$

幸运的是, 我们用不着手工计算这一置信区间, 因为 SAS 的 UNITS 命令可以让我们设置模型中连续变量变化的单位. 当 x_k 变化一个常数 Δ 单位时, 相应发生比率的改变可按 $e^{\beta\Delta}$ 来估计. 这一发生比率置信区间上下限的改变可通过 SAS 的 PROC LOGISTIC 程序的 WALDRL 命令计算.

```
* SAS PROGRAM: Estimating 95% C.I. for Customized Odds Ratio;
PROC LOGISTIC DESCENDING;
MODEL COLLEGE = GENDER KEYSCH MEANGR/WALDRL ALPHA = 0.05;
UNITS MEANGR = 5 - 5;
RUN;
```

① 对于像 $\text{logit}(y) = \alpha + \beta x$ (x 为连续变量) 这样的 logistic 回归模型, x 发生 Δ 单位的变化所导致对数发生比的变化由 logit 的变化计算取得, $[\hat{\alpha} + \hat{\beta}(x + \Delta)] - (\hat{\alpha} + \hat{\beta}x) = \hat{\beta}\Delta$, 然后通过对 logit 变化求指数幂相应的发生比率, $e^{\hat{\beta}\Delta}$. 计算置信区间要用的标准误通过 $\hat{\beta}$ 的标准误乘以常数 Δ 取得. 因此, $e^{\hat{\beta}\Delta}$ 的 95% 置信区间的上下限分别为: $(e^{\hat{\beta}\Delta - 1.96\Delta \times \text{SE}_{\hat{\beta}}}, e^{\hat{\beta}\Delta + 1.96\Delta \times \text{SE}_{\hat{\beta}}})$. 由于两个点估计和置信区间的上下限依赖于 Δ 的选择, 所以必须在所有计算中明确设定 Δ 的值.

```

* SAS PROGRAM: Estimating 99% C.I. for Customized Odds Ratio;
PROC LOGISTIC DESCENDING;
MODEL COLLEGE = GENDER KEYSCH MEANGR/WALDRI ALPHA = 0.001;
UNITS MEANGR = 5 - 5;
RUN;

```

发生比率的改变量也称作条件发生比率(conditional odds ratio). 对应连续变量 MEANGR 的 ± 5 个单位的变化, 其发生比率的 95% 和 99% 置信区间的估计在表 5.2.2 中提供.

表 5.2.2 发生比率的变化及其置信区间

Conditional Odds Ratios and 95% Confidence Intervals				
Variable	Unit	Odds Ratio	Wald Confidence Limits	
			Lower	Upper
MEANGR	5.0000	8.354	6.196	11.263
MEANGR	-5.0000	0.120	0.089	0.161

Conditional Odds Ratios and 99.9% Confidence Intervals				
Variable	Unit	Odds Ratio	Wald Confidence Limits	
			Lower	Upper
MEANGR	5.0000	8.354	5.058	13.796
MEANGR	-5.0000	0.120	0.072	0.198

5.2.3 事件概率的置信区间

为了更好地解释事件概率的预测值, 就需要计算相应的概率真值的置信区间. 对某个具有一定特征的案例的概率的置信区间的计算步骤为: 首先, 计算对应 logit 的置信区间上下限; 其次, 将其转换为相应发生比的置信区间上下限; 最后, 将发生比的置信区间上下限再转换为事件概率置信区间的上下限.

设 $\text{logit}(y) = (\hat{\alpha} + \hat{\beta}_k x_k)$ 为某案例的估计 logit, 要计算 $\text{logit}(y)$ 的 95% 置信区间就需要 $\text{logit}(y)$ 的方差. 该 logit 的方差计算公式如下:

$$\text{Var}[\hat{\text{logit}}(y)] = \text{Var}(\hat{\alpha}) + x_k^2 \text{Var}(\hat{\beta}_k) + 2x_k \text{Cov}(\hat{\alpha}, \hat{\beta}_k), \quad 5.2.4$$

其中, $\text{Var}(\hat{\alpha})$ 和 $\text{Var}(\hat{\beta}_k)$ 分别为 $\hat{\alpha}$ 和 $\hat{\beta}_k$ 的方差, 而 $\text{Cov}(\hat{\alpha}, \hat{\beta}_k)$ 为 $\hat{\alpha}$ 和 $\hat{\beta}_k$ 之间的协方差. 对 $\hat{\text{logit}}(y)$ 进行 95% 置信区间估计的公式为:

$$\hat{\text{logit}}(y) \pm 1.96 \sqrt{\text{Var}[\hat{\text{logit}}(y)]}. \quad 5.2.5$$

将式 5.2.5 估计的置信区间上下限求指数:

$$(e^{\hat{\text{logit}}(y) - 1.96 \sqrt{\text{Var}[\hat{\text{logit}}(y)]}}, e^{\hat{\text{logit}}(y) + 1.96 \sqrt{\text{Var}[\hat{\text{logit}}(y)]}}). \quad 5.2.6$$

将式 5.2.6 中的指数幂分别代入式 4.4.1 中, 便可求得相应的概率置信区间. 这一方法的关键在于估计 $\hat{\text{logit}}(y)$ 的方差, 这一计算需要系数估计的协方差矩阵. 这一矩阵可通过在 SAS 的 PROC LOGISTIC 程序中设置 COVB 命令取得. SPSS 的 LOGISTIC REGRESSION 程序不能提供系数估计的协方差矩阵, 但可以提供相关矩阵. 但两个参数之间的相关系数可以很容易换算为协方差(即 $\text{Corr}(\hat{\beta}_1, \hat{\beta}_2) = \text{Cov}(\hat{\beta}_1, \hat{\beta}_2) / (\text{SE}_{\hat{\beta}_1} \text{SE}_{\hat{\beta}_2})$). 下列 SAS 和 SPSS 程序可以分别提供式 2.5.1 模型系数估计的协方差矩阵和相关矩阵:

```
* SAS PROGRAM: PRODUCING COVARIANCE MATRIX OF LOGISTIC COEFFICIENTS;
PROC GENMOD;
MODEL COLLEGE = GENDER KEYSCH MEANGR/COVB;
RUN;
```

```
* SPSS PROGRAM: PRODUCING CORRELATION MATRIX OF LOGISTIC COEFFICIENTS.
LOGISTIC REGRESSION VAR = COLLEGE
/METHOD = ENTER GENDER KEYSCH MEANGR
/PRINT = CORR.
```

式 2.5.1 模型的系数估计的协方差矩阵和相关矩阵分别在表 5.2.3 的上部和下部提供.

现在, 我们来计算重点中学且平均高中成绩高于总平均水平 2 分的男生考入大学的概率的 95% 置信区间.

这组学生的 logit 估计为:

$$\text{logit}(y) = -1.7575 + 0.8661 \times 1 + 0.9130 \times 1 + 0.4245 \times 2 = 0.8706$$

而 $\text{logit}(y)$ 的方差为:

$$\begin{aligned} \text{Var}[\text{logit}(y)] = & \text{Var}(\hat{\alpha}) + \text{GENDER}^2 \text{Var}(\hat{\beta}_1) + \\ & \text{KEYSCH}^2 \text{Var}(\hat{\beta}_2) + \text{MEANGR}^2 \text{Var}(\hat{\beta}_3) + \\ & 2\text{GENDER} \text{Cov}(\hat{\alpha}, \hat{\beta}_1) + 2\text{KEYSCH} \text{Cov}(\hat{\alpha}, \hat{\beta}_2) + \\ & 2\text{MEANGR} \text{Cov}(\hat{\alpha}, \hat{\beta}_3) + \\ & 2\text{GENDER} \text{KEYSCH} \text{Cov}(\hat{\beta}_1, \hat{\beta}_2) + \\ & 2\text{GENDER} \text{MEANGR} \text{Cov}(\hat{\beta}_1, \hat{\beta}_3) + \\ & 2 \text{KEYSCH} \text{MEANGR} \text{Cov}(\hat{\beta}_2, \hat{\beta}_3) \end{aligned}$$

将 $\text{GENDER} = 1$, $\text{KEYSCH} = 1$, $\text{MEANGR} = 2$, 及 $\hat{\alpha}$ 、 $\hat{\beta}_1$ 、 $\hat{\beta}_2$ 、 $\hat{\beta}_3$ 的值代入此式, 可以求得:

$$\text{Var}[\text{logit}(y)] \approx 0.0536$$

那么 $\text{logit}(y)$ 的 95% 置信区间为:

$$0.8706 \pm 1.96 \sqrt{0.0536} = (0.4168, 1.3244)$$

将 $\text{logit}(y)$ 代入式 4.4.1 求指数幂得到这组学生考入大学的预测概率为:

$$e^{0.8706} / (1 + e^{0.8706}) = 0.70$$

再将 $\text{logit}(y)$ 的 95% 置信区间的上下限值代入式 4.4.1 的指数求出相应事件概率的置信区间上下限:

$$[e^{0.4168} / (1 + e^{0.4168}), e^{1.3244} / (1 + e^{1.3244})] = (0.60, 0.79)$$

所以, 重点中学且平均高中成绩高于总平均水平 2 分 (即 $83.7 + 2 = 85.7$) 的男生考入大学的概率的 95% 置信区间为 $(0.60, 0.79)$.

表 5.2.3 系数估计的协方差矩阵和相关矩阵

SAS 输出的协方差矩阵

Estimated Covariance Matrix

Variable	INTERCPT	GENDER	KEYSCH	MEANGR
INTERCPT	0.0251704883	-0.021590829	-0.00981759	-0.001327287
GENDER	-0.021590829	0.0331625089	-0.000686528	-0.000271654



续表

KEYSCH	-0.00981759	-0.000686528	0.0581521925	0.000986248
MEANGR	-0.001327287	-0.000271654	0.000986248	0.0009297755

SPSS 输出的相关矩阵

	Constant	GENDER	KEYSCH	MEANGR
Constant	1.00000	-.74731	-.25661	-.27437
GENDER	-.74731	1.00000	-.01563	-.04892
KEYSCH	-.25661	-.01563	1.00000	.13413
MEANGR	-.27437	-.04892	.13413	1.00000

尾注：

如果手头没有 χ^2 分布表，我们也可以用下面的 SAS 程序来计算任意显著水平和自由度的 χ^2 值：

```
DATA __NULL__ ;
CHISQ1 = CINV (0.95,1);
CHISQ2 = CINV (0.99,1);
CHISQ3 = CINV (0.999,1);
PUT CHISQ1 = ;
PUT CHISQ2 = ;
PUT CHISQ3 = ;
RUN;
```

其中，CINV 为 SAS 中 χ^2 概率分布 PROBCHI 的反函数。SAS 命令 CINV (0.95,1), CINV (0.99,1), CINV (0.999,1) 分别计算 d.f. = 1 时 $\alpha = 0.05$ 、0.01、0.001 的 χ^2 统计值。

SPSS 也可以做同样的工作。在程序中定义一个变量代表 α 水平做起来比较容易。比如，下列 SPSS 程序可以分别计算 d.f. = 1 时 $\alpha = 0.05$ 、0.01、0.001 的 χ^2 统计值。

```
DATA LIST FREE / ALPHA.
BEGIN DATA
.05 .01 .001
END DATA.
COMPUTE CHISQ = IDF.CHISQUARE (1 - ALPHA,1).
EXECUTE.
```

建立模型



- 6.1 选择变量 (146)
 - 6.1.1 筛选自变量 (146)
 - 6.1.2 模型的比较 (152)
 - 6.1.3 逐步模型选择法 (153)
 - 6.1.4 排除有意义的变量和包括没有意义的变量 (171)
- 6.2 非线性与非加性(Nonlinearity and Nonadditivity) (172)
 - 6.2.1 非线性 (172)
 - 6.2.2 非加性 (177)

前面各章已经介绍了 logistic 函数、logistic 回归模型的估计、模型的评价、系数的解释以及 logistic 回归系数的统计推断，本章将讨论建立模型的有关问题。

如同线性回归，建立 logistic 回归模型中最重要的也是正确设立模型。设立模型有两重意思：一是正确选择所设模型变量；二是正确设立模型的函数形式。误设模型将导致 logistic 回归参数估计有偏。

6.1 选择变量

在选择模型的自变量之前，必须先设置反应变量的类型。反应变量的测量可设为两种形式。第一种应用于案例水平上的二分类反应变量，即每一个案例的反应变量中用编码 1 代表事件发生、用编码 0 代表事件未发生。这种情况在 logistic 回归分析中较为普遍。第二种形式应用于汇总水平上的二分类反应变量，即从分组数据取得事件发生与否的信息。在这种情况下，需要两个变量来分别设置每组的事件发生数和案例数。第二章的 2.6 小节讨论的使用分组数据的 logistic 回归模型便是上述第二种形式。

在给定反应变量形式后，建模需要设置一系列自变量。前面各章讨论过的示范模型只设置了几个自变量。实际上，模型应该纳入所有理论上可以接受的自变量。在建立模型阶段，我们需要做的是识别可以很好预测反应变量的候选自变量，并将它们全部纳入模型。

6.1.1 筛选自变量

选择自变量的工作通常从检查每个自变量与反应变量之间二元关系着手。对于连续变量，通常通过拟合单变量 logistic 回归模型来取得变量的显著性检验。对于名义变量和序次变量，建议对每个变量按其 m 个水平进行与结果 ($y=0$ 或 1) 的二维交互表分析。自由度为 $m-1$ 的似然比 χ^2 检验与简单 logistic 回归中

($m-1$)个虚拟设计变量(design variables)的模型 χ^2 显著性检验的结果相同. 用高考升学的例子来加以示范, 对连续变量 MEANGR 的显著性检验通过简单 logistic 回归完成, 而对两个虚拟变量 GENDER 和 KEYSCH 的检验要通过 2×2 交互表. 相应的 SAS 和 SPSS 程序列在下面, 它们的运行结果在表 6.1.1 中提供.

```
* SAS Program: Univariate Analysis;
...
PROC LOGISTIC DESCENDING;
MODEL COLLEGE = MEANGR;
RUN;

PROC FREQ;
TABLES (GENDER KEYSCH) * COLLEGE/CHISQ;
RUN;

* SPSS Program: Univariate Analysis.
...
LOGISTIC REGRESSION VAR = COLLEGE
  /METHOD = ENTER MEANGR
  /CRITERIA PIN(.05) POUT(.10) ITERATE(20) CUT(.5).
CROSSTABS
  /TABLES = GENDER KEYSCH BY COLLEGE
  /FORMAT = AVALUE TABLES
  /STATISTIC = CHISQ
  /CELLS = COUNT.
```

表 6.1.1 自变量的二元关系分析

SAS 输出 (节选)			
(以 MEANGR 为唯一自变量做简单 logistic 回归)			
Model Fitting Information and Testing Global Null Hypothesis BETA=0			
Criterion	Intercept Only	Intercept and Covariates	Chi-Square for Covariates
AIC	1277.326	883.507	.
SC	1282.234	893.323	.



续表

-2 LOG L	1275.326	879.507	395.819 with 1 DF (p=0.0001)
Score	.	.	319.053 with 1 DF (p=0.0001)

Analysis of Maximum Likelihood Estimates

Variable	DF	Parameter Estimate	Standard Error	Wald Chi-Square	Pr>Chi-Square	Standardized Estimate	Odds Ratio
INTERCPT	1	-1.0876	0.0938	134.4218	0.0001	.	.
MEANGR	1	0.4381	0.0294	222.3920	0.0001	1.038318	1.550

(COLLEGE 与 GENDER 之间的交互表)

TABLE OF GENDER BY COLLEGE

GENDER		COLLEGE		
Frequency				
Percent				
Row Pct				
Col Pct		0	1	Total
0		374	76	450
		37.40	7.60	45.00
		83.11	16.89	
		56.24	22.69	
1		291	259	550
		29.10	25.90	55.00
		52.91	47.09	
		43.76	77.31	
Total		665	335	1000
		66.50	33.50	100.00

STATISTICS FOR TABLE OF GENDER BY COLLEGE

Statistic	DF	Value	Prob
Chi-Square	1	101.340	0.001
Likelihood Ratio Chi-Square	1	106.019	0.001
Continuity Adj. Chi-Square	1	99.989	0.001
Mantel-Haenszel Chi-Square	1	101.239	0.001
Fisher's Exact Test (Left)			1.000
(Right)			7.85E-25
(2-Tail)			1.32E-24

续表

Phi Coefficient	0.318
Contingency Coefficient	0.303
Cramer's V	0.318

Sample Size = 1 000

(COLLEGE 与 KEYSCH 的交互表)

TABLE OF KEYSCH BY COLLEGE

KEYSCH		COLLEGE		
Frequency				
Percent				
Row Pct				
Col Pct				
	0	1	Total	
0	596	272	868	
	59.60	27.20	86.80	
	68.66	31.34		
	89.62	81.19		
1	69	63	132	
	6.90	6.30	13.20	
	52.27	47.73		
	10.38	18.81		
Total	665	335	1000	
	66.50	33.50	100.00	

STATISTICS FOR TABLE OF KEYSCH BY COLLEGE

Statistic	DF	Value	Prob
Chi-Square	1	13.818	0.001
Likelihood Ratio Chi-Square	1	13.223	0.001
Continuity Adj. Chi-Square	1	13.092	0.001
Mantel-Haenszel Chi-Square	1	13.804	0.001
Fisher's Exact Test (Left)			1.000
(Right)			1.95E-04
(2-Tail)			3.35E-04
Phi Coefficient		0.118	
Contingency Coefficient		0.117	
Cramer's V		0.118	

Sample Size = 1000

续表

SPSS 输出(节选)

(以 MEANGR 为唯一自变量做简单 logistic 回归)

- 2 Log Likelihood	879.507
Goodness of Fit	1229.285
Cox & Snell - R ²	.327
Nagelkerke - R ²	.454

	Chi-Square	d.f.	Significance
Model	395.819	1	.0000
Block	395.819	1	.0000
Step	395.819	1	.0000

Variables in the Equation							
Variable	B	S.E.	Wald	d.f.	Sig.	R	Exp (B)
MEANGR	.4380	.0294	222.3522	1	.0000	.4157	1.5496
Constant	-1.0874	.0938	134.3921	1	.0000		

(COLLEGE 与 GENDER 的交互表)

Crosstab
Count

		COLLEGE		Total
		.00	1.00	
GENDER	.00	374	76	450
	1.00	291	259	550
Total		665	335	1000

Chi-Square Tests

	Value	d.f.	Asymp. Sig. (2 - sided)	Exact Sig. (2 - sided)	Exact Sig. (1 - sided)
Pearson Chi-Square	101.340	1	.000		
Continuity Correction	99.989	1	.000		
Likelihood Ratio	106.019	1	.000		

续表

	Value	d.f.	Asymp. Sig. (2 - sided)	Exact Sig. (2 - sided)	Exact Sig. (1 - sided)
Fisher's Exact Test				.000	.000
Linear - by - Linear Association	101.239	1	.000		
N of Valid Cases	1000				

a. Computed only for a 2x2 table

b. 0 cells (.0%) have expected count less than 5. The minimum expected count is 150.75.

(COLLEGE 与 KEYSCH 的交互表)

Crosstab

Count

		COLLEGE		Total
		.00	1.00	
KEYSCH	.00	596	272	868
	1.00	69	63	132
Total		665	335	1000

Chi - Square Tests

	Value	d.f.	Asymp. Sig. (2 - sided)	Exact Sig. (2 - sided)	Exact Sig. (1 - sided)
Pearson Chi - Square	13.818	1	.000		
Continuity Correction	13.092	1	.000		
Likelihood Ratio	13.223	1	.000		
Fisher's Exact Test				.000	.000
Linear - by - Linear Association	13.804	1	.000		
N of Valid Cases	1 000				

a. Computed only for a 2x2 table

b. 0 cells (.0%) have expected count less than 5. The minimum expected count is 44.22.

在二元关系分析完成后，我们用若干变量进行多元分析。如果一个自变量在其简单关系的检验中有 $p < 0.25$ 者，都应该考虑与其他重要变量一起作为多元模型的候选变量。

在筛选候选变量时以 0.25 的显著水平(即 $\alpha = 0.25$)作为标准的原因是，如果我们不选择较大一点的显著水平，就有可能在建立模型时遗漏某些重要的自变量。它们很有可能在简单分析时显示与结果变量的弱相关，而在多元分析时就成为重要的自变量。所以，我们应该选择一个足够大的 α 水平，以保证将有可能为重要预测变量的候选者纳入多元分析模型。Bendel 和 Afifi (1977)以及 Mickey 和 Greenland (1989)都曾说明，使用较常规的水平(如 $\alpha = 0.05$)为标准常常可能导致遗漏重要变量。我们例子中的三个自变量 GENDER、KEYSCH 和 MEANGR 都是多元模型的重要候选变量。

当然，使用较大的 α 值为标准对于建立模型也有不利之处，比如可能将一些不太重要的变量包括在模型之中。因此，重要的是在决策一个模型之前不仅需要从统计上把关，而且应该从理论上加以考虑。一旦选择了建立模型的候选变量，我们便开始模型的设置工作。

6.1.2 模型的比较

通常，建立模型的基础是理论假设或实际发现。也就是说，在实际数据分析开始之前，我们便有了模型设置的一些基本想法。有时，对于特定数据可以有几个候选的模型。那么在建立模型时，通常所做的便是检验所有可能模型，以可解释性、简约性、变量的易得性等为依据，从中选择一个模型作为“最终”模型。

比如，我们先拟合一个初始模型，再添加若干自变量成为扩展模型，然后对两者加以比较。类似的调整、比较可能重复多次才能达到确定最终模型。第 4 章所讨论的 L.R. 检验可以用来对两个嵌套的模型进行比较。

对于高考升学的例题，如果我们假设高中的类型和高中平均成绩对于升学很重要，便可以先将两个自变量 KEYSCH 和 MEANGR 纳入模型。然后，我们将 GENDER 加入模型，看看

这样是否可以使模型更好地拟合数据.

$$M_1: \ln(p/(1-p)) = \alpha + \beta_1 \text{KEYSCH} + \beta_2 \text{MEANGR}$$

$$M_2: \ln(p/(1-p)) = \alpha + \beta_1 \text{KEYSCH} + \beta_2 \text{MEANGR} + \beta_3 \text{GENDER}$$

其中, 模型 M_1 与模型 M_2 嵌套. 我们要检验的是加入变量 GENDER 是否对于预测结果有显著的贡献. 所用的统计检验为 L.R. 检验, 通过比较两个模型的 χ^2 统计量 (或 $-2LL$, 或偏差统计量) 来检验这一自变量的作用. 在零假设之下, (即这一新加变量的系数为 0), L.R. 统计量服从 χ^2 分布, 自由度为两个模型自由度的差, 即模型 M_2 中新加的变量数. 于是, 模型 M_1 的 χ^2 值和自由度分别为 412.134 和 d.f. = 2; 模型 M_2 的 χ^2 值和自由度分别为 435.361 和 d.f. = 3. 那么, $L.R. = 435.361 - 412.134 = 23.227$, 并有 d.f. = $3 - 2 = 1$. 这是一个高度显著的结果, 表明新加变量 GENDER 的确对模型有显著贡献, 所以模型 M_2 比模型 M_1 好. 此检验法亦可用于对一组新加变量进行检验.

对于非嵌套模型, L.R. 检验便不再适用. 比如, 下列两个模型之间便不是嵌套关系:

$$M_3: \ln(p/(1-p)) = \alpha + \beta_1 \text{KEYSCH} + \beta_2 \text{MEANGR}$$

$$M_4: \ln(p/(1-p)) = \alpha + \beta_2 \text{MEANGR} + \beta_3 \text{GENDER}$$

其中, 模型 M_3 不是模型 M_4 的简化型, M_4 也不是 M_3 的简化型. 在这种情况下, 我们不能用 L.R. 检验来比较两个模型. 然而有关信息测度指标如 AIC, SC, BIC, BIC' 等可以用来比较非嵌套模型. 关于这些信息指标统计量的计算请参见第 3 章的 3.1.4 节. 读者可以自行计算并比较模型 M_3 和 M_4 的信息指标.

6.1.3 逐步模型选择法

为了建立模型, 可以任意在模型中加入变量, 然后进行模型比较检验, 以选择拟合数据较好的模型. 当模型中有很多自变量时, 这样的工作既费时又费力. 在这种情况下, 可以让计算机程序“自动”地选择自变量来加入模型. 在应用选择变量程序时, 我们只需要设置因变量和候选自变量的名单, 而不用一一设置具

体模型。在运行程序时，就能够根据所设的显著标准将变量加入模型或是从模型中剔除。常用的计算机模型选择方法有：

1. 正向逐步选择法(forward stepwise)：即在截距模型的基础上，将符合所定显著水平的自变量一次一个地加入模型。

2. 反向逐步选择法(backward stepwise)：在模型包括所有候选变量的基础上，将不符合保留要求显著水平的自变量一次一个地删除掉。

3. 混合逐步选择法(combined stepwise)：它将正向选择和反向选择结合起来，根据所设的显著性标准分别将变量加入到模型中去或删除掉。它既可以由正向选择法开始，也可以由反向选择法开始。

SAS 的 PROC LOGISTIC 程序能够设置以上三种选择方法。在下面的 SAS 程序中以升学数据为例示范如何运行正向、反向及混合的逐步选择法。

```
* SAS PROGRAM: STEPWISE COMPUTER MODEL SELECTION;
...
X = 2 + 0.01 * COLLEGE + (0 + 1 * NORMAL(0));
/* In SAS, function (0 + 1 * NORMAL(0)) generates a random variable
with standard normal distribution */

* FORWARD STEPWISE SELECTION;
PROC LOGISTIC DESCENDING;
MODEL COLLEGE = GENDER KEYSCH MEANGR X
  /SELECTION = FORWARD SLENTRY = 0.05 DETAILS;
RUN;

* BACKWARD STEPWISE SELECTION;
PROC LOGISTIC DESCENDING;
MODEL COLLEGE = GENDER KEYSCH MEANGR X
  /SELECTION = BACKWARD SLSTAY = 0.05 DETAILS;
RUN;

* COMBINED STEPWISE SELECTION;
PROC LOGISTIC DESCENDING;
```

```
MODEL COLLEGE = GENDER KEYSCH MEANGR X
/SELECTION = STEPWISE SLENTRY = 0.05 SLSTAY = 0.05 DETAILS;
RUN;
```

为了示范目的，我们新造了一个自变量 X，它不是因变量的显著预测变量，只是作为模型的一个候选自变量。新变量 X 和原有的其他三个变量(即 GENDER, KEYSCH 和 MEANGR)都列在程序的清单中候选。

在 SAS 程序中，命令“SELECTION = FORWARD”、“SELECTION = BACKWARD”及“SELECTION = STEPWISE”分别为设置正向、反向和混合逐步选择法(在 SAS 中混合逐步选择法从正向选择开始)。加入或保留的标准都设为 0.05(这同时是 SAS 的 PROC LOGISTIC 的默认状况)。在 SAS 运行中 Score 统计量用来进行加入选择，Wald 统计量用来做删除选择^①。备选命令 DETAILS 可提供模型选择过程的信息。

表 6.1.2 列出了上述 SAS 程序运行的结果。在正向逐步选择的第 0 步(Step 0)，只有一个常数(即截距 intercept)加入了模型。残差 χ^2 统计值可以用来检验所有不在模型中的变量的系数都为 0 的零假设。由于残差 χ^2 的 p 值很小($p=0.0001$)，表明至少有一个为非 0 值的系数，或至少可以在模型中纳入一个自变量。从 Analysis of Variables Not in the Model 的表中，可以看到变量 MEANGR 有最大的 Score 统计值 319.0525，其对应的 p 值为 0.0001，小于加入标准 0.05。所以，变量 MEANGR 在第 1 步(step 1)正向选择中被加入模型。按照同样的过程，变量 GENDER 和 KEYSCH 在第 2 步和第 3 步也分别被纳入模型。在这一选择过程的最后，专有一个注表示没有其他符合所设加入标准的变量了。最后，输出一个正向选择过程的总结表“Summary of Forward Selection Procedure”。表中列出每一步对应的加入自变量及其 χ^2 值和概率值。在最终模型中，包括了自变量 MEANGR、GENDER 和 KEYSCH。

反向逐步选择法也始于第 0 步，但与正向逐步选择相反，这时模型之中包括截距和所有四个候选自变量(GENDER、

^① 参见 SAS Institute Inc., 1995

KEYSCH, MEANGR, X). 在 Analysis of Maximum Likelihood Estimates 一栏中, 注意变量 X 的 Wald χ^2 值最小(0.003 5)、p 值最大(0.952 9). 这一 p 值已大于模型的保留标准 0.05, 因此这一变量在第 1 步反向选择中就被删除出模型. 然后, 选择过程便结束了, 因为没有符合可删标准的变量了, 即 “No (additional) variables met the 0.05 significance level for removal from the model”. 反向选择结束之后也输出一个总结表 “Summary of Backward Elimination Procedure”, 表中列出各步所删除的变量名及其 χ^2 值和概率值. 由反向选择法所建立的模型与正向选择法相同.

用 SAS 做 logistic 回归, 正向和反向混合的逐步选择法始于正向选择. 也就是说, 它由零模型开始, 然后将符合标准的变量逐步加入模型. 在每一步中, 程序自动检查是否已经加入的变量因为模型纳入其他变量而变为不显著. 如果变量的 Wald 统计量显著水平值超过了所设的删除标准, 就被删除掉. 如果没有变量符合删除标准, 那么还要在未加入的变量中寻找符合加入标准者. 这一过程一直延续到再没有一个可加入或可删除的变量为止. 在本例中, 选择从截距模型开始, 然后逐步加入了变量 MEANGR、GENDER、KEYSCH. 在此之后, 按照标准既没有变量可供加入, 也没有变量可供删除.

表 6.1.2 SAS 模型选择的输出

正向逐步选择:

Step 0. Intercept entered:

Analysis of Maximum Likelihood Estimates							
Variable	DF	Parameter Estimate	Standard Error	Wald Chi-Square	Pr>Chi-Square	Standardized Estimate	Odds Ratio
INTERCPT	1	-0.6857	0.0670	104.7321	0.0001	.	.
Residual Chi-Square = 344.8751 with 4 DF (p=0.0001)							

Analysis of Variables Not in the Model

Variable	Score Chi-Square	Pr>Chi-Square
GENDER	101.3400	0.0001
KEYSCH	13.8176	0.0002
MEANGR	319.0525	0.0001
X	0.3834	0.5358

续表

Step 1. Variable MEANGR entered:

Model Fitting Information and Testing Global Null Hypothesis BETA = 0

Criterion	Intercept and		Chi-Square for Covariates
	Intercept Only	Covariates	
AIC	1277.326	883.507	.
SC	1282.234	893.323	.
- 2 LOG L	1275.326	879.507	395.819 with 1 DF (p=0.000 1)
Score	.	.	319.053 with 1 DF (p= 0.000 1)

Analysis of Maximum Likelihood Estimates

Variable	DF	Parameter Estimate	Standard Error	Wald Chi-Square	Pr > Chi-Square	Standardized Estimate	Odds Ratio
INTERCPT	1	- 1.0876	0.0938	134.4218	0.0001	.	.
MEANGR	1	0.4381	0.0294	222.3920	0.0001	1.038318	1.550

Association of Predicted Probabilities and Observed Responses

Concordant = 85.3%	Somers' D = 0.710
Discordant = 14.3%	Gamma = 0.714
Tied = 0.5%	Tau - a = 0.317
(222775 pairs)	c = 0.855

Residual Chi-Square = 39.6154 with 3 DF (p = 0.0001)

Analysis of Variables Not in the Model

Variable	Score Chi-Square	Pr > Chi-Square
GENDER	25.1329	0.0001
KEYSCH	16.6799	0.0001
X	0.0571	0.8112

Step 2. Variable GENDER entered:

Model Fitting Information and Testing Global Null Hypothesis BETA = 0

Criterion	Intercept and		Chi-Square for Covariates
	Intercept Only	Covariates	
AIC	1277.326	860.378	.
SC	1282.234	875.101	.
- 2 LOG L	1275.326	854.378	420.949 with 2 DF (p=0.000 1)
Score	.	.	335.220 with 2 DF (p= 0.000 1)

续表

Analysis of Maximum Likelihood Estimates							
Variable	DF	Parameter Estimate	Standard Error	Wald Chi-Square	Pr > Chi-Square	Standardized Estimate	Odds Ratio
INTERCPT	1	-1.6284	0.1517	115.1902	0.0001	.	.
GENDER	1	0.8920	0.1805	24.4271	0.0001	0.244780	2.440
MEANGR	1	0.4168	0.0300	192.4835	0.0001	0.988016	1.517
Association of Predicted Probabilities and Observed Responses							
Concordant = 86.2%				Somers' D = 0.727			
Discordant = 13.5%				Gamma = 0.729			
Tied = 0.3%				Tau-a = 0.324			
(222775 pairs)				c = -0.864			

Residual Chi-Square = 14.706 2 with 2 DF (p = 0.000 6)

Analysis of Variables Not in the Model

Variable	Score Chi-Square	Pr > Chi-Square
KEYSCH	14.7032	0.0001
X	0.0165	0.8979

Step 3. Variable KEYSCH entered:

Model Fitting Information and Testing Global Null Hypothesis BETA = 0

Criterion	Intercept		Chi-Square for Covariates
	Only	and Covariates	
AIC	1277.326	847.965	.
SC	1282.234	867.596	.
-2 LOG L	1275.326	839.965	435.361 with 3 DF (p=0.000 1)
Score	.	.	344.873 with 3 DF (p=0.000 1)

Analysis of Maximum Likelihood Estimates

Variable	DF	Parameter Estimate	Standard Error	Wald Chi-Square	Pr > Chi-Square	Standardized Estimate	Odds Ratio
INTERCPT	1	-1.7575	0.1587	122.7106	0.0001	.	.
GENDER	1	0.8661	0.1821	22.6201	0.0001	0.237677	2.378
KEYSCH	1	0.9130	0.2411	14.3335	0.0002	0.170465	2.492
MEANGR	1	0.4245	0.0305	193.8485	0.0001	1.006257	1.529

Association of Predicted Probabilities and Observed Responses

续表

Concordant = 86.8%	Somers' D = 0.737
Discordant = 13.0%	Gamma = 0.739
Tied = 0.2%	Tau-a = 0.329
(222775 pairs)	c = 0.869
Residual Chi-Square = 0.0035 with 1 DF (p = 0.9529)	
Analysis of Variables Not in the Model	

Variable	Score Chi-Square	Pr > Chi-Square
X	0.0035	0.9529

NOTE: No (additional) variables met the 0.05 significance level for entry into the model.

Summary of Forward Selection Procedure

Step	Variable Entered	Number In	Score Chi-Square	Pr > Chi-Square
1	MEANGR	1	319.1	0.0001
2	GENDER	2	25.1329	0.0001
3	KEYSCH	3	14.7032	0.0001

反向逐步选择:

Step 0. The following variables were entered:

INTERCPT GENDER KEYSCH MEANGR X

Model Fitting Information and Testing Global Null Hypothesis BETA=0

Criterion	Intercept Only	Intercept and Covariates	Chi-Square for Covariates
AIC	1277.326	849.961	.
SC	1282.234	874.500	.
- 2 LOG L	1275.326	839.961	435.365 with 4 DF (p = 0.0001)
Score	.	.	344.875 with 4 DF (p = 0.0001)

Analysis of Maximum Likelihood Estimates

Variable	DF	Parameter Estimate	Standard Error	Wald Chi-Square	Pr > Chi-Square	Standardized Estimate	Odds Ratio
INTERCPT	1	-1.7473	0.2344	55.5694	0.0001	.	.
GENDER	1	0.8662	0.1821	22.6255	0.0001	0.237716	2.378
KEYSCH	1	0.9137	0.2415	14.3196	0.0002	0.170598	2.494
MEANGR	1	0.4246	0.0305	193.7241	0.0001	1.006377	1.529
X	1	-0.0035	0.0912	0.0035	0.9529	-0.002824	0.995



6. 建立模型

续表

Association of Predicted Probabilities and Observed Responses

Concordant = 86.8%	Somers' D = 0.738
Discordant = 13.1%	Gamma = 0.739
Tied = 0.1%	Tau-a = 0.329
(222 775 pairs)	c = 0.869

Step 1. Variable X is removed:

Model Fitting Information and Testing Global Null Hypothesis BETA = 0

Criterion	Intercept Only	Intercept and Covariates	Chi-Square for Covariates
AIC	1277.326	847.965	.
SC	1282.234	867.596	.
- 2 LOG L	1275.326	839.965	435.361 with 3 DF (p=0.0001)
Score	.	.	344.873 with 3 DF (p=0.0001)

Analysis of Maximum Likelihood Estimates

Variable	DF	Parameter Estimate	Standard Error	Wald Chi-Square	Pr > Chi-Square	Standardized Estimate	Odds Ratio
INTERCPT	1	-1.7575	0.1587	122.7106	0.0001	.	.
GENDER	1	0.8661	0.1821	22.6201	0.0001	0.237677	2.378
KEYSCH	1	0.9130	0.2411	14.3335	0.0002	0.170465	2.492
MEANGR	1	0.4245	0.0305	193.8485	0.0001	1.006257	1.529

Association of Predicted Probabilities and Observed Responses

Concordant = 86.8%	Somers' D = 0.737
Discordant = 13.0%	Gamma = 0.739
Tied = 0.2%	Tau-a = 0.329
(222 775 pairs)	c = 0.869

Residual Chi-Square = 0.0035 with 1 DF (p = 0.9529)

NOTE: No (additional) variables met the 0.05 significance level for removal from the model.

Summary of Backward Elimination Procedure

Step	Variable Removed	Number In	Wald Chi-Square	Pr > Chi-Square
1	X	3	0.00348	0.9529

续表

正向反向混合的逐步选择:

Step 0. Intercept entered:

Analysis of Maximum Likelihood Estimates

Variable	DF	Parameter Estimate	Standard Error	Wald Chi-Square	Pr > Chi-Square	Standardized Estimate	Odds Ratio
INTERCPT	1	-0.6857	0.0670	104.7321	0.0001	.	.

Residual Chi-Square = 344.8751 with 4 DF ($p=0.0001$)

Analysis of Variables Not in the Model

Variable	Score Chi-Square	Pr > Chi-Square
GENDER	101.3400	0.0001
KEYSCH	13.8176	0.0002
MEANGR	319.0525	0.0001
X	0.3834	0.5358

Step 1. Variable MEANGR entered:

Model Fitting Information and Testing Global Null Hypothesis BETA = 0

Criterion	Intercept Only	Intercept and Covariates	Chi-Square for Covariates
AIC	1277.326	883.507	.
SC	1282.234	893.323	.
-2 LOG L	1275.326	879.507	395.819 with 1 DF ($p=0.0001$)
Score	.	.	319.053 with 1 DF ($p=0.0001$)

Analysis of Maximum Likelihood Estimates

Variable	DF	Parameter Estimate	Standard Error	Wald Chi-Square	Pr > Chi-Square	Standardized Estimate	Odds Ratio
INTERCPT	1	-1.0876	0.0938	134.4218	0.0001	.	.
MEANGR	1	0.4381	0.0294	222.3920	0.0001	1.038318	1.550

续表

Association of Predicted Probabilities and Observed Responses

Concordant = 85.3%	Somers' D = 0.710
Discordant = 14.3%	Gamma = 0.714
Tied = 0.5%	Tau-a = 0.317
(222 775 pairs)	c = 0.855

Residual Chi-Square = 39.6154 with 3 DF (p= 0.0001)

Analysis of Variables Not in the Model

Variable	Score Chi-Square	Pr > Chi-Square
GENDER	25.1329	0.0001
KEYSCH	16.6799	0.0001
X	0.0571	0.8112

Step 2. Variable GENDER entered:

Model Fitting Information and Testing Global Null Hypothesis BETA=0

Criterion	Intercept and		Chi-Square for Covariates
	Intercept Only	Covariates	
AIC	1277.326	860.378	.
SC	1282.234	875.101	.
-2 LOG L	1275.326	854.378	420.949 with 2 DF (p= 0.0001)
Score	.	.	335.220 with 2 DF (p= 0.0001)

Analysis of Maximum Likelihood Estimates

Variable	DF	Parameter Estimate	Standard Error	Wald Chi-Square	Pr > Chi-Square	Standardized Estimate	Odds Ratio
INTERCPT	1	-1.6284	0.1517	115.1902	0.0001	.	.
GENDER	1	0.8920	0.1805	24.4271	0.0001	0.244780	2.440
MEANGR	1	0.4168	0.0300	192.4835	0.0001	0.988016	1.517

Association of Predicted Probabilities and Observed Responses

Concordant = 86.2%	Somers' D = 0.727
Discordant = 13.5%	Gamma = 0.729

续表

Tied	= 0.3%	Tau-a	0.324
(222 775 pairs)		c	- 0.864
Residual Chi-Square = 14.7062 with 2 DF (p = 0.0006)			
Analysis of Variables Not in the Model			
Variable	Score	Pr >	
	Chi-Square	Chi-Square	
KEYSCH	14.7032	0.0001	
X	0.0165	0.8979	

Step 3. Variable KEYSCH entered:

Model Fitting Information and Testing Global Null Hypothesis BETA = 0

Criterion	Intercept and		
	Intercept Only	Covariates	Chi-Square for Covariates
AIC	1277.326	847.965	.
SC	1282.234	867.596	.
- 2 LOG L	1275.326	839.965	435.361 with 3 DF (p = 0.0001)
Score	.	.	344.873 with 3 DF (p = 0.0001)

Analysis of Maximum Likelihood Estimates

Variable	DF	Parameter		Wald Chi-Square	Pr > Chi-Square	Standardized Estimate	Odds Ratio
		Estimate	Standard Error				
INTERCPT	1	-1.7575	0.1587	122.7106	0.0001	.	.
GENDER	1	0.8661	0.1821	22.6201	0.0001	0.237677	2.378
KEYSCH	1	0.9130	0.2411	14.3335	0.0002	0.170465	2.492
MEANGR	1	0.4245	0.0305	193.8485	0.0001	1.006257	1.529

Association of Predicted Probabilities and Observed Responses

Concordant = 86.8%	Somers' D = 0.737
Discordant = 13.0%	Gamma = 0.739
Tied = 0.2%	Tau-a = 0.329
(222775 pairs)	c = 0.869

Residual Chi-Square = 0.0035 with 1 DF (p = 0.9529)

Analysis of Variables Not in the Model

续表

Variable	Score	Pr >
	Chi-Square	Chi-Square
X	0.0035	0.9529

NOTE: No (additional) variables met the 0.05 significance level for entry into the model.

Summary of Stepwise Procedure						
Step	Variable Entered	Number Removed	In	Score Chi-Square	Wald Chi-Square	Pr > Chi-Square
1	MEANGR		1	319.1	.	0.0001
2	GENDER		2	25.1329	.	0.0001
3	KEYSCH		3	14.7032	.	0.0001

SPSS 的 LOGISTIC 回归程序只能提供混合逐步选择法, 然而选择过程既可以由正向选择开始, 也可以由反向选择开始. SPSS 的命令 “METHOD = FSTEP (WALD)” 执行始于正向选择的混合逐步选择. 它与 SAS 所做的混合逐步选择完全相同. SPSS 命令 “METHOD = BSTEP (WALD)” 执行始于反向选择的混合逐步选择. 也就是说, 在选择开始时, 所有的候选变量全在模型之中, 然后再逐步地评价、删除、加入. 这种方法与反向选择法的不同之处在于, 被删除的变量如果在其他变量被删除出模型后重新符合标准, 还可以在随后的选择过程中重新加入模型. 与 SAS 的 PROC LOGISTIC 程序一样, 在 SPSS 中作为加入评价的标准也是 Score 统计量. 然而, 删除标准却可以在 Wald 统计量或 LR 统计量中进行选择. 为了与前面做过的 SAS 结果一致, 我们还选用 Wald 统计量作为删除的检验标准 (即 METHOD = FSTEP (WALD) 或 METHOD = BSTEP (WALD)).

在 SPSS 的打印输出中常见模型 χ^2 (model chi-square)、分组 χ^2 (block chi-square) 和分步 χ^2 (step chi-square) 等统计值. 对某些 SPSS 的用户来说, 后两个统计值可能不太熟悉. SPSS 的 LOGISTIC 回归程序在设置模型时可以允许将自变量组织成多元的分组, 然后在运行程序时, 可以按不同分组进行变量选择和加



入。这种设置在 SPSS 视窗第 6.0 版及以后各版都可以轻松地完成。与此相应,在程序中重复使用 METHOD 命令也能完成同样的工作。比如,我们将变量 MEANGR 和 GENDER 作为第一组(Block 1),将其他变量作为第二组(Block 2)。下面的命令将第一组变量一次强制纳入模型,而将第二组变量逐步选择加入。

```
LOGISTIC REGRESSION VAR = COLLEGE
  /METHOD = ENTER MEANGR GENDER
  /METHOD = FSTEP (WALD)KEYSCH X
  /CRITERIA PIN(.05) POUT(.05) ITERATE(20) CUT(.5).
```

在下一个例子中,我们不用多个分组,而是将所有候选自变量放在第一组中(默认状态),然后对其执行混合逐步选择,分别起始于正向选择和反向选择。加入和删除的标准由标准备选命令“PIN(.05)”和“POUT(.05)”都设置为 0.05(在 SPSS 默认状况中,加入标准为 0.05,而删除标准为 0.10)。于是示范的 SPSS 程序如下:

```
* SPSS PROGRAM: STEPWISE COMPUTER MODEL SELECTION.
...
COMPUTE X = 2 + 0.01 * COLLEGE + NORMAL(1).
/* In SPSS, function (NORMAL(1) generates a random variable with
standard normal distribution
*/
EXECUTE .
LOGISTIC REGRESSION VAR = COLLEGE
  /METHOD = FSTEP (WALD)GENDER KEYSCH MEANGR X
  /CRITERIA PIN(.05) POUT(.05) ITERATE(20) CUT(.5).
LOGISTIC REGRESSION VAR = COLLEGE
  /METHOD = BSTEP (WALD)GENDER KEYSCH MEANGR X
  /CRITERIA PIN(.05) POUT(.05) ITERATE(20) CUT(.5).
```

上述 SPSS 程序的输出列在表 6.1.3 中。选择始于截距模型,然后在第一组的变量中进行逐步选择,所用的方法是以正向选择

开始的混合逐步选择法,这与用 SAS 的 PROC LOGISTIC 程序所做的混合选择法相同.在每一步,模型 χ^2 和分组 χ^2 都是相同的,因为只定义了一个分组.分步 χ^2 代表了这一步所选变量对模型拟合的贡献.在始于反向选择的混合逐步选择中,所有四个候选自变量都在第一步便纳入了模型,然后变量 X 被删除了.此后,没有其他变量符合删除标准,被删除的变量 X 在下一步中也不符合重新加入的标准.于是,操作得到了同样的最终模型.

表 6.1.3 SPSS 输出的模型选择结果

以正向选择开始的混合逐步选择过程:

Dependent Variable: COLLEGE

Beginning Block Number 0. Initial Log Likelihood Function

-2 Log Likelihood 1275.3263

* Constant is included in the model.

----- Variables in the Equation -----

Variable	B	S.E.	Wald	d.f.	Sig	R	Exp (B)
Constant	-.6857	.0670	104.7321	1	.0000		

Beginning Block Number 1. Method: Forward Stepwise (WALD)

----- Variables not in the Equation -----

Residual Chi Square 345.743 with 4 d.f. Sig = .0000

Variable	Score	d.f.	Sig	R
GENDER	101.3400	1	.0000	.2791
KEYSCH	13.8176	1	.0002	.0963
MEANGR	319.0525	1	.0000	.4986
X	3.6888	1	.0548	.0364

Variable (s) Entered on Step Number 1: MEANGR

Estimation terminated at iteration number 4 because

Log Likelihood decreased by less than .01 percent.

-2 Log Likelihood 879.507

Goodness of Fit 1229.285

Cox & Snell - R² .327

Nagelkerke - R² .454

	Chi-Square	d.f.	Significance
Model	395.819	1	.0000
Block	395.819	1	.0000
Step	395.819	1	.0000

续表

Variables in the Equation							
Variable	B	S.E.	Wald	d.f.	Sig.	R	Exp (B)
MEANGR	.4380	.0294	222.3522	1	.0000	.4157	1.5496
Constant	-1.0874	.0938	134.3921	1	.0000		
Variables not in the Equation							
Residual	Chi-Square 40.011 with 3 d.f.			Sig = .0000			
Variable	Score	d.f.	Sig.	R			
GENDER	25.1246	1	.0000	.1347			
KEYSCH	16.6756	1	.0000	.1073			
X	.3297	1	.5659	.0000			

Variable (s) Entered on Step Number 2.. GENDER

Estimation terminated at iteration number 5 because
parameter estimates changed by less than .001

-2 Log Likelihood 854.378

Goodness of Fit 1337.010

Cox & Snell - R² .344

Nagelkerke - R² .477

	Chi-Square	d.f.	Significance
Model	420.949	2	.0000
Block	420.949	2	.0000
Step	25.130	1	.0000

Variables in the Equation							
Variable	B	S.E.	Wald	d.f.	Sig.	R	Exp (B)
GENDER	.8920	.1805	24.4271	1	.0000	.1326	2.4400
MEANGR	.4168	.0300	192.4835	1	.0000	.3865	1.5172
Constant	-1.6284	.1517	115.1901	1	.0000		
Variables not in the Equation							
Residual	Chi-Square 15.143 with 2 d.f.			Sig = .0005			
Variable	Score	d.f.	Sig.	R			
KEYSCH	14.7032	1	.0001	.0998			
X	.5444	1	.4606	.0000			



续表

Variable (s) Entered on Step Number 3.. KEYSCH

Estimation terminated at iteration number 5 because
parameter estimates changed by less than .001

- 2 Log Likelihood	839.965
Goodness of Fit	1417.363
Cox & Snell - R ²	.353
Nagelkerke - R ²	.490
	Chi-Square d.f. Significance
Model	435.361 3 .0000
Block	435.361 3 .0000
Step	14.413 1 .0001

Variables in the Equation							
Variable	B	S.E.	Wald	d.f.	Sig	R	Exp (B)
GENDER	.8661	.1821	22.6201	1	.0000	.1272	2.3776
KEYSCH	.9130	.2411	14.3335	1	.0002	.0983	2.4917
MEANGR	.4245	.0305	193.8484	1	.0000	.3879	1.5289
Constant	- 1.7575	.1587	122.7106	1	.0000		

Variables not in the Equation				
Residual Chi-Square	.486 with	1 d.f.	Sig = .4856	
Variable	Score	d.f.	Sig	R
X	.4862	1	.4856	.0000

No more variables can be deleted or added.

以反向选择开始的混合逐步选择过程:

Beginning Block Number 1. Method: Backward Stepwise (WALD)

Variable (s) Entered on Step Number 1..

GENDER
KEYSCH
MEANGR
X

续表

Estimation terminated at iteration number 5 because
parameter estimates changed by less than .001

- 2 Log Likelihood	839.479
Goodness of Fit	1387.169
Cox & Snell - R ²	.353
Nagelkerke - R ²	.490

	Chi-Square	d.f.	Significance
Model	435.848	4	.0000
Block	435.848	4	.0000
Step	435.848	4	.0000

Variables in the Equation							
Variable	B	S.E.	Wald	d.f.	Sig.	R	Exp (B)
GFENDER	.8708	.1823	22.8234	1	.0000	.1278	2.3889
KEYSCH	.9125	.2415	14.2813	1	.0002	.0981	2.4905
MEANGR	.4228	.0305	191.9205	1	.0000	.3859	1.5263
X	.0609	.0874	.4859	1	.4858	.0000	1.0628
Constant	-1.8821	.2402	61.3718	1	.0000		

Variable (s) Removed on Step Number 2. . X

Estimation terminated at iteration number 5 because
parameter estimates changed by less than .001

- 2 Log Likelihood	839.965
Goodness of Fit	1417.363
Cox & Snell - R ²	.353
Nagelkerke - R ²	.490

	Chi-Square	d.f.	Significance
Model	435.361	3	.0000
Block	435.361	3	.0000
Step	-.486	1	.4857

Note: A negative Chi-Square value indicates that the Chi-Square
value has decreased from the previous step.

续表

Variables in the Equation							
Variable	B	S.E.	Wald	d.f.	Sig.	R	Exp (B)
GENDER	.8661	.1821	22.6201	1	.0000	.1272	2.3776
KEYSCH	.9130	.2411	14.3335	1	.0002	.0983	2.4917
MEANGR	.4245	.0305	193.8484	1	.0000	.3879	1.5289
Constant	-1.7575	.1587	122.7106	1	.0000		
Variables not in the Equation							
Residual Chi Square			.486 with		1 d.f.	Sig = .4856	
Variable	Score		d.f.	Sig		R	
X	.4862		1	.4856		.0000	

No more variables can be deleted or added.

注：在 Windows 7.5 及以后的 SPSS 版本中，当输出文件很大，因而计算机屏幕上不能显现所有输出时，可用光标器右键点击输出，并选择“SPSS Rtf Document Object -- Open”，便可将锁住的输出窗口打开。

自动逐步选择有一些优点。第一，自动逐步选择使我们避免双次运行 LOGISTIC 回归程序以取得模型 χ^2 之差来进行比较两个模型的 LR 检验。自动选择可使我们一次运行便得到这些统计结果。第二，逐步选择过程能够提供评价尚未进入模型的候选自变量贡献的 Score 统计量。这样，我们便能更好理解每一候选自变量的重要性。但是，在使用自动逐步选择功能时要注意的，当候选自变量的数量很多时，需要更多的观测案例。如果案例数量相对于自变量数量过少，便会产生一些问题（我们将在第 7 章对此加以讨论）。在较多离散变量相互单元没有观测值时，logistic 回归可能产生极大的参数估计值和标准误值，甚至可能出现不收敛的结果。更重要的是，我们应该牢记，自动选择仅仅依据统计标准操作，所以，最好将其看作为变量筛选或是建立假设模型的初步步骤。它主要是用于探测性分析，而不是关注于检验理论。这种分析通常用于研究的早期阶段，这时尚不存在现象之间的关系的完善理论和知识。机械的选择程序可能选到无关或噪音变量。在这时，应该由研究者负责变量的选择和评价、及模

型的最终建立，而不是完全依赖于计算机。

6.1.4 排除有意义的变量和包括没有意义的变量

建立模型时，如果若干有理论意义的变量被删除了、或若干没有意义的变量被包括于模型之中，我们就说这是一个错设的(misspecified)或错误的模型。在线性回归中，如果应该保留的有意义的自变量被排除出模型的话，回归系数的估计将是有偏的(Berry & Feldman, 1985; Kmenta, 1986)。这是因为，保留在模型中的自变量很有可能与排除掉的自变量相关。如果是这样，这些自变量便会与模型的误差项相关，于是，这便违反了回归的基本假设条件。偏差的方向(正的或负的)取决于排除变量对因变量的作用方向和排除变量与保留变量之间关系的方向。偏差的幅度取决于排除变量与保留变量之间的相关强度。如果排除变量与保留变量之间完全无关，那么这些变量的删除便对参数估计没有影响。但这种情况在实际中很少发生。

从模型中排除一个变量会导致其他保留变量系数估计的标准误减小。这是因为，当一个自变量与其他自变量相关时，由于多元共线性(multicollinearity)，其系数估计的标准误会增加(我们将在第7章讨论这个问题)。标准误减小的幅度取决于排除变量与保留变量之间的相关强度。当然，我们并不会通过排除有意义的变量来增进保留变量的估计效率，因为这种“增进”的代价是这些估计的偏差的增加(Berry & Feldman, 1985)。

在模型包括了若干不应包括的无意义变量时，不会造成估计系数有偏，但是会导致系数标准误膨胀，以致估计效率下降。标准误膨胀的程度取决于模型中无意义的变量与其他变量之间的相关强度。如果包括在模型之中的无意义变量与其他变量完全无关，在样本规模很大时所导致的标准误的增加是极为有限的(Berry & Feldman, 1985; Kmenta, 1986)。

在logistic回归模型中排除有意义的变量或包括无意义的变量所产生的问题与在线性回归中的情况相似(Menard, 1995)。

6.2 非线性与非加性(Nonlinearity and Nonadditivity)

就模型设置错误而言的第二个问题关系到模型设置的函数形式。在第1章我们就讨论了对于二分类因变量进行 OLS 模型回归是不对的，因为模型的函数形式的设定是错误的。在 logistic 回归模型中，logistic 函数用来作为联系函数(link function)，代表了模型因变量与事件概率之间的关系(即 $\ln[p/(1-p)]$)。在正确的联系函数形式下，还要认真考虑因变量与自变量之间的函数形式。通常，我们假设因变量与自变量之间的关系既是线性的、又是可加的。如果这些假设条件被违反，参数估计将发生偏差。在本节中，我们将讨论在 logistic 回归模型中的非线性问题和非加性问题

6.2.1 非线性

在选择变量阶段，假设 logistic 回归为线性函数是普遍的作法。这种作法是与肯定一个变量的重要性相一致的。不管一个自变量与因变量之间的关系是线性的还是非线性的，只要这个变量真的重要，拟合线性模型总可以得到显著的回归系数。一旦确定这个变量很重要，我们便应该从设立模型角度考虑如何取得正确的参数估计。一个以自变量线性组合的 logistic 回归模型也许在其函数形式上是错误的。很有可能的是，logit 并不是自变量的线性组合函数，而是自变量的非线性组合的函数。

在 logistic 回归中存在几种检查非线性关系的方法。第一，可以先将每个自变量视为序次测量，用正交多项对比法(orthogonal polynomial contrast)来检验线性、二次方、三次方或更高次项在二元或多元 logistic 回归模型中的作用(Hosmer & Lemeshow, 1989, pp.54-55)。然而，如果自变量是连续变量或有大量类别的序次变量，正交多项对比方法便不适宜，因为标准误会很大，结果无论是线性作用也好还是某种非线性作用也好，

即使真有显著作用,也不容易得到统计显著的结果(Menard, 1995, p.60).

在多元回归中的一种常用的探索非线性关系的方法是,将相应的连续自变量的值分成若干组,在每组中找出对应组中值的因变量平均值.这种方法也可以用于 logistic 回归,对每个组找出对应组中值的 logit 值.然后,检查由此产生的“曲线”的非线性类型.

通常,可以按照变量分布的四分位(quartiles^①)或五分位(quintiles^②)值将变量值分成 4 类或 5 类;然后用虚拟变量代表这些类别,并以最低的一组作为参照组.然后,再用这些虚拟变量代替原先的连续变量,并重新估计模型,并对应每段四分位(或五分位)的中值估计相应的 logit.

尽管这一方法看起来很简单,但操作起来却涉及很多步计算.比如,需要计算变量的四分位或五分位,还要对数据重新分组,并要对每组计算 logit 估计值,并将 logit 估计值和各组的中值输入作图软件,并画出图来.一个等价的简单检查非线性的方法,是审阅虚拟变量系数的估计值的模式.如果出现无序的系数估计值,便说明存在非线性关系.更为直观或“精确”的方法是,将虚拟变量的估计系数按各组的中值画出,如果 logit 与自变量之间存在线性关系,所画出的点便会落在一条直线上.如果画出的点不在一条直线上,便说明存在非线性关系(Hosmer & Lemeshow, 1989; DeMaris, 1992).在这种方法中,尽管非线性关系是通过肉眼直观判断的,但通常足以保证其准确性.然而,如果要求更为确切的估价,我们就应该采用正交设计方法(Hosmer & Lemeshow, 1989, pp.54-55).

将连续变量分成不同组别并用一套虚拟变量来代表,这不仅有助于检查这一变量的非线性模式,还提供在非线性关系存在条件下的无偏系数估计.这实际上是在建立回归模型时对付非线性关系的一个常用方法.

在确信自变量 x_k 对 logit 存在非线性作用时,可以考虑采用高次项(如 $x_k^2, x_k^3, \dots$).假设 x_k 与 logit 之间的关系是二次项,

① 即将所有案例按值的顺序排列分成四个具有同样规模的组时的分割点.

② 即将所有案例按值的顺序排列分成五个具有同样规模的组时的分割点.

便应该在模型中加上 x_k^2 项. 对于非线性模型的线性设置可以通过比较非线性模型与线性模型轻易地检查出来. 如果模型中加入一个二次项 x_k^2 后模型 χ^2 便有了显著的提高, 这说明 x_k^2 与 logit 之间为非线性关系. 这意味着: 第一, 在 logistic 回归中处理非线性问题可以被认为是模型中的自变量采用相应正确尺度, 如 x_k, x_k^2, x_k^3 等等. 第二, 对非线性模型的线性设置意味着在建模中省略了某些代表自变量与因变量之间非线性关系的有关变量(如高次项), 这种省略可能导致有偏的系数估计.

作为例子, 我们将示范检查模型 2.5.1 中自变量 MEANGR 的非线性关系的过程.

先采用分组法来检查分组变量 GRADE 在其四分位上是否表现非线性关系. 注意变量 MEANGR 是变量 GRADE 的线性组合(即, $\text{MEANGR} = \text{GRADE} - 83.76$), 于是按 GRADE 分组与按 MEANGR 分组相同. 为了更容易理解, 表 6.2.1 提供了分组变量 GRADE 的结果, 其值域为 $[66.80, 96.20]$. 按照分布的四分位来分组, 其各组的中值分别为: 73.85, 82.25, 85.15, 91.95.

表 6.2.1 按四分位划分的分组变量 GRADE

Quartile	Value Range	n	Midpoint	Dummy
Quartile 1	$66.80 \leq \text{Grade} < 80.90$	53	73.85	-
Quartile 2	$80.90 \leq \text{Grade} < 83.60$	52	82.25	D2
Quartile 3	$83.60 \leq \text{Grade} < 86.70$	53	85.15	D3
Quartile 4	$87.70 \leq \text{Grade} < 96.20$	42	91.95	D4

注: “-”代表参照类

将最低一段作为第 1 类, 并作为参照类, 并且用虚拟变量 D2、D3、D4 分别代表变量 GRADE 的第 2 个到第 4 个四分位, 并代替式 2.5.1 中的变量 MEANGR, 产生以下模型:

$$\ln(p/(1-p)) = \alpha + \beta_1 \text{GENDER} + \beta_2 \text{KEYSCH} + \beta_3 D_2 + \beta_4 D_3 + \beta_5 D_4. \quad 6.2.1$$

用 SAS 的 PROC LOGISTIC 程序运行此模型, 其结果列在表 6.2.2 中.

表 6.2.2 模型 6.2.1 的结果

SAS 输出 (节选)							
Intercept							
Criterion	Intercept Only		Intercept and Covariates		Chi-Square for Covariates		
AIC	1277.326		885.060		.		
SC	1282.234		914.506		.		
-2 LOG L	1275.326		873.060		402.266 with 5 DF (p=0.0001)		
Score	.		.		362.982 with 5 DF (p=0.0001)		
Analysis of Maximum Likelihood Estimates							
Variable	DF	Parameter Estimate	Standard Error	Wald Chi-Square	Pr > Chi-Square	Standardized Estimate	Odds Ratio
INTERCPT	1	-3.6567	0.3323	121.1253	0.0001	.	.
GENDER	1	0.9591	0.1815	27.9315	0.0001	0.263185	2.609
KEYSCH	1	0.8862	0.2378	13.8840	0.0002	0.165457	2.426
D2	1	1.4465	0.3555	16.5539	0.0001	0.346411	4.248
D3	1	2.2868	0.3425	44.5679	0.0001	0.548378	9.844
D4	1	4.1131	0.3527	136.0182	0.0001	0.971717	61.136

检查表 6.2.2 中虚拟变量 D2, D3, D4 的系数, 很明显 logit 在第 2 四分位至第 4 四分位是单调增加. 为了检查 GRADE 与 logit 之间的关系, 我们首先对变量 GRADE 的四个类别按 4 个四分位组中值画出分性别和高中类型的 logit 估计值^①. 正如所见, 高中平均成绩与大学升学之间的关系在“男生-重点高中”(图 6.1 中 MKEYSC 线)、“男生-非重点高中”(图 6.1 中 MNONKEYSC 线)、“女生-重点高中”(图 6.1 中 FKEYSC 线)、“女生-非重点高中”(图 6.1 中 FNONKEYSC 线)”保持相同类型. 在各种分组中未发现“显著”不同的曲线关系.

此外, 我们还在图 6.2 中对应各类中值标画了三个虚拟变量系数. 图 6.1 和 6.2 中, 由于标注点基本上未偏离一条直线, 我们认为在 GRADE 与 logit 之间的关系基本上是线性的.

接下来, 我们用在模型中加入变量高次项的方法来检验非线性

① 对模型 6.2.2 按 GENDER 和 KEYSCH 所做的 logit 估计分别为:

$$\text{GENDER}=1 \text{ 和 } \text{KEYSCH}=1: \text{logit}(y) = -3.6567 + 0.9591 + 0.8862$$

$$\text{GENDER}=1 \text{ 和 } \text{KEYSCH}=0: \text{logit}(y) = -3.6567 + 0.9591$$

$$\text{GENDER}=0 \text{ 和 } \text{KEYSCH}=1: \text{logit}(y) = -3.6567 + 0.8862$$

$$\text{GENDER}=0 \text{ 和 } \text{KEYSCH}=0: \text{logit}(y) = -3.6567$$

这四个 logit 估计被用来标注于图 6.1 中的四分位组中值上.




图 6.1 按变量 GRADE 的类别中值标画的 logit 估计值




图 6.2 按变量 GRADE 的组中值标画的虚拟变量系数

性关系。当怀疑一个自变量与因变量之间为非线性关系时，最理想的是能够从原理上指导非线性关系类型的合理选择，这样设定的非线性参数便可以进行意义明确的解释。然而在社会科学研究中，建模时最常采用的非线性关系是二次项关系 (quadratic relationship)。假如在我们的例子中，自变量 MEANGR 与升学的 logit 之间为二次项关系，我们便可以通过比较线性模型 2.5.1 与包括二次项 $MEANGR^2$ 的新模型来进行检查。新建的二次项模型如下：

$$\ln(p/(1-p)) = \alpha + \beta_1 GENDER + \beta_2 KEYSCH + \beta_3 MEANGR + \beta_4 MEANGR^2 \quad 6.2.2$$

模型的结果在表 6.2.3 中提供。二次项 $MEANGR^2$ 的回归系数的统计性并不显著。与此一致，比较模型 2.5.1 和模型

6.2.2 的 L.R. 统计量也没有统计显著. 模型 2.5.1 和 6.2.2 的 χ^2 统计值分别为 435.361, d.f. = 3 (见表 2.5.2), 和 436.224, d.f. = 4 (见表 6.2.3). 于是, $L.R. = 436.224 - 435.361 = 0.863$, 且 $d.f. = 4 - 3 = 1$. 模型比较结果表明, 自变量 MEANGR 与因变量之间的关系用二次项非线性关系表示并不好, 简单地用线性关系表示更为恰当.

表 6.2.3 模型 6.2.2 的部分结果

SAS 输出 (节选)							
Model Fitting Information and Testing Global Null Hypothesis BETA=0							
	Intercept						
	Intercept and						
Criterion	Only	Covariates	Chi-Square for Covariates				
AIC	1277.326	849.102	.				
SC	1282.234	873.641	.				
- 2 LOG L	1275.326	839.102	436.224 with 4 DF (p=0.0001)				
Score	.	.	373.211 with 4 DF (p=0.0001)				
Analysis of Maximum Likelihood Estimates							
	Parameter	Standard	Wald	Pr >	Standardized	Odds	
Variable	DF	Estimate	Error	(Chi-Square)	Chi-Square	Estimate	Ratio
INTERCPT	1	-1.8064	0.1675	116.2818	0.0001	.	.
GENDER	1	0.8716	0.1826	22.7923	0.0001	0.239184	2.391
KEYSCH	1	0.9141	0.2400	14.5037	0.0001	0.170674	2.495
MEANGR	1	0.4095	0.0332	152.4075	0.0001	0.970506	1.506
MEANGR2	1	0.00654	0.00694	0.8899	0.3455	0.095841	1.007

6.2.2 非加性

一旦我们肯定模型中的连续变量采取了正确的尺度, 我们就要检验模型的非加性. 非加性意味着自变量之间存在互动作用 (interaction). 当与某个自变量一个单位变化相联系的因变量的变化同时还取决于一个或多个其他自变量的值时, 互动作用便产生了. 比如, 性别和年龄之间的互动意味着年龄的作用还依赖于性别. 换句话说, 对于男性和女性, 年龄的影响是不同的. 性别和年龄之间的互动作用还可以有另一种解释, 即性别的影响取决于年龄.

让我们用一个含互动项的线性回归模型来加以说明:

$$y = \alpha + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_1 \cdot x_2 + e, \quad 6.2.3$$

其中, 互动项是通过一个高次项加入模型的, 它是自变量 x_1 与

x_2 的积. 这一公式可以将 x_2 的偏作用改写为 x_1 的函数:

$$y = \alpha + \beta_1 x_1 + (\beta_2 + \beta_3 x_1) x_2 + e. \quad 6.2.4$$

这表明变量 x_2 的偏作用依赖于变量 x_1 的水平. 正如我们看到的, x_2 的偏作用由二项组成: β_2 和 $\beta_3 x_1$. 第一项 β_2 为 x_2 的主影响(main effect), 它是一个常数; 第二项 $\beta_3 x_1$ 与 x_1 的特定值相联系. 这导致 x_2 对 y 的作用依 x_1 的取值而有变化. 在这个模型中, 只有一个可能的互动影响, 即 β_3 . 如果系数 β_3 显著区别于 0, 就表明数据之中的互动作用, 并表明模型是非加性的; 否则, 这一模型不存在互动作用, 并且是可加性的(additive). 然而, 在模型中有很多自变量时, 检查非加性便不像检查非线性那样简单了. 除非从理论上或实际经验能够提供指导, 人们通常只有如下的选择: 假设模型是可加性性质的, 检验那些特别可能的互动作用项, 或检验所有可能的互动作用项. 在一个相对简单的模型中进行上述后一项工作还有一定可能, 但这随着模型中的变量数增加而变得越来越困难. 比如, 对只有三个自变量(x_1, x_2, x_3)的模型, 可能的互动项便有: $x_1 \cdot x_2, x_1 \cdot x_3, x_2 \cdot x_3, x_1 \cdot x_2 \cdot x_3$. 前三项为一阶互动(first order interaction)项, 第四项为二阶互动(second order interaction)项. 当自变量数量增加时, 互动项的数量(包括各阶)极为迅速的增加. 通常我们所做的是只检验那些在实际中可能性较大的互动项.

含互动作用的 logistic 回归模型可以像线性回归模型一样来表达. 仍以升学数据为例, 我们可以通过式 6.2.5 来进行一阶(或称双因素, 2-way)互动作用的检验:

$$\ln(p/(1-p)) = \alpha + \beta_1 \text{KEYSCH} + \beta_2 \text{GENDER} + \beta_3 \text{MEANGR} + \beta_4 \text{KEYSCH} \times \text{MEANGR} \quad 6.2.5$$

其中互动项为乘积 $\text{KEYSCH} \times \text{MEANGR}$. 这里检验的是, 是否高中平均成绩对 logit 的影响在不同高中类型中有所差别. 如果互动系数 β_4 统计性显著, 那么就可以断定, 变量 MEANGR 对事件概率的影响依高中类型不同而变化.

这是一个连续变量(MEANGR)与一个标志变量(KEYSCH)之间互动的例子. 互动还可以发生于两个标志变量之间(比如 KEYSCH 和 GENDER 之间), 或者发生于两个连续变量之间(但在本例中只有一个连续变量).

SAS 的 PROC LOGISTIC 程序要求用户通过数据处理来建立互动项。如果互动项涉及两个名义测度或序次测度的变量，它们分别有 m_1 和 m_2 个类别，那么要产生 $(m_1 - 1) \times (m_2 - 1)$ 个互动项(见尾注)。

而对于 SPSS 而言，却用不着预先的数据处理，可直接在 logistic 回归模型中加入互动项。下面分别为 SAS 和 SPSS 在运行含互动项的 logistic 回归模型的程序命令。

```
* SAS PROGRAM: INTERACTION MODEL;
...
INTER = KEYSCH * MEANGR;
PROC LOGISTIC DESCENDING;
MODEL COLLEGE = GENDER KEYSCH MEANGR INTER;
RUN;

* SPSS PROGRAM: INTERACTION MODEL.
...
LOGISTIC REGRESSION VAR = COLLEGE
  /METHOD = ENTER GENDER KEYSCH MEANGR KEYSCH * MEANGR
  /PRINT = GOODFIT CI (95)
  /CRITERIA PIN (.05)POUT (.10)ITERATE (20)CUT (.5).
```

模型 6.2.5 的结果在表 6.2.4 中提供。拟合含与不含互动项的模型可以使我们比较出互动项是否对模型有重要贡献。含有互动项的模型有： $\chi^2 = 435.393$, d.f. = 4。不含互动项的模型有： $\chi^2 = 435.361$, d.f. = 3。互动影响模型 χ^2 变化为： $\chi^2 = 0.32$, d.f. = 1，它的统计性并不显著。因此，不能拒绝互动项作用为 0 的假设。换句话说，互动项 KEYSCH $\times$ MEANGR 对模型拟合没有显著贡献，所以可以从模型中删除。

实际上，互动项的系数 β_4 的统计性也不显著，表明高中平均成绩对高校录取概率的作用并不受高中类型的影响。换句话说，高中平均成绩对高校录取概率有正向作用，并且这一作用对于重点高中和非重点高中都一样。但是，如果 β_4 统计性显著，我们如何解释 MEANGR 对高校录取的作用呢？这一作用可以表

达为:

$$\text{logit}(\hat{y}) = \beta_3 \text{MEANGR} + \beta_4 \text{KEYSCH} \times \text{MEANGR},$$

对于非重点高中的学生而言, MEANGR 的作用为:

$$\text{logit}(\hat{y}) = \beta_3 \text{MEANGR} + \beta_4 \times 0 \times \text{MEANGR} = \beta_3 \text{MEANGR}.$$

因此, MEANGR 上 1 分成绩的增加, logit 的相应变化为 $\beta_3 = 0.4268$.

而对于重点高中的学生来说, MEANGR 的作用为:

$$\text{logit}(\hat{y}) = \beta_3 + \beta_4 \times \text{MEANGR},$$

MEANGR 上 1 分成绩的增加, logit 的相应变化为 $0.4268 - 0.0152$, 这一变化小于 MEANGR 自己的主影响. 这样的解释好像不太好理解, 我们可以从另一角度来解释这个互动作用, 即看平均成绩变动是否影响学校类型对升学机会的影响. 这一作用可表达为:

$$\text{logit}(y) = \beta_2 \text{KEYSCH} + \beta_4 \text{KEYSCH} \times \text{MEANGR}$$

如果互动作用为负, 且统计显著, 则说明学生高中平均成绩升高可以缩小学校类型对升学机会影响的差别.

当模型含有互动项时, 高阶作用是否显著最为关键. 我们经常可以看到互动项显著, 然而主影响并不显著. 在这种情况下, 如何解释相应变量的作用呢? 比如一个模型中有互动项 $x_1 \times x_2$, 不管 x_1 (或 x_2) 的主影响是否显著, 都说 x_1 (或 x_2) 有显著作用, 因为它的主影响应该作为 x_1 (或 x_2) 对事件发生可能性的组成部分. 另一方面, 如果高阶效应 (本例即为一阶互动作用) 不显著, 主效应则只应作为相应自变量自身的作用看待. 在本例中, 互动项 (即 β_4) 统计性不显著, 说明 MEANGR 对高校录取机会的主影响不依赖于高中类型. 因此, 互动项系数 β_4 不应看作 $\text{logit}(\hat{y})$ 的组成部分.

表 6.2.4 模型 6.2.5 的结果

SAS 输出 (节选)			
Model Fitting Information and Testing Global Null Hypothesis BETA = 0			
	Intercept		
	Intercept	and	
Criterion	Only	Covariates	Chi-Square for Covariates
AIC	1277.326	849.934	.
SC	1282.234	874.472	.

续表

-2 LOG L	1275.326	839.934	435.393 with 4 DF (p=0.0001)
Score	.	.	345.299 with 4 DF (p=0.0001)

Analysis of Maximum Likelihood Estimates

Variable	DF	Parameter Estimate	Standard Error	Wald Chi-Square	Pr > Chi-Square	Standardized Estimate	Odds Ratio
INTERCPT	1	-1.7607	0.1598	121.3532	0.0001	.	.
GENDER	1	0.8655	0.1821	22.5763	0.0001	0.237499	2.376
KEYSCH	1	0.9239	0.2474	13.9422	0.0002	0.172505	2.519
MEANGR	1	0.4268	0.0331	166.6592	0.0001	1.011530	1.532
INTER	1	-0.0152	0.0855	0.0317	0.8586	0.012931	0.985

SPSS 输出 (节选)

	Chi-Square	d.f.	Significance
Model	435.393	4	.0000
Block	435.393	4	.0000
Step	435.393	4	.0000

Variable	B	S.E.	Wald	d.f.	Sig	R
GENDER	.8655	.1821	22.5763	1	.0000	.1270
KEYSCH	.9239	.2474	13.9422	1	.0002	.0968
MEANGR	.4268	.0331	166.6591	1	.0000	.3593
KEYSCH by MEANGR	.0152	.0855	.0317	1	.8586	.0000
Constant	-1.7607	.1598	121.3532	1	.0000	

尾注:

新版 SAS 6.12 的 PROC LOGISTIC 程序改善了处理互动项的功能,即不用预先处理数据,互动项可以被直接纳入模型。SAS 程序指令如下:

```
PROC LOGISTIC DESCENDING;
MODEL COLLEGE = GENDER KEYSCH MEANGR KEYSCH * MEANGR;
RUN;
```

Logistic 回归诊断



• 7.1	过离散(Overdispersion)	(184)
• 7.2	空单元(Zero Cell Count)	(187)
• 7.3	完全分离(Complete Separation)	(188)
• 7.4	多元共线性(Multicollinearity)	(190)
• 7.5	特异值和特殊影响案例(Outliers and Influential Observations)	(195)
7.5.1	残差影响的测量	(195)
7.5.2	检查特异值和特殊影响案例	(202)

在第 6 章中,我们讨论了错误的模型设置可能导致有偏或精度差的系数估计.所谓有偏指 logistic 回归系数的估计上有系统性偏差,如与真值相比偏大或偏小.精度差指系数估计的标准误较大.它将导致难以拒绝零假设(即关于因变量与自变量之间无关的假设).除了模型的误设问题以外,因变量和自变量观测的数据结构也可能导致 logistic 回归在系数估计上发生问题.这并不是设置模型的问题或模型正确与否的问题,而是某种数据结构对参数估计产生的影响.常见的数据结构问题有过离散(over-dispersion)、空单元(zero cell count)、完全分离(complete separation)、多元共线性(multi-collinearity)、特异值(outliers)、以及特殊影响案例(influential cases)等.除了过离散和特异值属因变量的数据结构问题外,其他各类都是自变量的数据结构问题.

7.1 过离散(Overdispersion)

对于第 j 个分组或第 j 种协变类型中事件的观测数 y_j 而言,有平均值为 $n_j p_j$ 和方差为 $n_j p_j (1 - p_j)$ 的二项分布,其中 n_j 是第 j 分组中的案例数, p_j 是同一组中的事件概率.如果发生反应变量的测量方差超过名义上的方差 $n_j p_j (1 - p_j)$,就称这种现象为过二项变异(extra binomial variation)或过离散.

实际数据中常有过离散现象存在.如果反应概率 p_j 并不是随机变化,那么 p_j 的变动将会造成 y_j 的方差大于其本来应有的方差,形成过离散.过离散会导致 logistic 回归系数的标准误偏低,从而影响到 Wald χ^2 值偏高.过离散也发生于模型系统组件存在某种缺陷时(Collett, 1991),比如:

- 1) 各个子总体或称协变类型中的观测数过少;
- 2) 某些重要解释变量没有纳入模型;
- 3) 某些必要的互动项没有纳入模型;
- 4) 在真实函数为二次或高次项时却按线性函数设置模型;
- 5) 数据中存在特异值;
- 6) 某些解释变量应该采用对数量度或其他转换时却没有这样做.

在过离散的情况下,观测的因变量方差为 $\sigma^2 np(1-p)$,其中 σ^2 为离散参数(dispersion parameter).离散参数大于1表示过离散;而小于1表示欠离散(under-dispersion).欠离散是可能发生的,但在实际数据应用中很少见.

在建模时,我们可以通过调整协方差来纠正过离散产生的影响.这涉及到对离散参数 σ^2 的估计,离散参数也称为量度参数(scale parameter).在SAS的6.10版及更新版本中,PROC LOGISTIC程序可通过备选命令“SCALE=”来设置量度参数.尽管当已知过离散(或欠离散)的原因时可以计算 σ^2 ,但在多数场合离散参数是未知的,所以需要进行估计.通常采用皮尔逊 χ^2 或Deviance统计量来估计离散参数.在第3章中已经讨论过,这些统计指标都近似于自由度为协变类型数减系数个数之差的 χ^2 分布.而离散参数估计即为 χ^2 除以相应自由度.

下面用一个例子示范过离散的检查和调整:

$$\text{Ln}[p/(1-p)] = \alpha + \beta_1 \text{KEYSCH} + \beta_2 \text{G85}. \quad 7.1.1$$

在式7.1.1中,升学的logit被设为两个虚拟变量的函数:KEYSCH(1代表重点高中;0代表其他);G85(1代表高中平均分在85及以上;0代表其他).相应的SAS程序命令为:

```
* SAS PROGRAM: LOGISTIC REGRESSION CORRECTING FOR OVERDISPERSION;
...
PROC LOGISTIC DESCENDING;
MODEL COLLEGE = KEYSCH G85 / AGGREGATE SCALE = DEVIANCE;
RUN;
```

在SAS程序中加设“AGGREGATE SCALE=”备选命令时,便会输出Deviance和 χ^2 指标(参见表7.1.1的上部).在Value/DF标签下的一栏是离散参数的估计.对我们的例题来说,根据Deviance和皮尔逊 χ^2 指标所估计的离散参数分别为1.308 5和1.357 5,都大于1.0很多,说明在logistic回归模型中存在过离散问题.输出中有一个注(NOTE),说明“协方差矩阵已乘以异质因子(heterogeneity factor) 1.308 47”.因为我们设置了“SCALE = DEVIANCE”,协方差矩阵所乘的1.308 5便是De-

viance 指标值与其自由度之比。

表 7.1.1 修正 logistic 回归中的过离散

修正了过离散的结果:

Deviance and Pearson Goodness-of-Fit Statistics

Criterion	DF	Value	Value/DF	Pr>Chi-Square
Deviance	1	1.3085	1.3085	0.2527
Pearson	1	1.3575	1.3575	0.2440

Number of unique profiles: 4

NOTE: The covariance matrix has been multiplied by the heterogeneity factor 1.30847.

Analysis of Maximum Likelihood Estimates

Variable	DF	Parameter Estimate	Standard Error	Wald Chi-Square	Pr>Chi-Square	Standardized Estimate	Odds Ratio
INTERCPT	1	-1.9564	0.1437	185.2586	0.0001	.	.
KEYSCH	1	0.9068	0.2582	12.3375	0.0004	0.169317	2.476
G85	1	2.4493	0.1838	177.6718	0.0001	0.657096	11.580

未修正过离散的结果:

Analysis of Maximum Likelihood Estimates

Variable	DF	Parameter Estimate	Standard Error	Wald Chi-Square	Pr>Chi-Square	Standardized Estimate	Odds Ratio
INTERCPT	1	-1.9564	0.1257	242.4054	0.0001	.	.
KEYSCH	1	0.9068	0.2257	16.1432	0.0001	0.169317	2.476
G85	1	2.4493	0.1606	232.4783	0.0001	0.657096	11.580

表 7.1.1 的下部显示了未修正过离散条件下的 logistic 回归的参数估计。比较修正和未修正过离散的 logistic 回归结果,我

们看到,修正过离散后,logistic 回归系数的标准误增大.这说明过离散会导致 logistic 回归系数估计的标准误偏低,因而又影响到其 Wald χ^2 值偏高及 P-Value 偏低.然而,过离散不会影响估计的系数、标准化系数以及发生比率.

如果我们在 SAS 的 PROC LOGISTIC 程序的 MODEL 命令之后设定 SCALE=PEARSON,程序运行时将采用皮尔逊 χ^2 指标,并除以其自由度,作为离散参数估计.当然,我们还可以通过“SCALE=”来设定常数值.在这种情况下,程序会取这一常数的平方作为过离散参数估计.如果我们设定 AGGREGATE SCALE=NONE,程序将产生一个拟合优度指标,其中同时包括 Deviance 和皮尔逊 χ^2 指标,但是不再运行过离散的调整.

正如在第 3 章已经提到的,在协变类型增加而导致各子总体的案例数减到相当少时,Deviance 和 Pearson 统计值将不再近似于 χ^2 分布.因而,当模型中有连续的自变量时,大部分子总体案例数都很少,因此不宜再用 Deviance 和皮尔逊 χ^2 统计量来估计离散参数.

我们在第 3 章曾经提到,SPSS 的 LOGISTIC 回归程序是按协变类型数等于案例数设定的(即 $n_j = 1$).因此,SPSS 的 LOGISTIC 回归程序不提供关于过离散参数 σ^2 的信息.然而,SPSS 视窗 10.0 版提供了一个新的程序,称作 NOMREG,是用来为名义因变量建立模型的,可以用它来解决 logistic 回归中的过离散问题.

7.2 空单元(Zero Cell Count)

数据结构中最简单、最明显的问题是空单元,即交互表中某些单元的观测频数为 0.比如,要是所有高中毕业的男生都进入了大学,交互表中升学与性别的关系便会发生问题.对于 GENDER=1 的案例而言,升学的发生比为 $1/(1-1) = +\infty$,那么 $\text{logit} = \ln(\text{odds})$ 也等于 $+\infty$.另一方面,如果这一类中观测的结果变量值都是 0(即所有男生都未能升学),那么发生比将为 0,

相应的 $\text{logit} = \ln(\text{odds})$ 将为 $-\infty$. 在这种情况下, 统计软件通常提供不能收敛的出错提示. 另外, 还存在一种十分明显的迹象表明模型出了问题, 即模型有很大的估计系数和特别大的系数估计标准误差.

空单元的问题主要发生于分类变量, 尤其是名义变量. 对于连续变量而言, 模型可以假设因变量与自变量之间某种模式的关系 (如在线性回归中的线性函数和在 logistic 回归中的 logistic 函数), 然后按这种模式对应自变量各值的因变量的分布“填补”起来. 但是对分类自变量来说, 模型无法设想这种模式.

空单元的产生往往是由于案例分布于太多的交互单元所致. 在一般情况下, 模型中没有太多的变量, 尤其是没有将互动项纳入模型之前, 很少发生空单元的现象. 应该先按单个变量来检查数据中是否存在空单元. 由于空单元会导致很多建模问题, 所以我们最好取得一个较大的样本来建立模型. 在小样本的情况下, 我们可以通过合并变量中的若干类型来消灭空单元. 或者, 在变量为序次量度 (ordinal measure) 且有较多等级时, 假设它们为连续变量.

7.3 完全分离 (Complete Separation)

随自变量变化, 反应结果被完全分离时便会有第二种数据结构问题的产生. 比如, 当自变量 x_k 中存在某一临界值 C , 只要 x_k 取值大于等于 C , 事件便发生; 而 x_k 取值小于 C 时, 事件便不发生. 于是, 如果 x_k 的值已知, 我们便肯定了结果变量的取值 (即肯定了事件发生与否). 在这种情况下, 反应变量的两种结果在 x_k 取值上并无任何重迭, 这就是所谓的数据“完全分离”. 对于这种类型的数据, 不存在最大似然估计 (Albert & Anderson, 1984; Santner & Duffy, 1986).

我们借用 Hosmer 和 Lemeshow (1989) 的例子来显示完全分离现象, 并说明其所导致的问题. 假设我们有表 7.3.1 中的 12 个案例.

表 7.3.1 数据中的完全分离、准完全分离和重迭

案例	y	x_k
1	0	1
2	0	2
3	0	3
4	0	4
5	0	5
6	0	5.5 \ 6.0 \ 6.05 \ 6.1 \ 6.15 \ 6.2 \ 8.0
7	1	6
8	1	7
9	1	8
10	1	9
11	1	10
12	1	11

注：数据取自 Hosmer and Lemeshow (1989, p.130).

在这些数据中，第 6 例可能取一系列不同值。一组 logistic 回归都是以 x_k 作为唯一的自变量，第 6 例的取值范围从 5.5 到 8.0，运行后的参数估计列在表 7.3.2 中。

当第 6 例的 $x_k = 5.5$ 时，数据便发生了完全分离，即所有 $x_k < 6$ 的案例都有 $y = 0$ ；所有 $x_k \geq 6$ 的案例都有 $y = 1$ 。在这种情况下，估计的系数及其标准误很大。当第 6 例的 $x_k = 6.0$ 时，仍然得到近似的结果。Albert 和 Anderson (1984) 称数据在一个或若干取值上重迭的现象为准完全分离(quasi-complete separation)。当 x_k 取值大于 6 时，便出现了较大的重迭，logistic 回归系数及其标准误的估计值也开始取得更为合理的值。

表 7.3.2 完全分离、准完全分离和重迭的数据所取得的参数估计

参数	第 6 个案例的取值						
估计	5.5	6.0	6.05	6.1	6.15	6.2	8.0
α	-118.3	43.3	-26.2	21.9	-19.5	17.8	-6.1
SE_{α}	130.2	95.0	36.6	25.1	20.3	16.9	3.5
β	20.6	7.2	4.3	3.6	3.2	2.9	1.0
SE_{β}	22.7	15.8	6.1	4.1	3.3	2.8	0.5

注:数据取自 Hosmer and Lemeshow (1989, p.131).

实际中完全分离或准完全分离的发生取决于样本规模、事件发生的案例数、模型中自变量的数目以及自变量的取值范围。在小样本又有很多自变量时,发生完全分离或准完全分离现象的机会便大大增加。

检查数据中是否存在完全分离或准完全分离现象的诊断工作相当复杂(Albert & Anderson, 1984; Santner & Duffy, 1986)。但是,我们可以通过仔细检查单变量统计来确定完全分离是否存在。如同空单元产生的问题一样,完全分离的迹象也是估计系数很大,尤其是系数估计标准误非常大。

7.4 多元共线性 (Multicollinearity)

与线性回归一样,拟合 logistic 回归模型时也对自变量中存在的多元共线性很敏感。在回归分析中存在多元共线性是一个十分普遍的现象。自变量之间的任何相关都标志着多元共线性的存在。

最极端的例子是完全的多元共线性,也称为奇异(singularity)。在完全的共线性存在时,一个变量完全是另外一个变量或多个变量的线性组合。换句话说,完全的多元共线性意味着,如果将某个自变量对其他自变量进行回归时,有确定系数 $R^2 = 1$ 。

当完全的多元共线性存在时,便不能对模型进行估计。在这种情况下,SAS和SPSS都会在其输出中提示有变量是其他变量的线性组合,并将其作为冗余变量对待。

当多元共线性不太严重时,无论是线性回归还是logistic回归,其系数估计基本还是无偏且有效的,所以几乎可以忽略其影响。当多元共线性程度增加时,其后果也变得越来越严重。它会造成两个问题:第一,从逻辑上讲,除非我们在进行结构分析,比如因子分析(factor analysis)、主成分分析(principal components analysis)或结构方程模型(structural equation modeling),否则根本不应该将冗余变量纳入分析。第二,与所有其他多元回归一样,logistic回归也对多元共线性敏感,在多元共线性程度较高时,系数标准误的估计将产生偏差(Berry & Feldman, 1985)。根据Hanushek和Jackson(1977)所进行的蒙特卡罗(Monte Carlo)模型试验^①,当变量之间的相关程度提高时,系数估计的标准误将会急剧增加。但是,这种趋势在相关程度小于0.50以前问题尚不太严重。并且,只是涉及相关的那些变量的标准误有所提高,而模型中其他无关的变量的标准误并不变化。最后,在多元共线性条件下,系数估计对样本和模型设置都非常敏感。模型设置的微小变化、在样本中删除或加入一个案例,都会导致系数估计的较大变化,如幅度的消长甚至符号的改变(Hanushek and Jackson, 1977)。

自变量之间的简单相关或多元相关都产生多元共线性。自变量间的相关矩阵可以用子多元共线性的诊断。如果任何两个变量之间有较高相关,便可能产生多元共线性。然而,正如多元共线性的称谓所示,问题往往不限于两个变量之间。如果问题产生于多个变量之间的高度多元相关,其诊断将变得较为困难,因为需要通过多元统计来寻找冒犯变量(即产生问题的变量)。

通常,多元共线性可产生很大的系数估计标准误。然而,并不是说所有很大的标准误都是由多元共线性造成的,它还可能产生于其他原因,如空单元、完全分离等我们已讨论过的问题。在

^① 蒙特卡罗方法是通过模拟来对数学和统计问题求解的一种方法,通常采用计算机模拟。



SAS 和 SPSS 的线性回归程序中, 都能提供一种称为容忍度 (tolerance) 的统计指标来检查多元共线性问题. 容忍度定义如下:

$$\text{TOLERANCE} = 1 - R_{x_k}^2 \quad 7.4.1$$

其中, $R_{x_k}^2$ 为 x_k 作为因变量时与其他自变量之间的确定系数. 当 $R_{x_k}^2$ 很高时, 容忍度便很低, 表明相应自变量与其他自变量之间存在高度相关, 即存在多元共线性. 当 $R_{x_k}^2 = 1$ 时, 容忍度便等于 0, 说明相应自变量已经与其他自变量完全相关, 于是模型便不能产生估计. 作为一个大致标准, 容忍度小于 0.20 可以认为是多元共线性存在的标志, 容忍度小于 0.10 说明多元共线性很严重 (Menard, 1995).

容忍度指标的倒数也是一个十分有用的多元共线性指标, 称为方差膨胀因子 (the variance inflation factor, 简称为 VIF). 还有其他一些指标如特征值和条件指数等, 也可以用于多元共线性的诊断, 但已经超出本书内容, 这里不做介绍.

令人遗憾的是, 在 SAS 的 PROC LOGISTIC 和 SPSS 的 LOGISTIC REGRESSION 程序中都不提供容忍度指标. 但是, 我们可以通过运行同样因变量和自变量设置的线性回归来取得容忍度指标. 由于我们现在只是关心自变量之间的关系, 因此容忍度指标的估计与模型中因变量的函数形式无关.

作为例子, 将式 2.5.1 中的因变量 (即对数发生比) 用二分类变量 COLLEGE 代替, 以进行容忍度的检查.

$$\text{COLLEGE} = \alpha + \beta_1 \text{GENDER} + \beta_2 \text{KEYSCH} + \beta_3 \text{MEANGR} + e \quad 7.4.2$$

这是一个线性概率模型 (linear probability model). 对自变量 GENDER、KEYSCH、MEANGR 的容忍度指标可以用下列 SAS 和 SPSS 程序来取得.

```
* SAS PROGRAM: ESTIMATING TOLERANCE STATISTICS;
...
PROC REG;
MODEL COLLEGE = GENDER KEYSCH MEANGR / TOL VIF;
RUN;
```

* SPSS PROGRAM: ESTIMATING TOLERANCE STATISTICS.

REGRESSION

/MISSING LISTWISE

/STATISTICS COEFF TOL

/CRITERIA = PIN(.05) POJT(.10)

/DEPENDENT COLLEGE

/METHOD = ENTER GENDER KEYSCH MEANGR.

SAS 命令中的 TOL 和 VIF 表示要求对所有自变量输出容忍度 (tolerance) 和 VIF 指标。在 SPSS 程序中, 只要有加入子命令 TOL, 便提供关于多元共线性的所有指标, 其中包括容忍度和 VIF。

估计的容忍度和 VIF 指标在表 7.4.1 中提供。式 7.4.2 中所有自变量的容忍度都大大高于 0.20, 表明这些自变量没有多元共线性问题。

多元共线性问题很容易被发现, 但是很难解决。通常情况下, 如果发现较高的多元共线性问题存在, 可以通过删除冗余的那个自变量来解决这一问题。但是, 如果删除的不是冗余自变量, 而是理论上有重要意义的自变量, 那么便会导致模型误设。由于错误模型产生有偏估计, 而错误模型的问题往往比多元共线性问题的后果更严重。

解决多元共线性问题的另一途径是取得更多的信息 (比如取得更多的案例)。要是可能增加样本规模, 这点当然可以做到。当样本规模扩大后 (而其他因素则保持不变), 标准误将会减小, 因而抵消了多元共线性的影响。然而, 在实际研究中并不总是可能扩大样本规模。研究人员通常总是一开始就用所有可得数据来建立模型, 如果发现多元共线性问题, 也就没有另外的可加案例。因此, 目前对于多元共线性还没有十分令人满意的解决方法。

空单元、完全分离和多元共线性问题一般都通过特大的标准误表现出来。一旦发现某一系数的估计标准误相对于这一系数的点估计而言很大, 我们应该考虑是否存在第 7.2 节至 7.4 节所述的数据结构问题。

表 7.4.1 式 2.5.1 中自变量的容忍度指标

SAS 输出 (节选)									
Parameter Estimates									
Variable	DF	Parameter Estimate	Standard Error	T for H0: Parameter=0	Prob > T	Tolerance	Variance Inflation		
INTERCEP	1	0.252538	0.01906773	13.244	0.0001	.	0.00000000		
GENDER	1	0.119684	0.02611769	4.582	0.0001	0.86793621	1.15215841		
KEYSCH	1	0.137605	0.03591911	3.831	0.0001	0.99126013	1.00881693		
MEANGR	1	0.057001	0.00301149	18.928	0.0001	0.87508164	1.14275052		
SPSS 输出 (节选)									
Model	Unstandardized Coefficients			Standardized Coefficients			Sig.	Collinearity Statistics	
	B	Std. Error	Beta					Tolerance	VIF
1									
(Constant)	.253	.019		13.244		.000			
GENDER	.120	.026	.126	4.582		.000		.868	1.152
KEYSCH	.138	.036	.099	3.831		.000		.991	1.009
MEANGR	5.700E-02	.003	.519	18.928		.000		.875	1.143

7.5 特异值和特殊影响案例 (Outliers and Influential Observations)

影响回归分析结果的其他数据问题还包括特异值和特殊影响案例。在线性回归中,所谓特异值是指案例中相对于自变量值而言其因变量取值非常特殊的情况。在 logistic 回归分析中,如果一个案例的实际结果属于一种类型而其预测事件却在另一类型上有很高的发生概率,便认为是特异值。而特殊影响案例是指一个对于回归估计有重大影响的观测。

当一个案例的自变量取一个很异常的值时,这一案例称为杠杆案例(high-leverage observation)。杠杆案例在其自变量取值上距离其他案例很远。杠杆案例不一定就产生对回归系数的特殊作用,但多数情况下其作用比较特别。但是,当杠杆案例与特异值结合在一起时,往往对回归系数估计有非常大的影响(Fox, 1991),所以被称之为特殊影响案例。在本节中,我们将介绍在 logistic 回归分析中一些有关的诊断方法和检查特异值与特殊影响案例的统计指标。

7.5.1 残差影响的测量

为了理解有关 logistic 回归诊断统计指标,先要理解模型的残差(residual)。下面是五种不同的残差定义:

1) 非标准化残差,这种残差定义为观测的事件概率与模型的预测概率之间的差。比如,我们对一个实际已经考入大学的考生的预测的升学概率为 0.75,那么这一案例的残差为:

$$[y - \hat{P}(y=1)] = 1 - 0.75 = 0.25.$$

2) 标准化残差,又称为 Pearson 残差。在线性回归中,假设误差项独立于因变量的条件平均值 $E(y|x)$ 。然而,在 logistic 回归中,残差的方差却是条件平均值的函数,即:

$$\text{Var}(y|x) = E(y|x) \times (1 - E(y|x)).$$

由于这一原因, 需要通过除以残差的标准误来调整残差, 使其标准化. 标准化残差定义为:

$$z = \frac{y - \hat{P}(y=1)}{\sqrt{\hat{P}(y=1)(1 - \hat{P}(y=1))}}, \quad 7.5.1$$

它就是观测概率与预测概率之差除以估计概率的二项分布标准差. 它又被称为 Pearson 残差. 由于每一个残差都被其标准误的近似估计所除, 因此在样本规模很大且模型正确时, 标准化残差应该近似服从平均值为 0、标准差为 1 的标准正态分布. 所以, 约有 95% 的案例的标准化残差应该在 $[-2, +2]$ 之间, 有 99% 的案例的标准化残差应该在 $[-2.5, +2.5]$ 之间.

3) Logit 残差. 这又是一种残差测量, 它等于残差 $y - \hat{P}(y=1)$ 除以自己的方差(而不是像标准化残差那样除以自己的标准差). 它的确切定义为:

$$L = \frac{y - \hat{P}(y=1)}{\hat{P}(y=1)(1 - \hat{P}(y=1))}. \quad 7.5.2$$

4) Deviance 残差. 以下公式表示 Deviance 残差, 当事件发生时(即 $y=1$ 时), 取正值; 事件不发生时(即 $y=0$ 时), 取负值.

$$d = +\sqrt{-2[y \ln(\hat{P}) + (1-y)\ln(1-\hat{P})]}. \quad 7.5.3$$

如果观测的反应值 $y=1$, 有

$$d = \sqrt{-2\ln(\hat{P})}, \quad 7.5.4$$

如果观测的反应值 $y=0$, 有

$$d = -\sqrt{-2\ln(1-\hat{P})}. \quad 7.5.5$$

在大样本情况下, 单个 Deviance 残差近似服从正态分布. 若一个案例有较大的 d 值, 则说明模型不能较好地拟合该案例.

5) 最后一种残差为学生化残差(studentized residual). 一个案例的学生化残差是对假如此案例被删除出样本后模型 Deviance 统计值发生变化的测量值. 较大的学生化残差值表示此案例在加大观测值与模型预测值之差上的作用较大.

SPSS 的 LOGISTIC REGRESSION 程序能输出以上五种类型的残差, 而 SAS 的 PROC LOGISTIC 程序只能提供 Pearson 残差、Deviance 残差和学生化残差。但是, SAS 的 PROC LOGISTIC 程序还提供另外一种残差 DIFCHISQ, 它表示皮尔逊 χ^2 统计值的变化。然而, 这种指标基本上是多余的, 因为它近似等于 Pearson 残差的平方。

在 SAS 和 SPSS 运行 logistic 回归时对这些残差的内部标名如下所示:

SAS:

RESCHI——标准化残差, 或称 Pearson 残差

RESDEV——Deviance 残差

DIFDEV——学生化残差, 是删除相应案例后 Deviance 统计量的变化近似值

DIFCHIS——删除相应案例后皮尔逊 χ^2 值的变化

SPSS:

RES_1——非标准化残差

LRE_1——Logit 残差

SRE_1——学生化残差^①。

ZRE_1——标准化残差, 或称 Pearson 残差

DEV_1——Deviance 残差

在 SAS 和 SPSS 中所有能提供的诊断统计量都可以作为一个新变量的值存盘, 以方便以后使用。在 SPSS 中, 当各种残差被存为新变量时, 都以相应内部标名加上后缀 “_1” 作为变量名。当在运行另外一个模型以后第二次将残差存为新变量时, SPSS 将产生后缀为 “_2” 的新变量, 如此等等。

除了残差以外, 还有其他有关建立和解释回归的影响指标,

① 在 SPSS 手册 (SPSS Inc., 1997b, p. 58) 中关于学生化残差的定义为: “当一个案例被删除后模型 Deviance 统计值的变化”。这实际上是 SAS 提供的诊断统计量 DIFDEV 的定义。其实, SPSS 的 LOGISTIC REGRESSION 程序所提供的学生化残差是当相应案例被删除后模型 Deviance 统计量变化值的平方根的近似值。

如杠杆度(leverage)、DFBETA(s)、以及 Cook 距离(Cook's distance)。这些指标经常用来检查那些对于参数估计或预测值有很大影响的案例。

1) 杠杆度统计量(leverage)。杠杆度 h_i 是 H 矩阵对角线上的第 i 个元素。在线性回归中, H 矩阵为 $H = X(X'X)^{-1}X'$, 并且 $\hat{Y} = XB = X(X'X)^{-1}X'Y = HY$ 。以 H 矩阵表达的线性回归的残差 $(Y - \hat{Y})$ 为 $(I - H)Y$, 其中 I 是 $n \times n$ 的单位矩阵。logistic 回归的 H 矩阵和杠杆度的推导不属于本书的范围, 有兴趣的读者可参阅 Pregibon (1981)。

Logistic 回归中的杠杆度在很多方面类似于常规回归中的杠杆度。它以解释变量的值来测量第 i 个案例与其他案例相分离的程度。杠杆度值的取值范围是 $[0, 1]$ 。在一个有 K 个自变量(包括每一个设计变量)的模型中, 所有 h_i 值的合计等于 $(K + 1)$, h_i 的平均值等于 $(K + 1)/n$ 。

2) DFBETA, 意思为 β 变化(difference in beta), 它所测量的是当某个案例被删除以后 logistic 回归系数所发生的变化。因此有一套 DFBETA 指标, 分别对应不同系数估计上的变化, 其中也包括截距。比如, 当第 i 个案例被删除后, 第一个回归斜率系数上的变化为:

$$DFBETA1_i = B_1 - B_1^i$$

其中, B_1 为模型包括所有案例时第一个自变量的回归斜率系数值, B_1^i 为第 i 个案例被删除后的系数值。

3) Cook 距离, 常标志为 Cook's D。它是标准化残差和杠杆度两者的合成指标。定义为:

$$\text{Cook's } D_i = (Z_i^2 \times h_i) / (1 - h_i)^2,$$

其中, Z_i^2 为标准化残差; h_i 为杠杆度值。

SAS 的 PROC LOGISTIC 程序和 SPSS 的 LOGISTIC REGRESSION 程序都能提供这三个影响指标。SAS 和 SPSS 在 logistic 回归中对影响指标给定的内部变量名为:

SAS:

H——杠杆度统计量, 或称 H 矩阵对角线

C and CBAR——C 为 Cook 距离, 定义为: $C_i = Z_i^2 h_i / (1 -$

$h_i)^2$; CBAR 为类似 Cook 距离的一种诊

断指标, 定义为: $CBAR_i = Z_i^2 h_i / (1 - h_i)$.

DFBETA——由于删除相应案例使回归系数估计产生的标准化差别. DFBETA 作为诊断指标, 计算删除每个案例对各个回归系数(包括截距在内)造成的变化.

SPSS:

LEV_1——杠杆度统计量, 或称 H 矩阵对角线

COO_1——类似 Cook 距离的一种诊断指标

DFB(s)_1——删除相应案例使回归系数估计产生的变化

请注意, 由 SAS 的 PROC LOGISTIC 程序所计算的回归系数变化的诊断指标(DFBETA)与 SPSS 的 LOGISTIC REGRESSION 程序计算的相应指标(DFB(s)_1)有所不同. 虽然都测量的是删除相应案例后在回归系数上发生的变化, 但前者为标准化的变化, 而后者则为变化. 另外, 由 SPSS 计算的 Cook 距离, Coo_1 与 SAS 计算的 CBAR 是相同的^①.

下列 SAS 程序为我们以式 2.5.1 表达的例题计算诊断指标:

```
* SAS PROGRAM: REGRESSION DIAGNOSTICS FOR LOGISTIC REGRESSION;
```

```
...
```

```
PROC LOGISTIC DESCENDING;
```

```
MODEL COLLEGE = GENDER KEYSCH MEANGR / AGGREGATE SCALE = NONE INFLUENCE;
```

```
RUN;
```

在 SAS 中, MODEL 命令中的 INFLUENCE 备选方式设置输出对每个案例所计算的所有诊断性指标. 本例的前 10 个案例的诊断结果列在表 7.5.1 中. 由于模型中有三个自变量, 所以有四项 DFBETA 值: DFBETA0, DFBETA1, DFBETA2, DFBETA3, 分别代表截距、第 1 个、第 2 个、第 3 个回归系数.

① SPSS 手册定义 Cook 距离为 (SPSS Inc., 1997b, p. 58): $D_i = Z_i^2 \times h_i / (1 - h_i)^2$.

然而, SPSS (Release 8.0) 实际计算的 Cook 距离为: $D_i = Z_i^2 \times h_i / (1 - h_i)$. 它与 SAS 的 PROC LOGISTIC 程序 (SAS, V. 6.12) 所计算的 CBAR 完全相同.

表 7.5.1 SAS 计算的回归诊断统计指标(部分案例)

Regression Diagnostics																			
					Pearson Residual														
					Covariates														
Case					(1 unit=2.8)														
Number	GENDER	KEYSCH	MEANGR	Value	-8	-4	0	2	4	6	8								
1	0	0	-1.5000	-0.3021			*												
2	0	0	8.1000	0.4314			*												
3	0	0	6.1000	0.6596			*												
4	0	0	3.6000	1.1214			*												
5	0	0	-2.0000	-0.2716			*												
6	0	0	-4.7000	-0.1531			*												
7	0	0	1.0000	-0.5135			*												
8	0	0	-4.4000	-0.1632			*												
9	0	0	-5.3000	-0.1348			*												
10	0	0	-3.2000	-0.2106			*												
...																			
					Deviance Residual				Hat Matrix Diagonal										
Case					(1 unit=0.44)				(1 unit=0)										
Number	Value				-8	-4	0	2	4	6	8	Value	0	2	4	6	8	12	16
1	-0.4179						*					0.00239		*					
2	0.5843						*					0.00856				*			
3	0.8500						*					0.00921				*			
4	1.2761						*					0.00683				*			
5	-0.3773						*					0.00219		*					
6	-0.2153						*					0.00130	*						
7	-0.6842					*						0.00387			*				
8	-0.2293						*					0.00139	*						
9	-0.1898						*					0.00115	*						
10	-0.2945						*					0.00176		*					
...																			
					INTERCPT Dfbeta							GENDER Dfbeta							
Case					(1 unit=0.03)							(1 unit=0.02)							
Number	Value				-8	-4	0	2	4	6	8	Value	-8	-4	0	2	4	6	8
1	-0.0143						*					0.00975				*			
2	0.0144						*					-0.0207			*				
3	0.0329						*					-0.0391		*					
4	0.0721						*					-0.0695		*					
5	-0.0121						*					0.00796			*				
6	-0.00454						*					0.00256			*				
7	-0.0315					*						0.0251				*			
8	-0.00508						*					0.00291			*				
9	-0.00363						*					0.00198			*				
10	-0.00789						*					0.00484			*				

续表

Case		KEYSCH Dfbeta (1 unit = 0.02)							MEANGR Dfbeta (1 unit = 0.05)							
Number	Value	-8	-4	0	2	4	6	8	Value	-8	-4	0	2	4	6	8
1	0.00393			*					0.00748			*				
2	-0.00120			*					0.0322			*				
3	-0.00482			*					0.0436			*				
4	-0.0146			*					0.0372			*				
5	0.00337			*					0.00720			*				
6	0.00138			*					0.00429			*				
7	0.00767			*					0.00273			*				
8	0.00153			*					0.00462			*				
9	0.00112			*					0.00367			*				
10	0.00229			*					0.00600			*				
Case		C (1 unit = 0.01)							CBAR (1 unit = 0.01)							
Number	Value	0	2	4	6	8	12	16	Value	0	2	4	6	8	12	16
1	0.000219	*							0.000219	*						
2	0.00162	*							0.00161	*						
3	0.00408	*							0.00404	*						
4	0.00870	*							0.00864	*						
5	0.000162	*							0.000162	*						
6	0.000031	*							0.000031	*						
7	0.00103	*							0.00102	*						
8	0.000037	*							0.000037	*						
9	0.000021	*							0.000021	*						
10	0.000078	*							0.000078	*						
Case		DIFDEV (1 unit = 0.79)							DIFCHISQ (1 unit = 31.3)							
Number	Value	0	2	4	6	8	12	16	Value	0	2	4	6	8	12	16
1	0.1748	*							0.0915	*						
2	0.3430	*							0.1877	*						
3	0.7265	*							0.4391	*						
4	1.6372	*							1.2661	*						
5	0.1425	*							0.0740	*						
6	0.0464	*							0.0235	*						
7	0.4691	*							0.2647	*						
8	0.0526	*							0.0267	*						
9	0.0361	*							0.0182	*						
10	0.0868	*							0.0444	*						

SPSS 的 LOGISTIC REGRESSION 程序运行时不是用一个命令来设置输出诊断指标，必须先将诊断指标存为新的变量，然后才能调用这些诊断数据。我们将在下一节示范如何用 SPSS 来取得回归的诊断统计。

7.5.2 检查特异值和特殊影响案例

当数据结构相对简单时，通过审阅数据就能发现特异值和特殊影响案例。但是在比较复杂的情况下，比如有很多自变量的 logistic 回归模型，就很难仅凭审阅找到特异值和特殊影响案例。然而，上一节所介绍的诊断统计量可以帮助我们完成这个工作。

首先，为了识别特异值，我们基本上依据对 logistic 回归模型的残差的检查。残差指标测量了每个案例的观测与模型拟合结果之间的差别程度。因此，如果一个观测案例导致异常大的残差绝对值便是一个特异值。

通常采用 Pearson 残差和 Deviance 残差来检查特异值。以这些残差指标标志特异值的临界点的选定是依据该残差最极端的 5% 的值 (Fox, 1991)。这是因为，在理想的正态分布条件下，大约有 5% 的案例处于正负两个标准差之外。而 Pearson 残差和 Deviance 残差在大样本时都有近似正态分布，于是凡这两种残差取值大于 2 的案例都表明此案例拟合很差，值得特别注意。根据 Menard (1995) 的意见，学生化残差的临界点也应该定为 ± 2 。SAS 所提供的残差指标 DIFCHISQ 基本提供重复信息，因为它约等于 Pearson 残差 (RESCHI) 的平方。

注意，一个案例具有特异值也不一定就影响回归系数估计；但是，特异值意味着模型拟合案例的程度很糟糕。如果有很多这样的案例，那么这个模型的拟合程度会极差。

检查残差不一定能辨认特殊影响案例。因为，一个案例具有较小的残差，也可能影响模型的系数估计。当一个案例在其自变量值方面距离其他案例遥远，便可能有特殊影响。杠杆度 h_i 测量的便是某个案例与其他案例的距离。一个案例的 h_i 较大说明它在自变量值上距离其他案例较远，这样的案例有时也称为杠杆点 (high leverage point)。它们可能是，但也不一定是特殊影响案例。与线性回归不同，logistic 回归中的杠杆度 h_i 的值不仅取决

于自变量的值,也多少依赖于反映变量的观测值。

总之,当 $h_i > 2(K+1)/n$ 时就可以说是异常大,这个水平便是杠杆度平均值的 2 倍。在我们的示范例题中有 3 个自变量和 1000 个案例,因此杠杆度的平均值为 $(3+1)/1000 = 0.004$ 。如果一个案例的 h_i 值大于 $2 \times 0.004 = 0.008$ 的话,这个案例就可以被看作为杠杆点。

当案例的 DFBETA 指标取得很大值时更值得仔细检查。SAS 输出的 DFBETA 估计是标准化变化,而 SPSS 估计的 DFB(s)_1 则就是变化;它们反映的都是某一案例被删除后系数估计发生的变化。对于 SAS 的估计,如果 DFBETA 的绝对值大于 1.0 (即大于一个单位的标准差),这一案例就值得特别注意 (Menard, 1995)。对于 SPSS 的估计,DFB(s)_1 的取值相对于相应系数估计值较大便值得注意。至于 Cook 距离的判断,则是根据取值远远大于其他案例的取值。由于 Cook 距离是残差与杠杆度的合成指标,一个案例有很大的 Cook 距离不仅意味着它是特异值,同时也意味着它是杠杆点,因此它便非常可能是一个特殊影响案例。

指标 DIFDEV (学生化残差的 SAS 内部标名)和 SRE_1 (学生化残差的 SPSS 内部标名)可以用来检查第 i 个案例对模型总体拟合的影响,因为它测量的是第 i 个案例被删除后模型 Deviance 统计值的变化。

另一种诊断特异值和特殊影响案例的更直观的方法是对残差做概要图示。通过对应每个案例序号或指数标注其诊断测量值的统计图,可以迅速检查到特异值和特殊影响案例。在 SAS 的 PROC LOGISTIC 程序中,MODEL 命令中的备选设置 IPLOTS (代表 Index plots)可以输出每个案例的诊断测量的统计图。但是,当样本规模很大时,SAS 的 PROC LOGISTIC 程序所输出的统计图质量不高。如果需要专业水平的作图,可以应用 SPSS 的 GRAPH 程序或 SAS 的 PROC GPLOT 程序来完成这类指数标注图。比如,下列 SPSS 程序输出诊断性统计指标及其统计图 (参见图 7.1)。



```

* SPSS PROGRAM: REGRESSION DIAGNOSTICS FOR LOGISTIC REGRESSION.

...

LOGISTIC REGRESSION VAR = COLLEGE

/METHOD = ENTER GENDER KEYSCH MEANGR

/SAVE COOK LEVER DFBETA RESID LRESID SRESID ZRESID DEV

/CRITERIA PIN(.05) POUT(.10) ITERATE(20) CUT(.5).

GRAPH

/LINE(SIMPLE) = VALUE(ZRE_1)

/TITLE = 'A. Pearson Residual vs Case Number Index' .

GRAPH

/LINE(SIMPLE) = VALUE(DEV_1)

/TITLE = 'B. Deviance Residual vs Case Number Index' .

GRAPH

/LINE(SIMPLE) = VALUE(SRE_1)

/TITLE = 'C. Studentized Residual vs Case Number Index' .

GRAPH

/LINE(SIMPLE) = VALUE(DFB0_1)

/TITLE = 'D. DFBETA0 vs Case Number Index' .

GRAPH

/LINE(SIMPLE) = VALUE(DFB1_1)

/TITLE = 'E. DFBETA1 vs Case Number Index' .

GRAPH

/LINE(SIMPLE) = VALUE(DFB2_1)

/TITLE = 'F. DFBETA2 vs Case Number Index' .

GRAPH

/LINE(SIMPLE) = VALUE(DFB3_1)

/TITLE = 'G. DFBETA3 vs Case Number Index' .

GRAPH

/LINE(SIMPLE) = VALUE(LEV_1)

/TITLE = 'H. leverage vs Case Number Index' .

GRAPH

/LINE(SIMPLE) = VALUE(COO_1)

/TITLE = 'I. Cooks Distance vs Case Number Index' .

```

通过上面的 SPSS 的 LOGISTIC REGRESSION 程序, 各种诊断统计指标被计算出来, 并在原始数据中存为新的变量. 注意, 在 SAVE 命令之后设置的一系列变量名(如: COOK LEVER DFBETA RESID LRESID SRRESID ZRESID DEV)不同于程序内部使用的变量名(如: RES_1 LRE_1 SRE_1 ZRE_1 DEV_1 COO_1 LEV_1 DFB(s)_1). 应用 SPSS 的 GRAPH 程序, 我们可以轻松地得到诊断统计标注图(见图 7.1a 至图 7.1i).




图 7.1a Pearson 残差与案例数量指数的比较




图 7.1b Deviance 残差与案例数量指数的比较




图 7.1c 学生化残差与案例数量指数的比较




图 7.1d DFBETA0 与案例数量指数的比较




图 7.1e DFBETA1 与案例数量指数的比较




图 7.1f DFBETA2 与案例数量指数的比较




图 7.1g DFBETA3 与案例数量指数的比较




图 7.1h 杠杆度与案例数量指数的比较

