



电商零售大数据分析云上实战

李建伟 – 大数据技术专家

议程

- 电商行业现状
- 数据驱动的电商业务场景
- 非结构化数据搜索架构解析
- 亚马逊电商案例

电商用户旅程



用户触达 – 售前

方式	市场
	媒体
	语音
	移动设备

渠道	邮件
	广告
	地理位置
	手机推送



兴趣/搜索 吸引/评估



用户转化 – 售中

搜索	网页搜索
	图片搜索
	语音搜索
	移动搜索

个性化	定制化首页
	产品推荐
	相关产品评分
	交叉销售

客服	我的订单
	修改订单
	问题
	客服

优化	页面加载
	导航
	虚拟现实
	评分



甄别/购买 期待/追踪



用户服务 – 售后

物流	线上下单，店面提货
	线上下单，店面发货
	全球仓库


派送	预约派送
	第三方退货
	退货流程优化




咨询/退货 忠诚/推荐

电商业务重点

电商企业KPI



电商企业投资重点



数据驱动电商业务

电商行业典型应用场景

□ 五大场景，围绕用户旅程全链路



商品搜索

- 高阶应用的前置条件
- 依赖于完善的数据湖建设和高效的数据处理
- 无缝集成机器学习来构建用户画像



运营分析

- 典型机器学习范畴，是大数据分析的高级应用
- 依赖于完善的数据湖进行数据预处理
- 更加精准地触达客户、提高最终成单率



用户画像

- 依赖于商品检索引擎架构及对应模块为分布式
- 商品标识明确时，快速定位到目标对象



个性化推荐

- 为电商运营提供决定依据
- 依赖于用户行为数据与RDS数据的多维度指标转化
- 分析业务链条各环节数据



IT运维分析

- 电商客户的基本需求
- 了解IT系统的整体运行状况，有效排查系统故障

AWS的价值主张

□ 数据服务的深度和广度




Amazon
S3

- 功能全面的存储层
- 综合计算层
- 高速可扩展的网络层
- 99.999999999%水平的可靠性
- 数据生命周期管理

深度集成



Amazon
EMR



Amazon
Redshift



Amazon
Elasticsearch
Service



Amazon
Athena




AWS
Glue



AWS Lake
Formation

广泛的ML和AI服务

场景1：商品搜索



业务场景



场景描述

- 目标商品明确，可通过文字、语音、扫码等方式快速搜索到
- 商品搜索引擎架构具备分布式、可扩展的特性
- 数据在线下流程和线上流程均起到比较核心的作用



数据特点

- 输入数据：通常，原始数据（结构化信息，文本、图像信息，动态信息等）来自前端数据库，数据源多个
- 搜索引擎：在数据采集方面更侧重于各种数据源的数据更新，其效果需要兼顾买家与卖家
- 输出数据：支持各种维度的排序，对数据的实时性要求非常高（主要体现在价格和库存两方面）




业务实现

- 商品搜索引擎为功能实现的核心支撑，具备分布式、可扩展的特性，在架构中需要考虑对索引模块、查询模块和排序干预模块的解耦和分离，以方便对各个模块进行单独的优化和扩展

参考架构


接口层



Amazon API Gateway



AWS Lambda




Elastic Load Balancing




Amazon Elastic Kubernetes
Service (Amazon EKS)


服务层




Amazon OpenSearch
Service



Amazon MemoryDB for
Redis



Amazon Aurora




Amazon DynamoDB

搜索意图



Amazon OpenSearch
Service

商业规则



Amazon
OpenSearch Service

个性化排序



Amazon
SageMaker

案例研究: Nike 耐克 - 商品检索

痛点



直接面向消费者业务的快速增长和扩张，迫切需要强大的商业搜索解决方案

解决方案

Amazon OpenSearch Service 服务作为耐克的核心搜索引擎

获得益处

Amazon ES的自动部署及管理工具大大简化了耐克的开发周期，加快了新搜索体验的上市时间。



AWS的优势和价值



全世界最大电商亚马逊的基石

- Amazon.com在AWS上面运行，使用Amazon OpenSearch Service扫描、读取和分析亚马逊市场数据，并且根据数据分析结果为买家和卖家提供服务



一种完全托管的搜索引擎服务

- 为突增的并发访问量提供搜索引擎的稳定性和弹性



高可用支持业务连续性

- Amazon OpenSearch Service允许电商客户在单个集群中存储多达3 PB的数据，并且可以根据需求变化轻松扩展或缩减容积；支持在三个可用区部署，使电商客户能够跨多个可用区部署实例



按需付费和弹性预留以节省成本

- 只需要按实际用量付费
- 与按需实例相比，预留实例可保留一或三年，大量节省使用成本




内置开箱即用的KNN算法

- 适用于Amazon OpenSearch Service




Amazon
Elasticsearch
Service

非结构化数据搜索架构解析




产品搜索

基于文本产品搜索



输入：
“男士背包”


基于图片产品搜索



输入：



Amazon SageMaker 和OpenSearch构建图像检索




Amazon SageMaker

- 图像分类模型训练
- 部署特征提取模型


Amazon OpenSearch

- KNN邻近算法做邻近搜索
- 高可用，安全的托管服务

图像检索原理




基于深度学习的图像特征提取




Pretrained 模型去除最后做分类全连接层，留最后池化层做特征向量

2048/4096维图像特征向量




图像检索架构




1. 通过SageMaker训练 ResNet模型，将所有产品图片向量化
2. 将向量化的数据注入到 OpenSearch索引中，其中图片数据用向量类型存储
3. 客户提交的图片调用 SageMaker的推理服务，将单张图片转成向量数据
4. 调用OpenSearch KNN检索匹配最相似的K张图片
5. 记录用户的点击，购买等行为，训练Learning to Rank模型，优化排序结果

K-NN search


- 基于矢量的搜索算法
- 使用特征提取或其他来创建特征向量
- 使用矢量进行查询以检索几何上最接近的点
- 几何相似或余弦相似



$$\text{similarity} = \cos(\theta) = \frac{A \cdot B}{\|A\| \|B\|} = \frac{\sum_{i=1}^n A_i \times B_i}{\sqrt{\sum_{i=1}^n (A_i)^2} \times \sqrt{\sum_{i=1}^n (B_i)^2}}.$$



Learn to rank plugin



- 机器学习的模型输入搜索结果的排名
- 使用新近、受欢迎程度和偏好等功能
- 将模型提供给Elasticsearch中的LTR插件
- LTR插件应用该模型，对搜索结果进行重新排序
- 在循环中使用，反馈搜索结果并单击数据以改进模型

Zalora产品搜索


ZALORA

ZALORA利用图片搜索提升用户体验，方便用户从大量的产品列表查找到自己喜欢的产品


“We want to give our customers joy in shopping by just taking a photo of any fashion objects that grab their attention”

Karthik Subramanian, CTO,
Zalora Group

https://www.visenze.com/blog/case_studies/zalora-uses-search-by-image-to-improve-product-search-and-discovery-on-its-extensive-catalogue/



场景2: 运营分析



业务场景



场景描述

- 围绕电商运营核心关注的三要素“用户、商品、平台”，根据不同业务目的进行数据分析
- 重视优化以及精细化运营，电商的商品品类种类繁多、用户覆盖面非常广泛客观上加大运营难度
- 关注流量、用户增长、销售额、留存与复购指标



数据特点

- 输入数据：主要有两个来源，客户端的用户行为数据、运营中的RDS数据
- 输出数据：八个维度的分析指标



业务实现

- 步骤：数据搜集、ETL、数仓分析、最终BI展示等
- 点击流数据：主要来源于客户端和服务端打点工具，格式以JSON为主，大部分转换为结构化数据存入数仓。交易数据、用户信息数据等来源于RDS，通过全量或者增量CDC的方式拷贝到S3进行后续发分析处理
- 运营数据：查询与分析通常在数仓内进行，数仓可以使用Redshift或Hive
- 大型客户主要基于开源软件自主开发BI报表，中小型客户会考虑使用商业BI报表




应用举例

- 离线运营数据分析：销售归因以及转化漏斗分析
- 实时信息分析：推送实时广告和获取数字营销解决方案

运营分析指标

- 总体运营指标
- 网站流量指标
- 销售转化率指标
- 商品品类指标
- 客户价值指标
- 活动营销指标
- 风险控制指标
- 竞争分析指标

建议架构



Anker 历经10年基于 AWS 打磨的数智舱




AWS的优势和价值




丰富的数据采集工具

- 多种数据管道摄入数据
- 中心存储有效打破数据孤岛




AWS
Glue



AWS
DMS



Kinesis
Data
Firehose



Amazon
MSK



Amazon
S3



支持处理多种数据类型


- 提供灵活支持结构化、半结构化、非结构化数据



Amazon
S3



Amazon
EMR



Amazon
Redshift



Amazon
Athena



计算存储分离

- 存储和计算解耦，按应用负载来构建专用集群
- EMR优势：弹性、Spot降低成本、S3数据低成本与持久性，相当于AWS对Hadoop的发行版，支持客户、减轻运维压力



Amazon
S3




Amazon
EMR



运用广泛、受欢迎的云
商数据库Redshift

- 可查询PB级到EB级别的结构化和半结构化数据；使用开放格式轻松地将查询结果保存回S3数据湖；借助Redshift Spectrum能分析规模至EB级别的数据
- 配合S3，AWS的解决方案可以做到冷热数据分级




Amazon
Redshift



Amazon
S3

场景3: 用户画像



业务场景



场景描述

- 指以优化客户体验、增强客户粘性和减少运营成本为目的，对用户特征和分类的研究
- 是电商企业应用大数据的根基，也是许多高阶数据分析场景的前置条件
- 常见的下游支持场景有个性推荐/展示、广告精准营销、BI中的用户聚类分析和搜索优化等



数据特点

- 输入数据：用户的社会属性，通常来自用户注册时主动提供的数据和从一些第三方机构购买的数据
用户在电商平台上的用户行为，通常来自于网页/应用的线上交易数据库和日志埋点数据
- 输出数据：形式一般为客户维度的具体标签，标签的形式取决于下游支持的具体应用要求



业务实现

- 两类实现方式：基于统计值的专家规则系统生成人工标签
基于历史数据的机器学习模型经训练生成自动标签




应用举例

- 提取用户的网购兴趣和消费行为等指标，用于广告精准营销


参考架构 - 使用基于统计规则的标签系统

用户画像 - 统计规则



参考架构 - 使用基于机器学习的标签系统

用户画像 - 机器学习




Club Factory – 电商平台



EMR和SageMaker快速搭建大数据
AI平台，实现用户画像和商品推荐

人工智能驱动的供应链管理，降低
行业市场成本30%以上

日均实时流入15亿行为日志，数仓
支撑的数据总量达到约600TB




<https://aws.amazon.com/cn/solutions/case-studies/club-factory/>

AWS的优势和价值

多种数据源协同分析

- 多种数据管道摄入数据



AWS
Glue



AWS
DMS



Kinesis
Data
Firehose

支持处理多种数据类型


- 提供灵活支持结构化、半结构化、非结构化数据



Amazon
S3



Amazon
EMR



Amazon
Redshift



Amazon
Athena

计算存储分离

- 存储和计算解耦，按应用负载来构建专用集群




Amazon
S3



Amazon
EMR


一站式机器学习平台

- 一站式机器学习平台辅以多种开箱即用AI SaaS



Amazon
SageMaker

场景4: 个性化推荐



业务场景



场景描述

- 是电商平台在了解客户的前提下创造出的需求，运营逐步精准化时将扮演越来越重要的角色
- 三方面实现持续稳定增长：帮助消费者在众多商品中更快地找到感兴趣的商品，提升购买决策效率
- 帮助商家更快地找到潜在消费者，提升长尾商品的动销
- 利用流量分发策略集中管控平台，使电商平台能提供更优质的服务体验



数据特点

- 输入数据：来源复杂，需要经过复杂处理，整理至用户或商品的维度数据，作为训练数据集输入算法
- 输出数据：基于当前用户行为产生的具体推荐产品列表（一般具有权重）



业务实现

- 依赖机器学习解决，分成线下模型训练和线上实时推荐，可采用简单至复杂等不同难度的算法，但是构建思路一致：模型训练需要客户具有功能完备的端到端数据处理系统，线上实时推荐则需要客户拥有模型生产化和部署运维的能力



应用举例

- 产品形态多种多样，包括基础商品推荐位、混排个性化推荐位、首焦个性化、核心频道个性化、活动频道个性化、类目个性化、营销个性化、权益个性化等

参考架构





LOTTE MART – 电商平台



“对比之前带来每月收入增长的大数据分析解决方案，通过使用 Amazon Personalize，我们推荐商品数量增长了 5 倍。特别值得一提的是，Amazon Personalize 促进客户下单从未购买过的商品数量增加了 40%。”

Jaehyun Shin，大数据团队负责人
Lotte Mart



<https://aws.amazon.com/cn/blogs/machine-learning/increasing-customer-engagement-and-loyalty-with-personalized-coupon-recommendations-using-amazon-personalize/>

AWS的优势和价值




丰富且多样的分析服务


- 能满足各种不同场景和需求下的分析服务，涵盖数据处理端到端的所有处理场景，方便客户快速建立模型训练数据预处理Pipeline，完成模型训练前训练数据集指标体系建立



Amazon
S3



AWS
Glue




AWS
DMS



Kinesis
Data
Firehose



Amazon
EMR



Amazon
Redshift



Amazon
Athena



AWS
Lake
Formation



AWS
IAM



AWS
Cloudtrail



开箱即用的机器学习服务

- AWS封装好的亚马逊电商实战中的有效算法，电商客户可以基于自己的数据来训练一个定制化的推荐模型并部署上线




Amazon
Personalize



经验丰富的实施人员

- 依托亚马逊电商平台经验，提供专业Professional Service团队

亚马逊电商案例



亚马逊电商 – 云原生之路

1995



在线书城

1997



1998-99

品类扩张

全球多站点

支持第三方卖家

1999-2000

单体架构



Kindle



Amazon S3



电商平台现代化改造

2006

搜索引擎 A9

2004



尝试核心服务 SOA 拆分

2002-03

单体到微服务化改造

Amazon Route 53

AWS WAF

Amazon S3

AWS Lambda

Amazon ECS

Amazon Aurora

Amazon Redshift

AWS Glue

Amazon CloudFront

AWS Shield

Amazon EC2

Amazon DynamoDB

2018+

2011

云原生

大型电商数仓云转型之旅

挑战


50PB数据，7万5千表，每天60万个分析任务

Oracle数仓处理超过1亿行的数据，经常报错

运维的复杂度和License成本的增加，不堪重负




Amazon
EMR



Amazon
Redshift



Amazon
S3



AWS DMS

客户成就

新的S3数据湖数据量达到200PB，是原先的4倍

S3强大的性能，支持超过3000个Redshift/EMR集群的访问

SCT迁移工具，节约1000个人月的人工

选择AWS的原因

S3 提供几乎无限的数据存储容量，且性能强大

DMS 服务的**SCT**工具，实现**SQL**查询语句自动转换

AWS 提供完整的大数据解决方案



公司简介

Amazon.com 是全球领先的电商；亚马逊遵循四项原则：客户至上而不是对标竞争对手、对创新的追求、对卓越运营的承诺以及长期思维。客户评论、一键下单、个性化推荐、Prime 会员、亚马逊物流、AWS、Kindle电子书、Fire 平板电脑、Fire 电视、亚马逊 Echo和 Alexa 是亚马逊首创的部分产品和服务。

客户引言

2018年11月1日，我们

关闭了5000个Oracle数

据库中的最后一个

了解详情，请访问：

<https://amazonaws-china.com/solutions/case-studies/amazon-migration-analytics>

采用AWS产品及方案的电商零售客户



AWS 是电商客户最坚实的技术平台和服务合作伙伴

用户互动	身份验证 Amazon Cognito	开源前端框架 AWS Amplify & Tools	前端开发	网络接入加速 Amazon Global Accelerator	负载均衡 ALB/NLB/CLB	全球分发	消息互动（短信/邮件/通知） Amazon Pinpoint/SMS/SES	机器翻译 Amazon Translate	语音朗读 API Amazon Polly	客户服务
	数据交互-GraphQL	终端测试		全球域名解析	内容分发（CDN） Amazon CloudFront		云呼叫中心 Amazon Connect	客服机器人/VR/AR Amazon Alexa/Lex/Sumerian	语意理解/分类 Amazon Comprehend	
	AWS AppSync	AWS Device Farm		Amazon Route 53						
服务路由和治理	API 管理 Amazon API Gateway		多区域数据复制 Amazon S3/ DynamoDB/ Aurora / ElastiCache for Redis		抗 DDoS AWS Shield	7层应用安全 AWS WAF	全球互联 Amazon Transit Gateway/Direct Connect/Direct Connect Gateway			
电商应用现代化	容器编排 Amazon ECS Amazon EKS	企业镜像库 Amazon ECR	函数计算 AWS Lambda	无服务器容器平台 AWS Fargate	研发运营一体化 (DevOps)	开发工具 AWS Cloud9 AWS IDE Toolkits		电商数据湖	跨数据源查询与分析 Amazon Athena	仪表板与报表展现 Amazon QuickSight
	服务网格 AWS AppMesh	配置管理 AWS Config	函数编排 AWS Step Functions			持续集成 AWS CodeCommit Amazon CodeGuru AWS CodeBuild AWS CodeDeploy AWS CodePipeline			ETL 与数据目录 AWS Glue	数据湖 Amazon S3/Glacier
	消息总线 Amazon EventBridge	简单消息服务 Amazon SQS	实时流 Amazon Kinesis	托管 Kafka Amazon MSK		研发团队赋能 文化 工具 实践 Amazon Builders' Library			分析 Amazon EMR Amazon Elasticsearch Service Amazon Redshift Kinesis Data Analytics	
	关系数据库 Amazon RDS/Aurora	NoSQL 数据库 Amazon DynamoDB ElastiCache Neptune	Cassandra QLDB DocumentDB					电商机器学习平台	AI 服务：视觉 语音 文字 预测 推荐 反欺诈	一站式机器学习研发测试部署平台 Amazon SageMaker
电商后台支撑	ERP 财务/采购/生产/销售/HR	CRM 客户关系	WMS 仓库管理	MES 制造执行系统	第三方接入	第三方支付 第三方数据服务			广告投放 Amazon Advertising	品牌推广 Amazon Global Selling

Q&A